

Халықаралық ақпараттық технологиялар университеті

ӘОЖ: 004.93:617.735

Қолжазба құқығында

ЕСМУХАМЕДОВ НҰРМАҒАНБЕТ СЕЙТҚАЛИҰЛЫ

**Fundus кескіндерін жақсарту және CNN жіктеуі арқылы
диабеттік ретинопатияны автоматтандырылған диагностикалау**

8D06104 – Есептеу техникасы және бағдарламалық жасақтама

Философия докторы (PhD) дәрежесін
алуға арналған диссертация

Ғылыми консультанты
физика-математика ғылымдарының
кандидаты,
қауымдастырылған профессор,
Халықаралық ақпараттық
технологиялар университеті
Сапакова С.З.

Шетелдік ғылыми консультанты
профессор, Universiti Putra Malaysia
Al-Haddad S.A.R.

Қазақстан Республикасы
Алматы, 2026

МАЗМҰНЫ

НОРМАТИВТІК СІЛТЕМЕЛЕР.....	—
БЕЛГІЛЕУЛЕР МЕН ҚЫСҚАРТУЛАР	—
АНЫҚТАМАЛАР.....	—
КІРІСПЕ.....	1
1 ДИАБЕТТІК РЕТИНОПАТИЯНЫ АВТОМАТТАНДЫРЫЛҒАН ДИАГНОСТИКАЛАУДЫҢ ПРОБЛЕМАЛЫҚ САЛАСЫН ТАЛДАУ ЖӘНЕ ҚАЗІРГІ ЖАЙ-КҮЙІ	24
1.1 Диабеттік ретинопатияның медициналық және эпидемиологиялық контексті	24
1.1.1 Патофизиология және клиникалық градациялау жүйелері	24
1.1.2 Ресурсы шектеулі денсаулық сақтау орталарындағы скрининг талаптары.....	27
1.2 Fundus кескіндерін алу және сапа вариабельдігі	30
1.2.1 Клиникалық тәжірибедегі кескін сапасының төмендеу көздері	30
1.2.2 Кескін сапасының диагностикалық модель өнімділігіне әсері	32
1.2.3 Көз түбі бейнелеуіндегі құрылғыға тән вариабельділік.....	35
1.3 Ретинальды кескіндерді жіктеудегі Deep Learning тәсілдері	37
1.3.1 Медициналық бейнелеуге арналған CNN архитектуралары	37
1.3.2 Офтальмологиялық диагностикадағы Transfer Learning және өзін-өзі бақылайтын алдын ала оқыту.....	41
1.3.3 Медициналық кескінді жіктеудегі түсіндірілу (explainability) әдістері	43
1.4 Қолданыстағы автоматтандырылған DR скрининг жүйелерінің сыни талдауы	45
1.5 Зерттеу проблемасының тұжырымдалуы	50
1-тарау бойынша қорытындылар	24
2 FUNDUS IMAGE ТАЛДАУЫ ҮШІН IMAGE PREPROCESSING ЖӘНЕ DEEP LEARNING ТЕОРИЯЛЫҚ НЕГІЗДЕРІ	53
2.1 Image Enhancement әдістерінің математикалық негіздері	60
2.1.1 Histogram Equalization және адаптивті контрастты күшейту.....	53
2.1.2 Қос шектеулі клип лимитімен CLAHE формализациясы	57
2.1.3 Кеңістіктік сүзгілеу және шуды азайту әдістері	61
2.2 Convolutional Neural Networks теориялық негіздері	63
2.2.1 Convolution, Pooling және Feature Extraction операциялары	63
2.2.2 Теңгерімсіз медициналық деректер жиынтықтары үшін Loss функциялары мен оптимизация	66
2.2.3 Регуляризация әдістері: Dropout, Batch Normalization және Data Augmentation	68
2.3 Transfer Learning және өзін-өзі бақылаусыз репрезентация оқыту теориясы	71
2.3.1 Визуалды домендер арасындағы белгі тасымалданушылығы.....	71
2.3.2 Frozen-Layer пен прогрессивті Fine-Tuning стратегиялары	73

2.3.3 Торқабық бейнелеуі үшін домен-ішілік өзін-өзі бақылайтын алдын ала оқыту	74
2.4 Ретинальды терапиядағы Laser–Tissue Interaction математикалық модельдеу	77
2.4.1 Көз түбі тінінің жауабының байланысқан жылулық-оптикалық моделі	77
2.5 Медициналық бейнелеуге арналған Deep Learning-тегі Explainability	162
2.5.1 CAM / Grad-CAM теориясы және формализациясы	80
2.5.2 Назар картасын интерпретациялау	82
2.5.3 Сандық explainability метрикалары ретінде ALO және IoU	83
2.6 Алдын ала өңдеуді бағалауға арналған кескін-сапасы метрикалары: CNR, VVI, Entropy, SSIM	85
2-тарау бойынша қорытындылар	53
3 ИНТЕГРАЦИЯЛАНҒАН PREPROCESSING-CNN PIPELINE ЖОБАЛАУ ӘДІСТЕМЕСІ	90
3.1 Біріздендірілген Preprocessing Pipeline формализациясы	129
3.1.1 Pipeline кезеңдерінің сипаттамасы: 8 кезеңді жүйе	90
3.1.2 Қос шектеулі клип лимитімен модификацияланған CLANE алгоритмі	106
3.1.3 Класс теңгерімсіздігін жұмсартуға арналған augmentation стратегиясы	109
3.1.4 Сыртқы кескіндерді қабылдау хаттамасы	113
3.2 DR жіктеуге арналған CNN архитектураларын жобалау	130
3.2.1 Негізгі эксперименттік архитектуралар ретінде ResNet-50 және EfficientNet-B3	115
3.2.2 Тарихи сілтеме архитектуралары (тек сілтеме ретінде)	119
3.3 Transfer Learning және алдын ала оқыту әдістемесі	133
3.3.1 Бес класты DR жіктеу үшін архитектураны бейімдеу	120
3.3.2 CNN backbone-ның офтальмологияға тән өзін-өзі бақылайтын алдын ала оқытуы (біріктірілген арна)	122
3.3.3 Екі кезеңді Fine-Tuning хаттамасының жобасы	125
3.3.4 Реттік класс құрылымы үшін салмақталған Loss функциясының формуляциясы	126
3.4 Бағалау негіздемесі және өнімділік метрикалары	128
3.4.1 Көп-метрикалы бағалау шеңбері	128
3.4.2 Cross-Validation және статистикалық сенімділік хаттамалары	132
3-тарау бойынша қорытындылар	90
4 ЭКСПЕРИМЕНТТІК ЗЕРТТЕУ — PREPROCESSING-ТІҢ CNN ДИАГНОСТИКАЛЫҚ ӨНІМДІЛІГІНЕ ӘСЕРІ	136
4.1 Деректер жиынтықтары және эксперименттік конфигурация	136
4.1.1 Деректер жиынтығының архитектурасы	136
4.1.2 Класс үлестірімі және деректерді бөлу	142
4.1.3 Аппарат және қайта жаңғыртылушылық хаттамасы	145
4.2 1-эксперимент: Біріктірілген pipeline басымдығы — pipeline + домен-ішілік алдын ала оқыту vs. baseline, EyePACS-те (H-1)	145

4.2.1 Қалпына келтірілген 2×2 факториалды жоба (A–D конфигурациялары)	147
4.2.2 Оқыту динамикасы және конвергенцияны талдау	150
4.2.3 Диагностикалық метрикаларды сандық салыстыру	153
4.3 2-эксперимент: Pipeline кезеңдерін абляциялау + CLANE/σ сканерлеулері (H-2)	147
4.3.1 Кумулятивті абляция жобасы (L0–L7 деңгейлері)	158
4.3.2 CLANE шектігіне сезімталдықты талдау (H-2 ішкі талдауы)	161
4.3.3 Flat-field σ сканерленуі және кескін-сапасы метрикалары	165
4.4 Алты нысаналы домен бойынша домен қашықтығының азаюы (H-3)	150
4.4.1 Өлшеу хаттамасы: репрезентациялар бойынша MMD және арна гистограммалары бойынша KL	168
4.4.2 Қашықтық азаюының нәтижелері және оларды түсіндіру шектері	170
4.5 3-эксперимент: APTOS 2019-дағы деректер жиынтығы аралық тасымалданушылық (H-4)	152
4.5.1 APTOS 2019-ға нөл-шот тасымалдау	175
4.5.2 Baseline мен pipeline салыстыруы	177
4.6 4-эксперимент: IDRiD + Клиникалық жиындағы Grad-CAM түсіндірілуі (H-5)	153
4.6.1 Grad-CAM генерациялау хаттамасы	179
4.6.2 IDRiD зақымдану маскарларымен сандық ALO және IoU	181
4.6.3 Назар әсерінің кескін-бойынша дәйектілігі және қазіргі дәлелдің шектері	184
4.7 5-эксперимент: IDRiD + Messidor-2-дегі сыртқы клиникалық өнімділік (H-7)	154
4.8 6-эксперимент: DDR + ODIR-5K + RFMiD-тегі құрылғы домен ығысуы (H-6)	154
4.9 7-эксперимент: Шағын деректе оқыту (IDRiD → Клиникалық)	155
4-тарау бойынша қорытындылар	136
5 СЕНІМДІЛІКТІ ВАЛИДАЦИЯЛАУ ЖӘНЕ САЛЫСТЫРМАЛЫ ТАЛДАУ	154
5.1 Түсіндірілу нәтижелері	197
5.2 Статистикалық валидация	199
5.2.1 Bootstrap сенімділік интервалдары және аралас-әсерлер моделі	199
5.2.2 Тұжырым күшінің түпкі жіктелуі	203
5.3 Жарияланған жүйелермен салыстырмалы талдау	201
5.3.1 Жарияланған нәтижелермен эталондау: IDx-DR, EyeNuk, DeepMind	208
5.3.2 Өнімділік–күрделілік айырбасын талдау	212
5.4 Ұсынылған тәсілдің шектеулері мен шекаралық шарттары	204
5-тарау бойынша қорытындылар	154
6 РЕСУРСТАРЫ ШЕКТЕУЛІ ОРТАҒА АРНАЛҒАН DR АВТОМАТТАНДЫРЫЛҒАН СКРИНИНГ ЖҮЙЕСІНІҢ АРХИТЕКТУРАСЫ	220

6.1 Жүйелік талаптар және жобалау қағидалары.....	221
6.1.1 Функционалдық және функционалдық емес талаптар сипаттамасы..	220
6.1.2 PACS пен EHR интеграциясы бар модульдік архитектура.....	224
6.2 AI өңдеу модулін жобалау	222
6.2.1 Конфигурацияланатын pipeline бар Preprocessing қозғалтқышы	228
6.2.2 Модель-таңдау логикасы бар Inference модулі	231
6.3 Клиникалық жұмыс процесіне интеграция	225
6.3.1 Ауылдық орналастыру үшін телемедицина және тасымалданатын құрылғыны қолдау	233
6.3.1.1 Таратылған телемедицина жүйелерінде орналастыру	234
6.3.1.2 Ұлттық eHealth платформаларымен интеграция	235
6.3.1.3 Ресурстары аз аймақтарда нақты уақыттағы қашықтан DR скринингі.....	235
6.3.2 Physician-in-the-Loop шешім-қолдау интерфейсі	237
6.4 Деректер қауіпсіздігі және нормативтік сәйкестік негіздемесі.....	238
6.4.1 GDPR/HIPAA-сәйкес деректерді басқару хаттамалары	238
6.4.2 Қазақстанның денсаулық сақтау инфрақұрылымына қолданылуы	240
6-тарау бойынша қорытындылар.....	220
ҚОРЫТЫНДЫ	242
ПАЙДАЛАНЫЛҒАН ӘДЕБИЕТТЕР ТІЗІМІ.....	246
А ҚОСЫМШАСЫ	255
Ә ҚОСЫМШАСЫ	259
Б ҚОСЫМШАСЫ.....	264
Д ҚОСЫМШАСЫ	271
Е ҚОСЫМШАСЫ	280
Ж ҚОСЫМШАСЫ	295

НОРМАТИВТІК СІЛТЕМЕЛЕР

Бұл диссертацияда келесі стандарттарға сілтемелер пайдаланылды:

Диссертация мен авторефератты ресімдеу жөніндегі нұсқаулық, Қазақстан Республикасы Білім және ғылым министрлігінің Жоғары аттестаттау комитеті, 2004 жылғы 28 қыркүйектегі № 377-3 ж.

ГОСТ 7.32-2001. Ғылыми-зерттеу жұмысы туралы есеп. Құрылымы және ресімдеу ережелері.

ГОСТ 7.1-2003. Библиографиялық жазба. Библиографиялық сипаттама. Жалпы талаптар мен жасау ережелері.

СТ ҚР 34.005-2002. Ақпараттық технология. Негізгі терминдер мен анықтамалар (бірінші басылым).

СТ ҚР 34.015-2002. Ақпараттық технология. Автоматтандырылған жүйелер стандарттарының жиынтығы. Ақпараттық жүйені құруға арналған техникалық тапсырма (бірінші басылым).

СТ ҚР 34.027-2006. Ақпараттық технологиялар. Бағдарламалық құралдарды жіктеу (бірінші басылым).

СТ ҚР 34.014-2002. Ақпараттық технология. Автоматтандырылған жүйелер стандарттарының жиынтығы. Автоматтандырылған жүйелер. Терминдер мен анықтамалар.

БЕЛГІЛЕУЛЕР МЕН ҚЫСҚАРТУЛАР

AI	Artificial Intelligence (жасанды интеллект)
ALO	Attention–Lesion Overlap (explainability метрикасы)
APTOS	Asia Pacific Tele-Ophthalmology Society (2019 Blindness Detection деректер жиынтығы)
AUC	Area Under the Curve (қисық астындағы аудан)
BYOL	Bootstrap Your Own Latent (өзін-өзі бақылаусыз оқыту әдісі)
CAM	Class Activation Mapping
CLAHE	Contrast-Limited Adaptive Histogram Equalization
CNN	Convolutional Neural Network
CNR	Contrast-to-Noise Ratio
DDR	Диабеттік ретинопатияны градациялау деректер жиынтығы (DDR)
DINO	self-Distillation with No labels (өзін-өзі бақылаусыз оқыту әдісі)
DR	Diabetic Retinopathy (диабеттік ретинопатия)
ECE	Expected Calibration Error
EHR	Electronic Health Record (электрондық денсаулық жазбасы)
EMD	Earth Mover's Distance
EyePACS	Eye Picture Archive Communication System (DR деректер жиынтығы)
FOV	Field of View (көру өрісі)
GDPR	General Data Protection Regulation
Grad-CAM	Gradient-weighted Class Activation Mapping
HIPAA	Health Insurance Portability and Accountability Act
IDRiD	Indian Diabetic Retinopathy Image Dataset
IoU	Intersection over Union
KL	Kullback–Leibler дивергенциясы
LAB	CIELAB түс кеңістігі
MLP	Multilayer Perceptron
MoCo	Momentum Contrast (өзін-өзі бақылаусыз оқыту әдісі)
NPV	Negative Predictive Value (теріс болжамдық мән)
OD	Optic Disc (көру дискісі)
ODIR-5K	Ocular Disease Intelligent Recognition деректер жиынтығы (5000 пациент)
PACS	Picture Archiving and Communication System
PPV	Positive Predictive Value (оң болжамдық мән)
ReLU	Rectified Linear Unit
RFMiD	Retinal Fundus Multi-disease Image Dataset
RIQA	Retinal Image Quality Assessment
ROC	Receiver Operating Characteristic
SimCLR	Simple framework for Contrastive Learning of Representations
SSIM	Structural Similarity Index
SSL	Self-Supervised Learning (өзін-өзі бақылаусыз оқыту)
STARE	Structured Analysis of the Retina (деректер жиынтығы)

UML	Unified Modeling Language
VRAM	Video Random-Access Memory
VVI	Vessel Visibility Index
WSL	Windows Subsystem for Linux
XAI	Explainable Artificial Intelligence
D	Көру өрісінің (FOV) диаметрі, пиксельмен
CL	CLANE түрлендіруінің клип-лимиті
F1	F1-score (precision және recall гармоникалық орташасы)
G	Жалпылау коэффициенті, $G = F1_external / F1_EyePACS$
T	Қос шектеулі CLANE-нің ғаламдық шектік мәні (T/80 формуляциясы)
α	Focal Loss класс салмағы параметрі (кері жиілік)
γ	Focal Loss фокустау параметрі ($\gamma = 2$)
к	Квадраттық салмақтары бар Cohen's Карра
σ	Flat-field correction-дегі Гаусс ядросының стандартты ауытқуы, $\sigma = 0.07 \cdot D$
$\Delta F1$	Деректер жиынтығы аралық F1 төмендеуі, $\Delta F1 = F1_EyePACS - F1_external$

АНЫҚТАМАЛАР

Архитектуралық күрделілік (Architectural complexity) — CNN сыйымдылығы, конволюциялық қабаттар саны, оқытылатын параметрлердің жалпы саны, сүзгі өлшемдерінің ауқымы және регуляризация компоненттерінің (batch normalization, dropout) болуы немесе болмауы арқылы анықталады.

Baseline (базалық тармақ) — Эксперимент 1-дің анықтамалық конфигурациясы: 512×512-ге дейін созып-масштабтау, одан кейін ImageNet нормализациясы; FOV маскасы мен preprocessing кезеңдерінсіз 3 арналы тензор шығарады, магистраль ImageNet-тен инициализацияланады.

CLANE (Contrast-Limited Adaptive Histogram Equalization) — контрастты күшейтуді шектейтін шектік мәнмен жергілікті кескін плиткалары бойынша жұмыс істейтін адаптивті контрастты күшейту әдісі; конвейерде LAB L-арнасына қос шектеулі шектік мәнмен қолданылады (5-кезең).

Композиттік тәуелсіз айнымалы (Composite independent variable) — Эксперимент 1-дің (H-1) біріктірілген басқарылатын факторы, мұнда толық конвейер тармағы baseline-нан preprocessing өсі (сегіз кезеңді конвейер vs. созып-масштабтау + ImageNet) және pretraining өсі (офтальмологияға бейімделген SSL vs. ImageNet) бойынша бірге ерекшеленеді.

Convolutional Neural Network (CNN) — белгілерді шығаруға арналған конволюциялық және pooling қабаттарынан және жіктеуге арналған толық байланысқан қабаттардан тұратын нейрондық архитектура; алдын ала өңделген fundus кескіндерінде бес класты DR градациясын жасайтын жіктеу магистралі.

Cross-Validation — 5 еселі, пациент деңгейінде стратификацияланған бөлуді пайдаланатын валидация стратегиясы; әр итерацияда төрт фолд оқыту, бір фолд тест ретінде қолданылады, бір пациенттің кескіндері екі бөлімде де болмайды; метрикалар орташа ± стандартты ауытқу түрінде беріледі.

Data Augmentation — оқыту деректерінің варибельділігін арттыру және жалпылауды жақсарту үшін қолданылатын кескін түрлендірулері (біртұтас аффинді, ColorJitter [жарықтылық/контраст/қанығу/реңк], Гаусс шуы, JPEG компрессия); конвейердің тек оқытуға арналған 6-кезеңі.

Деректер жиынтығына тән нормализация (Dataset-specific normalization) — ImageNet статистикасының орнына негізгі деректер жиынтығының оқыту бөлігінен есептелген орташа мән мен стандартты ауытқуды пайдаланатын арна бойынша нормализация (7-кезең); толық конвейердің нормализациясы.

Диабеттік ретинопатия (Diabetic Retinopathy, DR) — қант диабетінің микротамырлық асқынуы және алдын алуға болатын көру қабілетінен айырылудың жетекші себебі; бес ауырлық сатысында градацияланады (0 — жоқ, 1 — жеңіл, 2 — орташа, 3 — ауыр, 4 — пролиферативті).

Диагностикалық тиімділік (Diagnostic effectiveness) — тест бөлімінде есептелген төрт негізгі метрика (accuracy, weighted F1-score, ROC-AUC және квадраттық салмақты Cohen's Kappa) бойынша бірлескен өнімділік профилі.

Domain Shift — бейнелеу жабдығының, пациенттер популяциясының немесе алу хаттамаларының айырмашылықтарынан туындайтын оқыту деректері мен мақсатты деректер арасындағы таралымдық айырмашылық.

FOV маскасы (Field-of-View mask) — 3-кезеңде жасалатын және 4-арна ретінде қосылатын бинарлық кеңістіктік маска (1.0 = нақты fundus деректері, 0.0 = нөлдік толтыру), CNN-ге нақты ретинальды пиксельдерді толтырылған фоннан ажыратуға мүмкіндік береді.

Flat-Field Correction (адаптивті) — FOV маскасы ішінде біркелкі емес жарықтандыруды қалыпқа келтіретін, жергілікті контрастты сақтайтын адаптивті $\sigma = 0.07 \cdot D$ ($D = \text{FOV}$ диаметрі) бар Гаусс бұлыңғырлауын азайту; конвейердің 4-кезеңі.

Fundus кескіні (Fundus image) — фундоскопия арқылы алынған ретинальды фотосурет; диссертацияның жалғыз бейнелеу модальділігі және preprocessing конвейері мен CNN жіктеуішінің кірісі.

Жалпылау (cross-database) — сол бір оқытылған модельмен қайта оқытусыз екінші деректер жиынтығындағы тест F1-score-дың негізгі деректер жиынтығындағы тест F1-score-ға қатынасы; жалпылау коэффициенті $G = F1_{\text{external}} / F1_{\text{EyePACS}}$.

Grad-CAM (Gradient-weighted Class Activation Mapping) — соңғы конволюциялық белгілер карталарының градиентпен өлшенген комбинациясынан класс-дискриминативті локализация карталарын жасайтын explainability әдісі; патологияны клиникалық локализациялау емес, интерпретация құралы.

Кескін сапасы (Image quality) — fundus кескінінің DR градациясына қатысты микротамырлық белгілерді автоматты түрде анықтауды қолдаудың өлшенетін қабілеті; субъективті визуалды баға арқылы емес, төмен ағындағы жіктеу өнімділігі арқылы бағаланады.

Интеграцияланған конвейер үстемдігі (H-1) — біріктірілген толық конвейер конфигурациясы baseline-нан біртұтас жүйе ретінде асып түседі деген негізгі гипотеза; эмпирикалық үстемдік критерийі ($\text{weighted F1} \geq 5$ пп өсу, $\text{ROC-AUC} \geq 0.02$ өсу, Карра нашарламауы) орындалғанда валидацияланады.

Офтальмологияға бейімделген өзін-өзі бақылаусыз алдын ала оқыту — CNN магистралін белгіленбеген ретинальды fundus корпусында (DR белгілерінсіз) өзін-өзі бақылаусыз алдын ала оқыту; толық конвейер тармағының инициализациясы ретінде қолданылады, 4-арналы конвейер тензорында fundus-домен репрезентацияларын үйренеді.

Physician-in-the-Loop — дәрігер AI шығысын тек тұтынушы ретінде емес, нәтижелерді интерпретациялайтын және жүйені баптайтын «баптаушы» әрі аудитор ретінде әрекет ететін жобалау парадигмасы; ұсынылған жүйе осы парадигма аясындағы шешім қабылдауды қолдау құралы.

Preprocessing Pipeline (алдын ала өңдеу конвейері) — CNN кірісіне дейін fundus кескіндеріне қолданылатын канондық сегіз кезеңді реттелген тізбек (0–7 кезеңдер); толық конвейер барлық сегіз кезеңді қолданып, 4-арналы тензор (RGB + FOV маскасы) шығарады.

Ресурстары шектеулі орта (Resource-limited environment) — келесілердің кемінде екеуімен сипатталатын орналастыру контексті: GPU үдетуінің болмауы; қолжетімді RAM 16 ГБ-тан төмен; пакеттік өңдеу уақытының шектеулері; үздіксіз бұлттық API-ге сенуге мүмкіндік бермейтін желілік байланыс.

Transfer Learning — алдын ала оқытылған желі салмақтарын fundus-кескін доменіне қайта пайдалану және бейімдеу; H-1 бойынша инициализация көзі тармаққа бағынады (baseline үшін ImageNet, толық конвейер үшін офтальмологияға бейімделген SSL).

Weighted Loss Function — класс теңсіздігін шешетін және бес класты DR градациясының реттік құрылымын пайдаланатын класс бойынша салмақтары бар кросс-энтропия шығын функциясы.