

Халықаралық ақпараттық технологиялар университеті

ӘОЖ: 004.93:617.735

Қолжазба құқығында

ЕСМУХАМЕДОВ НҰРМАҒАНБЕТ СЕЙТҚАЛИҰЛЫ

**Fundus кескіндерін жақсарту және CNN жіктеуі арқылы
диабеттік ретинопатияны автоматтандырылған диагностикалау**

8D06104 – Есептеу техникасы және бағдарламалық жасақтама

Философия докторы (PhD) дәрежесін
алуға арналған диссертация

Ғылыми консультанты
физика-математика ғылымдарының
кандидаты,
қауымдастырылған профессор,
Халықаралық ақпараттық
технологиялар университеті
Сапакова С.З.

Шетелдік ғылыми консультанты
профессор, Universiti Putra Malaysia
Al-Haddad S.A.R.

Қазақстан Республикасы
Алматы, 2026

МАЗМҰНЫ

НОРМАТИВТІК СІЛТЕМЕЛЕР.....	6
БЕЛГІЛЕУЛЕР МЕН ҚЫСҚАРТУЛАР	7
АНЫҚТАМАЛАР.....	9
КІРІСПЕ.....	—
1 ДИАБЕТТІК РЕТИНОПАТИЯНЫ АВТОМАТТАНДЫРЫЛҒАН ДИАГНОСТИКАЛАУДЫҢ ПРОБЛЕМАЛЫҚ САЛАСЫН ТАЛДАУ ЖӘНЕ ҚАЗІРГІ ЖАЙ-КҮЙІ	12
1.1 Диабеттік ретинопатияның медициналық және эпидемиологиялық контексті	12
1.1.1 Патофизиология және клиникалық градациялау жүйелері	12
1.1.2 Ресурстары шектеулі денсаулық сақтау жағдайындағы скрининг талаптары.....	15
1.2 Fundus кескіндерін алу және сапа вариабельдігі	18
1.2.1 Клиникалық тәжірибедегі кескін сапасының төмендеу көздері	18
1.2.2 Кескін сапасының диагностикалық модель өнімділігіне әсері	20
1.2.3 Fundus бейнелеудегі құрылғыға тәуелді вариабельділік.....	23
1.3 Ретинальды кескіндерді жіктеудегі Deep Learning тәсілдері	26
1.3.1 Медициналық бейнелеуге арналған Convolutional Neural Network архитектуралары.....	26
1.3.2 Офтальмологиялық диагностикадағы Transfer Learning және өзін-өзі бақылаусыз алдын ала оқыту	29
1.3.3 Медициналық кескіндерді жіктеудегі Explainability әдістері.....	32
1.4 DR автоматтандырылған скрининг жүйелеріне сыни талдау	34
1.5 Зерттеу мәселесін тұжырымдау және зерттеу бағытын негіздеу.....	38
1-тарау бойынша қорытындылар	12
2 FUNDUS IMAGE ТАЛДАУЫ ҮШІН IMAGE PREPROCESSING ЖӘНЕ DEEP LEARNING ТЕОРИЯЛЫҚ НЕГІЗДЕРІ	42
2.1 Image Enhancement әдістерінің математикалық негіздері	42
2.1.1 Histogram Equalization және Adaptive Contrast Enhancement	42
2.1.2 Қос шектеулі шектік мәні бар CLAHE формализациясы.....	46
2.1.3 Spatial Filtering және Noise Reduction әдістері	49
2.2 Convolutional Neural Networks теориялық негіздері.....	51
2.2.1 Convolution, Pooling және Feature Extraction операциялары.....	51
2.2.2 Imbalanced медициналық деректер жиынтықтары үшін Loss Functions және оптимизация.....	54
2.2.3 Regularization әдістері: Dropout, Batch Normalization және Data Augmentation	57
2.3 Transfer Learning және өзін-өзі бақылаусыз репрезентация оқыту теориясы	59
2.3.1 Визуалды домендер арасындағы Feature Transferability.....	59
2.3.2 Frozen-Layer және Progressive Fine-Tuning стратегиялары	61

2.3.3 Ретинальды бейнелеуге арналған домендік өзін-өзі бақылаусыз алдын ала оқыту	63
2.4 Ретинальды терапиядағы Laser–Tissue Interaction математикалық модельдеу65	
2.4.1 Fundus тіндерінің жауабын сипаттайтын Coupled Thermal-Optical Model (диагностикалық кескін белгілерін интерпретациялауға ықпалын қоса).....	65
2.5 Медициналық бейнелеуге арналған Deep Learning-тегі Explainability.....	68
2.5.1 Class Activation Mapping (CAM) және Grad-CAM математикалық формуляциясы.....	68
2.5.2 Офтальмологиялық контексттегі Attention Maps интерпретациясы.....	71
2.5.3 Сандық Explainability метрикалары ретіндегі ALO және IoU	72
2.6 Preprocessing бағалауға арналған кескін сапасы метрикалары	74
2-тарау бойынша қорытындылар	42
3 ИНТЕГРАЦИЯЛАНҒАН PREPROCESSING-CNN PIPELINE ЖОБАЛАУ ӘДІСТЕМЕСІ.....	78
3.1 Біріздендірілген Preprocessing Pipeline формализациясы	78
3.1.1 Pipeline кезеңдерінің спецификациясы: 8 кезеңді жүйе	78
3.1.2 Қос шектеулі шектік мәні бар модификацияланған CLANE алгоритмі94	
3.1.3 Класс теңсіздігін азайтуға арналған Augmentation стратегиясы	97
3.1.4 Сыртқы кескіндерді қабылдау хаттамасы	98
3.2 DR жіктеуге арналған CNN архитектураларын жобалау.....	100
3.2.1 ResNet-50 және EfficientNet-B3 негізгі эксперименттік архитектуралар ретінде.....	100
3.2.2 Тарихи анықтамалық архитектуралар (тек анықтама үшін).....	103
3.3 Transfer Learning және алдын ала оқыту әдістемесі	104
3.3.1 Бес класты DR жіктеуге арналған архитектураны бейімдеу	104
3.3.2 CNN магистралын офтальмологияға бейімделген өзін-өзі бақылаусыз алдын ала оқыту (тармағы).....	106
3.3.3 Екі кезеңді Fine-Tuning хаттамасын жобалау.....	108
3.3.4 Реттік класс құрылымына арналған Weighted Loss Function формуляциясы.....	109
3.4 Бағалау негіздемесі және өнімділік метрикалары	111
3.4.1 Көп метрикалық бағалау негіздемесі	111
3.4.2 Cross-Validation және статистикалық сенімділік хаттамалары	115
3-тарау бойынша қорытындылар	78
4 ЭКСПЕРИМЕНТТІК ЗЕРТТЕУ — PREPROCESSING-ТІҢ CNN ДИАГНОСТИКАЛЫҚ ӨНІМДІЛІГІНЕ ӘСЕРІ.....	119
4.1 Деректер жиынтықтары және эксперименттік конфигурация	119
4.1.1 Деңгейлік деректер жиынтығы архитектурасы.....	119
4.1.2 Класс таралуын талдау және деректерді бөлу стратегиясы.....	125
4.1.3 Аппараттық спецификация және қайта жаңғырту хаттамасы.....	128

4.2 Эксперимент 1: Интеграцияланған Pipeline үстемдігі — EyePACS-та Pipeline + домендік алдын ала оқыту vs. Baseline (H-1).....	—
4.2.1 Қалпына келтірілген 2×2 факторлық жобалау (A–D конфигурациялары).....	—
4.2.2 Оқыту динамикасы және конвергенция талдауы.....	—
4.2.3 Диагностикалық метрикаларды сандық салыстыру	—
4.3 Эксперимент 2: Pipeline кезеңдерін абляциялау + CLANE/σ жинақтары (H-2).....	—
4.3.1 абляция жобалауы (0–6 деңгейлер)	—
4.3.2 CLANE шектік сезімталдық талдауы (H-2 қосалқы талдауы).....	—
4.3.3 Flat-Field σ жинағы және кескін сапасы метрикалары	—
4.4 Эксперимент 3: APTOS 2019-дағы Cross-Dataset Transferability (H-4)	—
4.4.1 APTOS 2019-ға Zero-Shot Transfer.....	—
4.4.2 Baseline және Pipeline салыстыруы.....	—
4.5 Эксперимент 4: IDRiD + Clinical-дегі Grad-CAM Explainability (H-5).....	—
4.5.1 Grad-CAM генерациялау хаттамасы.....	—
4.5.2 IDRiD зақымдану масктарымен сандық ALO және IoU.....	—
4.5.3 Деректер жиынтықтары бойынша Attention консистенттілігі.....	—
4.6 Эксперимент 5: IDRiD + Messidor-2-дегі клиникалық деградацияға төзімділік (H-7).....	—
4.7 Эксперимент 6: DDR + ODIR-5K + RFMiD-тегі Device Domain Shift (H-6). —	—
4.8 Эксперимент 7: Аз деректермен оқыту (IDRiD → Clinical)	—
4-тарау бойынша қорытындылар.....	119
5 СЕНІМДІЛІКТІ ВАЛИДАЦИЯЛАУ ЖӘНЕ САЛЫСТЫРМАЛЫ ТАЛДАУ	—
5.1 Explainability нәтижелері.....	—
5.2 Статистикалық валидация	—
5.2.1 Bootstrap сенімділік интервалдары және Mixed-Effects моделі.....	—
5.2.2 Түпкілікті claim күштілік жіктеулері	—
5.3 Жарияланған жүйелермен салыстырмалы талдау	—
5.3.1 Жарияланған нәтижелермен Benchmarking: IDx-DR, EyeNuk, DeepMind.....	—
5.3.2 Performance-Complexity Trade-Off талдауы	—
5.4 Ұсынылған тәсілдің шектеулері мен шекаралық шарттары.....	—
5-тарау бойынша қорытындылар	—
6 РЕСУРСТАРЫ ШЕКТЕУЛІ ОРТАҒА АРНАЛҒАН DR АВТОМАТТАНДЫРЫЛҒАН СКРИНИНГ ЖҮЙЕСІНІҢ АРХИТЕКТУРАСЫ.....	130
6.1 Жүйелік талаптар және жобалау қағидалары.....	131
6.1.1 Функционалдық және функционалдық емес талаптар спецификациясы.....	130
6.1.2 PACS және ENR интеграциясы бар модульдік архитектура	133
6.2 AI өңдеу модулін жобалау	132
6.2.1 Конфигурацияланатын Pipeline параметрлері бар Preprocessing Engine.....	137

6.2.2 Model Selection Logic бар Inference модулі.....	139
6.3 Клиникалық жұмыс процесіне интеграция	134
6.3.1 Ауылдық жерлерде орналастыруға арналған телемедицина және портативті құрылғыларды қолдау.....	141
6.3.1.1 Таратылған телемедицина жүйелерінде орналастыру.....	141
6.3.1.2 Ұлттық eHealth платформаларымен интеграция.....	142
6.3.1.3 Ресурстары аз аймақтарда нақты уақыттағы қашықтан DR скринингі.....	143
6.3.2 Physician-in-the-Loop шешім қабылдауды қолдау интерфейсі	144
6.4 Деректер қауіпсіздігі және нормативтік сәйкестік негіздемесі.....	145
6.4.1 GDPR/HIPAA-ге сәйкес деректерді басқару хаттамалары.....	145
6.4.2 Қазақстан денсаулық сақтау инфрақұрылымына қолданылуы	147
6-тарау бойынша қорытындылар.....	130
ҚОРЫТЫНДЫ	—
ПАЙДАЛАНЫЛҒАН ӘДЕБИЕТТЕР ТІЗІМІ.....	157
ҚОСЫМШАЛАР.....	150
А қосымшасы — Preprocessing Pipeline бастапқы коды.....	—
Б қосымшасы — Қосымша эксперименттік нәтижелер және Confusion Matrices	—
В қосымшасы — Жүйе архитектурасының UML диаграммалары	—
Г қосымшасы — Енгізу сертификаттары және апробация актілері.....	—
Д қосымшасы — Grad-CAM визуализация галереясы	—
Е қосымшасы — Device Domain Shift қосымша кестелері	—

НОРМАТИВТІК СІЛТЕМЕЛЕР

Бұл диссертацияда келесі стандарттарға сілтемелер пайдаланылды:

Диссертация мен авторефератты ресімдеу жөніндегі нұсқаулық, Қазақстан Республикасы Білім және ғылым министрлігінің Жоғары аттестаттау комитеті, 2004 жылғы 28 қыркүйектегі № 377-3 ж.

ГОСТ 7.32-2001. Ғылыми-зерттеу жұмысы туралы есеп. Құрылымы және ресімдеу ережелері.

ГОСТ 7.1-2003. Библиографиялық жазба. Библиографиялық сипаттама. Жалпы талаптар мен жасау ережелері.

СТ ҚР 34.005-2002. Ақпараттық технология. Негізгі терминдер мен анықтамалар (бірінші басылым).

СТ ҚР 34.015-2002. Ақпараттық технология. Автоматтандырылған жүйелер стандарттарының жиынтығы. Ақпараттық жүйені құруға арналған техникалық тапсырма (бірінші басылым).

СТ ҚР 34.027-2006. Ақпараттық технологиялар. Бағдарламалық құралдарды жіктеу (бірінші басылым).

СТ ҚР 34.014-2002. Ақпараттық технология. Автоматтандырылған жүйелер стандарттарының жиынтығы. Автоматтандырылған жүйелер. Терминдер мен анықтамалар.

БЕЛГІЛЕУЛЕР МЕН ҚЫСҚАРТУЛАР

AI	Artificial Intelligence (жасанды интеллект)
ALO	Activation–Lesion Overlap (explainability метрикасы)
APTOS	Asia Pacific Tele-Ophthalmology Society (2019 Blindness Detection деректер жиынтығы)
AUC	Area Under the Curve (қисық астындағы аудан)
BYOL	Bootstrap Your Own Latent (өзін-өзі бақылаусыз оқыту әдісі)
CAM	Class Activation Mapping
CLAHE	Contrast-Limited Adaptive Histogram Equalization
CNN	Convolutional Neural Network
CNR	Contrast-to-Noise Ratio
DDR	Диабеттік ретинопатияны градациялау деректер жиынтығы (DDR)
DINO	self-Distillation with No labels (өзін-өзі бақылаусыз оқыту әдісі)
DR	Diabetic Retinopathy (диабеттік ретинопатия)
ECE	Expected Calibration Error
EHR	Electronic Health Record (электрондық денсаулық жазбасы)
EMD	Earth Mover's Distance
EyePACS	Eye Picture Archive Communication System (DR деректер жиынтығы)
FOV	Field of View (көру өрісі)
GDPR	General Data Protection Regulation
Grad-CAM	Gradient-weighted Class Activation Mapping
HIPAA	Health Insurance Portability and Accountability Act
IDRiD	Indian Diabetic Retinopathy Image Dataset
IoU	Intersection over Union
KL	Kullback–Leibler дивергенциясы
LAB	CIELAB түс кеңістігі
MLP	Multilayer Perceptron
MoCo	Momentum Contrast (өзін-өзі бақылаусыз оқыту әдісі)
NPV	Negative Predictive Value (теріс болжамдық мән)
OD	Optic Disc (көру дискісі)
ODIR-5K	Ocular Disease Intelligent Recognition деректер жиынтығы (5000 пациент)
PACS	Picture Archiving and Communication System
PPV	Positive Predictive Value (оң болжамдық мән)
ReLU	Rectified Linear Unit
RFMiD	Retinal Fundus Multi-disease Image Dataset
RIQA	Retinal Image Quality Assessment
ROC	Receiver Operating Characteristic
SimCLR	Simple framework for Contrastive Learning of Representations
SSIM	Structural Similarity Index
SSL	Self-Supervised Learning (өзін-өзі бақылаусыз оқыту)
STARE	Structured Analysis of the Retina (деректер жиынтығы)

UML	Unified Modeling Language
VRAM	Video Random-Access Memory
VVI	Vessel Visibility Index
WSL	Windows Subsystem for Linux
XAI	Explainable Artificial Intelligence
D	Көру өрісінің (FOV) диаметрі, пиксельмен
CL	CLANE түрлендіруінің клип-лимиті
F1	F1-score (precision және recall гармоникалық орташасы)
G	Жалпылау коэффициенті, $G = F1_external / F1_EyePACS$
T	Қос шектеулі CLANE-нің ғаламдық шектік мәні (T/80 формуляциясы)
α	Focal Loss класс салмағы параметрі (кері жиілік)
γ	Focal Loss фокустау параметрі ($\gamma = 2$)
к	Квадраттық салмақтары бар Cohen's Kappa
σ	Flat-field correction-дегі Гаусс ядросының стандартты ауытқуы, $\sigma = 0.07 \cdot D$
$\Delta F1$	Деректер жиынтығы аралық F1 төмендеуі, $\Delta F1 = F1_EyePACS - F1_external$

АНЫҚТАМАЛАР

Архитектуралық күрделілік (Architectural complexity) — CNN сыйымдылығы, конволюциялық қабаттар саны, оқытылатын параметрлердің жалпы саны, сүзгі өлшемдерінің ауқымы және регуляризация компоненттерінің (batch normalization, dropout) болуы немесе болмауы арқылы анықталады.

Baseline (базалық тармақ) — Эксперимент 1-дің анықтамалық конфигурациясы: 512×512-ге дейін созып-масштабтау, одан кейін ImageNet нормализациясы; FOV маскасы мен preprocessing кезеңдерінсіз 3 арналы тензор шығарады, магистраль ImageNet-тен инициализацияланады.

CLANE (Contrast-Limited Adaptive Histogram Equalization) — контрастты күшейтуді шектейтін шектік мәнмен жергілікті кескін плиткалары бойынша жұмыс істейтін адаптивті контрастты күшейту әдісі; конвейерде LAB L-арнасына қос шектеулі шектік мәнмен қолданылады (5-кезең).

Композиттік тәуелсіз айнымалы (Composite independent variable) — Эксперимент 1-дің (H-1) біріктірілген басқарылатын факторы, мұнда толық конвейер тармағы baseline-нан preprocessing өсі (сегіз кезеңді конвейер vs. созып-масштабтау + ImageNet) және pretraining өсі (офтальмологияға бейімделген SSL vs. ImageNet) бойынша бірге ерекшеленеді.

Convolutional Neural Network (CNN) — белгілерді шығаруға арналған конволюциялық және pooling қабаттарынан және жіктеуге арналған толық байланысқан қабаттардан тұратын нейрондық архитектура; алдын ала өңделген fundus кескіндерінде бес класты DR градациясын жасайтын жіктеу магистралі.

Cross-Validation — 5 еселі, пациент деңгейінде стратификацияланған бөлуді пайдаланатын валидация стратегиясы; әр итерацияда төрт фолд оқыту, бір фолд тест ретінде қолданылады, бір пациенттің кескіндері екі бөлімде де болмайды; метрикалар орташа ± стандартты ауытқу түрінде беріледі.

Data Augmentation — оқыту деректерінің варибельділігін арттыру және жалпылауды жақсарту үшін қолданылатын кескін түрлендірулері (аударып шығару, бұру, масштабтау, жарықтық/контраст, PCA түс); конвейердің тек оқытуға арналған 6-кезеңі.

Деректер жиынтығына тән нормализация (Dataset-specific normalization) — ImageNet статистикасының орнына негізгі деректер жиынтығының оқыту бөлігінен есептелген орташа мән мен стандартты ауытқуды пайдаланатын арна бойынша нормализация (7-кезең); толық конвейердің нормализациясы.

Диабеттік ретинопатия (Diabetic Retinopathy, DR) — қант диабетінің микротамырлық асқынуы және алдын алуға болатын көру қабілетінен айырылудың жетекші себебі; бес ауырлық сатысында градацияланады (0 — жоқ, 1 — жеңіл, 2 — орташа, 3 — ауыр, 4 — пролиферативті).

Диагностикалық тиімділік (Diagnostic effectiveness) — тест бөлімінде есептелген төрт негізгі метрика (accuracy, weighted F1-score, ROC-AUC және квадраттық салмақты Cohen's Kappa) бойынша бірлескен өнімділік профилі.

Domain Shift — бейнелеу жабдығының, пациенттер популяциясының немесе алу хаттамаларының айырмашылықтарынан туындайтын оқыту деректері мен мақсатты деректер арасындағы таралымдық айырмашылық.

FOV маскасы (Field-of-View mask) — 3-кезеңде жасалатын және 4-арна ретінде қосылатын бинарлық кеңістіктік маска (1.0 = нақты fundus деректері, 0.0 = нөлдік толтыру), CNN-ге нақты ретинальды пиксельдерді толтырылған фоннан ажыратуға мүмкіндік береді.

Flat-Field Correction (адаптивті) — FOV маскасы ішінде біркелкі емес жарықтандыруды қалыпқа келтіретін, жергілікті контрастты сақтайтын адаптивті $\sigma = 0.07 \cdot D$ ($D = \text{FOV}$ диаметрі) бар Гаусс бұлыңғырлауын азайту; конвейердің 4-кезеңі.

Fundus кескіні (Fundus image) — фундоскопия арқылы алынған ретинальды фотосурет; диссертацияның жалғыз бейнелеу модальділігі және preprocessing конвейері мен CNN жіктеуішінің кірісі.

Жалпылау (cross-database) — сол бір оқытылған модельмен қайта оқытусыз екінші деректер жиынтығындағы тест F1-score-дың негізгі деректер жиынтығындағы тест F1-score-ға қатынасы; жалпылау коэффициенті $G = F1_{\text{external}} / F1_{\text{EyePACS}}$.

Grad-CAM (Gradient-weighted Class Activation Mapping) — соңғы конволюциялық белгілер карталарының градиентпен өлшенген комбинациясынан класс-дискриминативті локализация карталарын жасайтын explainability әдісі; патологияны клиникалық локализациялау емес, интерпретация құралы.

Кескін сапасы (Image quality) — fundus кескінінің DR градациясына қатысты микротамырлық белгілерді автоматты түрде анықтауды қолдаудың өлшенетін қабілеті; субъективті визуалды баға арқылы емес, төмен ағындағы жіктеу өнімділігі арқылы бағаланады.

Интеграцияланған конвейер үстемдігі (H-1) — біріктірілген толық конвейер конфигурациясы baseline-нан біртұтас жүйе ретінде асып түседі деген негізгі гипотеза; эмпирикалық үстемдік критерийі ($\text{weighted F1} \geq 5$ пп өсу, $\text{ROC-AUC} \geq 0.02$ өсу, Карра нашарламауы) орындалғанда валидацияланады.

Офтальмологияға бейімделген өзін-өзі бақылаусыз алдын ала оқыту — CNN магистралін белгіленбеген ретинальды fundus корпусында (DR белгілерінсіз) өзін-өзі бақылаусыз алдын ала оқыту; толық конвейер тармағының инициализациясы ретінде қолданылады, 4-арналы конвейер тензорында fundus-домен репрезентацияларын үйренеді.

Physician-in-the-Loop — дәрігер AI шығысын тек тұтынушы ретінде емес, нәтижелерді интерпретациялайтын және жүйені баптайтын «баптаушы» әрі аудитор ретінде әрекет ететін жобалау парадигмасы; ұсынылған жүйе осы парадигма аясындағы шешім қабылдауды қолдау құралы.

Preprocessing Pipeline (алдын ала өңдеу конвейері) — CNN кірісіне дейін fundus кескіндеріне қолданылатын канондық сегіз кезеңді реттелген тізбек (0–7 кезеңдер); толық конвейер барлық сегіз кезеңді қолданып, 4-арналы тензор (RGB + FOV маскасы) шығарады.

Ресурстары шектеулі орта (Resource-limited environment) — келесілердің кемінде екеуімен сипатталатын орналастыру контексті: GPU үдетуінің болмауы; қолжетімді RAM 16 ГБ-тан төмен; пакеттік өңдеу уақытының шектеулері; үздіксіз бұлттық API-ге сенуге мүмкіндік бермейтін желілік байланыс.

Transfer Learning — алдын ала оқытылған желі салмақтарын fundus-кескін доменіне қайта пайдалану және бейімдеу; H-1 бойынша инициализация көзі тармаққа бағынады (baseline үшін ImageNet, толық конвейер үшін офтальмологияға бейімделген SSL).

Weighted Loss Function — класс теңсіздігін шешетін және бес класты DR градациясының реттік құрылымын пайдаланатын класс бойынша салмақтары бар кросс-энтропия шығын функциясы.

1 ДИАБЕТТІК РЕТИНОПАТИЯНЫ АВТОМАТТАНДЫРЫЛҒАН ДИАГНОСТИКАЛАУДЫҢ ПРОБЛЕМАЛЫҚ САЛАСЫН ТАЛДАУ ЖӘНЕ ҚАЗІРГІ ЖАЙ- КҮЙІ

§1.1.1 Патофизиология және клиникалық градациялау жүйелері

Диабеттік ретинопатия (DR) — қант диабетінің созылмалы асқынуы әрі еңбекке қабілетті жастағы ересектер арасында алдын алуға болатын көру қабілетінен айырылудың негізгі себептерінің бірі. Оның ауқымы елеулі: DR патофизиологиясының баяндамалық шолуында Kusuhaга және әріптестері [1] бүкіл әлемдегі диабеттік популяциялар арасында кез келген DR-дің біріктірілген таралымын 34,6% деп келтірді, ал Moya және әріптестері [2] патофизиология мен емдеудің одан әрі баяндамалық шолуында DR диабеті бар науқастардың шамамен үштен бірінде кездесетінін байқады. Бұл екі бағалау да осы диссертацияның нәтижелері ретінде емес, үшінші тараптың клиникалық контексті ретінде келтіріледі, әрі екеуі де эпидемиологиялық көрсеткіштері өздері сілтейтін бастапқы зерттеулерден мұраланатын жүйелі емес баяндамалық синтездерден алынған. DR-дің автоматтандырылған скрининг жүйесі үшін клиникалық маңызы оның жиілігінде ғана емес, ауырлық дәрежесінің торқабық көз түбінде көрінетін дискретті, реттелген құрылымдық өзгерістер жиынтығымен айқындалатынында жатыр. Бұл бөлім сол өзгерістердің биологиялық негізін және оларды дискреттейтін стандартты бес класты градациялау шкаласын (DR 0–4) — осы диссертациядағы әрбір жіктеуіш қайта жаңғыртуға міндетті реттік мақсат таксономиясын (орталық тезис бойынша, IT-1) — орнықтырады.

Осы көрінетін өзгерістердің астарындағы патофизиологиялық үдеріс, өзінің классикалық сипаттамасында, микроваскулярлық сипатта. Тұрақты гипергликемия торқабық капиллярлық арнасында метаболизмдік және тамырлық зақымданудың каскадын қозғайды. Kusuhaга және әріптестері [1] торқабық капиллярлық қабырғаларынан перициттердің түсуін (pericyte dropout) ішкі қан–торқабық бөгетінің бұзылуына жауапты консенсустық механизм ретінде анықтап (370-б.), васкулярлық эндотелий өсу факторының (VEGFA–VEGFR2) сигнализациясын асқынған аурудың сипаты болып табылатын торқабық ангиогенезі мен тамырлық сіңуінде шешуші деп сипаттады (369-б.). Дауыстама салдарлар — тамырлық өткізгіштіктің артуы, капиллярлық перфузияланбау және прогрессивті торқабық ишемиясы — ең ауыр түрінде патологиялық неоваскуляризациямен аяқталады. Бұл жүйелі іздеу әдіснамасы жоқ баяндамалық шолу болғандықтан, әрі авторлардың өздері гипергликемиялық жануарлар модельдері ерте аурудың тек шектеулі қырларын ғана қайта жаңғыртатынын ескере отырып, DR-дің астарындағы жасушалық және молекулалық механизмдер «толық анықталмаған» (364-б.) деп атап өткендіктен, бұл механизмдік тұжырымдар орнықтырылған факт ретінде емес, шолудың сала бойынша синтезі ретінде қабылданады.

Алайда DR-дің таза микроваскулярлық сипаттамасы толымсыз, әрі келтірілген әдебиет кеңірек тұжырымдамаға тоғысады. Wang пен Lo [3] DR-ді микроваскулярлық зақымдану, қабыну және торқабық нейродегенерациясының үйлесімі ретінде сипаттап, торқабық нейродегенерациясы дәстүрлі түрде аурудың айқындаушы белгілері деп саналатын микроваскулярлық өзгерістерден бұрын болуы мүмкін екенін хабарлады. Kusuhara және әріптестері [1] да тамырлық зақымданулардан бұрын болатын қайтымсыз нейрондық жоғалтудың клиникалық және эксперименттік дәлелін атап өтті (369-б.), ал Gettinger және әріптестері [4], эксперименттік DR модельдерін шола келе, DR тек гипергликемиямен ғана емес, көп факторлы екенін әрі торқабық нейродегенерациясы тамырлық патологиядан бұрын болуы мүмкін екенін алға тартты. Жинақтай келгенде, бұл тоғысатын байқаулар DR-ді тек тамыр жүйесінің емес, торқабық нейроваскулярлық бірлігінің бұзылысы ретінде түсінуді қолдайды. Бұл айырмашылық кескінге негізделген жіктеуіш үшін маңызды: көз түбі фотосуреті аурудың *микроваскулярлық* көріністерін бейнелейді, сондықтан стандартты клиникалық шкала бойынша грацияланған модель ерте патологиясы ішінара нейрондық әрі әлі толық көрінбейтін болуы мүмкін үдерістің тамырлық қолтаңбасын міндетті түрде үйренеді. Gettinger және әріптестері [4] ешбір жалғыз эксперименттік модель адамдағы DR фенотипінің толық спектрін қайта жаңғыртпайтынын (16-б.) атап өту арқылы аурудың гетерогендігін күшейтті, бұл пациенттер мен сатылар бойынша кескіндік көріністердің тиісінше гетерогенді ауқымын меңзейді.

Көз түбі кескінінің өзінде ауру зақымданулардың сипатты, шамамен реттелген прогрессиясы арқылы білінеді. Ең ерте әрі ең ұсақтары — микроаневризмалар — әлсіреген капиллярлардың фокалды шығыңқылары, олардан кейін сол тамырлардың жарылуымен интраторқабықтық (нүктелі және дақты) қанталаулар келеді. Сіңетін бөгеттен липид пен ақуыздың экссудациясы қатты экссудаттарды түзеді, ал фокалды торқабық ишемиясы жүйке-талшық қабатында мақта тәріздес дақтарды (жұмсақ экссудаттар) тудырады. Микротамыр жүйесі одан әрі нашарлаған сайын интраторқабықтық микроваскулярлық аномалиялар (IRMA) және веналық тізбектелу пайда болып, кең ауқымды перфузияланбауды білдіреді; пролиферативтік фазада неоваскуляризация — диск немесе басқа жерлердегі сынғыш жаңа тамырлар — қосылып, шыны тәрізді дене қанталауы мен тракциялық сетчатканың сөгілу қаупін тудырады. Осы ауырлық осіне жапсарласа орналасқан әрі одан тәуелсіз — диабеттік макулярлық ісіну (DME): орталық көру қабілетінен айырылудың жетекші себебі болып табылатын макуладағы сұйықтық жиналуы, ол Wang пен Lo [3] атап өткендей, бірінші кезектегі интравитреалды anti-VEGF терапиясының басты көрсеткіші (9-б.). Автоматтандырылған жіктеуіш үшін бұл зақымданулар кескіннің операциялық белгілері, әрі олардың аналитикалық айқындылығы біркелкі емес: ең ерте, скрининг үшін ең шешуші дәрежелерді айқындайтын микроаневризмалар мен ұсақ қанталаулар — ұсақ, төмен контрастты құрылымдар, ал асқынған аурудың неоваскулярлық және экссудативтік өзгерістері салыстырмалы түрде анық байқалады.

Клиникалық градациялау шкаласы осы зақымдану жүгін ауырлық кластарына бөледі. Ең ірі деңгейде DR пролиферативтік емес DR-ге (NPDR) және пролиферативтік DR-ге (PDR) дихотомияланады, соңғысы неоваскуляризацияның болуымен ерекшеленеді [5, 699-б.]. Kesharwani және әріптестері [5] — дәйексөзде құжатталған дәлсіздіктері бар, күмәнді редакциялық тәжірибелері белгіленген журналда жарияланған баяндамалық клиникалық шолу, әрі мұнда тек осы жалпы ауру-фонды айырмашылық үшін келтіріледі; оның нақты сандық тұжырымдарына сүйенілмейді. Алайда қазіргі скрининг нәзігірек реттік шкаланы пайдаланады. Могуа және әріптестері [2] жинақтағандай, DR ауырлығы стандартталған жүйелермен — Early Treatment Diabetic Retinopathy Study (ETDRS) шкаласымен және International Clinical Diabetic Retinopathy (ICDR) шкаласымен — градацияланады, олар ауруды бес реттік деңгейге ажыратады: DR 0 (көрінетін ретинопатия жоқ), DR 1 (жеңіл NPDR), DR 2 (орташа NPDR), DR 3 (ауыр NPDR) және DR 4 (пролиферативтік DR). DR 1-ден DR 3-ке прогрессия пролиферативтік емес ауқым шегінде микроаневризмалардың, қанталаулардың және микроваскулярлық аномалиялардың санының және таралымының артуымен айқындалады, ал DR 4-ке өту неоваскуляризациямен белгіленеді. Бұл DR 0–4 шкаласы — осы диссертацияда жіктеу мақсаты ретінде қабылданатын канондық бес класты таксономия (IT-1).

(1.1-сурет)



Сурет 1.1 – DR 0–4 дәрежелеріндегі көз түбінің репрезентативті кескіндері (клиникалық градациялау контексті)

Бұл таксономияның екі қасиеті автоматтандырылған градациялау жүйесінің жобасына тікелей өтеді. Біріншіден, шкала *реттік*: бес класс ауырлығы бойынша сараланады, әрі қате жіктеудің клиникалық құны болжанған мен шынайы дәреже арасындағы қашықтыққа сай артады — көрші дәрежелерді (мысалы, жеңіл және орташа NPDR) шатастыру аурудың жоғын пролиферативтік аурумен шатастырудан әлдеқайда аз салдарлы. Сондықтан градациялау моделі еркін бес жақты категориялық есепті емес, құрылымды қателік құндарымен реттелген есепті шешеді, бұл қасиет осы диссертацияда кейінірек реттік тұрғыдан сезімтал бағалауды негіздейді. Екіншіден, ерте араласу үшін ең маңызды дәреже шекаралары жоғарыда ұсақ әрі төмен контрастты деп анықталған дәл сол зақымдануларға сүйенеді; DR 0-ді DR 1-ден, немесе DR 1-ді DR 2-ден ажырату кескіннің бірнеше пикселін алып жатқан бірнеше микроаневризмаға тіреледі. FIG-1.1-дегі дәрежеге стратификацияланған репрезентативті көз түбі кескіндері осы қиындықты,

төменгі дәрежелер бойынша көрінетін зақымдану жүгінің тек біртіндеп өзгеретінін көрсете отырып, бейнелейді. Нәзік, сирек ерте белгілер мен клиникалық тұрғыдан тең емес, реттелген қателіктердің үйлесімі келесі тарауларда қайталанатын мәселені шеңберлейді: диагностикалық тұрғыдан шешуші құрылымдардың көрінуі кескін сапасы мен түсіру жағдайларына қатты тәуелді, бұл тәуелділік §1.2-де қарастырылады.

Ерте айқындау клиникалық тұрғыдан шешуші, өйткені ауру ерте дәрежелерінде емделуге келеді. Kesharwani және әріптестері [5] — әрі бұл көрсеткіш дереккөздің аталған сенімділік шектеулерін ескере отырып, қатаң түрде келтірілген клиникалық уәждеме ретінде қаралады — асқынған ретинопатиясы бар науқастар торқабық ауыр зақымданғанға дейін емделсе, көру қабілетінен айырылуды болдырмаудың жоғары ықтималдығын сақтайтынын хабарлады (701-б.), ал Wang пен Lo [3] anti-VEGF агенттерінің DME мен PDR үшін бірінші кезектегі терапия ретіндегі рөлін құжаттады (9-б.). Осы тұжырымдар сипаттайтын терапиялық терезе тек ауру әлі де төменгі, нәзігірек дәрежелерінде айқындалғанда ғана болады, бұл қолжетімді, сенімді скринингке деген сұранысты орнықтырады. Сол сұраныс және оны ресурсы шектеулі орталарда қанағаттандырудың құрылымдық кедергілері §1.1.2-нің тақырыбы; ал осы бөлім ауруды, оның көрінетін белгілерін және кез келген осындай скрининг жүйесі қайта жаңғыртуды үйренуге тиіс DR 0–4 градациялау таксономиясын бекітті.

§1.1.2 Ресурсы шектеулі денсаулық сақтау орталарындағы скрининг талаптары

§1.1.1-де орнықтырылған терапиялық терезе — диабеттік ретинопатияның төменгі, нәзік дәрежелерінде емделуге келетіні — тек ауру нақ сол терезе ішінде шынымен айқындалғанда ғана клиникалық мәнге ие. Ерте дәрежелер жиі симптомсыз болғандықтан, айқындау пациенттің өз бетімен қаралуына емес, бүкіл диабеттік популяцияны жүйелі әрі қайталанатын скринингтен өткізуге тәуелді. Бұл §1.1.1-дің клиникалық императивін логистикалық императивке айналдырады: қауіп төнген популяция үлкен әрі өсіп келеді, әр мүшесі мерзімді қайта тексеруді талап етеді, ал тексерудің өзі — маман міндеті. Қажетті скрининг көлемі мен оны жеткізуге қолжетімді әлуат арасындағы алшақтық — осы бөлім орнықтыратын құрылымдық проблема, әрі дәл осы проблема автоматтандырылған, орналастыруға жарамды шешім қабылдауды қолдау жіктеуішін скринингтік құрал ретінде уәждейді.

Қажетті скрининг іс жүзінде жеткізілмей жатқаны байқалатын сәйкестікте көрінеді. Моруа және әріптестері [2] DR патофизиологиясы мен емдеудің баяндамалық шолуында диабеті бар науқастардың тек 35–55%-ы ғана ұсынылған жыл сайынғы көз скринингіне сай келетінін хабарлады. Тек ағылшын тіліндегі іріктеу қиғаштығы мойындалған жүйелі емес шолу ретінде дереккөз бұл көрсеткішті өлшемейді, синтездейді, әрі ол мұнда осы диссертация орнықтырған шама ретінде емес, үшінші тараптың клиникалық контексті ретінде келтіріледі; дегенмен, қауіп төнген популяцияның шамамен

жартысындағы сәйкестік шегі қазіргі скрининг модельдері аясында емделуге болатын аурудың елеулі үлесінің айқындалмай қалатынын білдіреді. Бұл кемшілік басым түрде пациенттің қалауының емес, қолжетімділік пен әлуеттің кемшілігі, әрі ол маман инфрақұрылымы ең жұқа жерде ең өткір.

Әлует шектеуі кездейсоқ емес, құрылымдық сипатта. Кандидаттың бұрынғы жұмысында, Есмұхамедов және әріптестері (2025) — жобалау үлесі осы диссертацияның 6-тарауында дамытылатын жүйе-архитектуралық зерттеу — шамамен 1200 офтальмолог бүкіл ұлттық популяцияға қызмет көрсететін, тұрғындардың шамамен 40%-ы ауылдық жерлерде тұратын әрі ауыл тұрғындарының болжамды 70%-ы мамандандырылған көз күтіміне шектеулі қолжетімділігі бар Қазақстан контекстін сипаттады (77, 87-б.). Бұл көрсеткіштер сол бұрынғы жарияланымда хабарланған контекстік шеңбер ретінде келтіріледі. Олардың аналитикалық маңызы — қолмен градациялаудың маман уақытына сызықты түрде масштабталуында: тіркелген әрі географиялық тұрғыдан шоғырланған градациялаушылар ұсынысы үлкен, ішінара ауылдық популяцияға таралған скрининг сұранысын өзінен өзі қанағаттандыра алмайды. Осындай арифметика аясында маман қосу арқылы скрининг қамтуын арттыру жақын мерзімді нұсқа емес, әрі байланыстырушы сұрақ — клиницистті шешімнен шығармай-ақ, градациялау қадамының өзін ішінара автоматтандыруға бола ма деген сұраққа айналады.

Келтірілген әдебиет автоматтандыруды дәл осындай жұмыс жүгін азайту механизмі ретінде шеңберлейді. Моруа және әріптестері [2] AI негізіндегі жүйелер скрининг тиімділігін арттыру және офтальмологтың жұмыс жүгін азайту үшін орналасқанын атап өтіп, орналастырылған құралдар үшін хабарланған операциялық нүктелерді жеткізді — мысалы, IDxDR жүйесі шамамен 80% сезімталдықта және 90%-дан төмен спецификалықта, ал Remidio Medios жүйесі 98% сезімталдықта және 86% спецификалықта. Бұл мәндер сол шолумен зерттеу-жобасы туралы егжей-тегжейсіз немесе сенімділік интервалдарынсыз хабарланады әрі мұнда осы диссертацияның болашақ жүйесі салыстырылатын эталондар ретінде емес, тек келтірілген үшінші тарап контексті ретінде қайталанады. Сол кандидаттың бұрынғы жарияланымы (Есмұхамедов және әріптестері, 2025) автоматтандыруды жеткізу моделі ішінде одан әрі орналастырды: Ұлыбританияның ұлттық DR скринингтік бастамасы диабеттік науқастар арасында шамамен 80% қамтуға қол жеткізгенін әрі тасымалданатын, телемедицинаға бағдарланған түсіру құрылғылары — реті бойынша 5000 доллар тұратын смартфонға негізделген көз түбі камерасы — скринингті үстелдік офтальмологиялық жабдықсыз орталарға кеңейте алатынын жеткізді (87-б.). Дәл осындай жеткізу модельдері ресурсы шектеулі орталарда орналастыруға жарамды жіктеуішті операциялық тұрғыдан өзекті етеді, өйткені олар тудыратын кескіндер маман клиникаларынан тыс жерлерден шығады.

Бұл прецеденттердің нені орнықтыратынын, нені орнықтырмайтынын тіркеп қою маңызды. Рұқсат етілген автономды жүйенің бар болуы және 80% қамтуға жететін ұлттық бағдарламаның бар болуы автоматтандырылған әрі телемедицинаға негізделген DR скринингінің нақты, дәлелденген қабілет екенін

көрсетеді — бұл бөлім жоққа шығарудан гөрі мойындауға тиіс қарама-қарсы ұстаным. Бірақ осы нәтижелердің әрқайсысы — келтірілген үшінші тарап нәтижесі, өзінің популяциясы, құрылғысы және нормативтік жағдайлары аясында алынған; ешбірі осы диссертацияның нәтижесі емес, әрі олардың ресурсы шектеулі, құрылғысы гетерогенді, инфрақұрылымы төмен контексттерге тасымалдануы олардың басқа жердегі табысынан туындамайды. Шынында да, сол тасымалданушылық — кейінгі тараулар қарастыратын ашық проблема. Сол бұрынғы жарияланым қосымша Қазақстандағы орналастыру үшін нәтижелерді — төрт миллионнан астам ауыл тұрғынына қолжетімділік және кеш сатыдағы асқынулар мен шығынның азаюын — болжады, бірақ бұлар осы зерттеудің дәлелденген нәтижелері емес, контекстік шеңбер үшін келтірілген үшінші тарап болжамдары, әрі олар осы диссертацияда тұтасымен солай қаралады.

Осы орналастыру шеңберінен екі шекаралық шарт туындап, кейінгі тарауларды байланыстырады. Біріншіден, операциялық орналастыру контексті — *ресурсы шектеулі орта*, осы диссертация үшін мыналардың кемінде екеуімен сипатталатын орта ретінде анықталады: inference үшін GPU жеделдетудің болмауы; 16 ГБ-тан төмен қолжетімді жады; нақты уақытқа жуық клиникалық өткізу қабілеті шектеулері; және үздіксіз бұлтқа сүйенуге жеткіліксіз желілік байланыс. Жоғарыда сипатталған скрининг контексттері — мобильді бөлімшелер, тасымалданатын камералар, ауылдық клиникалар — осы анықтаманы дәлелдейді, әрі ол диссертация модельдері орналастырылатын есептеу қабығы. Екіншіден, мұндағы автоматтандыру алмастыруды емес, шешім қабылдауды қолдауды білдіреді: жүйе *physician-in-the-loop* парадигмасы ішінде жұмыс істейтін көмекші ретінде ойластырылған, онда клиницист интерпретациялайды, аудиттейді әрі диагноз үшін жауапкершілікті сақтайды. Келтірілген операциялық нүктелер де, болжанған қамту көрсеткіштері де дербес диагностикалық сенімділікті орнықтыру ретінде қабылданбайды.

Соңында, мұндай скрининг сүйенетін деректердің өздері географиялық және демографиялық тұрғыдан нақты. Жария қолжетімді скрининг-зерттеу деректер жиынтықтары белгілі бір популяциялар мен құрылғылардан жинақталады — мысалы, IDRiD дерекқоры DR скрининг зерттеуі үшін үнді популяциясынан құрастырылды [6] — бұл бір жағынан автоматтандырылған градациялаушыларды әзірлеуге материал береді, екінші жағынан өнімділіктің ол орнықтырылған деректерге байланғанын білдіреді. Скрининг деректерінің бұл деректер жиынтығына байланулы сипаты осы диссертацияда қайталанатын шектеу болып табылады әрі автоматтандырылған скринингтің техникалық алғышарттары көрінген соң тікелей қарастырылады. Бұл бөлім бекіткені — жүйе деңгейіндегі сұраныс: мамандардың құрылымдық тапшылығына қарсы популяция масштабындағы скрининг, оны ресурсы шектеулі орталарда орналастыруға жарамды, шешім қабылдауды қолдау жіктеушісі қанағаттандыруға тиіс. Мұндай жіктеуіш нақты әлемдегі, жиі маман емес скрининг іс жүзінде тудыратын кескіндерде жұмыс істей ала ма — бұл сол кескіндердің сапасына тәуелді, яғни §1.2-нің тақырыбына.

§1.2.1 Клиникалық тәжірибедегі кескін сапасының төмендеу көздері

§1.1.2-де орнықтырылған скрининг контексттері — мобильді бөлімшелер, тасымалданатын камералар және арнайы офтальмологиялық клиникалардан тыс жұмыс істейтін маман емес операторлар — дәл сол көз түбі кескіндерінің идеалды түрде түсірілуі ең аз ықтимал жағдайлары. Кескін сапасы мен автоматтандырылған өнімділік арасындағы қатынасты эмпирикалық тұрғыдан қарастырмас бұрын, түсіру жағындағы төмендеу көздерінің өздерін айқындап, реттеу қажет. Бұл бөлім сол таксономияны диссертацияның кескін сапасының операционалды анықтамасына негізделген құрылымды талдау ретінде ұсынады; ол ешбір өлшенген төмендеу шамасын бекітпейді, барлық сандық сапа–өнімділік қатынастарын §1.2.2-ге шегереді. Сол операционалды анықтама (OD-1) бойынша, кескін сапасы — дербес тұрған эстетикалық қасиет емес, көз түбі кескінінің DR сатылауына қатысты микроваскулярлық белгілерді автоматтандырылған анықтауды қолдаудағы өлшенетін қабілеті, бұл сәйкес жағдайлардағы downstream жіктеу өнімділігі арқылы бағаланады. Тиісінше, төмендеу — сол қабілетті бұзатын кез келген түсіру жағындағы құбылыс, әрі төменде дамытылғандай, осыны істейтін құбылыстар кездейсоқ та, диагностикалық тұрғыдан бейтарап та емес.

Төмендеудің бірінші әрі ең тікелей осі — оптикалық. Торқабық жазықтығына кемелсіз фокустаудан туындайтын дефокус және қысқа экспозиция кезіндегі еріксіз көз қозғалысынан немесе камераның тұрақсыздығынан туындайтын қозғалыс бұлыңғырлығы екеуі де кескінге төменгі жиілікті сүзгі сияқты әрекет етеді: олар торқабықтың нәзік құрылымын фоннан ажырататын дәл сол жоғары кеңістіктік жиілікті мазмұнды әлсіретеді. Ең ерте DR зақымданулары — §1.1.1-де бірнеше пиксельді ғана алып жатады деп орнықтырылған микроаневризмалар мен ұсақ интраторқабықтық қанталаулар — өздері ұсақ, жоғары жиілікті белгілер болғандықтан, тіпті жеңіл оптикалық бұлыңғырлық та оларды айналадағы капиллярлық арнадан ажыратылмайтын етіп жіберуі мүмкін. Сондықтан оптикалық төмендеу — бұл дәлдіктің біркелкі жоғалуы емес, скрининг үшін ең шешуші сигналды таңдамалы өшіру.

Екінші ось — фотометриялық. Көз түбі фотосуреті қисық, жартылай шағылысатын ішкі бетті кішкентай қарашық арқылы жарықтандырады, әрі нәтижесіндегі жарықтандыру сирек біркелкі болады: шеткі виньеттеу, орталық рефлекс және көлеңкелі градиенттер торқабық патологиясына қатысы жоқ үлкен, төменгі жиілікті қарқындылық вариацияларын өріс бойынша таңады. Бұларды экспозиция қателіктері — қараңғы егжей-тегжейді қысатын жеткіліксіз экспозиция және жарық аймақтарды қанықтыратын артық экспозиция — әрі жаһандық төмен контраст асқындырады. Диагностикалық салдар екі жақты. Біркелкі емес жарықтандыру көлеңкелі аймақтардағы шынайы зақымдануларды бүркемелей алады, әрі патологияны еліктей де алады, өйткені жарық көлеңке артефактісі жергілікті тұрғыда қатты экссудаттан, ал қараңғы градиент қанталаудан ажыратылмайды. Осылайша фотометриялық

төмендеу сезімталдыққа да, спецификалыққа да қауіп төндіреді әрі мұны аддитивті шу арқылы емес, құрылымды, кеңістіктік корреляцияланған бұрмалаулар арқылы жасайды.

Үшінші ось — геометриялық. Осьтен тыс түсіру, оптикалық ось пен қарашық арасындағы сәйкессіздік, дөңгелек көру өрісінің кесілуі және ұлғайтудағы вариация — барлығы астарлы анатомияны өзгертпей-ақ, торқабық құрылымдарының қайда көрінетінін және қаншалықты үлкен болатынын өзгертеді. Автоматтандырылған градациялаушы үшін бұл белгі үйренуі сүйенетін кеңістіктік дәйектілікті бұзады: оптикалық диск пен фовеа — зақымдану локализациясын бекітетін табиғи бағдарлар — дәйексіз позицияларда және бағдарларда тұруы мүмкін, ал кесілген өріс шеткі зақымдануларды кескіннен мүлдем шығарып тастауы мүмкін. Геометриялық төмендеу — оны еш қиындықсыз өтейтін адам-оқырманға ең аз көрінетін, бірақ оған қарсы айқын нормаланбаған модель үшін ең бұзушы ось.

Төртінші ось — пациентке және ортаға қатысты. Сапалы бейнелеу жеткілікті кеңіген қарашыққа және мөлдір оптикалық ортаға тәуелді; екеуі де скрининг бағыттаптын диабеттік популяцияда жиі бұзылады. Жеткіліксіз мидриаз тиімді апертураны тарылтып, шетті қараңғылатады, ал орта мөлдірсіздіктері — әсіресе катаракта, сонымен қатар шыны тәрізді дене мөлдірсіздігі мен қасаң қабық бұлыңғырлығы — бейнелеу жолы бойынша жарықты шашыратып, әлсіретеді. Қасаң қабық шағылысулары, линза жарық шашырауы және оптикадағы шаң — көлеңке сияқты патология деп қабылдануы немесе оны бүркемелеуі мүмкін жергілікті артефактілерді қосады. Бұл осьтің ерекшелейтін белгісі — оның себептері ішінара аспаптан емес, пациенттен туындайтыны, сондықтан оны тек жақсырақ камера инженериясымен жоюға болмайды әрі ол кез келген нақты скрининг популяциясында сақталады.

Бұл осьтер орналастыру контекстінен тәуелсіз емес. Әрқайсысы §1.1.2-де диссертацияның мақсатты скрининг контексті ретінде орнықтырылған ресурсы шектеулі, тасымалданатын және маман емес оператор басқаратын орталарда асқынады: қол және смартфонға негізделген камералардың оптикасы кішірек әрі тұрақсызырақ; маман емес операторлар фокусты, туралауды және жарықтандыруды оңтайландыруға қабілеті азырақ; әрі кеңіймеген, оппортунистік скрининг кездесулері ортаға және қарашыққа қатысты төмендеуді барынша арттырады. Сондықтан автоматтандырылған скрининг ең қажет орталар — кескін төмендеуі ең таралған әрі ең ауыр орталар, бұл байланыс техникалық проблеманы жұмсартпай, керісінше өткірлендіреді.

Орынды қарсылық — қазіргі камералар мен автоматты сапа-бақылау сүзгісі түсіру кезінде пайдаланылмайтын кескіндерді әлдеқашан тастап, проблеманы шектейді деген тұжырым. Сапа-бақылау сүзгісі шынымен бар әрі құнды, бірақ ол проблеманы жоймайды, қайта қояды. Сүзгі кескіндердің сигналын қалпына келтірмей, оларды тастайды, бұл дәл қайта түсіру қымбат немесе мүмкін емес ресурсы шектеулі контексттерде тиімді скрининг қамтуын төмендетеді; әрі сүзгіден өтетін шектен төмен төмендеу ерте градациялау сүйенетін ұсақ-зақымдану сигналын әлі де бұзады. Сондықтан осы бөлімнің аналитикалық қорытындысы — көз түбі кескінінің төмендеуі мақсатпен

корреляцияланған: барлық төрт ось бойынша ол ең ерте әрі ең емделуге келетін DR дәрежелерін айқындайтын ұсақ, төмен контрастты белгілерге басымдықпен шабуыл жасайды. Бұл сипаттаманы торқабық кескіндеу әдебиеті растайды, онда дәл сол төмендеу факторлары — біркелкі емес жарықтандыру, бұлыңғырлық және бейнелеу артефактілері — айқын модельденіп, арнайы көз түбін жақсарту желілерін қозғау үшін пайдаланылды [7]; сол зерттеу — төмендеу моделі DR-дәреже таралымы арқылы емес, тамыр сегментациясы мен оптикалық диск анықтауы арқылы бағаланатын жақсарту әдісі, сондықтан ол өлшенген төмендеу шамасын бермей, осы бөлімнің таксономиясын негіздейді. Дәл осы корреляция төмендеуді косметикалық кедергіден диагностикалық қауіпке көтереді әрі дәл осы геометрияны, жарықтандыруды және контрастты жіктеуге дейін айқын нормалайтын алдын ала өңдеу кезеңін — 2-ші және 3-ші тарауларда дамытылатын жобаны — уәждейді. Төмендеудің жоғалған жіктеу өнімділігіне *өлшенген* дәрежеде қаншалықты айналатыны келесі §1.2.2-де қарастырылады.

§1.2.2 Кескін сапасының диагностикалық модель өнімділігіне әсері

§1.2.1-дегі төмендеу таксономиясы көз түбі кескіндерінің диагностикалық сигналды қалай жоғалтатынын сипаттайды; бұл бөлім одан туындайтын әрі эмпирикалық әдебиетте жауап табатын сандық сұрақты қояды: сол жоғалту автоматтандырылған жіктеудің өлшенетін төмен өнімділігіне қаншалықты айналады? Осы диссертацияда қабылданған операциялдық анықтама (OD-1) бойынша сұрақ риторикалық емес, конститутивті — кескін сапасы кескіннің DR-ге қатысты белгілерді автоматтандырылған анықтауды қолдаудағы өлшенетін қабілеті ретінде *анықталады*, сондықтан градацияланған сапа мен downstream метрикалар арасындағы кез келген дәлелденген байланыс, OD-1 тұрғысынан, конструктивті өзін тікелей бақылау. Төменде қарастырылатын келтірілген дәлел кескін сапасы мен дерек шығу тегі өлшенген өнімділіктің бірінші реттік анықтаушылары екенін — кей жерлерде архитектура таңдауының әсерімен бәсекелесетін шамада — көрсетеді, әрі сонымен бірге, маңыздысы, қатынас аңғал оқудан күтілуі мүмкін қарапайым монотонды «нашар кескіндерді тастап, дәлдік ұтып ал» түрінде еместігін де көрсетеді.

Ең тікелей дәлел архитектураны тіркеп, тек сапаны өзгертеді. Fu және әріптестері [8] 28 792 EyePACS кескінін үш деңгейлі сапа шкаласына (Good, Usable, Reject) қайта аннотациялап, EyeQ деректер жиынтығын құрды, әрі downstream DR-анықтау дәлдігі сапа төмендеген сайын монотонды түрде құлдырағанын хабарлады — ResNet-50 жіктеуіші үшін Good кескіндердегі 0,9154-тен Usable кескіндердегі 0,9150-ге және Reject кескіндердегі 0,9068-ге дейін — бұл авторларды автоматтандырылған диагностикалық жүйелердің өнімділігі кескін сапасына қатты тәуелді деп тұжырымдауға жетеледі. Бұл — қатынастың қолжетімді ең таза тұжырымы, бірақ оның ауқымы шектеулі: EyeQ жалғыз көзден (EyePACS) алынған, бағалау сыртқы валидациясыз ішкі оқыту/тест бөлуін пайдаланады, әрі сенімділік интервалдары хабарланбайды,

сондықтан шамалар жалпыланатын емес, индикативті. Zago және әріптестері [9] байланысты деректер жиынтықтары бойынша растайды, торқабық кескін сапасы жіктеуіші үшін (DRIMDB, ELSA-Brasil) деректер жиынтықтары арасында күшті жалпылауды хабарлайды, бірақ ол DR-дәреже дәлдігін тікелей емес, жалпы градацияланушылықты бағалайды. Өндірістік DR жүйелерінің сапаны өнімділік үшін шешуші деп қарайтынын Dai және әріптестері [10] көрсетеді, олардың DeepDR жүйесі 466 247 кескін бойынша зақымдану анықтау мен градациялаудың алдына айқын кескін-сапасын бағалау кезеңін ендірді, дегенмен басым түрде жабық қытай деректерінде.

Дәлелдің екінші желісі кескін сапасын деректер жиынтықтары *арасындағы* өнімділік айырмашылықтарының үнемді түсіндірмесі ретінде қарайды. Rakhlin [11] бинарлық referable-DR анықтау үшін модификацияланған VGG стиліндегі желіні бағалап, Messidor-2-де 0,967 AUC-ке қарсы ұсталынған Kaggle/EyePACS бөлігінде 0,923 AUC хабарлады әрі Messidor-2 артықшылығын жоғары жалпылауға емес, кескін градацияланушылығына телді — Messidor-2 кескіндерінің шамамен 100%-ы градацияланатын, ал Kaggle үшін шамамен 75% — сонымен бірге басқа жабдықтан немесе ұсынылмаған популяциялардан алынған кескіндер «кейде дәлдіктің төмендеуіне әкелуі мүмкін» деп ескертті. Бұл дереккөз диссертацияның парадигма картасында P1 позициясын алады: ол нормализация pipeline қолданады, бірақ кескін сапасын формализацияланған модель компоненті ретінде емес, деректердің экзогенді қасиеті ретінде қарайды, әрі оған preprocessing маңыздылығы туралы ешқандай теориялық тұжырым телінбейді. Оның шектеулері елеулі — анықталмаған pipeline бар рецензияланбаған препринт, осы диссертацияның бес класты DR 0–4 шкаласын емес, бинарлық referable-DR міндетін (ICDR 1–4) бағалайды — сондықтан градацияланушылық телінуі оқшауланған эксперименттік нәтиже емес, автордың интерпретациясы ретінде оқылады.

Деректер жағдайлары архитектурамен бәсекелесе алатынының ең күшті дәлелі архитектураны деректер көздері бойынша *бірдей* ұстаудан туындайды. Voets және әріптестері [12] Gulshan және әріптестерінің [13] pipeline-ін InceptionV3 желісімен жария деректерде қайта жаңғыртып, Kaggle/EyePACS тест жиынында 0,951 AUC, бірақ Messidor-2-де тек 0,853 AUC алды — сол желі, сол оқыту процедурасы, модель жобасы емес, дерек шығу тегі мен таңбалауға телінетін 0,098 AUC алшақтығы. Жалғыз архитектураның деректер көздері бойынша айтарлықтай түрлі өнімділік тудыруы өздігінен деректер мен сапа жағдайлары архитектуралық вариациямен салыстырмалы ықпал жасайтынының дәлелі. Қайта жаңғырту мұнда Gulshan-ға қарсы салыстыру ретінде емес, өзінің табысы үшін келтіріледі, ол осы диссертацияда тек парадигмалық сілтеме ретінде қызмет етеді, сандық эталон ретінде емес; әрі оның авторлары төрт шатасқан фактор (таралу, бір рет градациялау мен көп рет градациялау, пациент бойынша мен кескін бойынша таңбалар, және гиперпараметрлер) ажыратылмайтынын анық айтады, сондықтан алшақтық тек кескін сапасына емес, деректер жағдайларына жиынтық түрде телінеді.

Дәл сол зерттеу артық күшті оқуды болдырмайтын екі нюанстың біріншісін береді. Voets және әріптестері [12] Kaggle кескіндерінің

градиацияланбайды деп бағаланған шамамен 19,9%-ын алып тастау алгоритм өнімділігін айтарлықтай өзгертпегенін анықтады. Егер кескін сапасы қарапайым монотонды иінтірек болса, ең нашар кескіндерді алып тастау көмектесуге тиіс еді; оның көмектеспегені жиынтық сапа-сүзгісі — шектен төмен кескіндерді тастау — жақсырақ өнімділікке сенімді жол еместігін, әрі сапа-өнімділік қатынасы дәрежі қосу немесе шығару деңгейінде емес, нәзік сигналды сақтау деңгейінде жұмыс істейтінін көрсетеді. Далалық зерттеу сүзгінің құнын орналастыру жағынан күшейтеді: Beede және әріптестері [14] он бір тай клиникасында далада түсірілген кескіндердің автоматты сапа бойынша қабылданбауы қамтуды азайтып, жұмыс үдерісін бұзғанын анықтады — бұл дәлдік өлшемі емес, әлеуметтік-техникалық байқау. Екінші нюанс міндетке тәуелділікке қатысты. DeepDRiD эталонында Liu және әріптестері [15] автоматты кескін-сапасын бағалаудың өзі тек шамамен 0,65–0,70 квадраттық-салмақталған каппа мен дәлдікке жеткенін хабарлады, оны авторлар клиникалық тұрғыдан орындалатын автоматты скрининг үшін жеткіліксіз деп сипаттады; сонымен бірге қалыпты көз түбі DR-градиациялау ішкі сынағын жеңіп алған топ мұны минималды preprocessing-пен, оның орнына multi-gate mixture-of-experts және online hard-example mining сияқты оқыту-стратегиясы жаңалықтарына сүйене отырып істеді. Бұл тұжырымдар — бір орталықты Шанхай деректерінен, сенімділік интервалдарынсыз, әрі тек дәлдікке негізделген кескін-сапасы метрикасымен алынған — preprocessing қажет, бірақ жеткіліксіз екенін, әрі оның шекті ұтысы міндетке және pipeline-нің қалған бөлігі әлдеқашан не істейтініне тәуелді екенін орнықтырады.

Кандидаттың өз бұрынғы жұмысы тағы бір дерек нүктесін қосады, ол мұнда бұрын жарияланған нәтижелер ретінде келтіріледі. Сапақова, Есмұхамедов және Сапақов (2025) жұмысында кескінді жақсарту preprocessing-і (өлшемін өзгерту және augmentation) APTOS 2019 мен жабық клиникалық кескіндерге қолданылған шағын тапсырыс конволюциялық желіде валидация дәлдігін 71%-дан 86%-ға көтергені анықталды, әрі жақсартылған конфигурация 0,9638 ROC-AUC-ке жетті. Бұл нәтиже жоғарыдағы сыртқы дәлелмен үйлеседі, бірақ оның салмағын дәл шектеу қажет: ол жалғыз шағын архитектурадан алынған әрі айқын салыстырусыз тиімді CNN-дердің кеңірек класына жалпыланбайды; ол осы диссертация дамытатын біріктірілген preprocessing-CNN формуляциясына қарай жылжитын, бірақ одан бұрын болған кандидаттың бұрынғы зерттеулерінің бірі; әрі ол бір рет хабарланады, өйткені серіктес карта дәл сол мақаланы сипаттайды, екеуі тәуелсіз растау ретінде қаралмауы тиіс. Қазіргі диссертация осы бұрынғы жұмыс желісін 3-тарауда көрсетілген сегіз кезеңді pipeline-ге формализациялайды әрі кеңейтеді.

Бірге оқығанда, әрі әр дереккөздің шектеулерін және түрлі міндеттерін, деректер жиынтықтарын мен метрикаларын ескере отырып, дәлел ұранға емес, дәл ұстанымға тоғысады. Кескін сапасы мен дерек шығу тегі — автоматтандырылған DR-жіктеу өнімділігінің өлшенген, бірінші реттік анықтаушылары, кей кезде өз әсерінде архитектурамен бәсекелеседі; алайда өнімділік төмен сапалы кескіндерді тастау арқылы сенімді түрде қалпына келмейді, әрі preprocessing-тің пайдасы міндетке және pipeline-ге тәуелді. Дәл

осы пайымдау диссертацияның жобалау таңдауын — кескіндерді *сыртқа сүзгілеудің* немесе кез келген жақсарту ұтысты кепілдейді деп жорудың орнына, геометрияны, жарықтандыруды және контрастты модельдің интегралды бөлігі ретінде нормалай отырып, кескіндерді *ішке жағдайлаудың* — уәждейді. Бұның ешқайсысы preprocessing әр деректер жиынтығында өнімділікті жақсартады деген әмбебап тұжырымды да, кез келген болашақ бақыланған әсерді оқшауланған preprocessing-ке телуді де ақтамайды; бұл шектеулер эксперименттік тарауларға алға тасымалданады. Мұнда дәлелденген сапа мен таралу вариациясының бір көзі мүлдем кездейсоқ емес, жүйелі әрі құрылымды — бейнелеу құрылғысы — әрі ол келесі §1.2.3-те қарастырылады.

§1.2.3 Көз түбі бейнелеуіндегі құрылғыға тән вариабельділік

§1.2.2-де қарастырылған кескін-сапасы вариациясы сонда жалғыз таралуығысуы проблемасы ретінде қаралды, бірақ оның сипаты мүлдем түрлі екі компоненті бар. §1.2.1-де тізімделген кескін ішілік төмендеудің көп бөлігі — дефокус, қозғалыс, өтпелі шағылысулар, пациентке тәуелді орта мөлдірсіздігі — ішінара стохастикалық, тіпті бір аспапта да түсірілімнен түсірілімге дейін өзгеріп отырады. Екінші компонент мүлдем стохастикалық емес: ол бейнелеу жабдығының өзімен айқындалады әрі сондықтан жүйелі әрі қайта жаңғыртылатын. Бұл бөлім сол компонентті оқшаулайды, өйткені жүйелі ығысу кездейсоқ ығысудан өзгеше әрекет етеді. Модель, негізінен, жеткілікті оқыту кескіндері бойынша көрінетін кездейсоқ төмендеуді орташалай алады, бірақ оқыту деректерін тудырған құрылғы мен орналастыру деректерін тудыратын құрылғы арасындағы жүйелі айырмашылық — кіріс таралуының келісімді, қайталанатын түрленуі, яғни машиналық оқыту әдебиеті domain shift ретінде зерттейтін дәл сол жағдай.

Көз түбі камералары кескін қалыптастырудың бірнеше қайта жаңғыртылатын осі бойынша бір-бірінен ерекшеленеді. Олар түс беруде ерекшеленеді, өйткені жарықтандыру спектрлері, сенсордың түс сүзгілері және борттық түс өңдеуі өндірушілер арасында стандартталмаған; жарықтандыру геометриясында, ол берілген оптикалық жобаға тән виньеттеу мен орталық-рефлекс үлгісін орнатады; көру-өрісі бұрышында, ол артқы полюсті қанша торқабық қоршайтынын айқындайды; және сенсор ажыратымдылығы мен оптикасында, олар қалпына келтірілетін ең нәзік егжей-тегжейді орнатады. Бұлардың ешқайсысы өтпелі түсіру қателігі емес; әрқайсысы — камера моделінің тұрақты қасиеті, сондықтан сол бір торқабықты бейнелейтін екі камера дәйекті, болжамды түрде ерекшеленетін кескіндер береді. Автоматтандырылған градациялаушы үшін бұл модель сау немесе ауру торқабықпен байланыстыруды үйренетін көрініс статистикасының ішінара оқыту кескіндерін тудырған құрылғымен шатаسقанын білдіреді.

Диссертацияның деректер жиынтығы архитектурасы осы құрылғы гетерогендігін жасыру үшін емес, оны қамту үшін әдейі құрастырылған. Бастапқы оқыту корпусы EyePACS басым түрде Canon көз түбі камераларымен (деректер жиынтығы құжаттамасы бойынша Canon CR-1) түсірілді; сыртқы

бағалау деректер жиынтықтары басқа өндірушілерді енгізеді — RFMiD Torcon (TRC-NW300) және Kowa камераларымен, DDR Canon және Torcon-мен, ал ODIR-5K Canon және Zeiss-пен. Бұл камера телінулері нәтижелер ретінде емес, жария деректер жиынтықтарының құжатталған түсіру қасиеттері ретінде келтіріледі, әрі сыртқы жиындардың екеуі, RFMiD пен ODIR-5K, тек диабеттік ретинопатия ішкі жиыны ғана пайдаланылатын көп ауру таксономияларын алып жүреді, сондықтан кез келген құрылғыаралық салыстырудан бұрын олардың таңбалары бес класты DR шкаласына салыстырылуы әрі демографиялық пен жабдықтық айырмашылықтары мойындалуы тиіс. Осындай құрылғы тұрғысынан алуан түрлі корпусты жинаудың мәні — құрылғыаралық жалпылауды жорудың орнына тікелей бақылауға болатыны.

Бұл бақылау орнықтырылған теориялық шеңберге бекітіледі. Модель орналастыру таралуы оның оқыту таралуынан өзгешеленгенде шегетін өнімділік жоғалтуы — domain generalization тақырыбы. Zhou және әріптестері [16] сала шолуында статистикалық оқыту алгоритмдерінің көпшілігі бастапқы және мақсатты деректер тәуелсіз әрі бірдей үлестірілген деген артық жеңілдетілген болжамға сүйенетінін, әрі тек бастапқы деректермен оқытылған оқыту агенті таралудан тыс мақсатты доменде әдетте айтарлықтай өнімділік құлдырауын шегетінін атап өтті. Түпнұсқа эксперименттері жоқ жалпы (торқабыққа қатысы жоқ) шолу ретінде бұл дереккөз торқабық дәлелін емес, концептуалды негіздеме береді, бірақ негіздеме тікелей қолданбалы: көз түбі камерасы доменді айқындайды, әрі бір камераның таралуында оқытылған модель басқа камераға қатысты дәл шолу сипаттайтын таралудан тыс оқыту агенті болып табылады. Сол әдебиет осындай ығысуды жұмсартуға ұсынылған стратегияларды да тізімдейді; Wang пен Deng [17], терең domain adaptation шолуында, оларды discrepancy негізіндегі, adversarial негізіндегі және reconstruction негізіндегі әдіс отбасыларына реттеді — бұл да жалпы таксономия, мұнда құрылғы ығысуын жаңа немесе шешілмейтін емес, жақсы сипатталған проблеманың данасы ретінде орналастыру үшін келтіріледі.

(1.2-сурет)

Cross-Dataset Comparison — 8 Active Datasets
All datasets used in dissertation experiments (H-1 through H-7)

Dataset	Size	Camera	Resolution	FOV	Population	Taxonomy	Tier
EyePACS	~35,126	Canon CR-1	3888×2592-5184×3456	45°	US (California)	5-class ICDR	Training
APTOS 2019	3,662	Various (mixed)	Various	Var.	Indian (rural)	5-class ICDR	Transfer
IDRiD	516	Kowa VX-10a	4288×2848	50°	Indian (Nanded)	5-class + masks	Clinical
Messidor-2	1,748	Topcon TRC NW6	1440×960-2240×1488	45°	French	Referable / Non-ref.	Degradation
DDR	13,673	Canon, Topcon	Various	Var.	Chinese	6-class (excl. gr. 5)	Domain
ODIR-5K	5,000 pts	Canon, Zeiss	Various	Var.	Chinese (Beijing)	Keyword → DR grade	Domain
RFMiD	3,200	Topcon, Kowa	Various	Var.	Indian	Binary DR (0/1)	Domain
Clinical (KZ)	60	Mixed (regional)	Various	45°	Kazakh (Almaty)	5-class ICDR	Local val.

Camera coverage: Canon Topcon Kowa Zeiss — 4 manufacturers across 8 datasets
Total labeled images: ~63,589 · Populations: US, Indian, French, Chinese, Kazakh.

Сурет 1.2 – Деректер жиынтықтары аралық / көп камералы ландшафт салыстыруы

Құрылғы вариабельділігін құрылымды domain-shift проблемасы ретінде шеңберлеу екі түрлі жауапты меңзейді, екеуі де осы диссертацияда кейінірек дамытылады, әрі әрқайсысы нені бекіте алатынын, нені бекіте алмайтынын нақты айту маңызды. Бірінші жауап — preprocessing стандарттау механизмі ретінде: геометрияны, жарықтандыруды және контрастты нормалау бір камераның кескіндерін екіншісінен ажырататын көрініс айырмашылықтарын тарылтады, бұл 2-ші және 3-ші тарауларда көрсетілген pipeline негіздемесінің бір бөлігі. Орынды қарсылық — мұндай нормалау, агрессивті қолданылса, құрылғы қолтаңбаларын әлдеқашан жойып, проблеманы оқыту уақытында мәнсіз етуі мүмкін деген тұжырым. Қарсылық тек ішінара дұрыс: стандарттау түс пен жарықтандыру айырмашылықтарын тарылта алады, бірақ ол ажыратымдылықта, оптикада және көру өрісінде жасайтын ығысуды дәлелді түрде өшіре алмайды, әрі қалдық ығысу жіктеуді әлі де нашарлата ма деген сұрақ — бекітумен шешілетін емес, эмпирикалық сұрақ. Сондықтан екінші жауап — айқын, бақыланатын құрылғы-домен-ығысуын бағалау (6-эксперимент, §4.7), онда EyePACS-те оқытылған модель DDR, ODIR-5K және RFMiD-те ұсынылған камера топтары бойынша тексеріледі. Бұл бөлім сол экспериментті уәждейді; ол оның нәтижесін алдын ала бағаламайды, әрі мұнда ешқандай құрылғыаралық өнімділік шамасы бекітілмейді.

Мұндай құрылғы-ығысуын бағалау түптеп келгенде нені орнықтыра алатынының айналасына шекара сызу қажет. Модельдің камера топтары бойынша өнімділікті сақтайтынын немесе жоғалтатынын көрсету — құрылғыаралық мінез-құлықты эмпирикалық бақылау; ол құрылғыдан тәуелсіз орналастыру дайындығының куәландыруы емес, әрі кез келген нақты аспаппен қолдану үшін нормативтік сәйкестікті құрамайды. Диссертацияның құрылғы-ығысуы нәтижелері, §4.7-де келгенде, тексерілген деректер жиынтықтарында ұсынылған нақты камера модельдерімен шектелген әрі ешқандай куәландыру тұжырымын алып жүрмейді — бұл шекара осында қойылады, сонда осы бөлімнің уәждемесі кейіннен күштірек кепілдік деп қате қабылданбасын.

Құрылғыға тән вариабельділік таралу-ығысу проблемасының жүйелі, теорияға негізделген компоненті ретінде айқындалған соң, скрининг міндетінің клиникалық және техникалық сипаттамасы аяқталады: ауру және оның градациялау таксономиясы (§1.1.1), скрининг жүгі мен орналастыру контексті (§1.1.2), кескін-сапасы жоғалтуының көздері мен өлшенген әсері (§1.2.1–§1.2.2), әрі енді кез келген сайтаралық жүйе төтеп беруге тиіс құрылымды құрылғы гетерогендігі. Сәйкесінше тарау *проблемадан* оны қанағаттандыруға ұсынылған *әдістерге* бұрылады. §1.3 бұл бұрылысты автоматтандырылған DR жіктеудің оқыту тетігін құрайтын конволюциялық нейрондық желі архитектураларынан бастайды.

§1.3.1 Медициналық бейнелеуге арналған CNN архитектуралары

Скрининг проблемасы сипатталған соң — ауру және оның градациялау таксономиясы, популяция масштабындағы анықтаудың жүгі, әрі анықтау жұмыс істеуге тиіс кескін-сапасы мен құрылғы-ығысуы жағдайлары — тарау оны қанағаттандыруға ұсынылған оқыту тетігіне бұрылады. Автоматтандырылған диабеттік ретинопатияны жіктеу, жүйелердің қазіргі буынында, басым түрде терең оқыту міндеті, әрі негізгі жұмыс моделі класы — конволюциялық нейрондық желі, Litjens және әріптестері [18] шолғандай, медициналық-кескін талдауы бойынша кеңірек басым тәсіл. CNN convolution мен pooling операцияларын құрастыра отырып, кеңістіктік белгілер иерархиясын үйренеді, ерте қабаттардағы жергілікті жиек- және текстура-детекторларынан тереңірек қабаттардағы барған сайын абстрактілі, міндетке тән репрезентацияларға қарай құрады; FIG-2.2 осы белгі иерархиясын схемалайды. Осы диссертация үшін өзекті сұрақ — CNN-дердің DR-ді градациялай алатыны емес (олар мұны айқын істей алады), есеп бойынша көрсетілген сандары жоғары, бірақ төменде көрсетілгендей тікелей салыстырылмайтын әдебиет аясында қай архитектураны және қандай негізде қабылдау керектігі.

Бүгінде медициналық бейнелеуде қолданылатын архитектуралар айқын ізделетін ImageNet дәуіріндегі шежіреден тарайды, әрі диссертацияның өз backbone-дары соның ішінде тұр. Krizhevsky және әріптестері [19] AlexNet-пен заманауи үлгіні орнықтырды, бұл — ReLU активацияларының, dropout регуляризациясының және PCA негізіндегі түс augmentation-нің үйлесімі ImageNet top-5 қателігін 15,3%-ға дейін төмендеткен сегіз қабатты желі. Тереңдік пен көп масштабты жоба VGG-нің қатталған 3×3 сүзгілерімен [20] және Inception отбасымен [21, 22] дамытылды, оның Inception-і бірнеше маңызды DR және дерматология жүйелерінің backbone-ы болды. Не және әріптестері [23] тереңірек желілерді зардап шектірген төмендеуді residual байланыстарды енгізу арқылы шешіп, ResNet-50, -101 және -152 сияқты желілерді бұрын орындалмайтын тереңдікте оқытуға мүмкіндік берді әрі ансамбльде 3,57% top-5 қателікке жетті; ResNet-50 — осы диссертацияда қабылданған екі backbone-ның бірі. Huang және әріптестері [24] байланыс идеясын DenseNet-тің тығыз белгіні қайта пайдалануымен кеңейтті, ал Tan мен

Le [25] EfficientNet-ті енгізді, оның тереңдік, ені және ажыратымдылықтың құрама масштабтауы B7-де 84,4% ImageNet top-1 дәлдікке жететін отбасын (B0–B7) тудырды; EfficientNet-B3 — диссертацияның екінші backbone-ы. Кейінгі EfficientNetV2 [26] оқыту тиімділігін одан әрі жақсартты әрі ImageNet-21k-да алдын ала оқытылған ViT-L/16 моделінен асып түседі деп хабарланды. Бұлар — диссертация мұралайтын архитектуралық жаңалықтар үшін келтірілген ImageNet-жіктеу сілтемелері, ешбір DR-ге тән нәтиже үшін емес.

Диабеттік ретинопатияға қолданылғанда, бұл архитектуралық отбасы күшті, бірақ гетерогенді өнімділікке жетеді, әрі гетерогендік — аналитикалық тұрғыдан маңызды факт. Pratt және әріптестері [27], Kaggle/EyePACS деректерінде бес класты DR градациялауға CNN қолданғандардың алғашқыларының бірі, 75% дәлдік және 95% спецификалық, бірақ тек 30% сезімталдық хабарлады — класс теңгерімсіздігі аясында жоғары тақырыптық дәлдіктің ауруды нашар анықтаумен қатар бола алатынының ерте әрі тағылымды иллюстрациясы. Rakhlin [11], кескін-сапасы тұжырымдары үшін жоғарыда талқыланды, VGG стиліндегі желі үшін Messidor-2-де 0,967 AUC хабарлады, бірақ бес класты шкалада емес, бинарлық referable-DR міндетінде, әрі рецензияланбаған препринт ретінде. Xu және әріптестері [28] APTOS 2019-да EfficientNet–Swin-Transformer гибриді үшін 0,97 дәлдік пен AUC хабарлады, тағы да бес класты, бірақ басқа деректер жиынтығында. Liu және әріптестері [15] EfficientNet-ті алдыңғы қатарлы DeepDRiD топтары арасында басым backbone деп тауып, жетекші 0,9303 квадраттық-салмақталған каппа көрсетті. Gargeya мен Leng [29] Messidor-2-де сыртқы валидацияланған 0,94 AUC хабарлады, ал Quеллес және әріптестері [30] referable DR-ді анықтап, әлсіз бақыланатын зақымдану жылу карталарын шығарды — әрқайсысы өз деректер жиынтықтары мен хаттамаларында. Бұл көрсеткіштер түрлі деректер жиынтықтарын, класс таксономияларын және валидация хаттамаларын қамтиды, әрі мұнда қабылданған метрика-дәйектілігі тәртібі бойынша оларды рейтинг ретінде тізуге болмайды; олар бірге орнықтыратыны — архитектура класы қабілетті екені, ешбір жалғыз конфигурация ең жақсы екені емес.

Бұл гетерогендік валидация қатандығына да таралады, әрі бірнеше кеңінен келтірілетін нәтиже айқын ескертулерді талап етеді. Arora және әріптестері [31] EfficientNetB0-ді Kaggle DR жиынына қолданып, орташа 0,8653 дәлдік хабарлады, бірақ максималды оқыту дәлдігі 97,11% — артық үйренуді көрсететін шамамен он бір пунктті оқыту–тест алшақтығы — әрі ешқандай AUC немесе сыртқы валидация хабарламады; оның нәтижесі тиімді CNN-дердің кеңірек класына жалпыланбайды. Sharma және әріптестері [32] EyePACS-те 94% дәлдік хабарлайтын ViT-CapsNet гибридин ұсынды, бірақ оның класс бойынша 0,44–0,56 AUC мәндері сол дәлдікпен ішкі үйлеспейді, сондықтан дәлдік көрсеткіші мұнда тек сол сәйкессіздік атап өтілгенде ғана келтіріледі, ал AUC көрсеткіштеріне сүйенілмейді. Бұлар шеткі кемшіліктер емес; олар әсерлі жалғыз сандық нәтижелер жиі бір деректер жиынтықты, ішкі валидацияланған немесе толық хабарланбаған бағалауларға сүйенетін әдебиетке тән.

Сол архитектуралар нысаны бойынша көршілес торқабық міндеттері мен модальдылықтарына жалпыланады, бұл бір жағынан олардың икемділігін көрсетеді, екінші жағынан мұндай нәтижелердің DR-көз түбі градациялауы туралы не айтатынының шекарасын белгілейді. Wan және әріптестері [33] CNN-ді IDRiD-те пиксел деңгейіндегі зақымдану сегментациясына қолданды, бұл кескін деңгейіндегі градациялаудан өзге міндет, FGADR эталоны [34] да солай, ол пиксел деңгейіндегі зақымдану масктарын дәрежелермен жұптайды. Khosravi және әріптестері [35] күшті сыртқы-валидация AUC-терін (FastViT 0,9811, ResNet18 0,9626) хабарлады, бірақ DR градациялауы емес, торқабық-қанталауын жіктеу үшін, әрі сенімділік интервалдарынсыз қатты теңгерімсіз жиында. Ryu және әріптестері [36] ResNet101 AUC-терін ішкі 0,960–0,976 және сыртқы 0,938–0,962 хабарлады, бірақ көз түбі фотосуретінде емес, оптикалық когеренттік томография ангиографиясында — осы диссертацияның модальдылық ауқымынан тыс. Торқабықтан тыс, дәл сол transfer-learning үлгісі дерматолог деңгейіндегі тері-обырын жіктеуге [37] және жасқа байланысты макулярлық дегенерацияны градациялауға [38] жетті — маңызды медициналық-бейнелеу CNN-дері, бірақ DR-көз түбі градациялауынан тыс міндеттерде. Әрқайсысы архитектураның байланысты проблемаға тасымалданғанын көрсетеді; ешбірі көз түбі-DR нәтижесі емес, әрі олар солай келтіріледі.

Екінші архитектуралық ағым, vision transformer, енді CNN-мен қатар жүреді әрі елеменнің орнына қарастырылуы тиіс. Dosovitskiy және әріптестері [39] кескін патчтарына қолданылған таза transformer жеткілікті алдын ала оқытумен 88,55% ImageNet top-1 дәлдікке жете алатынын көрсетіп, теңгерімді ауқымды оқыту конволюциялық индуктивті қиғаштықтан асып түсе алатыны ретінде шеңберледі. Бірнеше DR және офтальмологиялық зерттеу transformer-лердің CNN-дермен теңелуін немесе асып түсуін хабарлайды: Goh және әріптестері [40] Swin transformer-дің [41] өз эксперименттерінде Kaggle, SEED және Messidor-1-де CNN базалықтарынан асып түсетінін тапты, ал González-Díaz және әріптестері [42] vision transformer-лерді төрт класты жасқа байланысты макулярлық дегенерация міндетінде бағалады — DR-ден өзге ауру, тек transformer-архитектура сілтемесі ретінде келтіріледі. Geetha мен Nema [43] ViT негізіндегі гибрид үшін 98,4% дәлдік хабарлады, бірақ пайдаланылған деректер жиынтықтарын да, ешқандай сыртқы валидацияны немесе статистикалық тексеруді де ашпады, сондықтан ол тек transformer-дәуірі архитектура сілтемесі ретінде ғана қабылданады, жалпылау дәлелі ретінде емес.

Бұл transformer нәтижелері өздерінің тиісті деректер жиынтықтарындағы шынайы табыстар, әрі олар CNN-орталықты жобаға ең күшті қарама-қарсы ұстанымды құрайды. Диссертация оны жоққа шығарудың орнына тікелей қарастырады. Хабарланған transformer артықшылықтары валидация қатандығында кеңінен ауытқиды; transformer-лерге қолайлы индуктивті-қиғаштық теңгерімі осы диссертация жормайтын дәл сол өте ауқымды алдын ала оқыту корпустары аясында ең айқын; әрі EfficientNetV2 жақсы масштабталған CNN-дердің transformer модельдерімен бәсекеге қабілетті болып қалатынын көрсетеді. Сондықтан диссертацияның CNN backbone-дарына

берілгендігі — әдейі жобалау таңдауы, ол CNN-нативті өзін-өзі бақылайтын алдын ала оқытуды, FOV маскасын қамтитын төрт арналы кірісті және екі архитектура отбасы бойынша қайталауды мүмкін етеді — әрі CNN-дер transformer-лерден артық деген тұжырым емес, осы диссертация мұндай тұжырым жасамайды, оның эксперименттері оны қолдау үшін жобаланбаған.

Бұл пайымдау архитектуралық берілгендікті бекітеді. Шешілмеген архитектура пікірталасын төрелік етудің орнына, диссертация архитектураны әдейі тұрақты ұстайды — екі орнықтырылған, жақсы сипатталған CNN backbone-ын, ResNet-50 мен EfficientNet-B3-ті қабылдай отырып, олар құжатталған мінез-құлқы үшін және екі жобалау отбасын қамтудың қайталау құндылығы үшін таңдалды, әрі екеуінің бірі оңтайлы деген немесе архитектура кеңістігі ізделген деген тұжырымсыз. Бұл архитектураны дауланатын айнымалыдан бақыланатынға айналдырады, сонда қызығушылық тудыратын эксперименттік фактор осы тіркелген backbone-дарға қолданылатын preprocessing және pretraining конфигурациясына айналады. Backbone қалай инициализацияланатыны және бейімделетіні — табиғи кескіндерден transfer learning арқылы немесе домен-ішілік өзін-өзі бақылайтын алдын ала оқыту арқылы — өнімділіктің келесі анықтаушысы, әрі диссертацияның толық-pipeline арнасы тіреледі. Бұл — §1.3.2-нің тақырыбы.

§1.3.2 Офтальмологиялық диагностикадағы Transfer Learning және өзін-өзі бақылайтын алдын ала оқыту

§1.3.1-дегі архитектуралық берілгендік тіркелген backbone өнімділігін ең тікелей қалыптастыратын сұрақты ашық қалдырады: оның салмақтары диабеттік ретинопатия деректерінде fine-tuning-ке дейін және оның барысында қалай инициализацияланатыны мен бейімделетіні. Инициализация — бейтарап бастау нүктесі емес. Кездейсоқ инициализацияланған терең желі DR үшін қолжетімді орташа өлшемді таңбаланған деректер жиынтықтарында бәсекеге қабілетті өнімділікке сирек жинақталады, сондықтан мәні бойынша әрбір заманауи жүйе алдын ала оқытылған салмақтардан басталып, оларды міндетке бейімдейді. *Қай* алдын ала оқытылған салмақтарды — әрі оларды қандай оқыту үдерісі тудырғанын — таңдау сондықтан бірінші реттік салдары бар жобалау шешімі, әрі ол диссертацияның толық-pipeline конфигурациясы өзінің базалығынан ең түбегейлі ажырайтын ось.

Сала ұсынатын әдепкі жауап — ImageNet-тен transfer learning. DR әдебиетінің маңызды жүйелері конволюциялық backbone-ды ImageNet табиғи-кескін жіктеу міндетінде үйренілген салмақтармен инициализациялап, содан кейін көз түбі деректерінде fine-tuning жасайды: Gulshan және әріптестері [13] Inception- ансамблін өздерінің әзірлеу жиынында оқытпас бұрын ImageNet салмақтарынан инициализациялады, ал Saxena және әріптестері [44] да ImageNet-те алдын ала оқытылған InceptionResNetV2-ні тасымалдап, бинарлық DR анықтау үшін Messidor-1-де 0,958 және Messidor-2-де 0,92 деректер жиынтығы аралық AUC хабарлады. Жуырдағы гибридті жобалар дәл сол үлгіні ұстанады; Xu және әріптестері [28] EfficientNet–Swin-Transformer моделін

құрып, бес класты APTOS 2019-да алдын ала оқытылған-содан-фине-түнделген негізде 0,97 дәлдік пен AUC хабарлады. Бұл көрсеткіштер түрлі деректер жиынтықтарында, класс таксономияларында және валидация хаттамаларында туындайды әрі мұнда жүйелер арасындағы салыстыру ретінде емес, тек ImageNet трансфері басым инициализация тәжірибесі екенінің дәлелі ретінде келтіріледі.

Бұл тәжірибенің мүлдем жұмыс істейтіні елеулі, өйткені ол елеулі домен алшақтығын көпірлейді. ImageNet нысандардың, көріністердің және жануарлардың табиғи фотосуреттерінен тұрады; ал көз түбі кескіні — тамырлы және нейрондық торқабық тінінің дөңгелек, жарықтандыруы басым көрінісі. Желі мысықтарды машиналардан ажыратуды үйренетін белгілер микроаневризманы сау капиллярдан ажырататын белгілер екені айдан анық емес, әрі сол алшақтық арқылы тасымалдау кепілдендірілген емес, тәжірибедегі табыс. Диссертация тасымалдау дәрежесін жорылатын қасиет емес, өзінің архитектуралары мен деректер жиынтықтарымен шектелген эмпирикалық мәселе ретінде қарайды.

Осы домен алшақтығын тану медициналық бейнелеудегі сарапшы таңбаларының созылмалы тапшылығымен бірге ауқымды таңбаланған корпустарға аз тәуелді оқыту парадигмаларына кең бұрылысты уәждеді. Cherlygina және әріптестері [45], медициналық кескін талдауындағы «онша бақыланды» оқытуды шола келе, бұл бұрылысты таңбалар шектеулі орталар үшін жартылай бақыланды, көп даналы және transfer-learning стратегияларына реттеді. Торқабыққа тән немесе эксперименттік зерттеу емес, медициналық бейнелеудің жалпы шолуы ретінде ол мұнда проблеманы шеңберлеуі үшін — таңба тапшылығы аз бақыланды сигналдардан репрезентация үйренуді тартымды ететіні үшін — келтіріледі, ешбір торқабық нәтижесі үшін емес.

Домен алшақтығына ең тікелей жауап — домен-ішілік алдын ала оқыту: таңбаланбаған көз түбі бейнелеуінің өзінен репрезентация үйрену, сонда инициализация кез келген диабеттік ретинопатия таңбасы көрінбес бұрын торқабық құрылымын — тамыр топологиясын, оптикалық диск пен макулярлық морфологияны, жарықтандыру мен артефакт статистикасын — әлдеқашан кодтайды. Өзін-өзі бақылайтын оқыту мұны аннотациясыз орындалатын етеді, желіні тек кескіндердің өзінде анықталған сылтаулық мақсаттарда оқыту арқылы, әрі диссертация корпусы енді SimCLR, MoCo, BYOL және DINO отбасыларының бастапқы өзін-өзі бақылайтын әдістерін masked-image моделдеумен бірге, сонымен қатар ауқымды торқабық корпусында домен-ішілік өзін-өзі бақылайтын алдын ала оқыту жалпыланатын торқабық репрезентацияларын беретінінің [46] (RETFound) және домен-ішілік медициналық алдын ала оқыту ImageNet трансферінен асып түсе алатынының [47] (MICLe) тікелей дәлелін қамтиды. Бұл дереккөздер домен-ішілік өзін-өзі бақылайтын алдын ала оқытудың жалпы сенімділігін орнықтырады; олар бермейтіні — осында қабылданған нақты конфигурация. RETFound дәлелі vision-transformer backbone-мен алынады, ал осы диссертация конволюциялық backbone-ды тұрақты ұстап, оны төрт арналы pipeline tensor-ында CNN-нативті

алдын ала оқытады — бұл — келтірілген жұмыстардың ешқайсысы бағаламайтын конфигурация. Сондықтан осы диссертацияда пайдаланылатын домен-ішілік өзін-өзі бақылайтын алдын ала оқыту §3.3.2-де көрсетілген, тиімділігі әдебиеттен импортталмай, эмпирикалық тұрғыдан орнықтырылуға тиіс кандидаттың өз әдістемелік жобасы ретінде ұсынылады.

Бұл диссертацияның екі режимді жобасын орнатады. Негізгі гипотеза бойынша эксперименттің екі арнасы *preprocessing* шартына бағынады: базалық конфигурация ImageNet-те алдын ала оқытылған салмақтарды пайдаланады, ал толық-pipeline конфигурациясы *sol* конволюциялық backbone-ды — ResNet-50 немесе EfficientNet-B3 — таңбаланбаған көз түбі корпусындағы офтальмологияға тән өзін-өзі бақылайтын алдын ала оқытудан, ешқандай диабеттік ретинопатия таңбаларын пайдаланбай, инициализациялайды. Архитектураны арналар бойынша бірдей ұстау — әдейі: бұл жобаның ертерек нұсқасы *transformer* негізіндегі торқабық іргетас моделін [46] (RETFound) қарастырды, бірақ оны қабылдау инициализацияны ғана емес, архитектураны да өзгертіп, салыстыруды архитектура ауысуымен шатастыратын еді; таңдалған CNN-нативті өзін-өзі бақылайтын инициализация тек алдын ала оқыту кезеңін өзгертіп, базалықта пайдаланылған backbone-ды сақтайды.

Бұдан тікелей әрі маңызды салдар туындайды, әрі ол кейіннен ашылған емес, жоба адалдығы мәселесі ретінде осында айтылады. Толық-pipeline арнасы базалықтан *екі* ось бойынша бір мезгілде — *preprocessing pipeline* мен *pretraining* көзі бойынша — ажырайтындықтан, эксперимент түптеп келгенде ашатын кез келген өнімділік айырмашылығы — оқшауланған *preprocessing*-тің емес, екі фактордың да бірлескен үлесі. Сәйкесінше диссертация *preprocessing pipeline* жалғыз бақыланған әсерді тудырады деп тұжырымдамайды әрі тұжырымдай алмайды; рұқсат етілген тұжырымдар тұтасымен біріктірілген конфигурациямен шектеледі — біріктірілген толық-pipeline-плюс-офтальмология-алдын-ала-оқыту конфигурациясы базалық-плюс-ImageNet конфигурациясынан берілген метрикада берілген шамаға асып түседі деген тұжырыммен. Бұл — әдейі ауқымдау шешімі: орталық тезис *preprocessing* мен CNN-ді жалғыз біріктірілген модель ретінде қарастырады, сондықтан біріктірілген конфигурация — тексерудің тиісті нысаны, ал *preprocessing*-ті оқшаулау үшін архитектураны өзгерту баламасы нашарырақ шатасу енгізетін еді. Бірлескен әсерді жеке *preprocessing* және *pretraining* үлестеріне ыдырату осы диссертация ауқымынан тыс болашақ жұмысқа айқын қалдырылады.

Инициализация мен бейімдеу архитектурамен тең дәрежелі анықтаушы ретінде орнықтырылып, эксперименттік қарама-қарсылықтың құрама сипаты бекітілген соң, автоматтандырылған DR жіктеудің үш әдістемелік тірегінің екеуі орнында: үйренетін архитектуралар және оларды инициализациялайтын *pretraining*. Үшіншісі — оқытылған модель шешімдерін тексеріп, жауапкершілікке тартуға болатын құрал — §1.3.3-те қарастырылатын *explainability* әдістері, олар кейінгі тараулар сүйенетін әдістер шолуын аяқтайды.

§1.3.3 Медициналық кескінді жіктеудегі түсіндірілу (explainability) әдістері

Осыған дейін орнықтырылған екі әдістемелік тірек — §1.3.1-дегі конволюциялық архитектуралар мен §1.3.2-дегі pretraining режимдері — ішкі шешім үдерісі мөлдір емес оқытылған модель тудырады. Терең CNN көз түбі кескінін миллиондаған үйренілген параметр арқылы бес класты дәрежеге бейнелейді, ал мұндай модель жұмыс істейтін клиникалық орта оның берілген шығысты *неліктен* тудыратынын түсінуге ерекше мән береді. Бұл — осында шолынатын үшінші әдістемелік тірек, explainability мәселесі. Tjoa мен Guan [48], медициналық қолданбаларға бағытталған түсіндірілетін жасанды интеллектіні шола келе, сала әдістерін перцептивті интерпретацияланушылықты — адам көре алатын түсіндірмелерді, мысалы, бөлектелген кескін аймақтарын — модельдің математикалық құрылымына негізделген интерпретацияланушылықтан ажырататын таксономия бойынша реттеді. Samek және әріптестері [49] мұндай түсіндірмелерді *бағалаудың* толықтырушы проблемасын шеңберлеп, релевантты-тарату тәсілдерін қарапайым сезімталдық талдауымен салыстырғанда қолайлы деп бағалап, перутрбацияға негізделген бағалауды ұсынды. Бұл шолулар жалғыз әдісті артықшыламай-ақ explainability-ді уәждейді, әрі «түсіндірме» түрлі сұрақтарға жауап беретін түрлі техникалар отбасы екенін айқындайды.

Кескінді жіктеу үшін ең тікелей пайдалы отбасы — болжам артындағы кеңістіктік дәлелді локализациялайтыны. Zhou және әріптестері [50] класс активациясын картаға түсіруді (CAM) енгізді, ол класқа тән маңыздылықты кескінге кері проекциялау үшін global-average-pooling қабатын пайдаланады, ILSVRC эталонында 37,1% top-5 локализация қателігімен әлсіз бақыланатын локализацияға жетеді. CAM-ның белгілі бір архитектуралық компонентті талап етуі оның қолданылуын шектеді, ал Selvaraju және әріптестері [51] оны Grad-CAM-мен жалпылады, ол соңғы конволюциялық қабатқа ағатын мақсатты кластың градиенттерін сол қабаттың feature map-тарын салмақтау үшін пайдаланып, мәні бойынша кез келген CNN үшін архитектуралық модификациясыз немесе қайта оқытусыз класс-дискриминативті локализация картасын тудырады. Chattopadhyay және әріптестері [52] кейіннен техниканы Grad-CAM++ ретінде жетілдіріп, локализация сапасын және кескін ішіндегі бір кластың бірнеше данасын өңдеуді жақсартып, ImageNet-класты деректерде Grad-CAM-ге қарағанда төменірек орташа сенімділік құлдырауын (36,8%-ке қарсы 46,6%) хабарлады. Бұл көрсеткіштер — табиғи-кескін эталондарында өлшенген әдістердің қасиеттері, торқабық зақымдануларындағы нәтижелер емес, әрі солай хабарланады.

Екінші отбасы болжамдарды кеңістіктік активацияға сілтемесіз түсіндіреді. Lundberg пен Lee [53] SHAP-ты ұсынды — жергілікті дәлдіктің, жоқтықтың және дәйектіліктің теориялық кепілдіктері бар біріктірілген аддитивті белгі-телу шеңбері, ал Ribeiro және әріптестері [54] LIME-ді енгізді, ол кез келген жіктеуішті жалғыз болжамның айналасына интерпретацияланатын суррогат модель сәйкестендіру арқылы жергілікті

түсіндіреді. Бұл телу әдістері күшті әрі модельден тәуелсіз, бірақ олар торқабық қолданбасы зақымдану орындарымен ең табиғи түрде салыстыратын пикселге тураланған кеңістіктік картаны тудырудың орнына белгі-маңыздылығы сұрағына жауап береді. Сондықтан осы диссертацияда олар операциялық құрал ретінде қабылданбай, түсіндірілетін-AI фоны ретінде сақталады.

Диссертация активация-картасы шежіресінен Grad-CAM-ды өзінің негізгі интерпретация әдісі ретінде нақты әрі шектелген себеппен таңдайды. Grad-CAM кескін бойынша кеңістіктік карта тудыратындықтан, сол картаны — IDRiD деректер жиынтығында қолжетімді — пиксел деңгейіндегі зақымдану аннотацияларымен тікелей салыстырып, модельдің класқа қатысты активациясының қаншасы аннотацияланған зақымдануларға түсетінін сандық бағалауға болады. Бұл салыстыру кейінірек енгізілетін explainability метрикаларының негізі: негізгі өлшем ретінде назар-зақымдану қабаттасуы (ALO) және қосалқы ретінде intersection-over-union (IoU), 4-экспериментте бағаланады. Grad-CAM CAM-нан диссертация backbone-дарына архитектуралық өзгеріссіз қолданылатыны үшін, ал телу әдістерінен өз шығысы беретін табиғи кеңістіктік салыстыру үшін артық көріледі; Grad-CAM++ пен телу әдістері қолдаушы немесе қарама-қарсы сілтемелер ретінде қолжетімді болып қалады.

Мұндай қабаттасу нені білдіре алатынын, нені білдіре алмайтынын дәл әрі байланыстырушы шектеу ретінде айту маңызды. Grad-CAM картасы соңғы конволюциялық қабаттағы жоғары градиентпен-салмақталған активация аймақтарын көрсетеді; ол патологияның клиникалық локализациясын құрамайды әрі зақымдану шекараларының пиксел деңгейіндегі диагностикалық сызбасы емес. Күшті активация аймағы — желінің класс сигналы қайда шоғырланатынының дәлелі, аурудың сегментациясы емес. Бұдан тіпті жоғары назар-зақымдану қабаттасуы да модельдің диагностикалық пайымдауының валидациясы ретінде оқылмауы тиіс екені туындайды: қабаттасу клиникалық тұрғыдан ақылға қонымды назармен үйлеседі, бірақ ол болжамның қандай да бір механизмдік мағынада зақымдану белгілерімен *тудырылғанын* да, активациялардың зақымдану шекараларын дәл бейнелейтінін де орнықтырмайды. Азғырушы қорытынды — «зақымдануларға қарайтыны» көрсетілген модельдің пайымдауы клиникалық валидацияланған деген — дәл осы диссертация жасамайтын қорытынды. Grad-CAM механизмдік түсіндірмені емес, post-hoc интерпретацияны береді, әрі оның 4-эксперименттегі қолданысы тұтасымен клиникалық валидация ретінде емес, explainability дәлелі ретінде шеңберленеді.

Бұл шекара бекітілген соң, explainability тірегі архитектура мен pretraining-пен қатар орнында, әрі эксперименттік тараулар сүйенетін әдістер шолуы аяқталады. Осы кезеңге дейін тарау проблеманы (§§1.1–1.2-дегі ауру, скрининг жүгі, кескін-сапасы және құрылғы-ығысуы жағдайлары) және оны шешуге ұсынылған әдіс компоненттерін (§1.3-тегі архитектуралар, pretraining стратегиялары және explainability құралдары) жинады. Зерттеу проблемасын тұжырымдамас бұрын қалғаны — осы компоненттердің жұмыс істейтін автоматтандырылған DR скрининг жүйелеріне іс жүзінде қалай жинақталғанын

және сол жүйелердің қай жерде жетіспейтінін қарастыру. Сол сыни талдау — §1.4-тің тақырыбы.

§1.4 Қолданыстағы автоматтандырылған DR скрининг жүйелерінің сыни талдауы

Алдыңғы бөлімдер автоматтандырылған диабеттік-ретинопатия скринингі проблемасын және оны шешуге пайдаланылатын әдіс компоненттерін — архитектураларды, pretraining-ті және explainability-ді — жинады. Бұл бөлім сол компоненттердің жұмыс істейтін жүйелерге қалай жинақталғанын және сол жұмыстар жиынтығын сыни оқу нені ашатынын қарастырады. Мақсат — осы жүйелерді рейтингтеу немесе қазіргі жұмысты олардың бәсекелесі ретінде орналастыру емес; ол — есеп бойынша көрсетілген өнімділіктің даусыз әсерлі тізбесінің астынан осы диссертация толтыруға жобаланған олқылықты құрайтын дәйекті әдістемелік үлгіні табу.

Саланың жоғары өнімді жүйелер тудырғаны даулы емес. Терең конволюциялық желінің referable диабеттік ретинопатияны сарапшымен салыстырмалы деңгейде анықтай алатынының маңызды демонстрациясы бинарлық referable-DR соңғы нүктесі үшін екі клиникалық валидация жиынында 0,991 және 0,990 ROC қисығы астындағы аудандарды хабарлады [13]; бұл көрсеткіштер мұнда тек тарихи және контекстік сілтеме ретінде келтіріледі, әрі қазіргі жұмыспен тікелей сандық салыстыру міндет, архитектура, pretraining, дерек бөлуі және эталондық стандарт айырмашылықтарын ескере отырып негізсіз болар еді. Зерттеу ортасынан тыс автономды жүйелер нормативтік рұқсатқа жетті: IDx-DR жүйесінің шешуші сынағы он бастапқы-медициналық сайттағы 900 пациент бойынша 87,2% сезімталдық, 90,7% спецификалық және 96,1% бейнеленушілік деңгейін хабарлап, оның автономды диагностикалық құрылғы ретінде авторизациялануын қолдады [55]. Алайда сол сынақ ешқандай preprocessing абляциясын және жария эталонмен салыстыруды хабарламады, сондықтан ол кез келген жеке pipeline компонентінің үлесіне емес, орналастырылған клиникалық өнімділікке сөйлейді.

Әдебиет бір сайтты ішкі валидациядан әлдеқайда асып жетілді. Ting және әріптестері [56] бастапқы когортта referable DR үшін 0,936 AUC-ке жететін скрининг моделін валидациялап, AUC-тері 0,889-дан 0,983-ке дейінгі он қосымша көп этникалық деректер жиынтығы бойынша өнімділікті хабарлады, дегенмен әзірлеу деректері жабық болды. Bellemo және әріптестері [57] сыртқы валидацияны Сахарадан оңтүстіктегі африкалық популяцияға кеңейтіп, замбиялық когортта 0,973 referable-DR AUC (92,25% сезімталдық, 89,04% спецификалық) хабарлады, бір елдік деректер жиынтығында. Zhang және әріптестері [58] төрт орталық пен 83 465 кескін бойынша көп орталықты сыртқы валидация жүргізіп, referable DR үшін кескін деңгейіндегі 0,9931 AUROC және пациент бойынша 0,9848 AUROC-ты 0,86–0,93 сарапшы-келісім қаппа мәндерімен хабарлады, бірақ толық Қытайдан алынған деректерде және қолданылған preprocessing-ті хабарламай. Ruamviboonsuk және әріптестері [59]

одан да әрі барып, жүйені Таиландтың ұлттық скрининг бағдарламасы аясында тоғыз сайт пен 7651 пациент бойынша проспективті бағалап, көру қабілетіне қауіп төндіретін DR үшін 94,7% дәлдік пен 91,4% сезімталдық және қатысушы мамандардан статистикалық тұрғыдан елеулі артықшылық ($p = 0,024$) хабарлады — жоғары сапалы проспективті нәтиже, бірақ тағы да бір елдік және архитектура немесе preprocessing бойынша мөлдірліксіз. Коммерциялық құралдардың клиникалық-валидация зерттеулері ұқсас әңгіме айтады: RetCAD жүйесі жабық испан когорттыңда 0,988 AUC-те 90,5% сезімталдық пен 97,1% спецификалық және 96% жұмыс жүгінің азаюымен хабарланды [60], ал Baget-Bernaldiz және әріптестері [61] төрт класты ICDR соңғы нүктесі үшін өз популяциясында 0,988 AUC және Messidor-да 0,968 AUC хабарлады. Біріктірілген дәлел деңгейінде бастапқы медицинадағы он терең-оқыту скрининг зерттеуінің мета-талдауы 87% біріктірілген сезімталдық, 90% спецификалық және 0,9543 қорытынды ROC AUC хабарлады [62], бұл бір жағынан саланың жиынтық күшін растайды, екінші жағынан гетерогенді зерттеулерді біріктіргендіктен кез келген жалғыз жүйенің тәуелсіз растауы ретінде оқылмайды.

[ТАБ-1.1: Қолданыстағы автоматтандырылған DR скрининг жүйелерінің шолуы — әдебиеттен алынған]

Жүйе / Зерттеу	Міндет (таксономия)	Деректер жиынтығы және популяция	Негізгі хабарланған метрика (контексте)	Валидация түрі	Негізгі шектеу
Gulshan et al. [13] #12	Бинарлық referable DR	EyePAC S-1 (АҚШ) + Messidor-2 (Франция), жабық dev	AUC 0,991 / 0,990 (бинарлық) — <i>тек контекстік сілтеме</i>	Қос сыртқы (ретроспективті)	Preprocessing қосымшаға шегерілген; жалғыз градиациялаушылар-пулы эталондық стандарты
IDx-DR — Abramoff et al. [55] #77	Бинарлық referable DR (автономды)	900 пац., 10 АҚШ бастапқы - медицин алық сайт	Сез 87,2% / Спе 90,7% / бейнеленушілік 96,1%	Проспективті шешуші (FDA)	Preprocessing абляциясы жоқ; жария-эталон салыстыруы жоқ
Ting et al. [56] #11	Referable DR	SIDRP (жабық) + 10 көп этникалы	AUC 0,936; сыртқы AUC	Көп этникалық сыртқы	Жабық әзірлеу деректері

		қ жиын	0,889– 0,983		
Bellemo et al. [57] #115	Referable DR	4504 кескін, Замбия (Африка)	AUC 0,973; Сез 92,25% / Спе 89,04%	Популяция ралық сыртқы	Бір елдік когорт
Zhang et al. [58] #44	Referable DR	83 465 кескін, 4 орталық, Қытай	AUROC 0,9931 кескін / 0,9848 пациент; к 0,86–0,93	Көп орталықты сыртқы	Тек Қытай; preprocessing хабарланбаған
Ruamviboonsuk et al. [59] #45	Көру қабілетін е қауіп төндіретін DR	7651 пац., 9 сайт, Таиланд	Дәл 94,7% / Сез 91,4%; p = 0,024 мамандарға қарсы	Проспективті (ұлттық бағдарлама)	Бір елдік; архитектура/preprocessing мөлдір емес
RetCAD — Sánchez-Gutiérrez et al. [60] #03	Referable DR	Жабық (Ramón y Cajal, Испания)	AUC 0,988; Сез 90,5% / Спе 97,1%; 96% жұмыс жүгі ↓	Клиникалық валидация	Жабық деректер; жариялау орны көрсетілмеген
Baget-Bernaldiz et al. [61] #07	Төрт класты ICDR	Испан жабық + Messidor	AUC 0,988 өз поп. / 0,968 Messidor (4 класс)	Сыртқы	Бір популяциялы әзірлеу
Saxena et al. [44] #02	Бинарлық DR	EyePACS dev → Messidor -1/-2	AUC 0,958 / 0,92 (бинарлық)	Деректер жиынтығы аралық	Бинарлық міндет; P1 preprocessing тәжірибесі
Wewetzer et al. [62] #14	Referable DR (біріктірілген)	10 бастапқы - медицин алық DL зерттеуі	Біріктірілген Сез 87% / Спе 90%; SROC AUC 0,9543	Мета-талдау	Гетерогенді зерттеулерді біріктіреді (тәуелсіз емес)

Тақырыпша. Метрикалар өздерінің деректер жиынтығы, популяция және класс-таксономия контексімен хабарланады әрі **өзара салыстырылмайды**: міндеттер бинарлық referable-DR-ден төрт класты ICDR-ге дейін ауытқиды; деректер басым түрде жабық және бір елдік; эталондық стандарттар әртүрлі. Gulshan және әріптестерінің [13] көрсеткіштері тек тарихи/контекстік сілтеме ретінде көрінеді, қазіргі жұмыстың эталоны ретінде емес.

Осы ландшафттан жасалатын бірінші қорытынды — оның сандарын рейтинг ретінде тізуге болмайтыны. Соңғы нүктелер ерекшеленеді — көпшілік жүйелерде бинарлық referable DR, басқаларында төрт класты ICDR, проспективті тай зерттеуінде көру қабілетіне қауіп төндіретін DR — деректер жиынтықтары, популяциялар, камера жабдығы және эталондық стандарттар да солай. Жабық бір елдік когортта хабарланған жоғарырақ AUC басқа таралудағы өнімділік туралы аз нәрсе айтады, әрі мұндай көрсеткіштерді зерттеулер арасында салыстыру осы диссертацияда сақталатын метрика-дәйектілігі тәртібін бұзар еді. Бұл салыстырылмаушылықтың өзі олқылықтың бір бөлігі: салада кез келген жеке жобалау таңдауының үлесін оқуға болатын бақыланатын, ортақ-хаттамалы негіз жоқ.

Екінші қорытынды қайта жаңғыртылушылыққа қатысты. §1.2.2-де атап өтілгендей, маңызды жүйені жария деректерде қайта жаңғыртудың тәуелсіз әрекеті — меншікті деректер мен код қолжетімсіз болғанда — айтарлықтай төмен өнімділікті қалпына келтірді: бастапқыда хабарланған 0,990-ге қарсы Messidor-2-де 0,853 AUC [12]. Бұл оқшауланған ескерту емес: DR терең оқытуының 2016-дан 2023-ке дейінгі PRISMA негізіндегі жүйелі шолуы артық үйренуді, класс теңгерімсіздігін және әлсіз ерте-сатылы анықтауды сала бойынша қайталанатын, шешілмеген әлсіздіктер ретінде айқындады [63]; офтальмологиядағы терең оқытудың кеңірек техникалық-және-клиникалық шолуы да дерек сапасын, жалпылауды және клиникалық-аударма кедергілерін ашық проблемалар ретінде белгіледі [64]. Басқаша айтқанда, ландшафттың тақырыптық метрикалары тәуелсіз қайталау аясында сынғыш әрі теңгерімсіздігі мен шығу тегі әрқашан бақыланбайтын деректер жиынтықтарына сүйенеді.

Осы диссертацияның мақсаттары үшін үшінші әрі ең елеулі қорытынды preprocessing-ке қатысты. Осы жүйелер бойынша кескін preprocessing-і формализацияланған модель компоненті ретінде емес, қосалқы деректерді дайындау ретінде қаралады, әрі тиісінше толық хабарланбайды: маңызды зерттеу өзінің preprocessing хаттамасын қосымша материалға шегереді; көп орталықты және проспективті орналастырулар өздерінің preprocessing-ін мүлдем хабарламайды; ал деректер жиынтығы аралық CNN зерттеулері нормализацияны тек жанай сипаттайды. Бұл — осы диссертация P1 парадигмасы деп айқындайтын бақыланатын әдістемелік тәжірибе — preprocessing әдістемелік талқылауды талап етпейтін қосалқы дайындау ретінде — әрі ол мұнда осы мақалалар не істейтінінің сипаттамасы ретінде аталады, олардың авторларының preprocessing маңызды емес деген телінген тұжырымы ретінде емес. Салдары — саланың көлемі мен клиникалық табысына қарамастан, preprocessing үлесі сирек оқшауланған, формализацияланған немесе модельдің интегралды бөлігі ретінде бағаланған.

Орналастыру ландшафты бұл шектеулерді басқаша түрде асқындырады. Кандидаттың бұрынғы жұмысында, Есмұхамедов және әріптестері (2025) тоғыз қолданыстағы офтальмологиялық AI жүйесін салыстырып, орналастырылған құралдардың әдетте тар немесе шектеулі екенін құжаттады — IDx-DR тек диабеттік ретинопатиямен шектелген, DeepMind-тікі сияқты жүйелер жетілдірілген бейнелеу жабдығын талап етеді, ал бұлтқа негізделген скрининг құралдары интернет байланысына тәуелді — сонымен бірге IDx-DR пен EyeArt-тан referable DR үшін 96% сезімталдық пен 93% спецификалық сияқты хабарланған операциялық нүктелерді жеткізді. Жүйе-архитектуралық үлесі 6-тарауда дамытылатын сол салыстырмалы талдау Қазақстандағы енгізу үшін орналастыру нәтижелерін де болжады; ол болжамдар — контекст үшін келтірілген үшінші тарап көрсеткіштері, осы зерттеудің нәтижелері емес. Оның үстіне коммерциялық орналастырылған жүйелер басым түрде бинарлық әрі мөлдір емес, ал кейбір жоғары өнімді модельдер мүлдем басқа модальдылықтарда жұмыс істейді — мысалы, Руи және әріптестерінің [36] ОСТА негізіндегі жіктеуші, осы диссертацияның көз түбі-фотосуреті ауқымынан тыс, немесе De Fauw және әріптестерінің [65] құрылғыдан тәуелсіз ОСТ жолдамалау жүйесі, сол сияқты басқа модальдылық, бірақ талдауын аралық сегментация репрезентациясы арқылы нақты сканер жабдығынан ажыратуымен ерекше. Preprocessing-і толық көрсетілген және бағаланған мөлдір, бес класты, құрылғыға төзімді жүйелер сирек.

Бірге алғанда, бұл қорытындылар олқылықты дәл табады, әрі бұл — өнімділік тапшылығы емес, әдістемелік олқылық. Қолданыстағы жүйелер көп жағдайда жоғары дәл әрі кейбір жағдайда проспективті және клиникалық валидацияланған; қазіргі жұмыс олардан асып түсуге ешқандай тұжырым жасамайды әрі ешбір аталған жүйеге қарсы бетпе-бет салыстыру жүргізілмейді. Әдебиет жүйелі түрде істемегені — preprocessing-ті интегралды модель компоненті ретінде формализациялау, оны толық хабарлау және оның үлесін деректер жиынтығы аралық тасымалдау мен құрылғы-домен ығысуын да зерттейтін бақыланатын, көп деректі, мөлдір жағдайларда бағалау. Бұл — олқылық, ал тағы бір жоғары бір-деректі метрикаға деген қажеттілік емес — диссертацияға өзінің нақты пішінін беретін нәрсе. Келесі бөлім бұл олқылықты айқын зерттеу проблемасына және одан туындайтын міндеттерге тұжырымдайды.

§1.5 Зерттеу проблемасының тұжырымдалуы

Алдыңғы бөлімдер енді дәл тұжырымдауға болатын проблемаға тоғысады. §§1.1–1.2-нің клиникалық және техникалық контексті диабеттік-ретинопатия скринингі популяция масштабында, сапасы мен шығу тегі құрылғысы жүйелі түрде ауытқитын кескіндерде, әрі дәл сол ауытқуларға ең осал нысанға — ерте аурудың ұсақ, төмен контрастты зақымдануларына — қарсы жұмыс істеуге тиіс екенін орнықтырды. §1.3-тің әдістемелік шолуы мен §1.4-тің сыни талдауы сосын саланың дәл әрі кейбір жағдайда проспективті валидацияланған жүйелер тудырғанын, бірақ мұны кескін preprocessing-ін

қосалқы деректерді дайындау ретінде қарай отырып істегенін орнықтырды: маңызды зерттеулердің негізгі мәтінінде толық хабарланбаған, бірнеше орналастыру есебінен мүлдем алынып тасталған және сирек оқшауланған немесе модель компоненті ретінде формализацияланған. Қайта жаңғырту дәлелі [12] және артық үйрену, класс теңгерімсіздігі мен әлсіз ерте-сатылы анықтаудың жүйелі-шолу тұжырымдары [63] бұл әдебиеттің тақырыптық өнімділігі сынғыш әрі біркелкі емес валидацияланғанын одан әрі көрсетеді. Сондықтан олқылық — дәлдік тапшылығы емес, әдіс тапшылығы: preprocessing-тің автоматтандырылған DR жіктеуіне үлесі бақыланатын, мөлдір, көп деректі жағдайларда модельдің интегралды бөлігі ретінде формализацияланбаған әрі бағаланбаған.

Осы диссертация шешетін зерттеу проблемасы сол олқылықтан тікелей туындайды. Бұл — кескін preprocessing-ін ажыратылатын, факультативті деректерді дайындау ретінде қараудың орнына CNN негізіндегі диабеттік-ретинопатияны жіктеу моделінің интегралды компоненті ретінде қалай формализациялауға болатыны, әрі оның үлесін скрининг іс жүзінде жеткізілуге тиіс ресурсы шектеулі орталарды бейнелейтін бақыланатын және мөлдір жағдайларда қалай бағалауға болатыны туралы сұрақ. Бұл проблеманың концептуалды және эмпирикалық өлшемі бар: концептуалды тұрғыдан ол preprocessing-ті қосалқы дайындаудан (осы диссертация P1 деп таңбалайтын парадигма) интегралды модель компонентіне (P2 парадигмасы) қайта шеңберлеуді талап етеді; эмпирикалық тұрғыдан ол сол қайта шеңберлеуді жорудың орнына тексеруге болатын зерттеу жобасын талап етеді.

Диссертацияның жауабы, мұнда дәлелденген нәтиже ретінде емес, оның орталық тезисі мен мақсаты ретінде айтылады — көп сатылы диабеттік-ретинопатия диагностикасы үшін біріктірілген көз түбі-кескінін-жақсарту және CNN-жіктеу шеңберін әзірлеу әрі эксперименттік валидациялау. Шеңбердің preprocessing-і реттелген сегіз кезеңді pipeline ретінде көрсетіледі — канондық бағдарлама, оптикалық диск/фовеа айналу нормализациясы, изотропты өлшемін өзгертумен көру-өрісін қию, төртінші кіріс арна ретінде көру-өрісі маскасын генерациялау, адаптивті жарық-өрісін жарықтандыруды түзету, қос шектеулі клип лимитімен LAB түс кеңістігінде жанартылған CLANE арқылы контрастты күшейту, оқыту уақытындағы augmentation және деректер жиынтығына тән нормализация — CNN жіктеушімен бірге қолданылып, бағалау мақсаттары үшін жалғыз модель ретінде қаралады. Бұл интеграция — концептуалды үлес: pipeline модельдің кіріспесі емес, оның бөлігі, жіктеуіш жұмыс істейтін белгі кеңістігін айқындайды.

Шеңбер зерттеу нысаны болғандықтан, зерттеу проблемасы шектелген, алдын ала тіркелген гипотезалар жиынына ыдырайды, әрқайсысы біріктірілген шеңбердің бір қырын сәйкес жағдайларда тексереді. Негізгі гипотеза (H-1) біріктірілген-pipeline басымдығына қатысты: толық pipeline, backbone-ның офтальмологияға тән өзін-өзі бақылайтын алдын ала оқытуымен жұптасқанда, бастапқы EyePACS деректерінде ImageNet pretraining-пен минималды preprocessing базалығынан асып түсе ме. Бұл жобаның адалдығы үшін екі арнаның бір мезгілде екі ось бойынша — preprocessing мен pretraining көзі

бойынша — ажырайтынын тіркеп қою маңызды, сонда кез келген бақыланған әсер біріктірілген конфигурацияның бірлескен үлесі болады әрі оқшауланған preprocessing-ке телінбеуі мүмкін. Қалған гипотезалар түрлі қасиеттерді зерттейді: компоненттерді абляциялау мен CLANE/жарықтандыру параметрінің сезімталдығы (H-2), APTOS 2019-ға деректер жиынтығы аралық тасымалдаушылық (H-4), IDRiD-те назар–зақымдану қабаттасуы арқылы explainability (H-5), бейнелеу құрылғылары бойынша беріктік (H-6), және IDRiD пен Messidor-2-де клиникалық төмендеуге төзімділік (H-7). Әр гипотеза өзінің деректер жиынтықтарымен, архитектураларымен және тексерілген диапазондарымен шектелген, әрі әрқайсысы жетілдірудің бейресми сезіміне емес, кейінгі тараулар қолданатын айқын дәлел критерийлеріне ұсталады.

Екі шекара бұл проблема тұжырымдамасының диссертацияны неге міндеттейтінін және неге міндеттемейтінін айқындайды. Біріншіден, мақсат — формализация мен бақыланатын бағалау, бәсеке емес: диссертация ешбір аталған қолданыстағы жүйеден асып түсуді көздемейді әрі біреуіне қарсы бетпе-бет салыстыру жүргізбейді. Оның үлесі — preprocessing-ті интегралды компонент ретінде бақыланатын, мөлдір тексеру — нәтиже бағытына қарамастан тұратын әдістемелік үлес, өйткені гипотезалар жоққа шығарылатын әрі нөлдік немесе қарама-қарсы тұжырым үнсіз қайта қаралмай, солай хабарлануға тиіс. Екіншіден, ауқым тұтасымен көз түбі фотосуретіндегі бес класты DR градациялауымен, көрсетілген деректер жиынтықтары отбасымен және ресурсы шектеулі есептеу жағдайларымен шектелген; осы архитектурадан тыс ешқандай жалпылау бекітілмейді, ал шеңберді орналастыру контекстінде орналастыратын жүйе-архитектуралық жұмыс — валидацияланған клиникалық жүйе емес, жобалау үлесі.

Зерттеу проблемасы тұжырымдалып, оның концептуалды жауабы аталып, эмпирикалық құрылымы алдын ала көрсетілген соң, 1-тараудың жұмысы аяқталады: ол үлесті уәждеді, ауқымдады және орналастырды. §1.С бұл желілерді біріктіріп, 2-тарауға өтуді орнатады, онда жақсарту, жіктеу, transfer-learning және explainability компоненттерінің теориялық негіздері шеңбер талап ететін егжей-тегжейде дамытылады.

§1.С 1-тарау бойынша қорытындылар

Бұл тарау автоматтандырылған диабеттік-ретинопатия скринингінің проблемалық саласын орнықтырып, оның ішінде диссертация жасайтын нақты үлесті орналастырды. Ол клиникалық және эпидемиологиялық негіздемеден басталды: диабеттік ретинопатия — ауырлығы әрбір downstream жіктеуіштің нысанын құрайтын бес класты реттік шкалаға (DR 0–4) операциялданатын, әрі емделуге келетін ерте дәрежелері тек жүйелі, популяция масштабындағы скрининг арқылы анықталатын ұсақ, төмен контрастты зақымдануларға сүйенетін прогрессивті нейроваскулярлық ауру. Сол скрининг мамандардың құрылымдық тапшылығына қарсы әрі ресурсы шектеулі орталарда жеткізілуге тиіс, бұл қолжетімді, шешім қабылдауды қолдау жіктеуішіне деген сұранысты және ол жұмыс істеуге тиіс есептеу қабығын орнықтырады.

Сосын тарау бұл сұранысты қанағаттандыруды қиындататын техникалық жағдайларды сипаттады. Нақты скрининг тәжірибесінде түсірілген көз түбі кескіндері оптикалық, фотометриялық, геометриялық және пациентке қатысты осьтер бойынша төмендейді, әрі сол төмендеу мақсатпен корреляцияланған — ол скрининг ең көп сүйенетін ұсақ ерте зақымдануларға басымдықпен шабуыл жасайды. Эмпирикалық әдебиет кескін сапасы мен дерек шығу тегі өлшенген жіктеу өнімділігінің бірінші реттік анықтаушылары екенін, дегенмен ешбір қарапайым нашар-кескіндерді-таста механизмі арқылы емес, әрі бұл вариацияның бір елеулі компоненті кездейсоқ емес, жүйелі екенін растайды: бейнелеу құрылғысы камералар мен популяциялар бойынша құрылымды domain shift таңады.

Осы проблемаға қарсы тарау автоматтандырылған жүйелер жинақтайтын әдіс компоненттерін — жіктеуді орындайтын конволюциялық архитектураларды, оларды инициализациялайтын transfer-learning мен өзін-өзі бақылайтын pretraining стратегияларын, әрі шешімдерін тексерілетін ететін explainability әдістерін — шолып, сосын сол компоненттердің жұмыс істейтін жүйелерге қалай біріктірілгенін қарастырды. Сол сыни талдау тараудың бұрылыс нүктесі болды. Қолданыстағы жүйелер дәл әрі жер-жерде проспективті және клиникалық валидацияланған, бірақ әдебиет жиынтық ретінде міндеттер мен популяциялар бойынша гетерогенді әрі салыстырылмайтын, тәуелсіз қайта жаңғырту аясында сынғыш, әрі — ең елеулісі — кескін preprocessing-ін қосалқы деректерді дайындау ретінде қарап, оны толық хабарламай және интегралды модель компоненті ретінде сирек бағалайды.

Бұдан диссертацияның зерттеу проблемасы тұжырымдалды: preprocessing-ті CNN негізіндегі DR-жіктеу моделінің интегралды компоненті ретінде формализациялау және оның үлесін ресурсы шектеулі орналастыруды бейнелейтін бақыланатын, мөлдір, көп деректі жағдайларда бағалау. Жауап — preprocessing-ті қосалқы дайындаудан (P1 деп таңбаланған парадигма) интегралды модель компонентіне (P2) концептуалды қайта шеңберлеу, ол біріктірілген сегіз кезеңді preprocessing және CNN шеңбері ретінде операциялданатын, біріктірілген-pipeline өнімділігін, компоненттерді абляциялауды, деректер жиынтығы аралық тасымалдауды, explainability-ді, құрылғы беріктігін және төмендеуге төзімділікті қамтитын шектелген, алдын ала тіркелген және жоққа шығарылатын гипотезалар жиыны арқылы тексеріледі. Тарау бұл үлестің шарттарына нақты болды: ол — әдістемелік үлес — формализация мен бақыланатын бағалау — әрі ешбір аталған қолданыстағы жүйеден асып түсуге тұжырым емес; негізгі гипотеза preprocessing мен pretraining-ті бірге өзгертеді, сондықтан оның түпкі әсері оқшауланған preprocessing-ке емес, біріктірілген конфигурацияға телінеді; әрі әр гипотеза жоққа шығарылатын болып қалады, бақыланғандай хабарлануға тиіс.

Проблема уәжделіп, көз түбі фотосуретіндегі бес класты DR градациялауымен, көрсетілген деректер жиынтықтары отбасы аясында ауқымдалып, әрі құрылымды жауабы бар әдістемелік олқылық ретінде орналастырылған соң, 1-тараудың негізі қаланды. 2-тарау шеңбер сүйенетін

теориялық негіздерді — контрастты күшейту мен CLANE математикасын, конволюциялық желілердің операциялары мен оқытуын, transfer және домен-ішілік өзін-өзі бақылайтын оқыту принциптерін, әрі explainability метрикаларының формальды негізін — біріктірілген шеңбер мен оның эксперименттік бағалауы талап ететін егжей-тегжейде дамытады.

2 FUNDUS IMAGE ТАЛДАУЫ ҮШІН IMAGE PREPROCESSING ЖӘНЕ DEEP LEARNING ТЕОРИЯЛЫҚ НЕГІЗДЕРІ

§2.1.1 Histogram Equalization және адаптивті контрастты күшейту

1-тарау зерттеу проблемасын әдіснамалық проблема ретінде айқындаумен аяқталды: көз түбі кескінінің сапасы — әсіресе скрининг үшін шешуші маңызы бар ерте дәрежелерді айқындайтын ұсақ, төмен контрастты зақымданулардың контрасты — автоматты жіктеуіштің нені үйрене алатынын айқындайды, ал §1.5-те қабылданған біріктірілген preprocessing–CNN жүйесі осы сапаны жақсартуды қосалқы деректерді дайындау емес, модель компоненті ретінде қарастырады. Бұл тарау сол жүйе сүйенетін теориялық негіздерді ұсынады және pipeline-нің контраст кезеңімен (5-кезең, OD-3 операцияналды pipeline анықтамасы бойынша) аяқталатын контрастты күшейту тармағынан басталады. Бұл тармақ үш қадаммен жүреді — глобалды Histogram Equalization, адаптивті Histogram Equalization және контрасты шектелген (клиптелген) адаптивті Histogram Equalization — әрі осы бөлімнің мақсаты контрастты күшейту бірыңғай пайдалы деп жорымай, әрбір қадамның неліктен қажет екенін және оның түпкілікті формасы қандай басқару параметрін ашатынын негіздеу болып табылады.

Histogram Equalization — осы тармақтың түбірінде жатқан элементар операция. Ол кескіннің пиксел қарқындылықтарын қайта үлестіреді, нәтижесінде қарқындылық гистограммасы шамамен біркелкі болады; бұған әрбір қарқындылықты кескін қарқындылықтарының (нормаланған) жинақтаушы үлестірім функциясы арқылы бейнелеу жолымен қол жеткізіледі; тығыз орналасқан қарқындылықтар бір-бірінен алшақтатылады, бұл кескін ақпаратының басым бөлігі жатқан динамикалық диапазонды кеңейтеді әрі осылайша глобалды контрастты арттырады. Іргелі кескінді жақсарту әдісі ретінде ол төменде дамытылатын адаптивті нұсқалардың концептуалды негізі болып қызмет етеді. Оның дәл көз түбі кескіндері үшін айқындаушы шектеуі тікелей оның глобалдылығынан туындайды: жалғыз бейнелеу бір кескін ауқымындағы гистограммадан алынады, ал дөңгелек көз түбі фотосуреті үшін бұл гистограммада торқабықтың көру өрісінен (FOV) тыс және айналасында жатқан үлкен, шамамен біркелкі қараңғы аймақ басым болады. Осы фон басым болатын гистограмманы ең жақсы теңестіретін бейнелеу бір квадрантта бірнеше пикселді алып жатқан микроаневризмалар шоғырын ең жақсы ажырататын бейнелеу емес, өйткені глобалды Histogram Equalization өзінің түрлендіруін жергілікті кескін мазмұнына бейімдеу механизміне ие емес.

Адаптивті Histogram Equalization (АНЕ) бұл локалдылық жетіспеушілігін кескін бөлінетін көптеген жергілікті аймақтардың, немесе тайлдардың (tile), әрқайсысы үшін бөлек теңестіру бейнелеуін есептеу арқылы шешеді, сонда белгілі бір орында қолданылатын контраст түрлендіруі бүкіл кескіннің емес, сол орынның төңірегінің қарқындылық статистикасын көрсетеді. Бұл глобалды әдіс жоғалтатын жергілікті контрастты дәл қалпына келтіреді. Алайда мұны өзіне тән шығынмен істейді. Шамамен біртекті аймақта — тегіс торқабық фоны немесе ірі тамырдың ішкі бөлігіндегі сияқты төмен қарқындылық дисперсиясы бар аймақта — жергілікті гистограмма тар жолаққа шоғырланады, ал оны теңестіру осы жолақ бойынша өте тік көлбеуі бар түрлендіруді тудырады. Тік бейнелеу шағын қарқындылық айырмашылықтарын талғаусыз күшейтеді, бұл басқаша белгілерсіз аймақтағы кез келген сенсорлық және кванттау шуы шынайы сигналмен бірге күшейетінін білдіреді. Pizer және әріптестері [66], адаптивті Histogram Equalization мен оның нұсқаларының іргелі зерттеуінде, АНЕ-ні «табиғи кескіндер үшін де, медициналық және басқа да бастапқыда визуалды емес кескіндер үшін де тамаша контрастты күшейту әдісі» деп сипаттай отырып, «негізгі әдіс баяу, әрі белгілі бір жағдайларда жақсартылған кескінде қалаусыз белгілер пайда болады» (355-б.) деп ашық атап өтті; бұл зерттеу сандық немесе торқабыққа тән бағалаудан гөрі медициналық модальдылықтар бойынша сапалық кескін салыстыруларын ұсынады, әрі оның байқаулары мұнда сандық тұрғыдан валидацияланған нәтижелер ретінде емес, ол ұсынатын әдіснамалық синтез ретінде қабылданады.

Шу күшею проблемасының шешімі — нақ сол зерттеу әдіснамалық бастауы болып табылатын үлес. Pizer және әріптестері [66] «бейнелеу функциясының көлбеуін шектеу гистограмманың биіктігін клиптеуге (қиюға) эквивалентті» (363-б.) екенін орнықтырды: егер жергілікті гистограмма жинақтаушы бейнелеу қалыптасқанға дейін белгілі бір максималды есеп мәнінде қиылса — ал қиылған артық мөлшер гистограмма бойынша қайта үлестірілсе — түрлендірудің қол жеткізуге болатын максималды көлбеуі шектеледі, онымен бірге біртекті аймақтардағы максималды шу күшеюі де шектеледі. Адаптивті Histogram Equalization-ның бұл клиптелген формасы контрасты шектелген адаптивті Histogram Equalization-ның (CLАНЕ) тікелей ізашары болып табылады — кейіннен оған Zuiderveld [67] канондық клиптеу-және-интерполяциялау алгоритмдік формасын берді — әрі дәл осы форма жаңартылған параметрлеуде pipeline-нің контраст кезеңі ретінде қабылданады. Гистограмма қиылатын биіктік — клип лимиті — сондықтан әдістің басқарушы тетігі болып табылады: ол контраст ұтысы мен шуды басу арасындағы теңгерімді орнатады. Pizer және әріптестерінің [66] өздері тиісті клиптеу деңгейлері «бейнелеу модальдылықтары мен түсіру жағдайларына қарай түрленеді» (367-б.) деп атап өтті, бұл осы диссертацияда қайталанатын ескертудің (DGL-5) алғашқы пайда болуы: клип лимиті мәндері, әрі жалпы CLАНЕ параметрлері, нақты кескін үлестірімдері мен архитектуралар үшін оңтайландырылады әрі олар арасында тасымалданады деп бекітілмейді. pipeline қолданатын клип лимитінің нақты қос шектеулі анықтамасы §2.1.2-де

шығарылады; ағымдағы бөлім тек клип лимитінің бар екенін және оның нені басқаратынын белгілейді.


Контрастты күшейтудің көз түбі кескінін талдауға елеулі әсер ететіні эмпирикалық алдын ала өңдеу әдебиетімен, біркелкі болмаса да, қолдау табады. Nayati және әріптестері [68] APTOS 2019 деректер жиынтығында бинарлық диабеттік ретинопатияны жіктеу үшін төрт CNN архитектурасы бойынша CLANE-ні жақсартылмаған кірістермен салыстыра бағалап (224×224 кірістер, жалғыз метрика ретінде ассигасу, сенімділік интервалдарынсыз жалғыз оқыту жүгірістері — ауқымы шектеулі конференция зерттеуі), CLANE EfficientNet-V4-тің тест accuracy-ін 95,57%-дан 97,83%-ға дейін көтергенін әрі VGG16 мен InceptionV3-ті де жақсартқанын хабарлады. Алайда сол зерттеу CLANE барлық төрт модельге қолданылған бірыңғай гиперпараметр конфигурациясында ResNet34-ті 12,02 пайыздық тармаққа *нашарлатқанын* хабарлады, бұл нәтижені авторлар архитектураға тән баптаудың болмауымен түсіндірді (62–64-б.). Бұл нәтиже диссертацияның контраст кезеңін орналастыру үшін шешуші маңызды: ол контрастты күшейту қадамының әсері параметрге де, архитектураға да тәуелді екенін көрсетеді, сондықтан контрастты күшейту жіктеуді бірыңғай немесе әмбебап түрде жақсартады деген ешқандай тұжырымға жол берілмейді. Дәл осы шарттылық контраст кезеңін болжамды түрде пайдалы тұрақты қадам ретінде емес, эмпирикалық сипатталуға тиіс формализацияланған, параметрленген компонент ретінде қарастыруды (§4.3.2) негіздейді. Келтірілген метрикалар APTOS 2019 бинарлық жіктеуіне 224×224 -те байланысты әрі диссертацияның EyePACS-тегі бес класты DR 0–4 міндетімен тікелей салыстырылмайды.

Тағы екі алдын ала өңдеу зерттеуі контрастты күшейту әдебиетінің ауқымын көрсетеді, бірақ дәлелдік салмағы шектеулі. Shaout пен Han [69], тек жалғыз шағын DRIVE тамырларды сегменттеу деректер жиынтығында он адамдық субъективті артықшылық сауалнамасы арқылы ғана бағаланған arXiv препринтінде, CLANE-мен араластырылған (2.0 клип лимиті және 8×8 тайл торымен қолданылған) фаззи-логика контрастты күшейту қадамы екі әдістің кез келгеніне жеке-жеке қарағанда артық көрілгенін хабарлады; бұл нәтиже контрастты күшейтудің жобалау таңдаулары торқабық кескінінің қабылданатын сапасына әсер ететінін көрсетеді, бірақ сандық метрикалар мен рецензиялаудың болмауынан бұдан күштірек қорытындыны қолдамайды. Chakka [70], орта мектеп ғылыми журналында жарияланған әрі сандық өнімділік мәндерінсіз оқыту қисықтарын ұсынатын зерттеуде, оптикалық когеренттік томография кескіндерінде — осы диссертация шектелетін көз түбі фотосуретінен өзгеше бейнелеу модальдылығында — торқабық ауруын жіктеу үшін төрт элементар алдын ала өңдеу операциясын салыстырды әрі торқабық кескіндеу әдебиетінде жүйелі алдын ала өңдеу салыстырулары бар екенін атап өту үшін ғана келтіріледі. Бұл дереккөздердің ешқайсысы бастапқы дәлел ретінде пайдаланылмайды.

Кандидаттың өзінің бұрынғы жұмысы осы тармақ ішінде контраст кезеңінің эволюциялық ізашары ретінде орналасады. Бұрын жарияланған нәтижелерде (Сапақова, Есмұхамедов және Сапақов, 2025) жаңартылған

CLANE сүзгісі — дәстүрлі тұрақты клип мәнін басқарылатын глобалды-шек тұжырымдамасымен ауыстыратын — STARE дерекқорында бес класты торқабық ауруын жіктеу үшін fine-tuned ResNet-50-мен біріктірілді әрі сол шағын, айналдырумен толықтырылған деректер жиынтығында 100% ассурасу, сезімталдық және спецификалық хабарланды. Осы диссертацияның ауқым шекараларына сәйкес, бұл мінсіз өнімділік көрсеткіші ағымдағы эксперименттік контекстке тасымалданбайды (SB-1.2): ол DR 0–4 градациялаудан өзгеше 5 ауру міндетінде, теңгерілген жиынтыққа дейін толықтырылған шамамен 150 бастапқы кескінде, артық үйренуді нақты талдаусыз алынды әрі мұнда әдістің жалпы қабілеті ретінде емес, қатаң түрде авторлардың бұрынғы нәтижесі ретінде хабарланады. Диссертация бұл ізашарды келесі тарауларда дамытылатын екі нақты тәсілмен кеңейтеді: ол жалғыз-шекті клип ережесін §2.1.2-де шығарылатын қос шектеулі клип лимиті тұжырымдамасымен ауыстырады әрі контраст кезеңін параметрлері 2-эксперименттің сезімталдық талдауымен (§4.3.2) сипатталатын біртұтас pipeline-ге (5-кезең, OD-3) біріктіреді.

(2.1-сурет)



Сурет 2.1 – Histogram Equalization → адаптивті теңестіру → контрасты шектелген (клиптелген) адаптивті теңестіру – тармақтың үш кезеңі бойынша қарқындылықты қайта үлестіру тұжырымдамасы

Қорыта айтқанда, контрастты күшейту тармағы контрасты шектелген адаптивті Histogram Equalization-ды pipeline-нің контраст кезеңінің принципті негізі ретінде орнықтырады: глобалды теңестіру қайта үлестіру қағидатын ұсынады, адаптивті теңестіру фокалды зақымдануларды ажырату үшін қажетті локалдылықты ұсынады, ал гистограмманы клиптеу арқылы көлбеуді шектеу жергілікті бейімделуді қолдануға жарамды ететін шу бақылауын ұсынады, мұнда клип лимиті контраст-шуы арасындағы теңгерімді басқаратын жалғыз параметр болып табылады. Эмпирикалық әдебиет бұл кезеңнің салдарлы, бірақ шартты, әмбебап түрде пайдалы емес екенін растайды. Қалғаны — клип лимитінің өзін формализациялау, яғни pipeline қабылдайтын қос шектеулі анықтама, бұл §2.1.2-нің тақырыбы.

§2.1.2 Қос шектеулі клип лимитімен CLANE формализациясы

§2.1.1 бөлімі контрасты шектелген адаптивті Histogram Equalization-ды pipeline-нің контраст негізі ретінде бекітіп, клип лимитін — әр тайлдың жергілікті гистограммасы оның жинақтаушы бейнелеуі қалыптасқанға дейін қиылатын биіктікті — Pizer және әріптестері [66] орнықтырған «бейнелеу функциясының көлбеуін шектеу гистограмманың биіктігін клиптеуге эквивалентті» (363-б.) эквиваленттігі негізінде контраст-пен-шу теңгерімін басқаратын жалғыз параметр ретінде оқшаулады. Сол бөлім әдейі ашық қалдырғаны — клип лимиті орнатылатын нақты ереже. Бұл бөлім сол ережені береді. Ол формализацияны үш кезеңде дамытады — кәдімгі контрасты шектейтін клип лимиті, кандидаттың бұрынғы жалғыз-шекті жаңартуы, және pipeline-нің 5-кезеңі (OD-3) қабылдайтын қос шектеулі клип лимиті — әрі әрқайсысы үшін басқарушы параметр нені бақылайтынын және келесі нақтылау қандай ақау режимін шешетінін түсіндіреді.

Кәдімгі контрасты шектейтін клип лимиті. Стандартты формуляцияда тайл үшін клип лимиті тайл гистограммасы оның қарқындылықтары біркелкі үлестірілсе ие болар биіктікке қатысты орнатылады. L дискретті сұр деңгей бойынша A пиксел ауданды (тайл-ауданы, контекстік аймақтағы пиксел саны) тайл үшін біркелкі гистограмма әр деңгейге орташа A/L есепті береді. Контрасты шектейтін клип лимиті әр гистограмма қоржынын осы орташаның еселігінде қияды,

$$CL_{conv} = \beta \cdot A/L, \quad \beta \geq 1, \quad (2.1)$$

мұнда β — клип факторы: $\beta = 1$ гистограмманы біркелкі биіктікке клиптейді (максималды контрасты шектеу), ал үлкенірек β клип іске қосылғанға дейін пропорционалды түрде көбірек контраст күшеюіне рұқсат береді. Қиылған артық тайлдың жалпы массасы сақталатындай гистограмма бойынша қайта үлестіріледі. Дәл сол контрасты шектеу қағидаты кандидаттың бұрынғы жұмысында алгебралық эквивалентті $CL = \lceil L/T \rceil + \beta(\phi - \lceil L/T \rceil)$ түрінде кездеседі, мұнда ϕ — тайлдағы пиксел популяциясы, T — шек параметрі (Сапақова, Есмұхамедов және Сапақов, 2025, 1-теңдеу, 5-б.). (2.1) теңдеуі клип факторының рөлін айқындайды: ол рұқсат етілген қоржын биіктігін *біркелкі* қоржын-ішілік есеп A/L -ге қарсы масштабтайды, бұл тайлдың қарқындылықтары L деңгейлердің көпшілігіне таралғанда ғана орташа толтырылған-қоржын биіктігінің дәл проксиі болады.

Жалғыз-шекті жаңарту (бұрынғы өз жұмысы). Бұрын жарияланған нәтижелерде кандидаттың бұрынғы жұмысы шығарылған кәдімгі клипті жалғыз басқарылатын глобалды шекпен ауыстырып, клип лимитін тікелей былай анықтады

$$CL_{T/80} = T/80, \quad (2.2)$$

мұнда T — глобалды шек мәні (Сапақова, Есмұхамедов және Сапақов, 2025, 2-теңдеу, 5-б.). Бұл жалғыз-параметрлі форма кескін айқындылығын, «әсіресе ұсақ веналарды» (5-б.) жақсартатыны хабарланды, кескін-сапасы балын кәдімгі CLANE-дегі 33,23-тен $T/80$ ережесіндегі 34,35-ке көтеріп (4-

сурет), әрі STARE дерекқорында fine-tuned ResNet-50-мен біріктірілді. Үш шектеу сол нәтиженің қазіргі диссертацияға қалай енетінін реттейді. Біріншіден, ол — бұрынғы өз жұмысы, тәуелсіз дәлел ретінде емес, бұрын жарияланған ізашар ретінде келтіріледі — әрі осы зерттеуден алынған екі әдебиет картасы (#23 және #24) дәл сол журнал мақаласын сипаттайтындықтан, олар жалғыз өзіне-сілтенген желіні құрайды әрі екі тәуелсіз растау ретінде қаралмайды (SIR-5). Екіншіден, хабарланған сезімталдық көрсеткіштері сол дереккөзде $Sen = TP/(TP+TN)$ ретінде басылған сезімталдық анықтамасына (3-тендеу, 9-б.) сүйенеді, ол стандартты $Sen = TP/(TP+FN)$ -нен ауытқиды; бұл аномалия мұнда атап өтіледі әрі дереккөздің сезімталдық мәндері салыстырмалы шамалар ретінде алға тасымалданбайды (SIR-3). Үшіншіден, шағын, айналдырумен толықтырылған STARE жиынында хабарланған тақырыптық 100% ассигура, сезімталдық және спецификалық диссертацияның эксперименттік контекстіне тасымалданбайды (SB-1.2): T/80 шегі STARE кескін үлестірімі үшін оңтайландырылды, әрі EyePACS-ке параметр деңгейіндегі тасымалданушылық жорылмайды (DGL-5).

Жалғыз-шекті форма (2.1) тендеуінен қарапайымырақ, бірақ жобаны уәждейтін құрылымдық әлсіздікті алып жүреді. T/80 әр тайлға бірдей қолданылатын жалғыз скаляр болғандықтан, ол көз түбі кескіні бойынша жергілікті қарқындылық статистикасының кең вариациясына жауап бере алмайды. (2.1) тендеуінің кәдімгі факторы тайлға жауап береді, бірақ біркелкі прокси A/L арқылы, ал ол көз түбі кескінінде мол кездесетін дәл сол аймақтарда сенімсіз: шынайы гистограммасы деңгейлердің тар жолағында шоғырланған үлкен, жуықтап біркелкі фон тайлдары. Мұндай тайлда толтырылған қоржындар A/L-ден әлдеқайда жоғары тұрады, сондықтан $\beta A/L$ ретінде орнатылған клип контраст күшеюі ең аз қажет жерде агрессивті қияды, немесе — үлкенірек β үшін — бірнеше толтырылған деңгей бойынша тік бейнелеуге рұқсат беріп, фон шуын күшейтеді. Осылайша жалғыз қоржын-ішілік фактор мен жалғыз глобалды шек толықтырушы түрде сәтсіздікке ұшырайды: біріншісі шыңды жергілікті гистограммаларды қате бағалайды, екіншісі жергілікті үлестірімді мүлдем елемейді.

Қос шектеулі клип лимиті. Pipeline мұны клип лимитін *екі* мүшемен бір мезгілде шектеп, екеуінің қатаңырағын ала отырып шешеді. $L = 256$ сұр деңгей бойынша A ауданды тайл үшін,

$$CL_{DC} = \min(\text{clip_factor} \cdot A/256, \text{global_threshold} \cdot A), \quad (2.3)$$

мұнда clip_factor және global_threshold — бапталатын гиперпараметрлер (RESEARCH_ARCHITECTURE §3.2; OD-3 5-кезең). Бірінші мүше — $L = 256$ бар (2.1) тендеуінің кәдімгі гистограммаға-қатысты клипі: ол рұқсат етілген қоржын биіктігін біркелкі қоржын-ішілік есепке қарсы масштабтап, қарқындылықтары жақсы таралған тайлдарды басқарады. Екінші мүше, $\text{global_threshold} \cdot A$, — тайлға-қатысты абсолютті төбе — бүкіл тайлдың пиксел санының тіркелген үлесі, қарқындылықтар тайл ішінде қалай үлестірілгеніне тәуелсіз. Минимумды алу шектеулерді логикалық конъюнкция ретінде әрекет еттіреді: жақсы таралған тайлда гистограммаға-қатысты мүше кішірек әрі

байланыстырады, кәдімгі контрасты шектеуді береді; қатты шындалған тайлда, гистограммаға-қатысты мүше деградациялық үлестіріммен масштабталар еді, абсолютті төбе кішірек әрі байланыстырып, жергілікті гистограмма қаншалықты шоғырланса да, қол жеткізілетін бейнелеу көлбеуін шектейді. Сондықтан қос шектеулі ереже жалғыз-параметрлі формалар нашар өңдейтін екі режимде де шу күшеюін шектейді, бұл оны контраст кезеңі ретінде қабылдаудың аналитикалық негіздемесі. Бұл негіздеме өлшенетін downstream артықшылық беретіні — бөлек, эмпирикалық сұрақ, оны 2-эксперименттің параметр сканерлеуі (§4.3.2) шешеді, әрі мұнда бекітілмейді.

Кезеңнің қалған сипаттамасы операцияларды анықтаманы ұстанады. Қос шектеулі клип лимиті LAB түс кеңістігінің L-арнасына, 8×8 тайл торы бойынша, қиылған гистограмма артығы қайта үлестіріле отырып және канондық CLANE алгоритміндегідей [67] тайл шекаралары бойынша билинеарлы интерполяциямен қолданылады; операция оқыту кезінде стохастикалық (0,8 ықтималдықпен), ал inference кезінде детерминистік қолданылады (OD-3 5-кезең). clip_factor және global_threshold екі гиперпараметрі бұл кезеңде жоба бойынша еркін қалдырылады: параметр-тасымалданушылығы ескертуіне (DGL-5) сәйкес, STARE-ден алынған T/80 нәтижесінен немесе кез келген сыртқы зерттеуден ешқандай нақты мән импортталмайды, ал pipeline пайдаланатын мәндер диссертацияның өз эксперименттік шеңбері ішіндегі тәуелсіз валидациямен таңдалғандар. Сондықтан диссертацияның формализация деңгейіндегі үлесі — (2.3) теңдеуінің қос шектеулі ережесінің өзі; бұрынғы өз жұмысы (2.2) теңдеуінің жалғыз-шекті T/80 формасын берді, оны қос шектеулі ереже қайта пайдаланбай, жалпылайды.

2.1-кесте үш формуляцияны жоба үшін маңызды өлшемдер бойынша — клип-лимит анықтамасы, ол ашатын параметрлер, оның шығу тегі және тасымалданушылығы — салыстырады.

ТАБ-2.1. CLANE клип-лимит формуляциялары: кәдімгі, жалғыз-шекті (T/80) және қос шектеулі.

Формуляция	Клип-лимит анықтамасы	Басқару параметр(лер)і	Шығу тегі	Тасымалданушылық / шектеу
Кәдімгі контрасты шектейтін	$CL = \beta \cdot A/L$ — қоржын биіктігі біркелкі қоржын-ішілік есептің еселігінде қиылады (2.1-тең.)	клип факторы β (жалғыз)	Стандартты CLANE; көлбеуді шектеу $\equiv$ клиптеу [66, 363-б.]	Біркелкі прокси A/L шыңды жергілікті гистограммаларды қате бағалайды (үлкен фон тайлдары)
Жалғыз-шекті	$CL = T/80$ — клип бір	глобалды шек T	STARE-дегі бұрынғы өз жұмысы	STARE-оптимизацияла

(Т/80)	глобалды шекпен тікелей орнатылады (2.2-тең.)	(жалғыз)	(Сапақова, Есмұхамедов және Сапақов, 2025)	нған; EyePACS-ке тасымалданады деп жорылмайды (DGL-5); әр тайлға бірдей қолданылады
Қос шектеулі	$CL = \min(\text{clip_factor} \cdot A / 256, \text{global_threshold} \cdot A)$ — гистограммаға а-қатысты және тайлға-қатысты төбенің қатаңырағы (2.3-тең.)	clip_factor және global_threshold (ekey)	Диссертация жобасы (OD-3 5-кезең; RESEARCH_ARCHITECTURE §3.2)	Параметрлер бапталатын; мәндер 2-эксп. валидацияланады (§4.3.2), тасымалданады деп жорылмайды (DGL-5); әмбебап оңтайлы деп бекітілмейді (NC-17)

Эмпирикалық алдын ала өңдеу әдебиеті бұл параметрлеу неліктен жорумен тіркелмей, сипатталуға тиіс шама ретінде қаралатынын күшейтеді. Nayati және әріптестері [68] CLANE-ні APTOS 2019-да төрт CNN архитектурасы бойынша бірыңғай конфигурацияда бағалап (бинарлық жіктеу, тек ассигасу, сенімділік интервалдарынсыз), контраст қадамы үш архитектураға көмектесіп, төртіншісін 12,02 пайыздық тармаққа нашарлатқанын тапты (62–64-б.) — берілген клип конфигурациясының downstream әсері архитектура мен баптауға тәуелді әрі түрлі деректер жиынтықтары мен міндеттер арасында салыстырылмайтынының тікелей дәлелі (SIR-3). Қос шектеулі формуляция бұл шарттылықтан құтылмайды; ол бірлескен орнатуы дәл Н-2 талап ететін сезімталдық профилін айқындау үшін 2-эксперимент сканерлейтін екі параметрді ашады.

Контраст кезеңі енді LAB L-арнасындағы параметрленген, қос шектеулі операция ретінде толық көрсетілген соң, теориялық даму шуды басудың және құрылымдық жиектерді сақтаудың толықтырушы проблемасына — §2.1.3-те қарастырылатын кеңістіктік-сүзгілеу мен шуды азайту негіздеріне — бұрылады.

§2.1.3 Кеңістіктік сүзгілеу және шуды азайту әдістері

§2.1.2-дегі контраст кезеңінің формализациясы клип лимитін контрастты күшейту кезінде шу күшеюін шектейтін тетік ретінде бекітті, бірақ ол шуды азайтудың өзінің толықтырушы төменгі деңгейлі операциясын қарастырмады.

Контрастты күшейту мен шуды азайту шиеленісте тұр: жергілікті контрастты күшейту шуды күшейтуге бейім, ал шуды басу контрастты күшейту ашуға тиіс құрылымдарды бұлыңғырлауға бейім. Бұл шиеленіс көз түбі бейнелеуінде 1-тарауда әлдеқашан орнықтырылған себеппен өткір — ерте, скрининг үшін шешуші дәрежелердің диагностикалық тұрғыдан айқындаушы белгілері, негізінен микроаневризмалар мен жіңішке тамырлар, өздері ұсақ әрі төмен контрастты, сондықтан кескінді тегістейтін кез келген операция дәл градациялау моделі сүйенетін сигналды өшіру қаупін тудырады. Тегістеуді талғаусыздың орнына мазмұнға-бейімделетін ете алатынды формализациялайтын жиекті- және құрылымды-сақтайтын сүзгілеудің теориялық негіздері сондықтан pipeline-нің төменгі деңгейлі жобасына өзекті фон, әрі осы бөлімнің тақырыбы.

Сызықты, тек домендік тегістеу сүзгісі — әр пикселді оның кеңістіктік көршілерімен олардың мәндеріне қарамастан орташалайтын — шуды азайтады, бірақ жиектерді бұлыңғырлайды әрі төмен контрастты егжей-тегжейді шайып кетеді, өйткені ол шынайы қарқындылық шекарасын шу ауытқуынан ажырата алмайды. Tomasi мен Manduchi [71] енгізген билатеральды сүзгілеу мұны орташалау салмақтарын кеңістіктік жақындықпен қатар фотометриялық ұқсастыққа да тәуелді ете отырып шешеді. Олардың формуляциясында сүзгіленген мән

$$h(x) = k^{-1}(x) \int f(\xi) c(\xi - x) s(f(\xi), f(x)) d\xi,$$

мұнда $c(\xi - x)$ кеңістіктік доменде геометриялық жақындықты, ал $s(f(\xi), f(x))$ қарқындылық диапазонында фотометриялық ұқсастықты өлшейді, сонда, авторлардың сөзімен, «тек перцептивті ұқсас түстер ғана бірге орташалаанады, әрі тек перцептивті маңызды жиектер ғана сақталады» (2-б.). Жиектер сақталады, өйткені қарқындылық шекарасы арқылы орналасқан пикселдер, фотометриялық ұқсамайтын болғандықтан, елеусіз салмақ алады әрі бір-біріне ағып кетпейді. Билатеральды сүзгі — итеративті емес, жергілікті операция; ол сандық эталондаудан гөрі аналитикалық шығару және сапалық кескін мысалдары арқылы ұсынылады, әрі авторлар оның параметрлерін автоматты таңдау ашық проблема болып қалатынын және әдістің медициналық-бейнелеу бағалауы жоқ екенін атап өтеді — сондықтан ол мұнда енгізетін қағидаты үшін келтіріледі, ешбір downstream диагностикалық ұтыс дәлелі ретінде емес.

Buades, Coll және Morel [72] құжаттаған жергілікті емес орташалау (non-local means) денойзингі ұқсастық түсінігін жергілікті көршіліктен бүкіл кескінге жалпылайды. Оның алғышарты — «берілген пикселге ең ұқсас пикселдердің мүлдем жақын болуына себеп жоқ» (209-б.): кеңістіктік көршілес пикселдерді орташалаудың орнына әдіс айналасындағы патчтары нысан айналасындағы патчка ұқсайтын пикселдерді орташалайды, ұқсастық «тек түсті ғана емес, әр пиксел айналасындағы бүкіл терезені салыстыру арқылы бағаланады» (209-б.). Кескін бойынша қайталанатын құрылымдардың — көп орында қайталанатын сол бір жиек немесе текстура — артықтығын пайдалану арқылы жергілікті емес орташалау «нәзік құрылымдар мен егжей-тегжейді сақтай отырып шуды жоятыны» хабарланды (211-б.). Билатеральды сүзгі

сияқты, ол да сандық өнімділік метрикаларынсыз немесе медициналық-бейнелеу валидациясынсыз параметр ұсыныстарын және сапалық мысалды ұсынатын алгоритм-сипаттау мақаласы, әрі дәл сол шектеулі негізде келтіріледі.

Бірге қарастырғанда, билатеральды сүзгілеу мен жергілікті емес орташалау — жалғыз проблеманың екі шешімі: ақпаратты алып жүретін құрылымдарды бұзбай шуды қалай басуға болады. Екеуі де сызықты тегістеудің талғаусыз орташалауын ұқсастықпен-салмақталған орташалаумен ауыстырады — билатеральды сүзгілеу кеңістіктік терезе ішіндегі фотометриялық ұқсастықпен, жергілікті емес орташалау кескін бойынша патч өзіне-ұқсастығымен — әрі екеуі де осылайша диагностикалық pipeline-дегі тегістеу операциясы мазмұнға-бейімделетін болуы тиіс деген талапты формализациялайды. Бұл талап — кеңістіктік-сүзгілеу әдебиетінің қазіргі жұмысқа берік үлесі; нақты алгоритмдер, медициналық емес мысал кескіндерде сапалық бағаланғандықтан, торқабық жіктеуі туралы өздері ештеңе орнықтырмайды.

Pipeline билатеральды сүзгілеуді немесе жергілікті емес орташалауды айқын кезең ретінде қабылдамайды, әрі себебі жаңа ғана сипатталған теңгеріммен үйлеседі. Жіктеудің алдына арнайы денойзер енгізу оны жұмсартуға жобаланған қауіпті алып жүреді — агрессивті тегістеу ерте дәрежелерді ажырататын төмен контрастты микроаневризмаларды өшіреді — әрі бұл қауіп дәл скрининг құндылығы ең жоғары жерде ең қолайсыз. Оның орнына pipeline шуды әлдеқашан көрсетілген екі нүктеде басқарады: контраст кезеңі қос шектеулі клип лимиті арқылы шуды күшейтудің орнына шектейді (5-кезең, §2.1.2), ол шу әйтпесе ұлғаятын біртекті аймақтарда қол жеткізілетін бейнелеу көлбеуін шектейді, ал біркелкі емес жарықтандыру адаптивті жарық-өрісі кезеңімен түзетіледі (4-кезең, OD-3). Сондықтан билатеральды сүзгілеу мен жергілікті емес орташалау формализациялайтын жиікті- және құрылымды-сақтау қағидаты бөлек компонент ретінде жүзеге асырылмай, жобалау шектеуі ретінде — бейімделіп әрекет ет, нәзік құрылымды сақта — құрметтеледі. Бұл — жобалау негіздемесі, денойзингпен толықтырылған pipeline-нен артықшылық тұжырымы емес.

Төменгі деңгейлі кескін-операция негіздері енді орнында — §2.1.1–§2.1.2-дегі контрастты күшейту және осындағы шуды азайту қағидаты — теориялық даму кескінді дайындайтын операциялардан оны тұтынатын операцияларға бұрылады: §2.2.1-де қарастырылатын конволюциялық нейрондық желінің convolution, pooling және feature-extraction механикасына.

§2.2.1 Convolution, Pooling және Feature Extraction операциялары


§2.1 бөлімдері алдын ала өңдеу кезеңдерінің көз түбі кескінін қалай дайындайтынын — клип-шектелген адаптивті схема аясында контрастты күшейтіп, ерте DR дәрежелерін айқындайтын ұсақ, төмен контрастты құрылымдарды сақтай отырып жарықтандыруды түзететінін — орнықтырды. Теориялық даму енді сол дайындалған кескінді тұтынатын модель

компонентіне бұрылады: конволюциялық нейрондық желіге (CNN), оның feature-extraction операциялары пиксел қарқындылықтарын жіктеуіш әрекет ететін репрезентацияға түрлендіреді. Бұл бөлім сол түрлендірудің механикасын — convolution, бейсызықтық және pooling, үйренілген белгі иерархиясына құрастырылған — және терең иерархияларды оқытылатын ететін байланыс жаңалықтарын орнықтырады, содан кейін көз түбі-зақымдану аясында feature extraction жобасы оның алдындағы алдын ала өңдеуден неліктен ажыратылмайтынын шығарады.

CNN-нің элементар операциясы — convolution: үйренілетін сүзгілердің шағын банкі кірістің кеңістіктік ауқымы бойынша конволюцияланады, әр сүзгі feature map тудыру үшін жергілікті рецептивті өріс бойынша салмақталған қосынды есептейді. Екі қасиет мұны классикалық нейрондық желінің тығыз (толық байланысқан) байланысынан ажыратады. Біріншіден, сүзгінің салмақтары барлық кеңістіктік позициялар бойынша ортақ, сондықтан бір орында үйренілген белгі-детекторы барлық жерде қолданылып, трансляциялық эквивариантты береді — кірістегі ығысу feature map-та сәйкес ығысу тудырады. Екіншіден, әр шығыс бірлік бүкіл кірістің емес, тек жергілікті рецептивті өрістің тәуелді болғандықтан, параметр саны сол бір кіріс бойынша тығыз қабаттан күрт төмен, бұл — үлкен кескіндерде оқытуды орындалатын ететін нәрсе. Бұл жобаның ауқымдағы өміршеңдігін Krizhevsky, Sutskever және Hinton [19] орнықтырды, олардың 60 миллион параметрлі «бес конволюциялық қабат ... және үш толық байланысқан қабат» желісі ImageNet-те алдыңғы қолмен-жасалған feature pipeline-дерінен айтарлықтай асып түсті (17,0% top-5 тест қателігін хабарлай отырып); нәтиже — табиғи-кескін эталоны, мұнда сенімділік интервалдарынсыз немесе сыртқы валидациясыз хабарланады, әрі ол ешбір медициналық-бейнелеу қорытындысы үшін емес, көрсеткен архитектуралық тетігі үшін келтіріледі.

Тағы екі операция элементар feature-extraction блогын аяқтайды. Әр convolution-нан кейін нүктелік бейсызықтық келеді; rectified linear unit (ReLU), Krizhevsky және әріптестері [19] терең CNN-дердің «tanh бірліктері бар баламаларынан бірнеше есе жылдамырақ оқуын» (3.1-бөлім) мүмкін ететінін көрсеткен, — стандартты таңдау әрі диссертация архитектураларында тұтасымен пайдаланылатын активация. Pooling — әдетте stride-пен шағын терезелер бойынша max-pooling — содан кейін әр feature map-ты кеңістіктік downsampling жасайды. Pooling екі мақсатқа қызмет етеді: ол белгінің бар болуы оның нақты позициясынан маңыздырақ болатындай жергілікті трансляциялық инварианттылықтың белгілі деңгейін береді, әрі кейінгі қабаттардың тиімді рецептивті өрісін ұлғайтып, оларды кеңірек кеңістіктік контекст бойынша интеграциялауға мүмкіндік береді. Convolution → бейсызықтық → pooling блогын қайталап қатарлау репрезентациялар иерархиясын тудырады, онда ерте қабаттар жиектер мен текстуралар сияқты төменгі деңгейлі құрылымға жауап береді, ал тереңірек қабаттар оларды барған сайын абстрактілі үлгілерге құрастырады, FIG-2.2-де схемалық бейнеленгендей.

(2.2-сурет)



Сурет 2.2 – CNN белгі-иерархиясы және convolution–pooling схемасы

Бұл иерархияның мәнерлеу қуаты тереңдікпен өседі, бірақ тереңдік еркін алынбайды. He, Zhang, Ren және Sun [23] белгілі бір нүктеден кейін «желі тереңдігі артқан сайын дәлдік қанығып, содан кейін тез нашарлайтын» төмендеу проблемасын сипаттады — артық үйрену емес, оптимизация сәтсіздігі, өйткені тереңірек жай желілер жоғарырақ оқыту қателігін көрсетті. Олардың шешімі — residual оқыту: әр блокты кірісіне сілтеме жасай отырып residual функцияны үйренуге қайта тұжырымдау, оларды, өз сөздерімен, «не қосымша параметр, не есептеу күрделілігін қоспайтын» (2-б.) сәйкестік (identity) қысқа байланыстар арқылы жүзеге асырылады. Бұл өте терең желілерді оптимизациялауды жеңілдетіп, жүз қабаттан асатын модельдерді оқытуды мүмкін етті, ал 50 қабатты bottleneck нұсқасы (ResNet-50) жалғыз-модельді 5,25% top-5 ImageNet қателігіне жетті. ResNet-50 — осы диссертацияда бағаланатын екі backbone архитектураның бірі; ол бекітілген оңтайлы ретінде емес, орнықтырылған, кеңінен қолданылатын жоба ретінде қабылданады, әрі архитектура кеңістігі бойынша толық іздеу жүргізілмейді (SB-3.1). Бұл көрсеткіштер де — статистикалық тексерусіз немесе медициналық валидациясыз табиғи-кескін эталондары.

Параллель байланыс шежіресі сол бір тереңдік-оқытылушылық проблемасына балама жауап ұсынады. Huang, Liu, van der Maaten және Weinberger [24] тығыз байланысқан желіні енгізді, онда әр қабат «барлық алдыңғы қабаттардың feature map-тарын конкатенация арқылы кіріс ретінде алады», авторлар бұл жобаны «vanishing-gradient проблемасын жұмсартатынын, белгі таралуын күшейтетінін, белгіні қайта пайдалануды көтермелейтінін және параметр санын айтарлықтай азайтатынын» хабарлады (Аннотация). Residual және тығыз байланыс мұнда бір-біріне қарсы рейтингтелмейді; олар белгі иерархиясын тереңдікте оқытылатын ұстайтын екі негізгі тетік ретінде ұсынылады, әрі §3.2-дегі диссертацияның backbone таңдаулары сүйенетін архитектуралық сөздікті — қысқа байланыстар, белгіні қайта пайдалану, параметр тиімділігі — орнықтырады. Алдыңғы архитектуралар сияқты, DenseNet тек компьютерлік-көру эталондарында ғана бағаланды, сыртқы немесе медициналық валидациясыз.

Бұл негіздер көз түбі бейнелеуі үшін диссертацияның орталық тезисіне тікелей қатысты нақты салдар алып жүреді. CNN-ге өзінің инварианттылығы мен рецептивті-өріс өсуін беретін pooling операциялары мұны кеңістіктік ажыратымдылықты тастау арқылы істейді, әрі сол жоғалтуға ең осал белгілер дәл ең ұсақтары — ерте, скрининг үшін шешуші дәрежелерді ажырататын микроаневризмалар мен нәзік тамырлық өзгерістер. Wan және әріптестері [33], диабеттік ретинопатия үшін зақымдану-сегментациясы желісін (EAD-Net) ұсына отырып, оны «ұсақ-зақымдану белгілерін сақтау» үшін арнайы тек жалғыз max-pooling кезеңін пайдаланатын етіп жобалап, оны қос назармен және кеңейтілген convolution-дармен толықтырды; солай бола тұра желінің микроаневризма сегментациясы әлсіз болды (авторлардың жергілікті деректер жиынтығында 17,32% сезімталдық; IDRiD сынағында 0,2408 AUPR), бұл нәтижені авторлардың өздері белгілейді әрі ол мұнда зерттеудің шағын деректер жиынтығын пайдаланғаны, сенімділік интервалдарын хабарламағаны және деректер жиынтығы аралық тасымалдау жүргізбегені ескертулерімен хабарланады. Қазіргі жұмыс үшін сабақ архитектуралық емес, аналитикалық: архитектуралық күрделілікті арттыру өздігінен ұсақ, төмен контрастты зақымдануларды анықтауды шешпейді, ал бұл — алдын ала өңдеу кезеңдері бөлісуге жобаланған дәл сол жүк. Бұл — диссертацияның модельді алдын ала өңдеу плюс CNN ретінде шеңберлеуінің бір нақты көрінісі — екі компонент ұсақ-зақымдану проблемасын бірге шешеді — әрі ол ешбір түпкі өнімділік әсері оқшауланған preprocessing-ке немесе архитектураға телінбейді деген шектеумен (CFC-2.8) үйлеседі.

Feature extraction, осында дамытылғандай, желінің жіктеуіш басы түптеп келгенде әрекет ететін репрезентацияны береді. Сол репрезентация қалай оқытылатыны — әрі әсіресе оқыту диабеттік-ретинопатия деректер жиынтықтарына тән қатты класс теңгерімсіздігімен қалай қалыптасатыны — loss функциясы мен оптимизация схемасымен басқарылады, оны §2.2.2 келесіде қарастырады.

§2.2.2 Теңгерімсіз медициналық деректер жиынтықтары үшін Loss функциялары мен оптимизация

§2.2.1-дің конволюциялық feature extractor-ы жіктеуіш басы класс баллдарына бейнелейтін репрезентация тудырады; сол бейнелеу қалай оқытылатыны loss функциясымен басқарылады, ал диабеттік-ретинопатияны жіктеуде loss таңдауы деректердің жалғыз қасиетімен — қатты класс теңгерімсіздігімен — басым. §1.1.1-де бекітілген бес класты DR градациялау таксономиясы іс жүзінде өткір қисайған: кандидаттың APTOS 2019 деректер жиынтығындағы бұрынғы эксперименттерінде ауру жоқ класс оқыту жиынының 73,5%-ын құраса, ауыр және пролиферативтік кластар (DR 3 және DR 4) сәйкесінше тек 2,5% және 2,0%-ын құрады (бұрын жарияланған нәтижелер; Сапақова және әріптестері, 2025; Есмұхамедов және әріптестері, 2025, олар дәл сол экспериментті хабарлайды әрі мұнда жалғыз бұрынғы-жұмыс желісі ретінде қаралады). Pratt және әріптестері [27] да 3 және 4

кластардың бірге олардың үлкен Kaggle DR оқыту жиынының «үш пайыздан азынан ... шыққанын» байқап, «ол осы кескіндердің белгілерін әлі де үйрене алатынын қамтамасыз ету» үшін әдейі өзгерістерді талап еткенін атап өтті (201-б.). Бұл бөлім мұндай қисайу аясында стандартты мақсаттың неліктен жеткіліксіз екенін және диссертация қандай теңгерімсіздікке-сезімтал баламаларды қабылдайтынын орнықтырады.

Көп класты жіктеу үшін әдепкі мақсат — softmax cross-entropy, ол жалғыз мысал үшін модель шынайы класқа теліген теріс лог-ықтималдықты жазалайды. Оқыту пакеті бойынша қосылғанда, бұл loss-тың градиенті мысалдар бойынша орташа, ал бір класс мысалдардың басым көпшілігін бергенде сол орташа басым класпен басым болады. DR үлестірімі аясындағы практикалық салдар — желі орташа loss-ты минимизациялай отырып, сирек ауыр дәрежелерді тиімді елемей, нашар азшылық-класс recall-ын жасыратын жоғары жалпы дәлдік тудыруы — әрі шектеулі деректермен асқынып, артық үйрену: кандидаттың бұрынғы жұмысы frozen-layer моделінде 0,87 оқыту F1-балын 0,62 тест F1-балына қарсы хабарлап, оны ішінара «класс теңгерімсіздігі мен ауыр жағдайлардың шектеулі ұсынылуымен» түсіндірді (бұрын жарияланған нәтижелер). Қысқасы, cross-entropy сирек, бірақ көру қабілетіне қауіп төндіретін жағдайларды анықтаудың клиникалық мақсатымен сәйкеспейтін шаманы оңтайландырады.

Шығынға-сезімтал оқыту бұл сәйкессіздікті деректер деңгейінде емес, loss деңгейінде түзетеді. Класс бойынша loss-қа қосылым салмақпен — ең қарапайымы класс жиілігінің кері мәнімен, жалпырақ түрде қате-жіктеу шығынымен — қайта масштабталады, сонда сирек кластағы қате пропорционалды үлкенірек жаза әрі тиісінше үлкенірек градиент тудырады. Нәзігірек салмақтау схемалары бар: Cui және әріптестері [73] шикі кері жиіліктің орнына «мысалдардың тиімді саны» бойынша қайта салмақтайды, таза кері-жиілік салмақтауы тудыруы мүмкін өте сирек кластарды артық-салмақтауды жұмсартады, дегенмен DR деректерінде емес, ұзын-құйрықты табиғи-кескін эталондарында. Pratt және әріптестері [27] класс салмақтауының ерте формасын әр пакеттегі ауру-жоқ кескіндердің үлесіне қатысты бапталатын динамикалық пакет-ішілік класс салмақтары арқылы жүзеге асырды. Тәсілдің ең жүйелі синтезінде Araf, Idri және Chairi [74], теңгерімсіз медициналық деректер үшін шығынға-сезімтал оқытудың 173 зерттеуін шола келе, шығынға-сезімтал оқыту қайта іріктеуге қатысты «деректер үлестірімін сақтай отырып, есептеу тиімділігін қамтамасыз ететінін» және жалған теріс нәтижелер клиникалық тұрғыдан ауыр медициналық орталарға ерекше сай келетінін хабарлады. Сол шолу — мета-талдаусыз дауыс-санау синтезі әрі диабеттік ретинопатияға тән емес, ол «тек екі зерттеу ғана валидация зерттеуі ретінде жіктелгенін» (20-б.) тапты — сондықтан шығынға-сезімтал оқыту мұнда қайта іріктеуден эмпирикалық орнықтырылған артықшылық ретінде емес, негізделген, үлестірімді-сақтайтын жобалау таңдауы ретінде қабылданады.

Оқыту хаттамасы қабылдайтын loss функциясы — focal loss, Lin және әріптестері [75] енгізген, ол салмақталған cross-entropy-ді модельдің дұрыс класқа сенімі артқан сайын кемитін мультипликативті модуляциялаушы

факторымен кеңейтеді. Әсері — желі әлдеқашан оңай жіктейтін мысалдардың — басым түрде мол ауру-жоқ кескіндердің — қосылымын төмендетіп, градиентті қиын және азшылық мысалдарға шоғырландыру, шығынға-сезімтал оқытудың класс-жиілігі салмақтауын қосымша мысал-бойынша қиындық салмақтауымен біріктіру. Диссертация focal loss-ты $\gamma = 2$ фокустау параметрімен және кері класс жиілігіне орнатылған α класс-теңгерімдеу салмағымен қолданады (әдістемеде көрсетілген және §3.3.4-тің focal-loss схемасында бейнеленген конфигурация). Lin және әріптестері [75] focal loss-ты торқабық немесе медициналық бейнелеуде емес, СОСО тығыз-нысан-анықтау эталонында енгізіп, бағалады, сондықтан ол мұнда DR зерттеуінен тасымалданған нәтиже ретінде емес, орнықтырылған loss-жоба негіздемесінің күшіне қабылданады; оның толық формализациясы, модуляциялаушы-фактор өрнегі мен параметр негіздемесін қоса, жүйенің әдістемелік компоненті ретінде көрсетілетін §3.3.4-ке шегеріледі.

Loss-ты қалыптастыратын сол теңгерімсіздік өнімділіктің қалай өлшенуі тиіс екенін де айқындайды, өйткені мақсатты бұрмалайтын басым класс ең таныс метриканы да солай бұрмалайды. Жалпы дәлдік басым ауру-жоқ класпен қампиды — әр кескінге «DR жоқ» деп болжайтын модель басым үлеске жуық балл алар еді — әрі сондықтан осы диссертацияның дәлел иерархиясында үлестірімді ескеретін метрикалардан төмен түсіріледі. Негізгі өлшемдер — салмақталған F1-балл, ROC-AUC және квадраттық салмақтары бар Cohen's κ ; соңғысы §1.1.1-де орнықтырылған реттік құрылымға әсіресе сай, өйткені оның квадраттық салмақтауы «көрші кластар арасындағы қателіктер ... алыс кластар арасындағы қателіктерден аз жазаланатынын қамтамасыз етті», бұл кандидаттың бұрынғы жұмысы атап өткендей, «жеңіл сатылар арасындағы ауысулардағы қателіктер ауыр жағдайларды жіберіп алудан аз критикалық болғандықтан, клиникалық маңызға» ие (бұрын жарияланған нәтижелер). Метриканың DR-дің реттік, тең емес-шығынды құрылымына осы туралануы теңгерімсіздік loss пен бағалау жобасының екеуін де басқарады деген ішкі-тұжырымның (§3.4 пен 4-тарауға тасымалданатын) негізі.

Класс теңгерімсіздігінің идиосинкратикалық емес, сала бойынша мәселе екенін шолу мен эталон дәлелі олардың зерттеу жобалары талап ететін ескертулермен растайды. Senapati және әріптестері [63], диабеттік-ретинопатия жасанды интеллектінің PRISMA негізіндегі жүйелі шолуында, класс теңгерімсіздігі мен артық үйренуді саланың қайталанатын әдістемелік олқылықтарының арасында айқындады; сала-картасын жасайтын шолу ретінде ол ешбір бастапқы эталондау бермейді. Arora және әріптестері [31] теңгерімсіздікті жұмсарту үшін кері іріктелген Kaggle DR жиынында 0,8653 орташа дәлдікке жететін EfficientNetB0 моделін хабарлады, бірақ 97,11% максималды оқыту дәлдігі айтарлықтай артық үйрену алшақтығын көрсетеді әрі сыртқы валидациясыз, эпистемикалық салмағы шектеулі нәтиже. Бұл EfficientNetB0 тұжырымдары, кандидаттың өз EfficientNetB0 эксперименттері сияқты, сол архитектурамен шектелген: архитектураны-жалпылау тыйымына сәйкес, олардан айқын салыстырмалы эксперименттерсіз тиімді CNN

архитектураларының кеңірек класы туралы ешқандай қорытынды шығарылмайды.

Қорыта айтқанда, DR деректерінің қатты теңгерімсіздігі салмақталмаған cross-entropy-ні жеткіліксіз етеді, шығынға-сезімтал салмақтауды және хаттама қабылдайтын focal-loss модуляциясын уәждейді, әрі бағалауды дәлдікпен емес, салмақталған F1, ROC-AUC және квадраттық салмақталған κ арқылы айқындайды. Теңгерімсіздік пен шектеулі деректер артық үйренуді де асқындырады — жоғарыда хабарланған оқыту-мен-тест алшақтықтарында әлдеқашан көрінетін — ол loss-пен емес, §2.2.3 келесіде қарастыратын регуляризация әдістерімен (dropout, batch normalization және data augmentation) бақыланады.

§2.2.3 Регуляризация әдістері: Dropout, Batch Normalization және Data Augmentation

§2.2.2-нің loss жобасы мақсатты сирек ауыр дәрежелерге қарай түзейді, бірақ ол сонда әлдеқашан көрінген теңгерімсіз, шектеулі DR деректерінің екінші салдарын шешпейді: артық үйрену, күшті оқыту өнімділігі мен әлсіздік ұсталынған өнімділік арасындағы алшақтық — кандидаттың 0,62 тест F1-балына қарсы 0,87 оқыту F1-балы бұрынғы нәтижесімен иллюстрацияланған. Регуляризация — сол алшақтықты тарылтатын әдістер отбасы. Бұл бөлім диссертация архитектураларына қатысты регуляризаторларды орнықтырады, олар үш деңгейде жұмыс істейді — желінің салмақтары, оқыту үдерісін бақылау және деректердің өзі — әрі үшінші деңгейде әрекет ететін data augmentation pipeline-ге неліктен тікелей біріктірілетінін көрсетеді.

Желінің салмақтары деңгейінде dropout — канондық регуляризатор. Оқыту кезінде ол бірліктердің бір бөлігін кездейсоқ өшіреді, бұл бірліктердің сынғыш, бірге-бапталған детекторларға бірге-бейімделуіне жол бермей, желіні артығырақ, берік репрезентацияларға қарай мәжбүрлейді. Оның маңызын алғашқы ауқымды CNN-мен бірге орнықтырды — Krizhevsky, Sutskever және Hinton [19] «dropout-сыз біздің желіміз айтарлықтай артық үйренуді көрсетеді» (§4.2) деп ашық хабарлады — әрі көп ұзамай Srivastava және әріптестері [76] формализациялады, олар dropout-ты экспоненциалды көп жұқартылған желілер бойынша орташалаудың тиімді жуықтауы ретінде сипаттады. Екеуі де — мұнда ешбір медициналық-бейнелеу қорытындысы үшін емес, тетік үшін келтірілген табиғи-кескін нәтижелері. Техника тікелей диабеттік-ретинопатия CNN-деріне өтеді — Pratt және әріптестері [27] dropout-ты соңғы конволюциялық блоктан және бірінші толық байланысқан қабаттан кейін 0,5 мөлшерде қолданды, ал кандидаттың бұрынғы жетілдірілген архитектурасы 0,4 dropout мөлшерін пайдаланды.

Batch normalization — толықтырушы салмақ-деңгейлі техника. Ioffe мен Szegedy [77] енгізген, ол қабаттың активацияларын әр оқыту пакеті бойынша нормалайды, бұл оптимизацияны тұрақтандырып, жеделдетеді әрі пакет статистикасы енгізетін шу арқылы жұмсақ регуляризациялаушы әсер береді — пакет кішірейген сайын әлсірейтін әсер, бұл — осы диссертацияның он алты

пакет өлшеміне қатысты әрі §3.2-де қайта қаралатын ескерту. Осы диссертацияның терминдерінде ол — жетілдірілген желіде бар, ал таяз базалықта жоқ архитектуралық компонент, бұл айырмашылық 4-тараудың факториалды салыстырулары үшін маңызды; Pratt және әріптестері [27] да batch normalization-ды конволюциялық қабаттардан кейін қолданды. Dropout та, batch normalization да артық үйренуді әмбебап түрде болдырмайды деп бекітілмейді; әрқайсысы — әсері эмпирикалық әрі архитектураға тәуелді үлес қосушы бақылау.

Регуляризацияның екінші деңгейі желіні емес, оқыту үдерісін бақылайды. Early stopping валидация метрикасы жақсаруды тоқтатқан соң оқытуды тоқтатып, модельдің ең жақсы жалпылау нүктесінен әрі оқыту жиынын сәйкестендіруді жалғастыруына жол бермейді; кандидаттың бұрынғы жұмысы валидация Cohen's κ « κ эпоха бойы жақсармаған кезде оқытуды тоқтатып, артық үйренуді болдырмады» (бұрын жарияланған нәтижелер; екі бұрынғы мақала дәл сол экспериментті хабарлайды әрі жалғыз бұрынғы-жұмыс желісі ретінде қаралады). Learning-rate жоспарлауы — бақыланатын метрика тегістелгенде оқыту жылдамдығын төмендету — байланысты мақсатқа қызмет етеді, әрі сол бұрынғы жұмыс ReduceLROnPlateau-ды early stopping-пен жұптады. Бұл оқыту-бақылау шаралары оқыту–тест алшақтығын азайтты, бірақ жоймады, әрі сол жұмыс одан әрі жақсарту қосымша деректер мен класс теңгерімдеуді талап ететінін айқын атап өтті — регуляризация шектеулі, теңгерімсіз деректер аясында артық үйренуді шешпей, жұмсартатынының ашық көрсеткіші.

Үшінші деңгей деректерге әрекет етеді. Data augmentation қолданыстағы кескіндерге таңба-сақтайтын түрлендірулерді қолдану арқылы қосымша оқыту мысалдарын синтездеп, тиімді деректер жиынтығын кеңейтіп, түрлендірілген факторларға инварианттылықты мәжбүрлейді. Тәжірибе тағы да Krizhevsky және әріптестеріне [19] тарайды, олар кездейсоқ қиюлар мен көлденең шағылыстарды RGB қарқындылықтарының басты-компонентке негізделген перутрбациясымен біріктірді; жобалау кеңістігі әлдеқайда кеңірек — Shorten пен Khoshgoftaar [78] шолған әрі mixup [79] мен RandAugment [80] сияқты әдістермен кеңейтілген, бәрі табиғи-кескін зерттеулері — дегенмен pipeline тек §3.1.3-те көрсетілген геометриялық және фотометриялық ішкі жиынды ғана қабылдайды. Augmentation DR CNN-дерінде стандартты: Pratt және әріптестері [27] нақты-уақыттық эпоха-бойынша augmentation қолданды (айналдыру, аудару және ығысулар), ал кандидаттың бұрынғы жұмысы айналдыру, масштабтау, ығысу, жарықтылықты түзету және қисайтуды қолданды. Ол сондай-ақ регуляризаторлар арасында §2.2.2-ге тікелей қатысты екінші функцияға қызмет етуімен ерекше: азшылық-класс кескіндерін басым-класс кескіндерінен агрессивтірек augment жасауға болатындықтан, augmentation тиімді класс үлестірімін де қайта теңгереді — артық іріктеуді ілеспе артық-үйрену жазасынсыз тиімді жұмсарту ретінде хабарлайтын жүйелі теңгерімсіздік зерттеуімен үйлеседі [81] — әрі кандидаттың бұрынғы жұмысы оны айқын «деректер жиынтығы теңгерімсіздігін шешу және вариабельділікті жақсарту» үшін қолданды. Бұл қос рөл — регуляризатор және теңгерімсіздік-жұмсарту

тетігі — augmentation сыртқы оқыту аяласы ретінде емес, pipeline-ге 6-кезең (OD-3) ретінде неліктен біріктірілетінінің себебі: тек оқыту кезеңі, ол біртұтас аффинді түрлендіруді басты-компонент түс джиттерімен және жарықтылық/контраст вариациясымен біріктіріп, соңғы нормализацияның алдында қолданылады (augmentation рендерлері мен түс-джиттер базисі §3.1.3-те құжатталған).

Регуляризация орнықтырылған соң, §2.2-нің CNN-оқыту негіздері аяқталады: §2.2.1 желінің белгілерді қалай шығаратынын, §2.2.2 оның класс теңгерімсіздігі аясында қалай оқытылатынын, ал бұл бөлім сол оқытудың артық үйренуге қарсы қалай регуляризацияланатынын бекітті. Әдістеме толық жүйені көрсете алмас бұрын қалғаны — желінің қалай *инициализацияланатыны* — fine-tuning басталмас бұрын желі нені білетінін айқындайтын transfer-learning және feature-transferability сұрақтары, оны §2.3 келесіде қарастырады.

§2.3.1 Визуалды домендер арасындағы белгі тасымалданушылығы

§2.2.3-тің регуляризация әдістері конволюциялық желінің қалай оқытылатыны туралы баянды аяқтайды, бірақ олар бастау нүктесін — оқыту басталатын салмақтарды — алдын ала жорамалдайды. Іс жүзінде бұл салмақтар сирек кездейсоқ: желі үлкен бастапқы деректер жиынтығында әлдеқашан оқытылған модельдің салмақтарынан инициализацияланып, тек содан кейін ғана мақсатты міндетке бейімделеді — Pan мен Yang [82] transfer learning ретінде жүйелеген парадигма, олар оның орталарын бастапқы мен мақсатты домен және міндет арасында не ерекшеленетіні бойынша жіктеп, нашар бастапқы-мақсатты сәйкестік теріс тасымалдау тудыруы мүмкін екенін ескертті. Алайда бұл тасымалдаудың тиімділігі автоматты емес, әрі белгі тасымалданушылығының теориясы — желінің бір доменде үйренгенінің қаншасы екіншісіне пайдалы өтетіні — диссертацияның pretraining жобасын тікелей шарттайды. Бұл бөлім сол теорияны орнықтырып, оны эксперименттік шеңбер салыстыратын екі pretraining режимін уәждеу үшін пайдаланады.

Іргелі эмпирикалық нәтиже — тасымалданушылықтың қабатқа-тәуелді екені. Yosinski, Clune, Bengio және Lipson [83] бір міндетте үйренілген белгілердің екіншісіне қаншалықты жақсы тасымалданатынын қабаттан қабатқа өлшеп, «бірінші және екінші қабаттар» міндеттер арасында «дерлік мінсіз тасымалданатынын», ал жоғарырақ қабаттар бастапқы міндетке прогрессивті мамандалатынын тапты (§4.1). Бұл ерте конволюциялық қабаттардың көпшілік визуалды домендерге ортақ жалпы құрылымды — жиектер, түстер, қарапайым текстуралар — үйренетіні, ал тереңірек қабаттардың оларды нақты бастапқы категорияларға бапталған репрезентацияларға құрастыратыны туралы қазір стандартты түсінікті ұстанады. Маңыздысы, сол зерттеу тасымалданушылықтың «базалық міндет пен мақсатты міндет арасындағы қашықтық артқан сайын кемитінін» (Аннотация) орнықтырып, нәтиже тек ImageNet-тен алынған бөлулерде, сенімділік интервалдарынсыз немесе статистикалық тексерусіз және ешбір медициналық-бейнелеу деректерінсіз

хабарланатынын — сондықтан ол торқабыққа-тән шаманы емес, жалпы қағидатты негіздейтінін көрсетті. Практикалық тұрғыдан маңызды салдар — тасымалданған белгілер, fine-tuning жасалған соң, «мақсатты деректер жиынтығында тікелей оқытылғандардан жақсырақ жалпылай алатыны» (§4.1): тасымалдау тек ыңғайлылық емес, түпкі модельді жақсартта алады.

Тасымалдаудың шамасы мен болжамдылығын архитектура ауқымында Kornblith, Shlens және Le [85] сандық бағалады, олар он алты CNN архитектурасын он екі табиғи-кескін деректер жиынтығы бойынша бағалап, ImageNet дәлдігі тасымалдау дәлдігін күшті болжайтынын тапты — тіркелген соңғы-алдындағы қабат белгілері үшін $r = 0,99$ корреляция және толық fine-tuning үшін $r = 0,96$ — fine-tuning 192 деректер жиынтығы–модель үйлесімінің 179-ында тіркелген-белгі тасымалдауынан асып түсіп, жинақталуды шамамен он жеті есе жеделдетеді. Бұл тұжырымдар да, медициналық немесе клиникалық валидациясыз табиғи-кескін жіктеуімен шектелген, жақсырақ бастапқы репрезентациялар жақсырақ тасымалданатынын және fine-tuning жалпы күштірек бейімдеу режимі екенін орнықтырады. Алайда сол зерттеу тасымалдау пайдасы мақсат ImageNet таңбаларынан алшақтаған сайын және мақсатты деректер жиынтығы өскен сайын кемитінін хабарлады — медициналық бейнелеуге тікелей қатысты ескерту.

Торқабық-көз түбі домені дәл осындай алшақ мақсат. Көз түбі фотосуреттері ImageNet-тің табиғи нысандарымен аз категория құрылымын бөліседі, сондықтан табиғи-кескін→көз түбі ығысуы — Yosinski қағидаты жоғарырақ, міндетке-тән қабаттардың — ең дискриминативті ақпаратты алып жүретін қабаттардың — тасымалдауын ең көп нашарлатады деп болжайтын үлкен домен қашықтығы. Бұл — Cherlygina, de Bruijne және Pluim [45] шектеулі бақылаумен оқыту тақырыбында шолатын орта, олар «таңбаланған деректердің жетіспеуі медициналық кескін талдауындағы басты кедергі» екенін және transfer learning оған негізгі жауаптардың бірі екенін байқайды; шолу ретінде ол түпнұсқа торқабық эталондарын қоспай, проблеманы реттейді. ImageNet белгілерінің үлкен домен алшақтығы арқылы медициналық бейнелеуге тасымалданатынының ең көп келтірілетін демонстрациясы — Esteva және әріптестері [37], олар ImageNet-те алдын ала оқытылған Inception-желісін дерматолог деңгейіндегі тері-обырын жіктеуге fine-tune жасады — домен аралық тасымалдау табысы, дегенмен торқабық көз түбі емес, дерматология кескіндерінде, сондықтан осы диссертацияның міндетінен тыс. DR міндетіне нақты тасымалдаудың дегенмен пайдалы екенін Arrieta және әріптестері [84] көрсетеді, олардың жартылай бақыланатын тәсілі тек 2% таңбаны пайдалана отырып EyePACS-те 0,94 AUC және Messidor-2-де 0,89 AUC-ке жетті — бинарлық referable-DR шеңберлеуінде тасымалдау аз таңбадан өте тиімді бола алатынының дәлелі, дегенмен жалпы кепілдік емес, жалғыз зерттеу болып қалады.

Бұл нәтижелер бір режим алдын ала артық деген ешқандай тұжырымды ақтамай, диссертацияның pretraining жобасын бірге уәждейді. Байланыстырушы transfer-learning қағидаты (DGL-6) бойынша H-1 эксперименті сол CNN backbone-дары үшін екі инициализация режимін салыстырады: ImageNet-тен

инициализацияланған базалық арна — осы бөлім жаңа ғана сипаттаған шектеулері бар домен аралық тасымалдау — және таңбаланбаған көз түбі бейнелеуінде офтальмологияға тән өзін-өзі бақылайтын алдын ала оқытудан инициализацияланған біріктірілген арна, ол репрезентацияларды мақсатты доменнің өзінде үйрену арқылы домен алшақтығын азайтады. Кез келген режим диссертацияның нақты деректер жиынтықтарына қаншалықты тасымалданатыны теориялық тұрғыдан кепілдендірілмеген әрі тек эксперименттік шеңбер ішінде эмпирикалық бағаланады; әрі біріктірілген арна базалықтан preprocessing мен pretraining осінің екеуі бойынша да ажырайтындықтан, ешбір түпкі өнімділік айырмашылығы оқшауланған pretraining-ке (немесе preprocessing-ке) телінбейді. Режим сүйенетін домен-ішілік өзін-өзі бақылайтын алдын ала оқыту теориясы §2.3.3-те дамытылады.

Олай болса, тасымалданушылық шынайы, бірақ шектеулі — төменгі қабаттарда ең күшті, домен қашықтығымен кемитін, әрі торқабық көз түбі сияқты табиғи кескіндерден алыс мақсат үшін дәл ең белгісіз. Бұл бөлім ашық қалдырғаны — оның тұжырымдары тудыратын практикалық сұрақ: тасымалданған салмақтар берілгенде, оларды қалай бейімдеу керек — тіркелген белгілер ретінде frozen ұстау ма, әлде прогрессивті unfreezing жасап, fine-tune жасау ма? Бейімдеу стратегиясының сол таңдауы — §2.3.2-нің тақырыбы.

§2.3.2 Frozen-Layer пен прогрессивті Fine-Tuning стратегиялары

§2.3.1 бөлімі тасымалданған белгілер пайдалы, бірақ шектеулі екенін орнықтырып, оның тұжырымдары тудыратын сұрақпен аяқталды: тасымалданған салмақтардан инициализацияланған желі берілгенде, сол салмақтарды мақсатты міндетке қалай бейімдеу керек? Жауап — екі полюс арасындағы спектрді алып жатқан бейімдеу стратегиясының таңдауы. Бір полюсте — frozen-base, немесе тіркелген-белгі стратегиясы: алдын ала оқытылған backbone frozen ұсталып, таза feature extractor ретінде пайдаланылады, ал мақсатты деректерде тек жаңа жіктеуіш басы оқытылады. Екіншісінде — прогрессивті fine-tuning: алдымен бас оқытылады, содан кейін backbone-ның жоғарғы қабаттары unfreeze жасалып, бейімделеді, бұл тасымалданған репрезентацияның өзіне мақсатты доменге мамандалуға мүмкіндік береді. Бұлар — түрлі конструкттар әрі осы диссертацияда тұтасымен терминологиялық тұрғыдан ажыратылып ұсталады — «feature extraction» мен «frozen-base стратегиясы» frozen полюсті, «прогрессивті» немесе «екі кезеңді fine-tuning» бейімделген полюсті білдіреді.

Transfer-learning теориясы fine-tuning-ке, әсіресе domain shift аясында, артықшылық береді. Yosinski және әріптестері [83] «белгілерді тасымалдап, содан кейін оларды fine-tune жасау мақсатты деректер жиынтығында тікелей оқытылғандардан жақсырақ жалпылайтын желілерге әкелетінін» (§4.1) хабарлап, frozen бөлу тудыруы мүмкін, бірақ fine-tuning жеңілдететін оптимизация жазасын — көрші бірліктердің бірге-бейімделуін — айқындады. Архитектура ауқымында Kornblith және әріптестері [85] fine-tuning-ті табиғи-кескін міндеттерінде 192 деректер жиынтығы-модель үйлесімінің 179-ында

тіркелген-белгі тасымалдауынан артық деп тапты. Екі нәтиже де медициналық валидациясыз табиғи-кескін жіктеуінде хабарланады, сондықтан олар торқабыққа-тән шаманы емес, күтілімді негіздейді; бірақ сол күтілім дәл мақсат бастапқыдан ең көп алшақтаған жерде ең күшті, ал оны §2.3.1 табиғи-кескін→көз түбі жағдайы ретінде айқындады.

Кандидаттың бұрынғы диабеттік-ретинопатия эксперименттері мақсатты міндеттің өзінде тікелей, дегенмен шектеулі растауды береді. Бұрын жарияланған нәтижелерде — дәл сол экспериментті сипаттайтын екі мақалада хабарланған әрі мұнда жалғыз бұрынғы-жұмыс желісі ретінде қаралатын — APTOS 2019-да бес класты DR жіктеуге бейімделген EfficientNetB0 моделі екі стратегия бойынша да бағаланды. Frozen-base конфигурациясы 0,62 тест F1-балына жетті; жоғарғы қабаттардың прогрессивті fine-tuning-і оны 0,74-ке көтерді, 12 пайыздық тармақ ұтыс, макро-орташаланған F1 0,72-ден 0,77-ге және салмақталған-орташаланған F1 0,74-тен 0,81-ге жақсарды, әрі азайған артық үйренуді көрсеткен оқыту-мен-тест алшақтығының тарылуы. Авторлар «жоғарғы қабаттарды unfreeze жасап, fine-tune жасау көрінбеген деректерде теңгерімдірек әрі берік жалпылауға әкелетінін, ал қабаттарды толық freeze жасау модельдің жалпылау қабілетін шектейтінін» қорытындылады. Екі ескерту бұл дәлелді шектейді: жалпы дәлдік екі стратегия бойынша да 0,80-де өзгеріссіз қалды (ұтыстар теңгерімсіздікке-сезімтал метрикаларда көрінеді, §2.2.2-мен үйлеседі), әрі нәтиже EfficientNetB0 архитектурасы мен APTOS деректеріне тән әрі айқын салыстырмалы эксперименттерсіз тиімді CNN архитектураларының кеңірек класына жалпыланбайды.

Осы теория мен бұрынғы дәлелдің тоғысатын күшіне сүйене отырып, жоба екі кезеңді прогрессивті fine-tuning хаттамасын — алдымен жіктеуіш басын оқыту, содан кейін backbone-ның жоғарғы қабаттарын unfreeze жасап, бейімдеу — қабылдайды, оның сипаттамасы §3.3.3-те берілген. Бұл таңдауды эксперименттік жоба ішінде дұрыс орналастыру маңызды: екі кезеңді хаттама — Н-1 конфигурациялары бойынша біркелкі қолданылатын ортақ оқыту әдісі, Н-1 салыстыруының тәуелсіз айнымалысы емес (оқыту әдістерін салыстырған ертерек гипотеза алынып тасталды). Сондықтан ол өзі базалық пен біріктірілген арналар арасында бақыланған кез келген өнімділік айырмашылығына үлес қоспайды әрі оған телінбейді.

Бейімдеу әдістерінің ерекше отбасы domain shift-ті қабатты freeze жасау арқылы емес, үйренілген репрезентация деңгейінде шешеді. Ganin және әріптестері [86] domain-adversarial оқытуды енгізді, онда gradient-reversal қабаты feature extractor-ды «негізгі оқыту міндеті үшін дискриминативті және ... домендер арасындағы ығысуға қатысты бейтарап» репрезентацияларға қарай жетелейді — таңбаны болжайтын, бірақ кірістің қай доменнен шыққаны туралы ақпарат бермейтін белгілер. Бұл — концептуалды түрде өзгеше бейімдеу стратегиясы, медициналық бейнелеуде емес, цифр және нысан эталондарында көрсетілген, әрі ол диссертацияның құрылғы-домен-ығысуын бағалауына (§4.7) салыстыру нүктесі ретінде өзекті; алайда ол қарапайым прогрессивті fine-tuning пайдаланатын Н-1 backbone-дары үшін таңдалған бейімдеу режимі емес.

Бейімдеу стратегиясы шешілген соң, эксперименттік шеңбер белсенді пайдаланатын transfer-learning негіздері — feature extraction, теңгерімсіздік аясында оқыту, регуляризация, әрі алдын ала оқытылған салмақтарды тасымалдау мен бейімдеу — орнында. Біріктірілген арна сүйенетін домен-ішілік өзін-өзі бақылайтын алдын ала оқыту §2.3.3-те бөлек қарастырылады. 2-тарау енді жіктеу эксперименттері пайдаланбайтын, бірақ өз алдына симуляцияға негізделген үлес ретінде тұратын диссертацияның жалғыз теориялық желісіне бұрылады: §2.4.1-де дамытылатын көз түбі тінінің жауабының байланысқан жылулық-оптикалық моделі.

§2.3.3 Торқабық бейнелеуі үшін домен-ішілік өзін-өзі бақылайтын алдын ала оқыту

§2.3.1 мен §2.3.2-де формализацияланған transfer-learning стратегиялары салмақтары табиғи кескіндердегі бақыланатын алдын ала оқытудан мұраланған backbone-ды берілген деп қабылдап, тек сол салмақтарды көз түбі доменіне қалай бейімдеу керектігін — frozen ма, прогрессивті fine-tune жасау ма — сұрады. Бұл бөлім диссертацияның бірінші гипотезасының біріктірілген арнасы қабылдайтын инициализацияның балама көзін дамытады: конволюциялық backbone-ды таңбаланбаған торқабық корпусында офтальмологияға тән өзін-өзі бақылайтын алдын ала оқыту, ол кез келген диабеттік-ретинопатия таңбасы көрінбес бұрын торқабыққа-сезімтал салмақтар тудырады. Бөлімнің тезисі — мұндай домен-ішілік инициализация табиғи-кескін инициализациясынан таңба-тиімдірек әрі клиникалық тұрғыдан жалпыланатынырақ болуы теориялық тұрғыдан уәждемеленген — бірақ бұл уәждеме, кепілдік емес, әрі DGL-6-мен үйлесімді ол жорылмай, диссертация шеңбері ішінде эмпирикалық бағаланады. Сондай-ақ басынан бастап айту керек: H-1-дің құрама тәуелсіз айнымалысы (CFC-2.8) бойынша бұл pretraining көзі preprocessing pipeline-мен бірге өзгертіледі; сондықтан ол тек біріктірілген конфигурацияның бір компоненті ретінде хабарланады әрі ешқашан тәуелсіз телінетін фактор ретінде алға тартылмайды.

Уәждеме медициналық бейнелеудің дерек экономикасынан басталады. Cherlygina және әріптестері [45] таңбаланған деректердің жетіспеуін медициналық кескін талдауындағы жиі кедергі ретінде сипаттап, толық аннотацияға тәуелділікті азайтатын әлсіз-бақылау парадигмаларын — жартылай бақыланатын, көп даналы және transfer learning — шолды. Өзін-өзі бақылайтын оқыту бұл логиканы бақылаушы сигналды таңбаланбаған кескіндердің өзінен шығару арқылы кеңейтеді: жалпы репрезентацияларды үйрену үшін ауқымды таңбаланбаған корпустарда сылтаулық мақсат шешіледі, олар сосын мақсатты міндет үшін шағын таңбаланған жиында fine-tune жасалады. Shurrab пен Duwairi [87], медициналық бейнелеу бойынша өзін-өзі бақылайтын оқытуды шола келе, саланы болжамдық (сылтау-міндет), контрастты және генеративті отбасыларға реттеп, мұндай әдістер қымбат медициналық аннотацияларға тәуелділікті азайтатынын — популяция

масштабындағы диабеттік-ретинопатия скринингі жұмыс істейтін дәл сол шектеуді — алға тартты.

Бұл шолулар картаға түсіретін жобалау кеңістігі негізінен табиғи кескіндерде дамытылған әдіс примаралары жиынымен толтырылған. Контрастты тәсілдер бір кескіннің augment жасалған көріністерін бір-біріне тарта отырып, түрлі кескіндерді бір-бірінен итере отырып репрезентацияларды үйренеді, SimCLR-да [88] нормаланған температурамен-масштабталған мақсатпен, ал MoCo-да [89] импульс кодтаушымен және жады кезегімен жүзеге асырылады. Негатив-еркін тәсілдер айқын негатив жұптарынан бас тартады: BYOL [90] мақсатты желіні bootstrap жасайды, ал SimSiam [91] тек stop-gradient операциясының өзі репрезентациялық коллапсты болдырмайтынын көрсетеді. DINO [92] алдын ала оқытуды өзін-өзі дистилляциялау ретінде шеңберлейді. Ақырында генеративті маскаланған модельдеу Ne және әріптестерінің [93] маскаланған автокодтаушысымен мысалданады, ол кескін патчтарының жоғары үлесін — реті бойынша 75% — маскалап, жетіспейтін пикселдерді қалпына келтіреді, бұл маңызды әрі тиімді таңба-еркін мақсат береді. Бұл нәтижелер табиғи-кескін эталондарында (негізінен ImageNet) хабарланады, сондықтан олар торқабық өнімділігін емес, қолжетімді жобалау кеңістігін орнықтырады, әрі олардың көрсеткіштері көз түбі міндетімен сәйкес келмейді (SIR-3).

Осы диссертация үшін шешуші сұрақ — *домен ішінде* — торқабық кескіндерінде — алдын ала оқыту табиғи-кескін алдын ала оқытудан жақсартатыны. Оған екі тәуелсіз дәлел желісі қатысты. Azizi және әріптестері [47], дерматология мен кеуде рентгенографиясында жұмыс істей отырып, пациент бойынша бірнеше кескіннен алынған көп-даналы позитив жұптарымен домен кескіндерінде өзін-өзі бақылайтын алдын ала оқыту жіктеуді бақыланатын ImageNet базалығынан дерматологияда 6,7% top-1 дәлдікке және кеуде рентгенографиясында 1,1% орташа AUC-ке көтеріп, таралу ығысуына беріктікті жақсартқанын хабарлады; сол зерттеу торқабық емес, дерматологиялық әрі рентгенографиялық болғандықтан, оның көз түбі бейнелеуіне тасымалдануы экстраполяция әрі мұнда тек домен аралық әдіс-деңгейлі қолдау ретінде келтіріледі (SIR-2). Тірек торқабық дәлелі — RETFound [46], шамамен 1,6 миллион таңбаланбаған торқабық кескінінде маскаланған автокодтаумен алдын ала оқытылып, содан кейін айқын таңбалармен ауру-анықтау міндеттеріне бейімделген іргетас моделі; авторлар оның салыстыру модельдерінен — контрастты базалықтар SimCLR, DINO және MoCo--ті қоса — көру қабілетіне қауіп төндіретін көз ауруларын диагностикалау мен болжауда дәйекті түрде асып түсетінін хабарлады, ең үлкен ұтыстар шектеулі таңбаланған деректер аясында. Бұл екі дереккөз бірлескен растау ретінде біріктірілмей, бөлек желілер ретінде ұсталады (SIR-5).

Бұл дәлел диссертация айқын ету тиіс архитектуралық ескертпені алып жүреді. Тірек домен-ішілік демонстрациялар — RETFound және ол сүйенетін маскаланған автокодтаушы — Vision-Transformer модельдері, ал осы жұмыста қабылданған backbone-дар — конволюциялық желілер (ResNet-50 және EfficientNet-B3, §3.2.1). Сондықтан домен-ішілік қағидат диссертация орнына ең тікелей жобалау кеңістігінің convolution-үйлесімді мүшелері арқылы

тасымалданады: контрастты және негатив-еркін отбасы (SimCLR, MoCo, BYOL, SimSiam) және Azizi және әріптестерінің [47] көп-даналы контрастты схемасы, олардың бәрі ResNet backbone-дарында жұмыс істейді. RETFound торқабық домен-ішілік алдын ала оқытуы принципі бойынша пайдалы екенін орнықтырады; сол қағидаттың convolution-нативті жүзеге асырылуы эмпирикалық таңдалады. Бірнеше мұраланған шектеу бұл уәждеменің күшін шектейді: RETFound ретроспективті, оның алдын ала оқыту корпусының құрылғы мен популяция шығу тегі толық бақыланбаған, әрі — мұнда ең өзектісі — ол ешбір preprocessing абляциясын қамтымайды, сондықтан бақыланған артықшылықты pretraining ма, әлде preprocessing ма басқаратынын төреші ете алмайды (SIR-2).

Дәл сол соңғы шектеу — диссертацияның pretraining көзін preprocessing-ке бәсекелес ретінде емес, оның серіктесі ретінде қарайтынының себебі. RETFound pretraining көзін негізгі өнімділік иінтірегі ретінде алға шығарады; сәйкесінше Н-1-дің біріктірілген арнасы офтальмологияға тән өзін-өзі бақылайтын инициализацияны preprocessing pipeline-мен біріктіріп, CFC-2.8 бойынша олардың арасында кредитті бөлудің орнына бірлескен әсерін хабарлайды. Бұл бөлімде ештеңе клиникалық-валидация тұжырымы емес: торқабыққа-сезімтал инициализация — диагностикалық құндылығы, болса да, тек 4-тараудың бақыланатын эксперименттерімен орнықтырылатын репрезентация-үйрену таңдауы. Оның теориялық негізі осында бекітілген соң, операциялық pretraining процедурасы — корпус, мақсат және convolution-нативті дана — §3.3.2-де көрсетіледі, ал оның эмпирикалық үлесі Н-1 бойынша бағаланады.

§2.4.1 Көз түбі тінінің жауабының байланысқан жылулық-оптикалық моделі

§2.3 арқылы дамытылған негіздер — алдын ала өңдеу операциялары, конволюциялық feature extraction, класс теңгерімсіздігі аясында оқыту, регуляризация және transfer learning — барлығы 4-ші және 5-ші тараулардың диагностикалық-жіктеу эксперименттерімен тікелей пайдаланылады. Бұл бөлім эпистемикалық регистрдің әдейі өзгеруін белгілейді. Ол көз түбі тініндегі лазерлік фотокоагуляцияның байланысқан жылулық-оптикалық моделін ұсынады: жіктеу жүйесінен бөлек тұратын, диабеттік ретинопатияның *диагностикасынан гөрі емдеуіне* қатысты, әрі — мұны басынан бастап айту керек — эксперименттік немесе клиникалық деректермен валидацияланбаған және ешбір клиникалық-деңгейлі тұжырым жасамайтын сапалық модель болып табылатын *теориялық*, симуляцияға негізделген үлес. Ол мұнда бұрын жарияланған өз жұмысы ретінде (KazUTB хабаршысында хабарланған модельдеу зерттеуі, 2024), тәуелсіз белгілеуде қайта өрнектеліп ұсынылады, әрі оның мәртебесі — қосалқы теориялық үлес; ол Н-1-ден Н-7-ге дейінгі гипотезаларға немесе диагностикалық өнімділік туралы кез келген тұжырымға қатысты емес.

Модельдің клиникалық уәждемесі лазерлік фотокоагуляцияда жатыр, ол — диабеттік ретинопатияның стандартты терапиясы, онда фокусталған лазер энергиясы аномальды торқабық тамырларының пролиферациясын тоқтату үшін акуыз коагуляциясын тудырады. Тиімді терапия айналадағы сау тінді сақтай отырып, нысанды коагуляциялауға жеткілікті энергия жеткізуді талап етеді, әрі бұл теңгерім лазер энергиясының қалай сіңірілетініне және нәтижесіндегі жылудың көз түбінің гетерогенді, қабатты құрылымы бойынша қалай таралатынына тәуелді. Сәйкесінше модельдеу проблемасы — берілген қуаты, дақ өлшемі және ұзақтығы бар лазер импульсі тінде тудыратын кеңістіктік-уақыттық температура өрісін болжау — оптикалық ішкі-модельді (қанша энергия қайда тұндырылады) жылулық ішкі-модельге (сол энергия жылу ретінде қалай диффузияланады) байланыстыратын проблема.

Оптикалық ішкі-модель түсетін сәуленің кеңістіктік профилінен басталады. Лазер Гаусс көлденең қарқындылық үлестірімі бар деп қабылданады,

$$I_0(r) = P/(\pi a^2)\exp(-r^2/a^2),$$

мұнда P — лазер қуаты, a — сәуле дағының радиусы, r — сәуле осінен радиалды қашықтық (бұрынғы модельдеу зерттеуінің формуляциясы бойынша, 7-теңдеу). Сәуле тінге енген сайын, оның қарқындылығы Бер–Ламберт заңы бойынша тереңдікпен әлсірейді,

$$I(r,z) = I_0(r)\exp(-\int_0^z \beta(r,\xi)d\xi),$$

мұнда z — тереңдік, $\beta(r,\xi)$ — тіннің кеңістіктік өзгертін сіңіру коэффициенті (2-теңдеу). Экспонентадағы интеграл жол бойынша сіңіруді жинақтайды, сонда алдымен кездесетін беткейлік тін терең тінге қарағанда түсетін энергияның үлкенірек үлесін ұстайды.

Оптикадан жылуға байланыс энергия-баланс қатынасы арқылы жасалады. Элементар ΔV көлемі бойынша сәуледен Δt уақыт аралығында сіңірілген энергия жергілікті температураны тіннің көлемдік жылу сыйымдылығы C_0 -ға пропорционал көтереді,

$$\Delta V \cdot C_0(x,y,z) \cdot \Delta T(x,y,z) = W \Delta t,$$

мұнда W — көлемдегі сіңірілген қуат (3-теңдеу). Мұны әлсіреген қарқындылықпен біріктіру сіңіру тұндыратын температура көтерілуін береді,

$$\Delta T(x,y,z) = (I_0 \exp(-\int_0^z \beta d\xi) \beta(x,y,z) \Delta t) / C_0(x,y,z) \sigma(x,y,z),$$

онда жергілікті сіңіру коэффициенті β берілген қарқындылықты тұндырылған жылуға айналдыратын көз мүшесі ретінде әрекет етеді (4-теңдеу). Жұқа тереңдік өсімі бойынша баяу өзгертін сіңіру коэффициенті үшін бөлшекті сіңіру $1 - \exp(-\int_z^{z+\Delta z} \beta d\xi) \approx \beta(r,z) \Delta z$ түріне (5-теңдеу) жеңілдейді, бұл көз мүшесін дискреттеу үшін шешілетін етеді.

Бұл сіңірілген-энергия температура көтерілуі жылулық ішкі-модельдің өзіне, кеңістіктік өзгертін қасиеттері бар жылу өткізгіштік теңдеуіне, бастапқы шартты береді,


$$C_0 \sigma(x, y, z, T) (\partial T) / (\partial t) = \nabla \cdot (k(x, y, z, T) \nabla T),$$

мұнда k — жылу өткізгіштік, тін біркелкісіздігін бейнелеу үшін позиция мен температурамен өзгеруге рұқсат етілген, ал бастапқы өріс тұндырылған көтерілу ΔT -ні базалық тін температурасымен біріктіреді (8-теңдеу). Бұрынғы зерттеу бұл теңдеуді NumPy және SciPy кітапханаларымен Python-да жүзеге асырылған айқын ақырлы-айырымдық схемамен сандық шешті, шекаралық шарттар сәуле осінен жылу энергиясы оларға жетпейді деп жорылатындай алыс орналастырылды.

Хабарланған симуляция нәтижелері сапалық. Модельденген тін қабаттары бойынша беткейлік тін (қасаң қабық) беткейге жуық жоғары энергия сіңіруіне байланысты тез қызатыны, ал тереңірек қабаттар (тамырлы қабық пен торқабық) баяу қызып, салыстырмалы тұрақты температураға жететіні, температура өрісі шамамен нөлден 4,5 секундқа дейінгі экспозиция аралығында дамитыны табылды. Ешбір нақты сандық температура мәндері, зақымдану шектері немесе қателік шектері хабарланбады; тұжырымдар кестеленген шамалардан гөрі жылу карталары мен температура-тереңдік және температура-уақыт графиктері арқылы ұсынылады. Бұрынғы зерттеу өз нәтижелері «лазерлік терапияны қолданудың тиімділігін растайтынын» және тәсіл «жақсартылған клиникалық нәтижелерге әкеле алатынын» айтты; модельдеу нәтижелерін экстраполяциялауға қарсы ережемен үйлесімді, бұлар осы диссертацияның валидацияланған тұжырымдары ретінде емес, сол дереккөз жасаған мәлімдемелер ретінде тіркеледі.

Модельдің эпистемикалық шектеулерін айқын ету қажет, өйткені олар оның қалай пайдаланылатынын айқындайды. Модель сапалық әрі эксперименттік немесе клиникалық өлшеулермен валидацияланбаған, сондықтан ол эксперименттік валидацияланған клиникалық модельді құрамайды әрі ешбір клиникалық-деңгейлі тұжырымды қолдамайды. Оның құрылысы ауқымын шектейтін жеңілдетуші болжамдарға сүйенеді: тіннің оптикалық және жылулық қасиеттері экспозиция кезінде статикалық деп қаралады, коагуляцияның өзі тудыратын қасиет өзгерістерін елемейді; әр көз түбі қабаты нақты тіннің мойындалған біркелкісіздігіне қарамастан біртекті деп модельденеді; Гаусс сәулесінің профилі тіркелген ұсталып, шашырау мен сәуле бұрмалануын қалдырады; әрі, ерекше атап өтерлігі, жылу өткізгіштік теңдеуінде қан-перфузия мүшесі жоқ — торқабық пен тамырлы қабық қанының ағынымен конвективті жылу алып кетуді бейнелейтін Пеннестің биожылу үлесі жоқ, дегенмен перфузия бұл тамырлы тінде физиологиялық тұрғыдан елеулі. Дәлел базасы да жұқа: модель кандидат бірге авторланған жалғыз бұрынғы жарияланыммен қолданылады, сыртқы растаусыз. Байланысқан модельдің концептуалды құрылымы — оптикалық әлсіреу қабаттар бойынша жылулық диффузияны қоректендіреді — FIG-2.4-те жинақталған.

(2.4-сурет)



Сурет 2.4 – Лазер–тін өзара әрекеттесуінің байланысқан жылулық-оптикалық моделі – Гаусс-сәуле қарқындылығы, Бер–Ламберт тереңдік әлсіреуі және көз түбі қабаттары бойынша жылу өткізгіштігі

Диссертация дәлелі ішінде бұл модель айқын шектелген орынды алады. Ол — лазерлік фотокоагуляцияның емдеу-жағындағы физикасына қатысты қосалқы, теориялық үлес, лазер параметрлерінің жылулық өрісті қалай қалыптастыратыны туралы пайымдау негізі ретінде ұсынылған, әрі ол диссертацияның эмпирикалық, жіктеуге бағытталған нәтижелерінің арасында емес, теориялық маңыздылығының мәлімдемесінде көрінеді. Ол диссертацияның басты мәселесі болып табылатын біріктірілген preprocessing–CNN диагностикалық жүйесінен эпистемикалық тұрғыдан тәуелсіз. Бұл теориялық желі өзінің тиісті шектеріне қойылған соң, тарау диагностикалық жүйеге және оның болжамдарының интерпретацияланушылығына оралады, §2.5.1-дегі класс активациясын картаға түсіру мен Grad-CAM формализациясынан бастап.

§2.5.1 CAM / Grad-CAM теориясы және формализациясы

§2.4.1-дің тек симуляциялық жылулық моделін өзінің тиісті, шектелген орнына қойған соң, тарау диагностикалық жүйеге және оның клиникалық тұрғыдан пайдаланылуы үшін ие болуы тиіс қасиетке оралады: интерпретацияланушылыққа. Конволюциялық жіктеуіш дәреже шығарады, бірақ скрининг шешімін қолдау құралы сол дәреже үшін дәлелі кескінде қайда жатқанын көрсете алса, әлдеқайда сенімдірек. Бұл бөлім диссертация сол мақсат үшін пайдаланатын әдістер отбасын — класс активациясын картаға түсіруді және оның градиентке негізделген жалпылауларын — формализациялайды әрі осы әдістер нені орнықтыратынының қатаң шегін басынан бастап бекітеді: класс активация картасы желінің соңғы конволюциялық қабатындағы градиентпен-салмақталған активация аймақтарын көрсетеді; ол — интерпретация визуализациясы, зақымдану шекараларының пиксел деңгейіндегі клиникалық сызбасы емес (NC-14).

Шежіре класс активациясын картаға түсіруден (CAM) басталады, оны Zhou және әріптестері [50] енгізді. Олардың түсінігі архитектуралық болды: егер соңғы конволюциялық feature map-тар жіктеу қабатының алдында тікелей global average pooling арқылы қысқартылса, онда k feature map-ты c класымен байланыстыратын үйренілген жіктеу салмағы w_k^c сол feature map-тың кеңістіктік активацияларына $f_k(x,y)$ кері проекцияланып, класс активация картасын құра алады,

$$M_c(x,y) = \sum_k w_k^c f_k(x,y),$$

ол, авторлардың сөзімен, класс үшін «әр кеңістіктік орындағы активациялардың маңыздылығын тікелей көрсетеді». Zhou және әріптестері [50] global average pooling «CNN-дердің тек кескін деңгейіндегі таңбалармен оқытылса да локализация қабілетін сақтауын мүмкін ететінін» көрсетіп, ImageNet-те әлсіз бақыланатын локализацияға жетті. Әдіске екі шектеу серіктес: ол желінің global-average-pooling соңғы-алдындағы кезеңімен құрылуын талап етеді (әрі сондықтан жиі қайта оқытылуын), әрі оның әлсіз бақыланатын локализациясы, елеулі болса да, толық бақыланатын локализациядан айтарлықтай нашар қалды — медициналық-бейнелеу бағалауы жоқ табиғи-кескін эталон нәтижесі.

Selvaraju және әріптестері [51] енгізген Grad-CAM архитектуралық шектеуді жіктеу салмақтарын градиенттермен ауыстыру арқылы алып тастайды. c мақсатты класы және A^k конволюциялық feature map үшін сол map-тың маңыздылығы y^c класс баллының map активацияларына қатысты градиентінің глобалды орташасы ретінде есептеледі,

$$\alpha_k^c = 1/Z \sum_i \sum_j (\partial y^c) / (\partial A_{ij}^k),$$

ал локализация картасы ректификатор арқылы өткізілген feature map-тардың салмақталған комбинациясы ретінде құрылады,

$$L^c_{\text{Grad-CAM}} = \text{ReLU}(\sum_k \alpha_k^c A^k).$$


Ректификатор тек класс баллына оң ықпал ететін белгілерді ғана сақтап, оған қарсы дәлелдейтін аймақтарды басады. Салмақтар нақты pooling құрылымынан емес, кері тарату арқылы алынғандықтан, Grad-CAM мәні бойынша кез келген конволюциялық архитектураға модификациясыз немесе қайта оқытусыз қолданылады, әрі ол GAP желілері үшін дербес жағдай ретінде CAM-ге дейін қысқарады.

Grad-CAM++ [52] салмақтауды одан әрі нақтылайды. Класс-балл градиенттерін кеңістіктік позициялар бойынша біркелкі орташалаудың орнына, ол пиксел-бойынша градиент салмақтарын жоғары-реттік туынды мүшелерінен шығарады, бұл авторлар хабарлағандай «жақсырақ нысан локализациясын, сондай-ақ жалғыз кескіндегі бірнеше нысан данасының пайда болуын түсіндіруді» береді. ImageNet адалдық бағалауында ол түсіндірме-маскалау кезіндегі орташа класс сенімі құлдырауын 46,56%-дан (Grad-CAM) 36,84%-ға дейін азайтты. Бұл көрсеткіштер мұнда дереккөздің табиғи кескіндердегі эталон салыстыруы ретінде хабарланады — зерттеу — шағын адам-бағалау когортымен (он үш қатысушы) және медициналық немесе сыртқы

валидациясыз arXiv препринті — әрі диссертация бекітетін жалпы рейтинг ретінде емес; диссертацияның Grad-CAM нұсқалары арасындағы таңдауы — 3-тарауда тіркелген әдістемелік шешім, мұнда жасалған артықшылық тұжырымы емес.

Бұл формуляциялар арасындағы схемалық қатынас — класс дәлелінің соңғы-қабат активацияларына проекциясы, Grad-CAM жалпылауында градиентпен-салмақталған — FIG-2.3-те жинақталған.

(2.3-сурет)



Сурет 2.3 – Grad-CAM математикалық формуляциясы – соңғы конволюциялық feature map-тардың ReLU-мен градиентпен-салмақталған комбинациясы

Диссертацияның бұл әдістерді пайдалануы үшін шешуші нүкте — оларды шектейтін бейтұжырым (non-claim). Grad-CAM картасы соңғы конволюциялық қабаттың кеңістіктік ажыратымдылығында — кіріс кескінге қатысты дәрежі — есептеледі әрі визуализация үшін upsampling жасалады; ол болжанған класс үшін градиентпен-салмақталған активация қайда шоғырланатынын бөлектейді. Ол зақымдануларды сегменттемейді әрі патология қайда екенінің пиксел деңгейіндегі диагностикалық анықтамасын бейнелемейді. Сондықтан диссертация кейінірек Grad-CAM активацияларын пиксел деңгейіндегі зақымдану масктарымен салыстырғанда, жоғары қабаттасу дәрежесі модельдің назары клиникалық тұрғыдан өзекті құрылымдарға бағытталғанының дәлелі ретінде оқылуы тиіс, модель патологияны клиникалық локализациялағанының немесе клиницистше пайымдағанының демонстрациясы ретінде емес. Бұл айырмашылық (NC-14) осы карталардың кез келген кейінгі қолданысына байланыстырушы әрі §2.5.3-тің қабаттасу талдауы анықтау эталоны емес, интерпретация өлшемі ретінде шеңберленуінің себебі.

Локализация картасы формальды анықталған соң, екі сұрақ қалады. Біріншісі — мұндай картаны қалай *интерпретациялау* керектігі — ол оқырманға нені қорытуға рұқсат береді, нені бермейді — оны §2.5.2 қарастырады. Екіншісі — оны шынайы зақымдану аннотацияларына қарсы қалай *сандық бағалау* керектігі, назар-зақымдану қабаттасуы және Intersection-over-Union метрикалары арқылы, оны §2.5.3 4-тарауда эксперименттік пайдаланудан бұрын формализациялайды.

§2.5.2 Назар картасын интерпретациялау

§2.5.1-дегі формализация локализация картасын тудырды; бұл бөлім мұндай картаны заңды түрде нені білдіреді деп қабылдауға болатынын қарастырады. Сұрақ кездейсоқ емес, өйткені скрининг контекстіндегі назар картасының құндылығы толығымен оқырманның одан шығаруға құқылы қорытындыларының күшіне тәуелді, ал жылу картасы торқабық кескініне сенімді түрде жапсырылғанда артық оқу нақты қауіп. Мұнда қорғалатын интерпретация әдейі консервативті: Grad-CAM картасы желінің болжанған класс үшін дәлелі қайда шоғырланғанын көрсетеді, одан күштіні ештеңе көрсетпейді.

Карта заңды түрде көрсететіні — класс-дискриминативті активация. Құрылысы бойынша ол соңғы конволюциялық белгілерді олардың нақты класс баллына ықпалы бойынша салмақтайды, сондықтан жоғары жауап аймағы — активациясы алып тасталса, модельдің болжанған дәрежеге сенімін ең көп азайтатын аймақ. Бұл — шынайы әрі пайдалы сигнал: ол модель сүйенген аймақтарды ол тиімді елемендерден ажыратады, әрі ол жалпы көрнектілік емес, класқа тән. Дәл осы негізде назар картасы *ақылға қонымдылық* туралы пайымдауды — модельдің дәлелі клиницист өзекті деп санайтын торқабық құрылымдарына түсе ме — қолдай алады, ол 4-тараудың сапалық талдауында атқаратын рөл.

Үш қасиет сол пайымдауды шектейді. Біріншісі — ажыратымдылық. Карта соңғы конволюциялық қабаттың кеңістіктік ажыратымдылығында есептеледі, ол кіріс кескінге қатысты дөрекі, әрі сосын көрсету үшін *upsampling* жасалады; сондықтан оның көрінетін шекаралары жуықтық. Ең ұсақ диагностикалық тұрғыдан шешуші зақымданулар — ерте дәрежелерді айқындайтын микроаневризмалар — дәл шектелмей-ақ дұрыс назарға алынуы мүмкін, сондықтан зақымдану-пішінді өткір активацияның болмауы зақымдану жіберіп алынғанының дәлелі де емес, диффузды активация дәлсіз пайымдаудың дәлелі де емес. Екіншісі — әдіс пен қабатқа тәуелділік. Карта қай қабаттың активациялары пайдаланылатынына және градиенттердің қалай салмақталатынына тәуелді; салмақтау схемасы нәтижені айтарлықтай өзгертетінін Grad-CAM++ [52] көрсетеді, оның пиксел-бойынша қайта-салмақтауы Grad-CAM-ге қатысты локализацияны және «сол кластың бірнеше пайда болуын» өңдеуді жақсартатыны хабарланды. Олай болса, назар картасы — модель-және-әдіс жұбының қасиеті, тек модельдің абсолютті оқылымы емес, әрі салыстырулар тек әдіс тіркелген кезде ғана мағыналы.

Үшінші әрі ең елеулі қасиет — активация мен патология арасындағы алшақтық, ол — осы тақырыптағы диссертацияның байланыстырушы бейтұжырымының (NC-14) мәні. Шоғырланған класс-дискриминативті активация аймағы — патология сонда орналасқанының анықтамасы емес. Желі зақымдануының өзіне емес, аурумен қатар кездесетін контекстке, немесе көрінісі дәрежемен себепсіз байланысқан құрылымдарға назар аударуы мүмкін; мұндай әлсіз бақыланатын локализация, Zhou және әріптестері [50] класс активациясын картаға түсіру үшін хабарлағандай, тіпті табиғи кескіндерде де

толық бақыланатын локализациядан айтарлықтай аз дәл қалады. Сондықтан назар картасы клиницист-аннотациялаған зақымданумен қабаттасқанда, сол қабаттасу модельдің назары клиникалық тұрғыдан өзекті құрылымдарға бағытталғанын меңзейтін дәлел — бірақ ол модель патологияны локализациялағанының немесе диагностикалық пайымдағанының дәлелі емес, әрі кері жоғары-қабаттасу оқылымы жасалмауы тиіс.

Бұл интерпретациялық шектеулер назар карталарының пайдалылығын кемітпейді; олар оларды пайдалы ететін регистрді бекітеді. Назар картасы «модельдің класс дәлелі қайда шоғырланды, әрі бұл ақылға қонымды ма?» деген сұраққа жауап береді — интерпретация мен сенім сұрағы — әрі ол «патология қайда?» деген сұраққа жауап бермейді, ол клиникалық анықтамаға тиесілі. Карталарды бірінші сұраққа ұстау олардың қолданысын адал ұстайтын нәрсе. Назар мен аннотацияланған зақымданулар арасындағы қатынасты шамаға айналдыру — «ақылға қонымдылықты» тек тексеру емес, өлшеуге болатындай — айқын қабаттасу метрикаларын талап етеді, әрі сол метрикалар, назар–зақымдану қабаттасуы мен Intersection-over-Union, §2.5.3-те формализацияланады, онда олар да анықтау эталоны ретінде емес, интерпретация өлшемдері ретінде шеңберленеді.

§2.5.3 Сандық explainability метрикалары ретінде ALO және IoU

§2.5.2 бөлімі назар картасының интерпретациясын ақылға қонымдылық туралы пайымдаумен — модельдің класс дәлелі клиникалық тұрғыдан өзекті құрылымдарға түсе ме — шектеп, сол пайымдауды санға айналдыру айқын қабаттасу өлшемін талап ететінін атап өтті. Бұл бөлім диссертация пайдаланатын осындай екі өлшемді формализациялайды: назар–зақымдану қабаттасуы (ALO), оның негізгі explainability метрикасы, және Intersection-over-Union (IoU), қосалқы өлшем ретінде сақталған. Екеуі де Grad-CAM активациясының бинарлық маскаға шектелген кеңістіктік аймағын пиксел деңгейіндегі зақымдану аннотациясымен салыстырады, әрі екеуі де клиникалық локализацияның анықтамасы емес, интерпретация өлшемдері (NC-14).

Негізгі метрика зақымдануға қатысты анықталады. Назар–зақымдану қабаттасуы — назар аймағы қамтитын аннотацияланған зақымдану ауданының үлесі,

$$ALO = (\text{area}(\text{Grad-CAM} \cap \text{lesion mask})) / (\text{area}(\text{lesion mask})),$$

сонда ALO модельдің класс-дискриминативті активациясы аннотацияланған зақымданудың бүкіл бетіне түскенде бірге жуықтайды, ал ол басқа жерге түскенде нөлге жуықтайды. ALO жоба бойынша асимметриялы әрі зақымдануға-сілтенген: ол қызығушылық тудыратын жалғыз интерпретация сұрағын қояды — модель зақымдануға назар аудара ма? — әрі диссертацияның explainability гипотезасы (H-5) бойынша негізгі explainability метрикасы.

Қосалқы метрика симметриялы. Intersection-over-Union қиылысуды екі аймақтың *біріктіруіне* нормалайды,

$$IoU = (\text{area}(\text{Grad-CAM} \cap \text{lesion mask})) / (\text{area}(\text{Grad-CAM} \cup \text{lesion mask})),$$

назар қамти алмаған зақымдану ауданын да, зақымданудан тыс шашыраған назар ауданын да жазалайды. IoU нысан анықтаудан шығады, онда Everingham және әріптестері [94] PASCAL VOC эталоны үшін анықталған шектеу қорабы шынайы қораппен қабаттасуы жартыдан асқанда дұрыс деп саналатын конвенцияны — $\text{area}(B_p \cap B_{gt})/\text{area}(B_p \cup B_{gt}) > 0.5$ — орнықтырды, ал Rezatofighi және әріптестері [95] кейіннен IoU-ды «қабаттаспайтын жағдайларды қоса, барлық мүмкін жағдайларда градиент беретіндей» жалпылап, IoU-дың өзінің қабаттаспайтын пішіндер үшін «IoU мәні нөл болатынын әрі екі пішіннің бір-бірінен қаншалықты алыс екенін бейнелемейтінін» атап өтті. Екеуі де медициналық-бейнелеу бағалауы жоқ arXiv/эталон нысан-анықтау сілтемелері, әрі олар мұнда тек қабаттасу анықтамасы үшін келтіріледі, ешбір торқабық нәтижесі үшін емес.

ALO-ны IoU-дың орнына негізгі метрика ретінде таңдау §2.5.1–§2.5.2-де орнықтырылған назар карталарының табиғатынан тікелей туындайды. Grad-CAM картасы соңғы конволюциялық қабаттың дәрекі ажыратымдылығында есептеледі әрі класс-дискриминативті, сондықтан құрылысы бойынша оның шектелген аймағы кез келген жалғыз зақымданудың нақты шекарасынан шығуға бейім. IoU сияқты симметриялы метрика сол шығуды қате ретінде қарайды, зақымдану маскасынан тыс жатқан активацияны біріктіру бөлгішіне есептейді; сондықтан назар картасы — өзіне тән болғандай — зақымданудан дәрекірек болғанда, ол шынайы назар–зақымдану сәйкестігін жүйелі түрде төмен бағалайды. ALO тек зақымдану ауданына сілтене отырып, зақымдану *қамтуын* өлшейді әрі бұл дәрекілікке төзімді, сондықтан ол негізгі. IoU қатаңырақ, қосалқы тексеру ретінде сақталады: ALO назардың зақымдануды қамтитынын растайтын жерде, IoU қосымша сол назардың айналасынан гөрі зақымдануға қаншалықты шоғырланғанын хабарлайды, бірақ жоғары ALO-мен қатар жүретін төмен IoU модельдің локализация сәтсіздігі ретінде емес, түсіндірме әдісінің ажыратымдылығының қасиеті ретінде интерпретацияланады.

Маңыздысы, екі метриканың да бірі анықтау эталоны емес, әрі IoU-ды нысан анықтаудан алу анықтау интерпретациясын импорттауға жол бермеуі тиіс. Нысан анықтауда IoU шегі нысан *табылды* ма деп төреші етеді; мұнда IoU мен ALO дәрекі интерпретация жылу картасы мен аннотация арасындағы сәйкестікті сандық бағалайды, әрі жоғары мән модельдің назары клиникалық тұрғыдан өзекті құрылымдарға бағытталғанын көрсетеді, модель патологияны локализациялағанын немесе анықтағанын емес. Бұл — §2.5 арқылы жүретін байланыстырушы бейтұжырымның (NC-14) метрика-деңгейіндегі көрінісі: explainability қабаттасуы — интерпретация сигналы, ал IoU критерийі ол бастапқыда анықтаған анықтау шегі ретінде емес, алынған қабаттасу өлшемі ретінде пайдаланылады.

Бұл анықтамалар explainability формализациясын аяқтайды. Метрикалар құрылған салыстыру — preprocessing pipeline базалыққа қатысты назар–зақымдану қабаттасуын көтере ме, Н-5 қоятын $ALO_{\text{preproc}} > ALO_{\text{baseline}}$ шарты — эмпирикалық сұрақ, ол 4-эксперимент (§4.5) үшін сақталған, онда ол IDRiD зақымдану масктарына қарсы сандық бағаланып, клиникалық деректер

жиынтығында сапалық иллюстрацияланады; мұнда ешбір осындай нәтиже бекітілмейді. Контрастты күшейту, CNN оқыту, transfer learning, жылулық модель және explainability енді формализацияланған соң, бір теориялық желі қалады: preprocessing pipeline-нің кескіннің өзіне — кез келген жіктеуіштен тәуелсіз — әсері бағаланатын кескін-сапасы метрикалары, оны §2.6 дамытады.

§2.6 Алдын ала өңдеуді бағалауға арналған кескін-сапасы метрикалары: CNR, VVI, Entropy, SSIM

§2.5.3-тің explainability метрикалары оқытылған жіктеуіштің қасиетін — оның назары қайда түсетінін — өлшейді. Бұл соңғы теориялық бөлім басқа түрдегі метрикаларға бұрылады, олар алдын ала өңдеуден кейінгі *кескіннің* қасиетін, кез келген жіктеуіштен тәуелсіз өлшейді. Уәждеме диссертацияның preprocessing-ті модель компоненті ретінде шеңберлеуіне тән: егер preprocessing pipeline кездейсоқ деректерді дайындау емес, модельдің интегралды бөлігі болса, оның әсері ол тудыратын кескінде тікелей бақыланатын болуы тиіс, тек downstream дәлдіктен тұжырымдалмауы тиіс. Жіктеуіштен тәуелсіз көріністі қалаудың әдістемелік себебі де бар. Біріктірілген-pipeline гипотезасы бойынша базалық пен толық-pipeline арналары бірден көп ось бойынша ажырайды, сондықтан жіктеу өнімділігіндегі өзгеріс оқшауланған preprocessing-ке телінбейді (эксперименттік тарауларда толық дамытылған шектеу); ал кескін-деңгейлі метрика, керісінше, preprocessing кезеңдерінің кескінге іс жүзінде не істейтінін оқшаулайды. Осында анықталған төрт метрика сол мақсатқа қызмет етеді, әрі олар қосымша дәлел ретінде хабарланады — pipeline мінез-құлқы туралы ақпаратты, бірақ өздері негізгі диагностикалық гипотезаларды орнықтыруға немесе жоққа шығаруға қабілетсіз.

Бірінші метрика, контраст-пен-шу қатынасы (CNR), диагностикалық тұрғыдан өзекті құрылымдардың фонынан кескін шуы деңгейіне қатысты қаншалықты жақсы ерекшеленетінін сандық бағалайды — операциялық тұрғыдан тамыр мен фон аймақтары арасындағы орташа қарқындылық айырмашылығы фон шуымен нормаланған. CNR дәл жарықтандыру мен контраст кезеңдері жақсартуға жобаланған қасиетті бағыттайды: адаптивті жарық-өрісін түзету (4-кезең) жергілікті контрастты басатын төменгі жиілікті жарықтандыру градиенттерін жояды, ал 5-кезеңнің контрасты шектелген адаптивті Histogram Equalization-ы шуды-шектейтін клип лимиті аясында жергілікті контрастты күшейтеді, сондықтан CNR осы кезеңдерден кейін өсуі күтіледі. Бұл күтілім — мұнда бекітілген нәтиже емес, 2-экспериментте тексерілуге тиіс жоба гипотезасы.

Екінші метрика, тамыр көрінушілік индексі (VVI), сол құрылымдарды сигнал қатынасынан гөрі анықталушылық тұрғысынан қарастырады: ол өңделген кескінде торқабық тамыр жүйесінің қаншалықты анық ажыратылатынын өлшейді. Торқабық тамырлары — көз түбіндегі ең контраст-сезімтал құрылымдар әрі ең диагностикалық ақпаратты құрылымдардың қатарында, әрі олар жарық-өрісі мен контраст кезеңдерінен ең тікелей әсер алатын құрылымдар, сондықтан VVI, CNR сияқты, preprocessing аясында

жақсаруы күтіледі. CNR мен VVI бірге pipeline әсерінің *жақсарту* жағын сипаттайды.

Үшінші метрика, кескін энтропиясы, өңделген кескіннің ақпарат мазмұнын оның қарқындылық үлестірімінен өлшейді. Диссертация глоссарийі тіркегендей, энтропия «контрастты күшейткеннен кейін артуы күтіледі, бұл қарқындылық диапазонының көбірек пайдаланылуын бейнелейді»: төмен контрастты кескін пикселдерінің көпшілігін қарқындылықтардың тар жолағында ұстайды, ал контрастты күшейту оларды кеңірек диапазон бойынша таратып, қарқындылық гистограммасының энтропиясын көтереді. Сонымен энтропия §2.1.1 Histogram Equalization үшін механизмдік тұрғыдан сипаттаған қайта үлестіру әсерінің үлестірім-деңгейлі қорытындысын береді.


Төртінші метрика басқа әрі қажетті функцияны орындайды. CNR, VVI және энтропия жақсартуды марапаттаса, Wang және әріптестері [96] кескін-сапасын бағалау үшін құрылымдық-ұқсастық өлшемі ретінде енгізген құрылымдық ұқсастық индексі (SSIM) түпнұсқа кескін құрылымының қаншасы өңделген кескінде сақталатынын өлшейді. SSIM күзет ретінде енгізілген: контрастты күшейтуді тым алысқа алып барып, артефактілер енгізуге немесе анатомиялық құрылымды бұрмалауға болады, ал тек контрастты марапаттайтын метрика мұндай зақымды анықтамас еді. Өңделген мен түпнұсқа кескін арасындағы жоғары SSIM жақсартудың құрылымдық ақпаратты ойдан шығармай немесе бұзбай сақтағанын растайды, сонда басқа үш метрика хабарлайтын ұтыстар бұзушы артық-өндеуді емес, шынайы жақсартуды бейнелейді. Сондықтан төрт метрика толықтырушы: үшеуі pipeline көрінушілікті қаншалықты жақсартатынын өлшейді, ал төртіншісі мұны құрылымдық зақымсыз істейтінін тексереді.

Бұл метрикалардың дәлелдік мәртебесі мен дереккөзі екеуі де ашық айтылуы тиіс. Диссертацияның дәлел иерархиясында олар қосалқы: олар preprocessing кескінге не істейтінін сипаттап, pipeline мінез-құлқын интерпретациялауды қолдайды, бірақ §2.2.2-нің жіктеу метрикаларына сүйенетін негізгі диагностикалық гипотезаларды тәуелсіз орнықтыра немесе жоққа шығара алмайды. Олардың әдебиет негіздемесі де жұқа әрі диабеттік-ретинопатияға тән емес, жалпы: SSIM дереккөзінде торқабық қолданысы жоқ жалпы кескін-сапасы эталонынан [96] шығады, ал контраст-пен-шу қатынасы мен тамыр көрінушілік индексі — диссертация корпусында арнайы бастапқы дереккөзі жоқ, осы жұмыс үшін әдістемеде операциялық анықталған стандартты сигнал- және құрылым-деңгейлі конструкттар (TAB-3.3, §3.4.1). Бұл жұқа, жалпы-мақсатты дереккөз жасырылмай, мойындалады: метрикалар DR-валидацияланған өлшемдер ретінде ұсынылмай, орнықтырылған кескін-талдау құралдары ретінде пайдаланылады. Дегенмен көз түбіне тән кескін-сапасын бағалау — өз алдына орнықтырылған зерттеу саласы — Zago және әріптестері [9] деректер жиынтықтары бойынша жалпыланатын (DRIMDB және ELSA-Brasil) торқабық-кескін-сапасы жіктеуішін оқытты — бұл кескін сапасы өлшенетін, торқабық-доменді қасиет екенін растайды, дегенмен сол зерттеу осында пайдаланылатын нақты CNR мен VVI конструкттары үшін бастапқы дереккөз беруден гөрі жалпы кескін градацияланушылығын бағалайды.

Байланысты, бірақ бөлек отбасы — модель-калибрлеу метрикалары, Guo және әріптестері [97] формализациялаған Expected Calibration Error мен Brier Score — кейде сапа өлшемдерімен топтастырылады, бірақ ерекше: олар болжанған ықтималдықтардың сенімділігін, жіктеуіштің қасиетін сандық бағалайды, әрі осында анықталған кескін-сапасы метрикаларымен емес, диагностикалық метрикалармен бірге жатады.

Төрт кескін-сапасы метрикасы арасындағы концептуалды қатынас — үш жақсарту өлшемі бір құрылымдық-сақтау күзетіне қарсы теңгерілген — FIG-2.5-те жинақталған.

(2.5-сурет)



Сурет 2.5 – Алдын ала өңдеуді бағалауға арналған кескін-сапасы метрикалары — CNR, VVI және энтропия жақсарту өлшемдері ретінде SSIM-мен құрылымдық-сақтау күзеті ретінде теңгерілген

Бұл метрикалар диссертация талап ететін теориялық аппаратты аяқтайды. Олардың формальды анықтамалары TAB-3.3-те (§3.4.1) шоғырландырылған әрі олар pipeline кезеңдеріне, flat-field σ сканерлеуін қоса, 2-экспериментте (§4.3.3) қолданылады, онда жоғарыда айтылған күтілімдер жорылмай, тексеріледі. Контрастты күшейту, кеңістіктік сүзгілеу, конволюциялық feature extraction, loss пен регуляризация, transfer learning, жылулық-оптикалық модель, explainability, әрі енді preprocessing-бағалау метрикалары барлығы формализацияланған соң, диссертацияның теориялық негіздері орнықтырылады. §2.С-дегі 2-тарау қорытындылары бұл негіздерді синтездеп, эксперименттік-негізделген желілерді жалғыз теориялық, тек симуляциялық желіден ажыратады.

§2.С 2-тарау бойынша қорытындылар

2-тарау диссертацияның қалған бөлігі сүйенетін теориялық негіздерді берді. 1-тарау зерттеу проблемасын орналастырып, оған жауап ретінде біріктірілген preprocessing–CNN шеңберіне міндеттенген жерде, бұл тарау сол шеңбердің әр компонентіне оның математикалық және теориялық негізін берді,

сонда 3-тараудың әдістемесі мен 4-ші және 5-ші тараулардың эксперименттері бекітілмей, берік негізде көрсетіліп, интерпретациялана алады.

Тараудың үлкен бөлігі эмпирикалық тараулар тікелей пайдаланатын негіздерді дамытады. §2.1-дің контрастты-күшейту шежіресі — Histogram Equalization-нан адаптивті теңестіру арқылы CLANE-нің контрасты шектелген, қос шектеулі формуляциясына дейін, жиекті-сақтайтын шу-бақылау қағидатымен бірге — pipeline-нің алдын ала өңдеу кезеңдерін негіздейді. §2.2-нің конволюциялық-желі теориясы — convolution, pooling және белгі иерархиясы; оны қатты класс теңгерімсіздігі аясында оқытатын loss функциялары; және нәтижесіндегі артық үйренуді бақылайтын регуляризация — жіктеуішті және оның оқытуын негіздейді. §2.3-тің transfer-learning теориясы — белгілердің қабатқа-тәуелді, доменмен-шектелген тасымалданушылығы, frozen-base пен прогрессивті fine-tuning арасындағы таңдау, әрі біріктірілген арнаны инициализациялайтын домен-ішілік өзін-өзі бақылайтын алдын ала оқыту (§2.3.3) — желі салмақтарының инициализациясы мен бейімделуін негіздейді. §2.5-тің explainability формализациясы — CAM мен Grad-CAM құрылысы, назар карталарының шектелген интерпретациясы, әрі назар-зақымдану қабаттасуы мен Intersection-over-Union метрикалары — интерпретация талдауын негіздейді. Ал §2.6-ның кескін-сапасы метрикалары — контраст-пен-шу қатынасы, тамыр көрінушілік индексі, энтропия және құрылымдық ұқсастық — preprocessing компонентін бағалаудың жіктеуіштен тәуелсіз құралын береді. Бұл желілердің әрқайсысы тек іргелі: олар шеңберлейтін эмпирикалық сұрақтар — CLANE сезімталдық профилі, біріктірілген-pipeline салыстыруы, деректер жиынтығы аралық тасымалдау, назар-зақымдану қабаттасуы және кескін-сапасы өзгерісі — 4-ші және 5-ші тарауларға сақталған әрі мұнда болжанбайды.

Бір желі эпистемикалық мәртебесі бойынша бөлек тұр. §2.4-тегі көз түбі тінінің байланысқан жылулық-оптикалық моделі — диабеттік ретинопатияны диагностикалық жіктеуден гөрі оның лазерлік-фотокоагуляциялық емдеуіне қатысты теориялық, тек симуляциялық үлес. Ол сапалық, жалғыз бұрынғы жарияланыммен қолданылады әрі — ұсынылуында атап өтілгендей — эксперименттік немесе клиникалық деректермен валидацияланбаған; ол — диссертацияның басты мәселесі болып табылатын біріктірілген диагностикалық жүйеден эпистемикалық тәуелсіз қосалқы үлес, әрі ол тек солай алға тасымалданады.

Ешбір теориялық желі шешілмей қалмады. Біріктірілген арнаның инициализациясы астарында жатқан торқабық бейнелеуі үшін домен-ішілік өзін-өзі бақылайтын алдын ала оқыту (§2.3.3) — арнайы бастапқы дереккөздердің болмауынан ертерек шегерілген жалғыз желі болатын; ол дереккөздер v6.1.0 корпус кеңейтуінде алынды, әрі бөлім содан бері §2.3-тің қалған бөлігімен қатар жазылды. Ол біріктірілген арнаның офтальмологияға тән инициализациясын, тиімділігі мұнда жорылудан гөрі 4-тарауда эмпирикалық орнықтырылатын репрезентация-үйрену таңдауы ретінде, негіздейді. §2.3.3 орнында болғандықтан, 2-тарау мазмұны толық:

эксперименттік тараулар талап ететін әр негіздің теориялық негізі орнықтырылған.

Бұл негіздер орнықтырылған соң, диссертация өзінің әдістемесін көрсетуге дайын. 3-тарау preprocessing pipeline-ді §2.1-дің контраст пен шу-бақылау теориясында, ResNet-50 және EfficientNet-B3 архитектураларын §2.2-нің конволюциялық теориясында, pretraining мен екі кезеңді fine-tuning хаттамасын §2.3-тің transfer-learning теориясында, ал көп-метрикалы бағалау шеңберін §2.5 пен §2.6-ның explainability және кескін-сапасы теориясында құрады. Осы тарауды басқарған эпистемикалық тәртіптер — Grad-CAM клиникалық локализация емес, интерпретация құралы екені; preprocessing параметрлері мен тасымалдау тасымалданады деп жорылмай, бағаланатыны; біріктірілген pipeline әсері ешбір жалғыз факторға телінбейтіні; әрі негізгі метрикалар теңгерімсіздікке-сезімтал метрикалар екені — сол әдістемеге өзгеріссіз тасымалданады.

3 ИНТЕГРАЦИЯЛАНҒАН PREPROCESSING-CNN PIPELINE ЖОБАЛАУ ӘДІСТЕМЕСІ


§3.1.1 Pipeline кезеңдерінің сипаттамасы: 8 кезеңді жүйе

2-тарау 1-тарауда міндеттенген диагностикалық шеңбердің әр компонентінің теориялық негіздерін берді — жақсарту кезеңдері артындағы контраст және шуды-азайту теориясын, жіктеуіш артындағы конволюциялық және оптимизация теориясын, оның инициализациясы артындағы transfer-learning теориясын, әрі оның бағалауы артындағы explainability және кескін-сапасы теориясын. Бұл тарау сол негіздер қолдайтын әдістемені, preprocessing pipeline-нен бастап, көрсетеді. Сипаттаманы ұйымдастырушы міндеттеме — осы жұмыстың орталық тезисінде айтылған тұжырым: диагностикалық модель — екі кезеңді жүйе, $model = preprocessing + CNN$, онда preprocessing кезеңі қосалқы деректерді дайындау емес, модельдің интегралды компоненті: ол конволюциялық желіге қолжетімді белгі кеңістігін айқындайды әрі сондықтан желінің нені үйрене алатынын бірге айқындайды (CENTRAL_THESIS; IT-1). Preprocessing-ті модельдің бөлігі ретінде формализациялау шешімі, ең алдымен, осы диссертация даналайтын біріктірілген preprocessing–CNN парадигмасымен (P2 парадигмасы) уәжделген концептуалды шешім; төменде келтірілген сегіз реттелген кезең — сол міндеттеменің инженерлік жүзеге асырылуы.


Бұл концептуалды шешім ол ажырайтын балама әдістемелік тәжірибеге карама-қарсы ең анық көрінеді. End-to-end парадигмасында (P1 парадигмасы), оның канондық өкілі ретінде осы диссертацияда Gulshan және әріптестері [13] қабылданады, preprocessing қосалқы деректерді дайындау ретінде қаралады: жарияланған әдістер preprocessing егжей-тегжейін қосымша материалға шегеріп, әдістемелік екпінді архитектураға, дерек ауқымына және оқыту хаттамасына орналастырады [13]. Бұл — бақыланатын әдістемелік тәжірибенің

сипаттамасы, сол авторларға preprocessing туралы қандай да бір теориялық тұжырымды телу емес (SIR-9). Қазіргі жұмыс қарама-қарсы әдістемелік таңдау жасайды: ол pipeline-ді кейіннен желіге қолданатын дәл сол қатаңдықпен көрсетеді, pipeline-ді бақыланатын эксперименттік қарама-қарсылыққа қояды (1-эксперимент, §4.2), әрі оны абляцияланатын кезеңдерге ыдыратады (2-эксперимент, §4.3). Әр кезеңнің сол pipeline-дегі орнын ақтайтыны — сол эксперименттер үшін сақталған эмпирикалық сұрақ; осы бөлімнің міндеті — сұрақты қоюға болатындай конструктты жеткілікті дәл анықтау. Осында көрсетілген pipeline — OD-3-тің канондық сегіз кезеңді конфигурациясы.

Pipeline — детерминистік, ретке-тәуелді түрлендіру: әр кезең өзінің алдындағысының шығысын тұтынады, әрі тізбекті нәтижені өзгертпей қайта реттеуге болмайды. 0-ден 5-ке дейінгі кезеңдер мен 7-кезең әрқашан, оқыту мен inference уақытында да қолданылады; 6-кезең (augmentation) тек оқыту уақытында қолданылады. End-to-end тізбегі 3.1-суретінде, ал оның downstream жіктеуішпен қатынасында 3.14-суретінде көрсетілген. Сегіз кезең төменде орындалу ретінде көрсетіледі.



Сурет 3.1 – 8 кезеңді preprocessing pipeline шолуы (тік)



Сурет 3.14 – End-to-end модель блок-схемасы, model = preprocessing + CNN

0-кезең — Канондық аудару (flip). Сол және оң көздің көз түбі кескіндері бір-бірінің шамамен айналы кескіндері: оң көзде оптикалық диск макуланың темпоральды оң жағында, ал сол көзде оның сол жағында жатады. 0-кезең әр сол-көз кескінін оң-көз канондық бағдарына (оптикалық диск онда, макула солда) көлденең аудару арқылы бұл латералдылық еркіндік дәрежесін жояды; оң-көз кескіндері өзгеріссіз өтеді. Көз латералдылығы қолжетімді жерде

кескін метадеректерінен, әйтпесе эвристикалық анықтаудан алынады. Кезең әрқашан қосулы. Оның негіздемесі — желінің әлуетін белгілі, алынатын геометриялық симметрияға емес, ауруға-қатысты вариацияға жұмсау, әрі кейінгі айналу-нормализация кезеңіне дәйекті бастау бағдарын беру (3.2-сурет).

Stage 0 — Canonical Flip

LEFT EYE ONLY

INPUT

RGB uint8 · H × W × 3

+ eye laterality $s \in \{\text{left}, \text{right}, \text{unknown}\}$

OPERATIONS

1. Read laterality s from metadata
2. If $s = \text{"left"}$ → horizontal mirror flip
3. If $s = \text{"right"} / \text{unknown}$ → pass-through

Purpose: unify orientation so the optic disc always lies on the right (right-eye convention)

PARAMETERS

— (no tunable parameters)

OUTPUT

RGB uint8 · H × W × 3


right-eye orientation

Сурет 3.2 – 0-кезең – канондық аудару (C→O)

1-кезең — Оптикалық диск–фовеа айналу нормализациясы. 1-кезең екі анатомиялық бағдарды анықтап, олардың арасындағы осьті горизонтальға туралау арқылы жазықтық-ішілік айналуды стандарттайды. Оптикалық диск көз түбінің ең жарық келісімді аймағы ретінде, ал фовеа оптикалық дискке қатысты қашықтық алғышартына бағынатын ең қараңғы аймақ ретінде локализацияланады; содан кейін кескін оптикалық диск-пен-фовеа осі

горизонталь болатындай айналдырылады. Кезең әрқашан қосулы, бірақ ол айқын төмен-сенімділік fallback-ін алып жүреді: бағдарды анықтау сенімсіз деп бағаланғанда айналу өткізіліп жіберіліп, $\sigma = 13,0^\circ$ fallback айналу дисперсиясы пайдаланылады. 6-кезеңнің augmentation айналу дисперсиясы, жоба бойынша, тіркелгеннен гөрі осы анықтаудың белгісіздігінен алынып, кескін бойынша адаптивті (OD-3 1-кезең).

Бұл классикалық-көру анықтау қадамының сенімділігі жорылмай, тәуелсіз эталондық координаталары қолжетімді IDRiD деректер жиынтығында (516 кескін) тікелей өлшенді; жабындау монтажы 3.10-суретінде, ал сандық нәтижелер валидация жазбасында (RES-VAL) ұсынылған. Сол нәтижелердің төмендегі талдауы — диссертацияның өзінікі. Оптикалық дискті локализациялау орташа болды: детектор дискті эталоннан бір оптикалық-диск радиусы шегінде оқыту-бөлігі кескіндерінің 67,3%-ында және тест-бөлігі кескіндерінің 61,2%-ында, ал жарты радиус шегінде сәйкесінше 34,9% және 32,0%-ында орналастырды, медианалық ығысуы шамамен 237–260 пиксель. Фовеаны локализациялау, керісінше, сенімсіз болды: детектор фовеаны эталоннан бір оптикалық-диск радиусы шегінде оқыту-бөлігі кескіндерінің 0,0%-ында және тест-бөлігі кескіндерінің 0,97%-ында орналастырды, медианалық ығысуы реті бойынша бес оптикалық-диск радиусы. Тағы бір тұжырым — детектордың ішкі confident жалаушасы бұл жиында ақпаратсыз болды — ол кескіндердің 100%-ы үшін сенімділік хабарлады әрі сондықтан сәтті локализацияларды сәтсіздерден ажырата алмады. Бұл өлшеулер IDRiD-пен (жалғыз деректер жиынтығы, Kowa камерасы, 516 кескін) шектелген әрі жалпыланады деп бекітілмейді (DGL-1). Алайда олар — 1-кезеңнің консервативті жобасының эмпирикалық негіздемесі: сенімді фовеа локализациясы жорылмайтындықтан, кезең мейірімді нашарлайтын етіп құрылған — сенімді, бірақ қате-тураланған айналудан гөрі өткізу-және-fallback жолын және белгісіздікке-адаптивті augmentation дисперсиясын артық көреді (3.3-сурет).



Сурет 3.10 – OD/фовеа детекторын валидациялау монтажы (IDRiD, 516 кескін)

Stage 1 — OD-Fovea Rotation

ALWAYS ON

INPUT

RGB uint8 · H × W × 3

right-eye-oriented from Stage 0

OPERATIONS

1. Detect OD centre (green-channel bright-region percentile threshold)
2. Detect fovea centre (darkest macular region within search window)
3. Compute $\theta = \angle(\text{OD} \rightarrow \text{Fovea}, \text{x-axis})$
4. Rotate image by $-\theta$

PARAMETERS

OD: top-percentile (green-channel)

Fovea: search window relative to OD

OUTPUT

RGB uint8 · H × W × 3

retinal axis aligned to horizontal

Сурет 3.3 – 1-кезең – OD-фовеа айналу нормализациясы

2-кезең — Көру-өрісін қию және изотропты өлшемін өзгерту. Көз түбі кескіндері гетерогенді ажыратымдылықтар мен аспект қатынастарымен келеді, дөңгелек көру өрісі (FOV) әр камерамен басқаша кадрланады. 2-кезең Hough-шеңбер сәйкестендіруінің орнына алдыңғы-панды анықтау процедурасын пайдаланып кескіннің алдыңғы планын — жарықтандырылған көз түбі дискін — анықтайды, FOV аймағына дейін қияды, әрі оны изотропты түрде ортаға толтырылған нөл-padding-пен 512×512 кенепке масштабтайды. Изотропия — операциялық қасиет: екі осьті де бірдей фактормен масштабтау көз түбінің дөңгелек геометриясын және зақымданулардың шынайы аспект қатынасын сақтайды, сонда микроаневризма анизотропты өлшем өзгертумен эллипске

созылмайды. 512×512 ажыратымдылық пен ортаға-толтыру конвенциясы әр деректер жиынтығы үшін тіркелген, желіге геометриялық тұрғыдан дәйекті кіріс кадрын береді. Кезең әрқашан қосулы (3.4-сурет).

Stage 2 — FOV Crop + Isotropic Resize

ALWAYS ON

INPUT

RGB uint8 · $H \times W \times 3$

OPERATIONS

1. Detect FOV bounding box (PIL foreground / brightness threshold)
2. Crop with margin m around (cx, cy, R)
3. Isotropic scale: $2R \rightarrow 512$ px
4. Centre zero-pad to 512×512

Contrast with baseline: baseline uses stretch-resize, distorting fundus geometry.

PARAMETERS

target = 512×512 · preserve aspect ratio

OUTPUT

RGB uint8 · $512 \times 512 \times 3$

circular FOV preserved + zero-padding map

Сурет 3.4 – 2-кезең – FOV қию + изотропты өлшемін өзгерту

3-кезең — Көру-өрісі маскасын генерациялау. 2-кезең енгізген ортаға-толтыру мәні торқабық ақпаратын алып жүрмейтін көз түбі емес пикселдердің жиегін жасайды. 3-кезең бұл айырмашылықты бинарлық маска — пиксел шынайы көз түбі деректері болғанда 1,0, толтыру болғанда 0,0 — генерациялау және оны кескінге төртінші кіріс арна ретінде қосу арқылы айқын етеді. Маска 2-кезеңде өлшемі өзгертілген кескінмен қатар тудырылады әрі әрқашан қосулы. FOV-ды желінің көз түбі шекарасын пиксел қарқындылықтарынан

тұжырымдауына қалдырудың орнына айқын арна ретінде алып жүру — pipeline-нің аталған жобалау белгілерінің бірі (RESEARCH_ARCHITECTURE §10): ол downstream жарық-өрісін түзетуге (4-кезең) және нормализацияға (7-кезең) тек шынайы торқабық пикселдерінде жұмыс істеуге мүмкіндік береді, әрі желіге жарамды деректер қайда аяқталатынының бір мәнді сигналын береді (3.5-сурет).

Stage 3 — FOV Mask Generation

SIDE BRANCH

INPUT

padding map / FOV geometry from Stage 2

OPERATIONS

1. $M[i, j] = 1.0$ if pixel inside FOV
 $M[i, j] = 0.0$ if pixel is zero-padding
2. Optional Gaussian smoothing of mask boundary (soften hard edge)

Routed in parallel to Stages 4–6, then
appended as 4th channel at Stage 7.

PARAMETERS

mask values $\in \{0.0, 1.0\}$

OUTPUT

float32 mask · 512 × 512

$M \in \{0.0, 1.0\}$

Сурет 3.5 – 3-кезең – FOV маскасы (4-ші арна)

4-кезең — Жарық-өрісін түзету. Көз түбі кескіндері патологияға қатысы жоқ, бірақ жіктеуіш оқуға тиіс төмен контрастты микроваскулярлық сигналмен бәсекелесетін баяу өзгертін жарықтандыру градиенттерін — виньеттеу мен біркелкі емес жарқыл қамтуын — көрсетеді. 4-кезең мұны жергілікті фонның

катты бұлыңғырланған бағасын алып тастап, қарқындылық диапазонын қайта ортаға келтіру арқылы түзетеді,

$$\text{corrected} = \text{image} - \text{GaussianBlur}(\text{image}, \sigma) + 128,$$

бұлыңғырлау масштабы кескін геометриясына адаптивті $\sigma = 0,07 \times D$ ретінде орнатылады, мұнда D — 3-кезең маскасынан алынған пикселдегі FOV диаметрі. Түзету тек FOV маскасының ішінде қолданылады, сонда нөл-padding жиегі бағаға тартылмайды. σ -ны абсолютті пикселде тіркеудің орнына кескін-бойынша FOV диаметріне байлау — кезеңнің айқындаушы таңдауы: ол түрлі бастапқы ажыратымдылықтардан қиылып, өлшемі өзгертілген кескіндер бойынша фон бағасының кеңістіктік масштабын торқабыққа қатысты тұрақты ұстайды. Кезең әрқашан қосулы; өнімділіктің σ факторына $0,05 \cdot D - 0,10 \cdot D$ диапазоны бойынша сезімталдығы 2-экспериментте (§4.3.3) эмпирикалық сипатталады әрі мұнда бекітілмейді (3.6-сурет).

Stage 4 — Adaptive Flat-Field

ALWAYS ON

INPUT

RGB uint8 · 512 × 512 × 3

OPERATIONS

1. Estimate background illumination

$B = \text{GaussianBlur}(I, \sigma)$

2. Subtract: $I' = I - B + 128$

3. Clip to valid range [0, 255]

σ is adaptive to FOV geometry — replaces the fixed $\sigma = 45$ from V4.

PARAMETERS

$\sigma = 0.07 \cdot D$ (D = FOV diameter)

sweep range in Exp 2: $\sigma \in [0.05, 0.10] \cdot D$

OUTPUT

RGB uint8 · 512 × 512 × 3

uniform illumination, vignetting removed

Сурет 3.6 – 4-кезең – адаптивті жарық-өрісін түзету

5-кезең — Контрасты шектелген адаптивті Histogram Equalization (CLANE). 5-кезең §2.1.2-де теориялық дамытылған қос шектеулі формуляцияны пайдалана отырып жергілікті контрастты күшейтеді. Әр тайл үшін клип лимиті екі шектеудің қатаңырағы ретінде орнатылады,

$$CL = \min(\text{clip_factor} \cdot \text{tile_area}/256, \text{global_threshold} \cdot \text{tile_area}),$$

LAB түс кеңістігінің L-арнасына қолданылған 8×8 тайл торы бойынша, операция оқыту кезінде стохастикалық (0,8 ықтималдық), ал inference кезінде детерминистік қолданылады (OD-3 5-кезең). LAB жарықтылық арнасында жұмыс істеу реңкті ауыстырмай контрастты күшейтеді; оқыту уақытындағы стохастикалық қолданыс жақсартуды бақыланатын вариабельділік көзіне

айналдырады. Қос шектеулі ереженің және оның екі гиперпараметрінің толық негіздемесі — §3.1.2-нің тақырыбы; мұнда маңыздысы — параметрлер кез келген сыртқы зерттеуден импортталмайды — кандидаттың бұрынғы жұмысында STARE-де валидацияланған параметрлер EyePACS-ке тасымалданады деп жорылмайды (DGL-5) — олар диссертацияның өз шеңбері ішіндегі валидациямен тіркеледі. Кезең әрқашан қосулы (3.7-сурет).

Stage 5 — Dual-Constraint CLAHE

STOCHASTIC

INPUT

RGB uint8 · 512 × 512 × 3

OPERATIONS

1. RGB → LAB colour space
2. Apply CLAHE to L-channel only with dual-constraint clip limit:
$$CL_tile = \min(c \cdot area / 256 , t \cdot area)$$
3. At train: apply with $p = 0.8$ (stochastic)
At inference: always apply
4. LAB → RGB

PARAMETERS

clip_factor $c = 2.0$ · threshold $t = 0.01$
tile_grid = 8 × 8

OUTPUT

RGB uint8 · 512 × 512 × 3
enhanced local contrast (microvasculature)

Сурет 3.7 – 5-кезең – қос шектеулі CLAHE (полярилық нұсқа және тамыр карталарымен)

6-кезең — Augmentation. 6-кезең — тек оқыту уақытында қолданылатын жалғыз кезең; inference кезінде ол толығымен айналып өтіледі, сонда өндірістік түрлендіру детерминистік болады. Оқыту кезінде ол біртұтас аффинді

түрлендіруді — айналу, дисперсиясы 1-кезеңнің анықтау белгісіздігінен адаптивті; $[0.9, 1.1]$ диапазонындағы zoom; және опционалды shear мен stretch — жарықтылық пен контраст джиттерімен және басты-компонент (PCA) түс джиттерімен бірге қолданады. Мұндағы augmentation-нің рөлі қос: ол артық үйренуге қарсы тұру үшін тиімді оқыту таралуын кеңейтеді, әрі таңдамалы қолданылғанда EyePACS-тің қатты класс теңгерімсіздігіне қарсы қолжетімді иінтіректердің бірі (SB-2.1). EyePACS оқыту жиынынан іс жүзінде бағаланған PCA түс базисін қоса, толық augmentation сипаттамасы §3.1.3-те берілген (3.8-сурет).

Stage 6 — Augmentation

TRAIN ONLY

INPUT

RGB uint8 · 512 × 512 × 3

OPERATIONS

1. Unified affine: rotation, zoom, optional shear / stretch
2. Brightness / contrast jitter (α , β)
3. PCA colour jitter (Krizhevsky-style)
4. Horizontal re-flip for diversity

At inference: skipped (deterministic).

PARAMETERS

rot σ_{adapt} (fallback 13° , clip $\pm 40^\circ$)
zoom $\in [0.9, 1.1]$ · shear $\pm 2^\circ$ ($p=0.3$)
PCA $\sigma = 0.1$ ($p = 0.5$)

OUTPUT

RGB uint8 · 512 × 512 × 3
augmented training sample

Сурет 3.8 – 6-кезең – augmentation (айналу/масштаб/shear/PCA-түс/жарықтылық)

7-кезең — Деректер жиынтығына тән нормализация. Соңғы кезең кескінді tensor-ға айналдырып, оның арна статистикасын стандарттайды. Ол алдымен HWC uint8 кескінді $[0, 1]$ аралығындағы CHW float32 tensor-ға бейнелейді, содан кейін арна-бойынша нормализация $(x - \text{mean}) / \text{std}$ қолданады, әрі FOV маскасын төртінші арна ретінде қосып, (4, 512, 512) пішінді шығыс tensor береді. Нормализация статистикасы ImageNet-тен мұраланғаннан гөрі деректер жиынтығына тән: арна-бойынша орташа мен стандартты ауытқу EyePACS оқыту жиынында, 0–4 кезеңдер қолданылғаннан кейін, тек FOV маскасы 1,0-ге тең пикселдерді пайдалана отырып есептеледі — сонда нөл-padding статистиканы қисайтпайды. Бұл статистика осы жұмыстың нақты артефактісі ретінде есептелді (RES-NORM): 5000 EyePACS кескінінен шамамен 1,25 миллиард маска-ішілік пиксель бойынша арна-бойынша орташалар шамамен $[0,506, 0,505, 0,504]$, ал стандартты ауытқулар $[0, 1]$ шкаласында шамамен $[0,090, 0,074, 0,058]$ болды. Стандартты ауытқулардың түс арналары бойынша айқын асимметриясы — қызыл арна көк арнадан шамамен 1,6 есе көп өзгереді — дәл ImageNet нормализациясы сәйкессіз болатын деректер жиынтығына тән құрылым, әрі статистиканы мақсатты таралуда есептеудің негіздемесі. Кезең әрқашан қосулы әрі әрқашан соңғы (3.9-сурет).

Stage 7 — Normalize + Mask Append

ALWAYS ON

INPUT

RGB uint8 · 512 × 512 × 3
+ FOV mask M (from Stage 3, float32 512²)

OPERATIONS

1. uint8 → float32, scale to [0, 1]
2. Per-channel normalize
$$x'_c = (x_c - \mu_c) / \sigma_c$$
3. Append M as 4th channel

Baseline uses ImageNet (μ , σ) on 3 channels.
Pipeline uses dataset-specific stats on 4ch.

PARAMETERS

(μ_c , σ_c) computed on training set
after deterministic Stages 0–4

OUTPUT

float32 tensor · (4, 512, 512)
CNN-ready

Сурет 3.9 – 7-кезең – деректер жиынтығына тән нормализация

Эксперименттік жоба үшін pipeline-нің екі жұмыс күйі анықталады (OD-3). **БЕЛСЕНДІ** күйінде — толық pipeline — сегіз кезеңнің бәрі қолданылады, 6-кезең тек оқыту уақытында, ал шығыс — жоғарыда сипатталған 4 арналы (RGB + FOV маскасы) tensor. **ЖОҚ** күйінде — эксперименттік базалық — сегіз кезеңнің ешқайсысы қолданылмайды; оның орнына кескін 512×512-ге созыла-өлшемі өзгертіліп, тіркелген ImageNet статистикасымен (орташа [0,485, 0,456, 0,406], std [0,229, 0,224, 0,225]) нормаланады, FOV маскасыз 3 арналы tensor береді. Бұл БЕЛСЕНДІ-мен-ЖОҚ қарама-қарсылығы — 1-эксперимент өзінің факториалды жобасының preprocessing осі ретінде манипуляциялайтын операциялық конструкт (§4.2); ол — OD-3 анықтайтын ішкі конструкт,

жоғарыда талқыланған P1 өкілінен терминологиялық тұрғыдан ерекше (SB-1.12). Екі шеткі арасында 2-эксперимент жеті деңгейлі абляция сатысын анықтайды — базалық, содан кейін flip, айналу, изотропты-өлшем-өзгерту-плюс-маска, жарық-өрісі, CLANE, әрі соңында толық pipeline-ді кумулятивті қосу — әр кезеңнің шекті үлесін сандық бағалау үшін (§4.3). Толық сегіз кезеңді конфигурацияның осында көрсетілгені оның әмбебап оңтайлы preprocessing конфигурациясы екенін білдірмейді; әр кезеңнің шекті құндылығы, әрі қандай да бір кезеңнің берілген архитектура үшін артық немесе зиянды болуы мүмкіндігі — дәл абляция тексеруге жобаланған нәрсе, әрі алдын ала бекітілмейді (NC-17).

Осылай көрсетілген pipeline — диссертацияның өз жобасы. Ол кандидаттың бұрын жарияланған нәтижелерінің шежіресін — кәдімгі preprocessing төрт қабатты конволюциялық желімен валидация дәлдігін 71%-дан 86%-ға көтерген (Сапақова, Есмұхамедов және Сапақов, 2025; ROC-AUC 0,9638-мен хабарланған), әрі жаңартылған CLANE нұсқасы STARE дерекқорында зерттелген бұрынғы жұмысты (оның тақырыптық көрсеткіштері қазіргі контекстке тасымалданбайды, SB-1.2; сол мақала, жалғыз өзіне-сілтенген желі ретінде қаралады, SIR-5) — формализацияланған, сегіз кезеңді, төрт арналы pipeline-ге дамытады. Кеңірек әдебиет стандарттау мақсатын орнықтырмай уәждейді: деректер жиынтығы аралық зерттеулер экзогенді кадам ретінде өңделген көз түбі көздері арасындағы өнімділік вариациясын хабарлайды [44], эталон зерттеулері кескін сапасы градациялау сенімділігіне қатысты екенін хабарлайды [15, 8], әрі жақсарту зерттеулері CLANE сияқты контраст операциялары деректер жиынтығы мен баптауға қарай жіктеуге көмектесе де, кемінде бір архитектура үшін зиян тигізе де алатынын хабарлайды [68, 69] — түрлі деректер жиынтықтары мен міндеттер арасында тек уәждеме деңгейінде, тасымалданатын сандар деңгейінде емес дәйекті контекст (SIR-3). Pipeline қызмет етуге жобаланған мақсат — диагностикалық тұрғыдан өзекті белгілерді сақтай отырып, бейнелеу құрылғылары мен түсіру жағдайлары бойынша вариабельділікті азайту, әрі мұны бұзушы құрылымдық артефактілер енгізбей істеу [96] — мұнда айтылған жобалау мақсаты, дәлелденген нәтиже емес; оның бағалауы 4-тарауға тиесілі. Pipeline дәл конструктор ретінде тіркелген соң, §3.1.2 5-кезеңге қос шектеулі CLANE формализациясын аяқтау үшін оралады, §3.1.3 6-кезең augmentation-ін және оның бағаланған PCA түс базисін егжей-тегжейлейді, ал §3.1.4 клиникалық деректер үшін 0-кезеңнің алдында тұратын сыртқы-кескінді қабылдау хаттамасын көрсетеді.

§3.1.2 Қос шектеулі клип лимитімен модификацияланған CLANE алгоритмі

§3.1.1-де контрастты-күшейту кезеңі ретінде енгізілген pipeline-нің 5-кезеңі §2.1.2-де теориялық формализацияланған қос шектеулі клип лимитін нақты кескін операциясы ретінде жүзеге асырады. Теориялық бөлім ережені және оның негіздемесін орнықтырды: әр тайл үшін клип лимиті гистограммаға-

катысты мүше мен тайлға-катысты абсолютті төбенің қатаңырағы ретінде орнатылады,

$$CL = \min(\text{clip_factor} \cdot \text{tile_area}/256, \text{global_threshold} \cdot \text{tile_area}), (\text{cf. 2.3-тең.})$$

сонда кәдімгі контрасты шектеу жақсы таралған жергілікті гистограммаларды басқарады, ал абсолютті төбе қатты шындалғандарда қол жеткізілетін бейнелеу көлбеуін шектейді (§2.1.2). Қазіргі бөлім бұл ережені қайта шығармайды; ол ереже 5-кезең ретінде қалай қолданылатынын — жұмыс істейтін түс кеңістігін, пайдаланатын тайлдау мен интерполяцияны, оны оқыту мен inference уақытында қолдану тәсілін, әрі оның екі еркін гиперпараметрі қалай тіркелетінін — көрсетеді.

Түс-кеңістік жүзеге асырылуы. Операция RGB арналарына тікелей емес, LAB түс кеңістігінің жарықтылық арнасына қолданылады. Кескін RGB-дан LAB-қа түрлендіріледі, қос шектеулі контрасты шектелген адаптивті Histogram Equalization тек L (жарықтылық) арнасына қолданылады, ал нәтиже RGB-ға кері түрлендіріледі. Теңестіруді жарықтылық арнасымен шектеу жергілікті контрастты — торқабық фонына қарсы төмен амплитудалы микроваскулярлық құрылымның көрінушілігін — а және b хроминанс арналарын өзгертпей күшейтеді, сонда реңк сақталады әрі зақымданулар мен тамыр жүйесінің сипатты түсі контраст операциясымен бұрмаланбайды. Бұл — LAB таңдауының инженерлік себебі: контраст пен түс ажыратылады, әрі тек контраст ғана манипуляцияланады.

Тайлдау, қайта үлестіру және интерполяция. L-арнасы 8×8 контекстік тайл торына бөлінеді (OD-3 5-кезең). Әр тайл ішінде жергілікті гистограмма құрылып, (cf. 2.3) теңдеуінің қос шектеулі лимитінде қиылады; клиптеу алып тастаған артық масса тайлдың жалпы массасы сақталатындай гистограмма бойынша қайта үлестіріледі, ал клиптелген гистограмманың жинақтаушы үлестірімі сол тайлдың қарқындылық бейнелеуін айқындайды. Тәуелсіз тайл-бойынша бейнелеулер тайл шекараларында тудыратын блок артефактілерін болдырмау үшін пиксел-бойынша бейнелеу көрші тайл центрлерінің бейнелеулері арасында билинеарлы интерполяциямен есептеледі — стандартты CLANE қайта құрылуы. 8×8 тор контекстік аймақтың кеңістіктік масштабын 2-кезең орнатқан 512×512 кадрға қатысты тіркейді, сонда контекстік аймақтың өлшемі кескіндер бойынша дәйекті болады.

Стохастикалық қолданыс. Кезең оқыту уақытында стохастикалық, 0,8 ықтималдықпен, ал inference уақытында детерминистік қолданылады (OD-3 5-кезең). Асимметрия — әдейі. Inference кезінде өндірістік түрлендіру қайталанатын болуы тиіс, сондықтан жақсарту әрқашан қолданылады; оқытуда оны кездейсоқ таңдалған 80% кірісте қолдану контраст операциясын Stage 6 augmentation рөлімен (§3.1.3) үйлестірілген қосымша, бақыланатын кіріс вариабельділігі көзіне айналдырады. Сондықтан оқыту таралуы деректердің жақсартылған және жақсартылмаған нұсқаларының екеуін де қамтиды, бұл желінің жалғыз тіркелген контраст профиліне тәуелді болуынан тартындырады, әрі жақсартылған профильді басым және inference-уақыттық шарт ретінде ұсынады.

Гиперпараметрлер және олардың қалай тіркелетіні. (cf. 2.3) теңдеуі екі еркін гиперпараметрді — клип факторы мен глобалды шекті — ашады, әрі жүзеге асыру оларды әдейі еркін қалдырады. Олардың мәндері кез келген сыртқы зерттеуден немесе кандидаттың бұрынғы жұмысынан импортталмайды: бұрын жарияланған нәтижелерде STARE дерекқорында валидацияланған жалғыз-шекте T/80 формасы (Сапақова, Есмұхамедов және Сапақов, 2025 — жалғыз өзі-авторланған желі ретінде келтіріледі, одан алынған екі әдебиет картасы дәл сол мақаланы сипаттайды, SIR-4/SIR-5) басқа кескін үлестірімі үшін оңтайландырылды, әрі оның тақырыптық көрсеткіштері, сол шағын деректер жиынтығында хабарланған 100% ассигасу-ді қоса, қазіргі эксперименттік контекстке тасымалданбайды (SB-1.2). Параметр-тасымалданушылығы шектеуімен (DGL-5) үйлесімді, pipeline пайдаланатын клип факторы мен глобалды шек H-2 гипотезасы талап ететін downstream сезімталдық профилін сипаттайтын 2-эксперименттің параметр сканерлеуімен (§4.3.2) айқындалады; мұнда ешбір нақты мән бекітілмейді. Бұл эмпирикалық айқындаудың факультативті емес, қажет екенін контраст операциясының әсері архитектура мен баптауға тәуелді деген сыртқы дәлел күшейтеді — Nayati және әріптестері [68], CLANE-ні APTOS 2019-да төрт желі бойынша жалғыз тіркелген конфигурацияда бағалап (бинарлық міндет, тек ассигасу, сенімділік интервалдарынсыз), оны үш архитектураға көмектесіп, төртіншісін 12,02 пайыздық тармаққа нашарлатқанын тапты. Сондықтан қос шектеулі формуляция алдын ала оңтайлы деп бекітілген конфигурация ретінде емес, параметрлері валидациямен тіркелетін бапталаатын жоба ретінде ұсынылады (NC-17).

Кеңістіктік-адаптивті нақтылау (FIG-3.7). Жүзеге асыру қосымша кезеңнің кеңістіктік-адаптивті нақтылауын зерттеді, онда тайлдау тіркелген декарттық торға емес, торқабық геометриясы мен жергілікті тамыр тығыздығына бейімделеді; нұсқа, ол пайдаланатын аралық тамыр-анықтау және тамыр-тығыздығы карталарымен бірге, 3.7-суретінде көрсетілген. Бұл нұсқаның елеулі жобалау егжей-тегжейі — ол өзінің бейімделуін анықталған фовеаға емес, FOV маскасының (3-кезең) центроидіне бұрады — §3.1.1-де хабарланған 1-кезең валидациясымен тікелей ақталған таңдау, онда IDRiD-те фовеа локализациясы сенімсіз болды (кескіндердің 1%-нан азында эталоннан бір оптикалық-диск радиусы шегінде); геометриялық тұрғыдан берік FOV центроидіне бұру детектордың фовеа-локализация сәтсіздіктерін контраст кезеңіне таратудан сақтайды. OD-3-тің канондық 5-кезең сипаттамасы, әрі осы әдістемеді алға тасымалданатын конфигурация, жоғарыда көрсетілгендей 8×8 тайл торы бойынша LAB L-арнасындағы қос шектеулі CLANE болып қалады; кеңістіктік-адаптивті нұсқаның pipeline әдепкісі ретіндегі қабылдану мәртебесі — операцияларды анықтамада әлі көрінбеген жүзеге асыру мәселесі әрі governance реконсильациясы үшін белгіленген [VERIFY: OD-3 5-кезең vs жеткізілген полярлық-CLANE әдепкісі].

Контраст кезеңі параметрлері 2-экспериментпен тіркелетін параметрленген, жарықтылық-арналы, стохастикалық-қолданылатын операция

ретінде көрсетілген соң, pipeline сипаттамасы 5-кезеңнің стохастикалылығы үйлестірілетін оқыту-уақыттық augmentation, 6-кезеңге §3.1.3-те бұрылады.

§3.1.3 Класс теңгерімсіздігін жұмсартуға арналған augmentation стратегиясы

6-кезең — pipeline-нің тек оқыту уақытында қолданылатын жалғыз кезеңі. §3.1.2 5-кезең CLANE-нің стохастикалық қолданысын — оқыту мен inference-те де бар, бірақ оқыту кезінде кездейсоқталатын түрлендіруді — көрсетсе, 6-кезең inference кезінде толығымен айналып өтіледі, сонда орналастырылған модель жаңа кескінге қолданатын өндірістік түрлендіру толық детерминистік. Бұл асимметрияның себебі — әдістемелік гигиена: augmentation оқыту деректерінің ақылға қонымды нұсқаларын әдейі ойдан шығарады, әрі мұндай ойдан шығарылған нұсқаларды валидация немесе тест бөліктеріне енгізу көрінетін өнімділікті кампитар еді. Сондықтан augmentation оқыту жолымен шектеледі, ал cross-validation хаттамасы (§3.4.2) ешбір augment жасалған кескін кез келген бағалау бөлігінде көрінбейтінін қосымша кепілдейді (RESEARCH_ARCHITECTURE §9.1). Кезең перутрбацияның үш отбасын — геометриялық, фотометриялық және хроматикалық — uint8 кескінге Stage 7 соңғы нормализациясының алдында сол ретпен қолданып құрастырады (3.8-сурет).

Геометриялық перутрбация (біртұтас аффинді). Геометриялық отбасы — айнаруды, $[0.9, 1.1]$ диапазонындағы zoom-ды және опционалды shear мен stretch-ті біріктіретін жалғыз біртұтас аффинді түрлендіру (OD-3 6-кезең). Оның мақсаты — желіге диагностикалық мазмұнды өзгертпей, көз түбі түсірілімдері бойынша туындайтын ақылға қонымды көзқарас және кадрлау вариациясының диапазонын ұсыну. Айналу компоненті ерекше: оның дисперсиясы тіркелген тұрақты емес, кескін бойынша адаптивті, 1-кезеңде орындалған оптикалық диск-фовеа анықтауының белгісіздігінен алынады (§3.1.1). Бұл augmentation-ді канондық бағдар сенімділігіне байлайды — бағдары сенімді нормаланатын кескін қатаңырақ жолақ ішінде айналдырылады, ал 1-кезең өзінің төмен-сенімділік жолына (fallback дисперсиясы $\sigma = 13,0^\circ$) шегінген кескінге кеңірек айналу таралуы рұқсат етіледі — сонда augmentation детектор қол жеткізбеген туралау дәлдігін бекітпейді. Аффинді түрлендіру екі кескін осін бірге масштабтайтындықтан, ол 2-кезең орнатқан изотропиямен үйлесімді дөңгелек көз түбі геометриясын және зақымданулардың шынайы аспект қатынасын сақтайды.

Фотометриялық перутрбация. Фотометриялық отбасы жарықтылық пен контраст джиттерін қолданады. 5-кезең CLANE-нің стохастикалық қолданысымен (§3.1.2) бірге, бұл желіні оқыту кезінде жалғыз тіркелгеннен гөрі контраст пен жарықтылық профильдерінің диапазонына ұшыратады, нақты жарықтандыру немесе контраст деңгейіне тәуелділіктен тартындыру ниетімен — дәлелденген нәтиже емес, беріктік мақсаты.

Хроматикалық перутрбация (PCA түс джиттері). Хроматикалық отбасы — Krizhevsky және әріптестері [19] ImageNet жіктеуі үшін енгізген

стильдегі басты-компонент түс джиттері, онда кескіннің түс басты-компоненттерінің кездейсоқ еселігі, өздерінің меншікті мәндерімен масштабталып, әр пикселге қосылады: пикселге қосылатын перутрбация — $[p_1 p_2 p_3][\alpha_1 \lambda_1, \alpha_2 \lambda_2, \alpha_3 \lambda_3]^T$, мұнда p_i мен λ_i — RGB пиксел ковариациясының меншікті векторлары мен меншікті мәндері, ал әр $\alpha_i \sigma = 0,1$ бар $N(0, \sigma)$ -дан алынады (OD-3 6-кезең). Әдіс Krizhevsky және әріптестерінен [19] алынған; алайда түс базисі — жоқ — ол осы жұмыстың нақты артефактісі ретінде тікелей EyePACS оқыту жиынында бағаланды (RES-PCA). Бағаланған меншікті мәндер айқын анизотропты — шамамен 20,4, 128,1 және 2374,0 — сонда жалғыз басым хроматикалық ось келесінің түс дисперсиясынан шамамен он сегіз есе, ал ең азынан жүз еседен астам үлесті құрайды. Практикалық салдар — түс джиттері еркін RGB бағыттарынан гөрі EyePACS көз түбі түсі іс жүзінде ең көп өзгеретін бағыт бойынша басым перутрбациялайды; ол біркелкі арна шуы емес, деректер жиынтығына тән, принципті түс augmentation-і (DGL-1 базисті EyePACS-пен шектейді).

Қос рөл және класс теңгерімсіздігі. 6-кезең екі мақсатқа бір мезгілде қызмет етеді. Регуляризация ретінде ол тиімді оқыту таралуын кеңейтіп, артық үйренуді азайтады, §2.2.3-те теориялық талданған тетік. Дерек теңгерімсіздігіне жауап ретінде ол шеңбер EyePACS градациялау таралуының қатты класс қисайуына қарсы пайдаланатын екі жобалау иінітірегіннің бірі (SB-2.1): augmentation төмен-ұсынылған ауырлық дәрежелері үшін олардың тиімді үлгісін ұлғайтуға, желі эпоха сайын көретін азшылық-класс мысалдарының алуандығын арттыруға баса назар аударыла алады (SC-1.4). Алайда ол — тек бір иінітірек. Теңгерімсіздіктің негізгі тетігі — §3.3.4-те көрсетілген кері-жиілікпен-салмақталған focal loss; augmentation оны loss бетінде емес, кіріс таралуында әрекет ете отырып толықтырады. Мұнда екі иінітіректің бірі де теңгерімсіздікті шешеді деп бекітілмейді, әрі augmentation деңгейінің шекті үлесі — әр басқа кезеңнің үлесі сияқты — 2-эксперимент абляциясы үшін сұрақ (§4.3), алдын ала бекітілген қасиет емес (NC-17).

6-кезең көрсетілген соң, оқыту-уақыттық pipeline аяқталады; 7-кезең (§3.1.1-де көрсетілген) төрт арналы tensor-ды түпкілендіреді, әрі сегіз кезеңді сипаттама жабылады. Қалған preprocessing мәселесі — сегіз кезең жорамалдайтын бақыланатын жағдайлардан тыс келетін клиникалық кескіндерді — гетерогенді, кейде нашарлаған, кейде қате-таңбаланған — өңдеу, оны §3.1.4 мұндай деректер үшін 0-кезеңнің алдында тұратын сыртқы-кескінді қабылдау хаттамасы ретінде қарастырады.

§3.1.4 Сыртқы кескіндерді қабылдау хаттамасы

§3.1.1–§3.1.3-те көрсетілген сегіз кезеңді pipeline 0-кезеңде жақсы қалыптасқан кірісті жорамалдайды: көру өрісі қалпына келтірілетін, латералдылығы белгілі, әрі диабеттік-ретинопатия дәрежесі 0–4 диапазонындағы жарамды таңба болып табылатын жалғыз-көзді түсті көз түбі фотосуреті. EyePACS сияқты жария таратылатын зерттеу деректер жиынтықтары бұл жорамды негізінен құрылысы бойынша қанағаттандырады.

Аурухана ақпараттық жүйесінен экспортталған клиникалық кескіндер оны әрқашан қанағаттандырмайды. Мұндай кескіндерді 0-кезеңге кіруге жағдайлайтын төмендегі хаттама — осы диссертацияның жобалау үлесі: оның осы жұмыс үшін жинақталған әдебиет корпусында ізашары жоқ, әрі төмендегі талдау сондықтан кез келген дереккөзге телу емес, диссертацияның өзінікі. Оның мақсаты — модельдің кіріс келісімін айқын ету — модель қай клиникалық кескіндерді қабылдай алатынын және келісімнен тыс кескіндер қалай өңделетінін айту — сонда клиникалық-валидация эксперименттері (4, 5 және 7-эксперименттер) арнайы таңдаудан гөрі айқындалған популяцияда жұмыс істейді.

Бұл келісімді көрсету — осы тарауда қабылданған біріктірілген-pipeline (P2) көрінісі бойынша өзі әдістемелік әрекет [UNSOURCED CLAIM: кіріс келісімінің тек инженерлік сантехника емес, әдістемелік шекара екені — диссертацияның өз аналитикалық ұстанымы, дереккөзге сүйенген тұжырым емес]. Preprocessing модельдің бөлігі болғандықтан, қай клиникалық кескіндердің preprocessing-ке кіретінін шешетін ереже — сыртқы ыңғайлылық емес, модель шекарасының бөлігі. Хаттама төрт компоненттен тұрады, әрқайсысы өзі қорғайтын downstream алғышартпен анықталады.

Формат пен контейнерді нормалау. Клиникалық экспорттар гетерогенді файл форматтарында, бит тереңдіктерінде және түс кодтауларында, кейде ендірілген қарау-аннотацияларымен немесе күйдірілген идентификаторлармен келеді. Бірінші компонент әр кірісті pipeline күтетін канондық репрезентацияға — 8-биттік RGB растрға — нормалап, түс кеңістіктері мен бит тереңдіктерін түрлендіріп, жалғыз көз түбі растрына декодталмайтын контейнерлерді қабылдамайды. Бұл 0-кезең мен барлық кейінгі кезеңдер сүйенетін uint8 RGB кіріс келісімін орнатады.

Көру өрісі мен сапа сүзгісі. Pipeline-нің 2-кезеңі көру өрісін алдыңғы-планды анықтау арқылы қалпына келтіріп, оған дейін қияды; бұл келісімді жарықтандырылған көз түбі дискінің бар болуын алдын ала жорамалдайды. Екінші компонент сол алғышартта сүзеді: көру өрісі қалпына келтірілмейтін кескіндер — кадр бос, өрескел артық- немесе жеткіліксіз-экспозицияланған, немесе артефактпен басым болғандықтан — геометриялық және жарықтандыру кезеңдері мағынасыз мазмұнда жұмыс істер еді деген pipeline-ге үнсіз өткізілгеннен гөрі белгіленіп, ұсталынады. Бұл сүзу операциялық тұрғыдан сапа сүзгісі, кескін сапасының downstream белгіні анықтауды қолдау қабілеті ретіндегі операциялды анықтамасымен (OD-1) үйлесімді, бірақ ол мұнда градацияланған сапа балы ретінде емес, қабылдау кезіндегі жарамдылық тексеруі ретінде қолданылады.

Латералдылық пен метадеректі реконсiliationлау. 0-кезең (канондық аудару) сол-көз кескіндерін оң-көз канондық кадрына қайта бағдарлау үшін көз латералдылығын талап етеді. Үшінші компонент бұл сигналды береді әрі реконсiliationлайды: экспорт метадеректері латералдылықты тіркеген жерде ол тікелей пайдаланылады, ал ол жоқ немесе сәйкессіз болған жерде эвристикалық анықтау алмастырылады, 1-кезеңдегі бағдарды анықтауға қабылданған дәл сол консервативті ұстаныммен — төмен-сенімділік анықтауы

бекітілгеннен гөрі солай тіркеледі. Пациент-деңгейлі cross-validation топтауы (§3.4.2) үшін қажетті метадерек өрістері сол нүктеде реконсиляцияланады, өйткені кескін файл атаулары сәйкессіз болғанда да, ағып кетуді болдырмау үшін пациент сәйкестігі сақталуы тиіс.


Таңба мен дәреже орындылығы. Төртінші компонент берілген таңбаны бес класты DR таксономиясына (DR 0–4) қарсы валидациялайды: диапазоннан тыс дәрежелер немесе дәрежесі жоқ кескіндер класқа мәжбүрлеуден гөрі төрелік ету үшін белгіленеді. Бұл метрикалары жарамды эталондық таңбаларды алдын ала жорамалдайтын бағалау бөліктерінің тұтастығын қорғайды.

Бұл хаттаманың жарамдылығы шектеулі. Ол осы жұмыста пайдаланылған нақты қазақстандық медициналық-орталық клиникалық деректеріне (60 кескін, RESEARCH_ARCHITECTURE §2.1.8) қарсы жобаланды әрі тек солар үшін валидацияланған; қабылдау хаттамасының басқа көздерден, түрлі экспорт конвенциялары мен төмендеу профильдері бар клиникалық деректерге жалпылануы тәуелсіз валидацияны талап етер еді әрі мұнда бекітілмейді (NC-15). Сол клиникалық деректер институционалды келісім бойынша ұсталып, жария қолжетімді болмағандықтан, оған тәуелді кез келген нәтиженің қайта жаңғыртылушылығы құрылымдық тұрғыдан шектеулі (SB-2.2). Хаттама нормативтік-деңгейлі де-идентификацияны немесе сәйкестікті орындамайды әрі ол туралы ешбір тұжырым жасамайды; пациентті-айқындайтын ақпаратты өңдеу §6.4.1-де жүйе-жобалау мәселесі ретінде қаралады, онда ол куәландырылған сәйкестік мәртебесі ретінде емес, жобалау сипаттамасы ретінде ұсынылады (SB-4.2). Қысқасы, хаттама — модель үшін айқындалған және шектелген кіріс келісімі — валидацияланған жалпы-мақсатты клиникалық-кескін тазалаушысы емес (CFC-2.4).

Қабылдау хаттамасы көрсетілген соң, preprocessing pipeline формализациясы (§3.1) аяқталады: клиникалық деректер үшін кіру шарттарынан, сегіз реттелген кезең арқылы, желіге жеткізілетін төрт арналы tensor-ға дейін. §3.2 екі кезеңді модельдің екінші компонентіне — сол tensor-ды тұтынатын конволюциялық архитектураларға бұрылады.

§3.2.1 Негізгі эксперименттік архитектуралар ретінде ResNet-50 және EfficientNet-B3

§3.1 екі кезеңді модельдің preprocessing компонентін және ол жеткізетін төрт арналы tensor-ды (немесе базалық шарттың үш арналы tensor-ын) көрсетті. Бұл бөлім екінші компонентті — сол tensor-ды тұтынатын конволюциялық желіні — эксперименттік жоба бойынша пайдаланылатын екі негізгі backbone архитектурасын тіркеу арқылы көрсетеді. Екеуі түрлі архитектура отбасыларынан таңдалады, әрі біреудің орнына екеуін пайдалану негіздемесі — жалғыз ең жақсы желіні іздеу емес, әдістемелік: ол 1-эксперименттің preprocessing қарама-қарсылығы аясында бақыланған кез келген әсерді архитектура отбасылары бойынша қайталауға тексеруге мүмкіндік береді (3.14-сурет). Екі backbone-ның кіріс tensor-мен қатынасы 3.11-суретінде көрсетілген.



Сурет 3.11 – ResNet-50 / EfficientNet-B3 backbone архитектурасы

ResNet-50. Бірінші backbone — ResNet-50, He және әріптестері [23] енгізген residual-оқыту архитектурасының 50 қабатты данасы. Оның айқындаушы элементі — residual байланыс — әр блокты сілтемесіз бейнелеудің орнына кірісіне қатысты residual функцияны үйренуге мүмкіндік беретін сәйкестік қысқа байланыс — ол градиент таралуын жеңілдету арқылы өте терең желілерді оқытылатын етеді. ResNet-50 осы диссертация жобасында конволюциялық желілердің residual-байланыс отбасын білдіреді.

EfficientNet-B3. Екінші backbone — EfficientNet-B3, Тан мен Ле [25] енгізген EfficientNet отбасының мүшесі, оның айқындаушы элементі — құрама масштабтау: тереңдік, ені және кіріс ажыратымдылығы тәуелсіз емес, жалғыз құрама коэффициентпен бірге масштабталады. EfficientNet-B3 құрама-масштабтау отбасын білдіреді. Сондықтан екі backbone терең конволюциялық feature extractor құрудың шынайы түрлі екі жобалау қағидатын — бір жағынан residual тереңдік, екінші жағынан теңгерімді құрама масштабтау — даналайды, бұл оларды пайдалы жұп ететін қасиет.

Неліктен екі архитектура отбасы. 1-эксперименттің эксперименттік қарама-қарсылығы preprocessing шартын (базалық пен толық pipeline) әр backbone ішінде манипуляциялайды: ResNet-50 базалық конфигурацияда (A) да, біріктірілген конфигурацияда (B) да көрінеді, ал EfficientNet-B3 базалық конфигурацияда (C) да, біріктірілген конфигурацияда (D) да көрінеді.

(RESEARCH_ARCHITECTURE §5.1). Preprocessing қарама-қарсылығын әр тіркелген backbone ішінде оқу, содан кейін екі backbone келіседі ме деп сұрау — дәл жеткілікті-валидация критерийі (ЕН-4) талап ететін архитектура аралық қайталау: тек бір архитектура үшін расталған әсер оны қанағаттандырмаз еді. Жалғыз backbone бұл дәлелді бере алмас еді; жұп — мұны істей алатын ең аз жоба. Бұл — екі-архитектуралы құрылымның жобалау негіздемесі, кез келген архитектураның мәртебесі туралы тұжырым емес — ResNet-50 де, EfficientNet-V3 де диабеттік-ретинопатияны жіктеу үшін жаһандық оңтайлы желі деп бекітілмейді, әрі архитектура кеңістігі бойынша толық іздеу орындалмайды әрі бекітілмейді (SB-3.1, NC-6).

Неліктен конволюциялық, transformer емес. Кеңірек ландшафт vision transformer-лерді [39], кейінгі EfficientNet нұсқаларын [26] және Xu және әріптестері [28] APTOS 2019-да бағалаған EfficientNet-Swin үйлесімі сияқты CNN-transformer гибридтерін қамтиды — мұнда тек таңдауды орналастыру үшін келтіріледі, ешбір бетпе-бет салыстыру меңзелмейді (SIR-3). Екі backbone-ды да конволюциялық ұстау шешімі — әдейі әрі зерттеудің себептік логикасымен байланысты; ол сондай-ақ жақсы прецедентті — маңызды автоматтандырылған-DR жүйелерінің өздері Inception- [22] сияқты конволюциялық backbone-дарда құрылды — мұнда тек таңдауды орналастыру үшін келтіріледі, салыстырушы ретінде емес (SIR-3). 1-эксперименттің біріктірілген арнасы ImageNet-тен емес, офтальмологияға тән өзін-өзі бақылайтын алдын ала оқытудан инициализацияланғандықтан (§3.3.2), архитектураны базалық пен біріктірілген арналар бойынша бірдей ұстау preprocessing-плюс-pretraining қарама-қарсылығының архитектура ауысуымен шатаспауын қамтамасыз етеді. Transformer backbone архитектураны да, инициализацияны да бір мезгілде өзгертер еді; CNN-нативті өзін-өзі бақылайтын инициализация тек инициализацияны өзгертіп, арналар бойынша конволюциялық жобаны сақтайды (INVARIANTS v6.0.0 §X). Сондықтан CNN-пен-transformer сұрағы осы диссертацияның эксперименттік тұжырымдарының ауқымынан тыс.

Кіріс-арналарды өңдеу. Екі backbone эксперименттік шарттар бойынша түрлі арна саны бар кірістерді қабылдауы тиіс: базалық шартта үш арна (RGB) және толық шартта төрт арна (RGB плюс 3-кезеңнің FOV маскасы). Бірінші конволюциялық қабат тиісінше бейімделеді. Үш арналы pretraining көзінен мұраланған салмақтар үшін алдын ала оқытылған салмақтар алғашқы үш кіріс арнасына көшіріліп, төртінші (маска) арнасы олардың арна-бойынша орташасынан инициализацияланады (experiments/src/models/resnet.py-дағы хаттама); алайда біріктірілген арнаның өзін-өзі бақылайтын алдын ала оқытуы үй ішінде орындалғандықтан, кодтаушыны балама түрде тікелей төрт арналы tensor-да алдын ала оқытуға болады, бұл арна-санының сәйкессіздігін толығымен жояды (AOQ-2 жеңілдетілген, INVARIANTS v6.0.0 §X; RESEARCH_ARCHITECTURE §4.2bis). Қалай болғанда да FOV-маска кезеңі (3-кезең) сақталады әрі OD-3-тің төрт арналы кіріс келісімі ұсталады.

Оқыту конфигурациясы мен аппараты. Екі backbone да TAB-3.1-де көрсетілген әрі §3.4.2 мен §4.1.3-те егжей-тегжейленген жалғыз стандартталған

конфигурацияда оқытылады (Adam, пакет өлшемі 16, 512×512 кіріс, focal loss, 5-fold пациент-деңгейлі cross-validation, тіркелген seed). Екі backbone да batch normalization-ға [77] тән сүйенеді, оның тұрақтандырушы және жұмсақ регуляризациялаушы әсері пакет статистикасынан туындайды әрі сондықтан жады бюджеті таңатын он алты пакет өлшемінде әлсірейді — §2.2.3-тен тасымалданған ескерту. Бір конфигурация егжей-тегжейі архитектураға тән: аралас-дәлдік (fp16) оқыту ResNet-50 үшін қосулы, бірақ EfficientNet үшін өшірулі, оған жарты-дәлдік оқыту кезінде сандық толып кету тудырды. Бұл — аппаратқа және жүзеге асыруға байланулы баптау, әрі осы жұмыстағы барлық тиімділікке-қатысты шарттар сияқты ол құжатталған аппаратпен шектелген (DGL-2); ол қайта бағалаусыз басқа есептеу контексттеріне жалпыланбайды.

Екі ауқым шарты сипаттаманы жабады. Біріншіден, екі негізгі backbone кандидаттың ертерек жұмысының кішірек желілерін — бұрын жарияланған нәтижелердің төрт қабатты конволюциялық жіктеуішін қоса (Сапақова, Есмұхамедов және Сапақов, 2025) — ауыстырады, оны қазіргі жоба бақыланатын факториал аясында орнықтырылған, тереңірек backbone-дарға көшу арқылы кеңейтеді. Екіншіден, кандидаттың transfer-learning өзін-өзі жариялауларында хабарланған EfficientNetB0 нәтижелері сол жалғыз желіге тән әрі мұнда тиімді CNN архитектураларының класына жалпыланбайды, оның ішінде EfficientNet-B3 — ерекше, үлкенірек мүше (SIR-7). Бұл backbone-дар қалай инициализацияланатыны — базалық арна үшін ImageNet, біріктірілген арна үшін офтальмологияға тән өзін-өзі бақылайтын алдын ала оқыту, тасымалдау дәрежесі кепілдік емес, эмпирикалық сұрақ ретінде қаралады (DGL-6) — §3.3-тің тақырыбы. Оған дейін §3.2.2 архитектуралық-күрделілік анықтамасын шектейтін тарихи сілтеме архитектураларын құжаттайды (OD-2).

§3.2.2 Тарихи сілтеме архитектуралары (тек сілтеме ретінде)

§3.2.1-де көрсетілген екі негізгі backbone — осы диссертация жобасына қатысты жалғыз конволюциялық архитектуралар емес; олар шеткі нүктелері екі қарапайымырақ тарихи архитектураға сілтемемен айқындалатын күрделілік шкаласында тұр әрі кандидаттың ертерек желілерінің желісін жалғастырады. Бұл бөлім сол сілтеме архитектураларын екі мақсатпен құжаттайды — архитектуралық күрделіліктің операциялды анықтамасын (OD-2) негіздеу және бұрынғы эмпирикалық желіні тіркеу — олардың тек сілтеме нүктелері екенін, қазіргі зерттеудің эксперименттік backbone-дары емес екенін айқын ете отырып.

Архитектуралық күрделіліктің операциялды анықтамасы екі сілтеме нүктесінде бекітіледі (OD-2). **Төмен-күрделілікті сілтеме** — batch normalization-сыз, dropout-сыз, 32-ден 64-ке дейінгі сүзгілері бар екі конволюциялық блоктан және сигмоид шығыстан тұратын ықшам конволюциялық жіктеуіш. **Жоғары-күрделілікті сілтеме** — 32-ден 256-ға дейінгі сүзгілері бар төрт конволюциялық блоктан, batch normalization-нан, 0,4 dropout мөлшерінен және бес DR класы бойынша softmax шығыстан тұратын тереңірек жіктеуіш; бұл кандидаттың бұрын жарияланған preprocessing

зерттеуінде хабарланған төрт қабатты конволюциялық желіге сәйкес келеді (Сапақова, Есмұхамедов және Сапақов, 2025). Бірге бұл екі архитектура зерттеудегі кез келген желінің күрделілігі оқылатын шкаланы тіркейді; осы шектерден тыс жатқан архитектуралар осы диссертация ішінде бағаланбайды (OD-2). Екі сілтеме нүктесі сонымен қатар теориясы §2.2.3-те дамытылған регуляризация компоненттерін нақты иллюстрациялайды — batch normalization мен dropout жоғары-күрделілікті сілтемеде бар әрі төмен-күрделілікте жоқ — әрі осылайша күрделілік анықтамасын абстрактілі қалдырмай, регуляризация талқылауымен байланыстырады.

Бұрынғы эмпирикалық желі — кандидаттың EfficientNetB0-дегі transfer-learning жұмысы. Сол бұрын жарияланған нәтижелер EfficientNetB0-де frozen-белгі конфигурациясын прогрессивті fine-tune жасалғанмен салыстырып бағалап, fine-tune жасалған конфигурация frozen-нан асып түсетінін хабарлады (бұл экспериментті хабарлайтын екі өзін-өзі жариялау дәл сол эксперименттік желіні сипаттайды әрі мұнда тәуелсіз растау ретінде емес, жалғыз дәйексөз ретінде қаралады, SIR-4 және SIR-5 бойынша). Екі шектеу бұл жазбаның қазіргі тарауға қалай енетінін реттейді. Біріншіден, сол нәтижелер нақты EfficientNetB0-мен алынды әрі тиімді CNN архитектураларының класына жалпыланбайды; §3.2.1 backbone-ы EfficientNet-B3 — EfficientNet отбасының ерекше әрі үлкенірек мүшесі, әрі B0 тұжырымдарының оған тасымалдануы бекітілмейді (SIR-7). Екіншіден, сол жазбада бақыланған fine-tuning мінез-құлқы §3.3.3-те көрсетілген екі кезеңді fine-tuning хаттамасын уәждейді, бірақ ол қазіргі backbone-дардың орнықтырылған қасиеті ретінде емес, кеңейтілуге тиіс бұрынғы өз жұмысы ретінде келтіріледі (SIR-4).

Бұл архитектуралар сілтемелер ретінде құжатталады, эксперименттік backbone-дар ретінде қабылданбайды. Осы диссертацияның эксперименттерін алып жүретін желілер — §3.2.1-дің ResNet-50 және EfficientNet-B3 жұбы; төмен- және жоғары-күрделілікті сілтемелер күрделілік анықтамасын шектеуге қызмет етеді, ал EfficientNetB0 желілері зерттеу сүйенетін бұрынғы эмпирикалық жазба ретінде қызмет етеді. Бұл архитектуралардың ешқайсысы үшін оңтайлылық тұжырымы жасалмайды, әрі архитектура кеңістігі бойынша толық салыстыру жүргізілмейді (SB-3.1, NC-6). Архитектуралық сілтемелер құжатталған соң, §3.3 негізгі backbone-дардың бес класты жіктеу үшін қалай бейімделетініне, pretraining-пен инициализацияланатынына және fine-tune жасалатынына бұрылады.

§3.3.1 Бес класты DR жіктеу үшін архитектураны бейімдеу

§3.2-де көрсетілген екі негізгі backbone — соңғы жіктеу қабаты диабеттік-ретинопатияны градациялауға емес, өздерінің pretraining міндетіне сай өлшенген алдын ала оқытылған желілер. Оларды диссертация міндетіне бейімдеу — §3.3-тің бірінші қадамы, әрі ол мұнда келесі бөлімдерде қарастырылатын екі түрлі шешімнен әдейі ажыратылады: алдын ала оқытылған салмақтардың көзі (§3.3.2) және бейімделген желі fine-tune жасалатын кесте

(§3.3.3). Қазіргі бөлім тек құрылымдық бейімдеуге — желінің шығысы бес класты есеп үшін қалай қайта пішінделетініне — қатысты.

Бейімдеу әр backbone-ның pretraining-міндет жіктеу басын pretraining тудырған конволюциялық feature extractor-ды сақтай отырып, DR 0-ден DR 4-ке дейінгі диабеттік-ретинопатия дәрежелері бойынша (IT-1-дің бес класты таксономиясы) бес жақты softmax үлестірімін тудыратын жаңа баспен ауыстырады. Softmax формуляциясы және оған байланысты loss — §2.2.1–§2.2.2-де дамытылғандар; мұнда тіркелетіні — кейбір скрининг әдебиетінде пайдаланылатын бинарлық referable/non-referable формуляциясы емес, шығыс кардиналдылығы мен құрылымы — бес өзара ерекше реттік дәреже. Бұл бес класты softmax құрылымы OD-2-нің жоғары-күрделілікті сілтемесін және кандидаттың бұрынғы бес класты желісін (Сапақова, Есмұхамедов және Сапақов, 2025) ұстанады, ол бұрынғы өз жұмысы ретінде әрі серіктес картасымен жалғыз желі ретінде келтіріледі (SIR-4, SIR-5).

Бейімдеудің әдістемелік тұрғыдан маңызды қасиеті — оның эксперименттік жобаның әр конфигурациясы бойынша бірдей екені. Сол бір бес жақты softmax басы, сол бір pretraining басын ауыстыра отырып, ResNet-50-ге де, EfficientNet-B3-ке де, әрі әр backbone ішінде базалық арнаға да, біріктірілген арнаға да қолданылады. Тек зерттелетін екі ось — preprocessing шарты және, оған бағынатын, pretraining көзі — төрт конфигурация бойынша өзгереді; шығыс құрылымы өзгермейді. Дәл осы 1-эксперимент факториалын таза қарама-қарсылық етіп ұстайды: бас тұрақты ұсталғандықтан, конфигурациялар бойынша бақыланған кез келген өнімділік айырмашылығы шығыс құрылымындағы айырмашылыққа телінбейді, әрі қарама-қарсылық ол тексеруге жобаланған preprocessing-және-pretraining осьтеріне сілтенеді. Бейімдеуді екі архитектура бойынша бірдей ұстау архитектура аралық қайталауды да мағыналы етеді: жеткілікті-валидация критерийі (EH-4) сол әсер бағыты екі backbone үшін де пайда бола ма деп сұрайды, ал бұл сұрақ тек екі backbone міндетке бірдей бейімделгенде ғана дұрыс қойылады.

Кандидаттың EfficientNetB0-дегі бұрынғы transfer-learning жұмысы — frozen-белгі конфигурациясын прогрессивті fine-tune жасалғанмен салыстырған (жалғыз эксперименттік желіні сипаттайтын екі өзін-өзі жариялауда хабарланған, SIR-4/SIR-5) — мұнда көрсетілген бас бейімдеуінен гөрі §3.3.3-те көрсетілген fine-tuning кестесін хабарлайды, әрі оның EfficientNetB0 тұжырымдары қазіргі backbone-дарға немесе тиімді CNN архитектураларының класына жалпыланбайды (SIR-7). Бейімдеу, ақырында, pretraining доменінен DR міндетіне тасымалдау әрекеті жасалатын құрылымдық тетік; сол тасымалдау іс жүзінде пайдалы репрезентациялар бере ме — бейімдеумен кепілдендірілмейді әрі жорылмай, эксперименттік шеңбер ішінде эмпирикалық бағаланады (DGL-6). Шығыс құрылымы барлық конфигурациялар бойынша ортақ тіркелген соң, §3.3.2 біріктірілген арнаны ажырататын инициализацияны — сол backbone-ның офтальмологияға тән өзін-өзі бақылайтын алдын ала оқытуын — көрсетеді, ал §3.3.3 бейімдеуден кейін қолданылатын fine-tuning кестесін көрсетеді.

§3.3.2 CNN backbone-ның офтальмологияға тән өзін-өзі бақылайтын алдын ала оқытуы (біріктірілген арна)

§3.3.1 құрылымдық бейімдеуді — бес класты softmax басын — 1-эксперименттің төрт конфигурациясы бойынша ортақ тіркеді. Конфигурацияларды ажырататыны — бас емес, fine-tuning-ке дейінгі backbone-ның *инициализациясы*, әрі бұл бөлім сол инициализацияны біріктірілген арна үшін көрсетеді. Базалық арнада (А және С конфигурациялары) backbone ImageNet салмақтарынан, табиғи кескіндерден стандартты домен аралық тасымалдаудан инициализацияланады. Біріктірілген арнада (В және D конфигурациялары) backbone оның орнына базалық арнада пайдаланылған сол ResNet-50 немесе EfficientNet-B3 архитектурасында орындалған, таңбаланбаған торқабық көз түбі корпусындағы офтальмологияға тән өзін-өзі бақылайтын алдын ала оқытудан инициализацияланады (RESEARCH_ARCHITECTURE §4.2bis; DGL-6).

Алдын ала оқыту хаттамасы. Біріктірілген-арна инициализациясы DINO [92], BYOL [90], SimCLR [88] және MoCo [89] әдістер отбасынан алынған CNN-үйлесімді домен-адаптивті өзін-өзі бақылайтын оқыту хаттамасымен тудырылады, нақты хаттама эмпирикалық таңдалып, таңдалған соң тіркеледі. Бұл алдын ала оқыту кезінде ешбір нүктеде диабеттік-ретинопатия таңбалары пайдаланылмайды; мақсат таза репрезентациялық — таңбаланбаған көз түбі кескіндерінен торқабық бейнелеуінің құрылымын ұстайтын белгілерді үйрену: тамыр топологиясы, оптикалық диск пен макулярлық морфология, торқабық текстурасы, жарықтандыру вариабельділігі және бейнелеу артефактілері (RESEARCH_ARCHITECTURE §4.2bis). Нәтижесіндегі салмақтар сосын базалық арна ImageNet-тен инициализациялайтын сол бейімделген желіні инициализациялайды, содан кейін екі арна да таңбаланған DR міндетінде бірдей fine-tune жасалады (§3.3.3). Өзін-өзі бақылайтын алдын ала оқыту сыртқы checkpoint-тен жүктелмей, үй ішінде орындалғандықтан, кодтаушыны тікелей төрт арналы tensor-да (RGB плюс FOV маскасы) алдын ала оқытуға болады, бұл үш арналы сыртқы checkpoint тудыратын кіріс-арна сәйкессіздігін жояды; §3.2.1-де сипатталған төртінші арнаны көшіру-және-орташамен-инициализациялау fallback ретінде қолжетімді болып қалады (AOQ-2 жеңілдетілген, INVARIANTS v6.0.0 §X).

Неліктен домен-ішілік, CNN-нативті инициализация. Бұл таңдаудың жобалау негіздемесі — экспериментті архитектура ауысуымен шатастырмай домен-ішілік инициализация алу. RETFound сияқты торқабық іргетас моделі ViT-Large vision transformer ретінде жарияланады; біріктірілген арнаны одан инициализациялау базалық арнаға қатысты архитектураны да, инициализацияны да өзгертер еді, сонда кез келген бақыланған айырмашылық preprocessing үлесін архитектура айырмашылығымен араластырап еді. CNN-нативті өзін-өзі бақылайтын инициализация тек инициализация кезеңін өзгертіп, екі арна бойынша да конволюциялық backbone-ды сақтайды (INVARIANTS v6.0.0 §X-те тіркелген пайымдау, ол backbone архитектурасы туралы ертерек ашық сұрақты CNN-үйлесімді SSL пайдасына шешіп, арналар

бойынша 2×2 архитектура симметриясын қалпына келтіреді, әрі сыртқы іргетас-модель лицензиясы сұрағын мәнсіз етеді). Сондықтан домен-ішілік инициализация — қолданыстағы іргетас моделін қабылдау емес, диссертацияның шатасуға өз әдістемелік жауабы.

Құрама тәуелсіз айнымалы. Бұл жобаның 1-эксперименттің интерпретациясы үшін салдары — байланыстырушы әрі кез келген нәтиже хабарланбас бұрын айтылуы тиіс. Біріктірілген арна базалық арнадан бір мезгілде екі ось бойынша ажырайды — preprocessing осі (толық pipeline пен ImageNet нормализациясымен созыла-өлшем өзгерту) және pretraining осі (офтальмологияға тән өзін-өзі бақылайтын инициализация мен ImageNet инициализациясы). Сондықтан 1-эксперименттің тәуелсіз айнымалысы — құрама фактор (*preprocessing* × *pretraining көзі*), әрі арналар арасындағы кез келген өнімділік айырмашылығы екі осьтің де бірлескен үлесін бейнелейді. Бұдан H-1 әсері тек preprocessing pipeline-ге де, тек pretraining көзіне де телінбейтіні туындайды: «preprocessing pipeline бақыланған жақсартуды тудырады» немесе «preprocessing басым» түріндегі тұжырымдар рұқсат етілмейді (CFC-2.8). H-1 тұжырымының жалғыз рұқсат етілген түрі — біріктірілген конфигурация деңгейінде — біріктірілген preprocessing-плюс-офтальмология-SSL конфигурациясы базалық-плюс-ImageNet конфигурациясынан берілген метрикада берілген шамаға асып түседі. Құрама әсерді жеке preprocessing және pretraining үлестеріне ыдырату осы диссертация ауқымынан айқын тыс әрі болашақ жұмыс ретінде аталатын қосымша факториалды талап етер еді.

Әдебиет мәртебесі мен адалдық шарттары. Бұл сипаттаманың екі шектеуі ашық айтылады. Біріншіден, біріктірілген-арна инициализациясы сүйенетін өзін-өзі бақылайтын әдістер енді жинақталған корпуста негізделген. Медициналық бейнелеуде шектеулі таңбалар аясында өзін-өзі бақылайтын, көп-даналы және transfer learning жалпы шолуынан [45] бөлек, корпус енді жоғарыда аталған бастапқы әдістерді маскаланған-автокодтаушы мақсатымен [93] және SimSiam-мен [91] бірге, медициналық бейнелеудегі өзін-өзі бақылайтын оқытудың арнайы шолуын [87], әрі — ең тікелей — торқабық көз түбі кескіндерінде домен-ішілік өзін-өзі бақылайтын алдын ала оқыту жалпыланатын торқабық репрезентацияларын беретінінің [46] (RETFound) және домен-ішілік медициналық өзін-өзі бақылайтын алдын ала оқыту ImageNet трансферінен асып түсе алатынының [47] (MICLe) дәлелін қамтиды. Бұл дереккөздер бағыттың жалпы сенімділігін орнықтырады; олар орнықтырмайтыны — осы диссертация қабылдайтын нақты конфигурация. RETFound-тың домен-ішілік дәлелі ViT-Large backbone-мен, ал MICLe-дікі көз түбі емес медициналық модальдылықтармен алынады, ал біріктірілген арна конволюциялық backbone-ды тұрақты ұстап, оны төрт арналы tensor-да CNN-нативті алдын ала оқытады — бұл дереккөздердің ешқайсысы бағаламайтын конфигурация [UNSOURCED CLAIM: төрт арналы tensor-да CNN-нативті домен-ішілік өзін-өзі бақылайтын алдын ала оқыту ImageNet базалығымен бәсекеге қабілетті көз түбіне-қатысты инициализация береді деген күтілім, осы кезеңде, диссертацияның өз әдістемелік гипотезасы; ол RETFound пен MICLe-

дің домен-ішілік SSL дәлелімен үйлеседі, бірақ ViT немесе көз түбі емес модальдылықтарды бағалайтын ешбір торқабық-SSL примарасымен тікелей орнықтырылмаған]. Сәйкесінше домен-ішілік өзін-өзі бақылайтын инициализация әдебиеттен мұраланған нәтиже ретінде емес, тиімділігі эмпирикалық орнықтырылуға тиіс кандидат әдістемелік үлес ретінде ұсынылады. Екіншіден, бұл бөлім нәтижені емес, жобаны көрсетеді: офтальмология-өзін-өзі-бақылайтын арна (B және D конфигурациялары) — орындалуға тиіс сипаттама, әрі ешбір өзін-өзі бақылайтын алдын ала оқыту нәтижесі мұнда хабарланбайды немесе осы диссертацияда сол орындаудан бұрын басқа жерде бекітілмейді.

Біріктірілген-арна инициализациясы көрсетіліп, шектелген соң, §3.3.3 бейімделген, инициализацияланған желі — кез келген инициализация аясында — таңбаланған DR міндетінде оқытылатын екі кезеңді fine-tuning кестесін көрсетеді, ал §3.3.4 ол оқытылатын loss-ты көрсетеді.

§3.3.3 Екі кезеңді Fine-Tuning хаттамасының жобасы

Backbone бес класты міндетке бейімделген (§3.3.1) және инициализацияланған соң — базалық арнада ImageNet-тен немесе біріктірілген арнада офтальмологияға тән өзін-өзі бақылайтын алдын ала оқытудан (§3.3.2) — ол таңбаланған DR міндетінде екі кезеңді fine-tuning кестесімен оқытылады. Кесте әр конфигурация үшін бірдей; ол — бейімделген, инициализацияланған желі оңтайландырылатын процедура, оның алдындағы инициализациядан және ол минимизациялайтын loss-тан (§3.3.4) ерекше.

Екі кезең жаңадан инициализацияланған баспен алдын ала оқытылған желіні fine-tune жасауға тән шиеленісті шешеді. Бірінші кезеңде backbone frozen ұсталып, тек жаңа бес класты жіктеу басы оқытылады. Алдын ала оқытылған feature extractor тіркелген ұсталғанда, бас оқытылмаған бастың үлкен, нашаршартталған градиенттері алдын ала оқытылған салмақтарға кері таралып, оларды бұзбай, орнықтырылған белгілерді DR дәрежелеріне бейнелеуді үйренеді. Екінші кезеңде backbone-ның жоғарғы қабаттары прогрессивті түрде unfreeze жасалып, баспен бірге оқытылады, бұл жоғары деңгейлі белгілерге — ең міндетке-тән әрі сондықтан бейімдеуден ең көп пайда көретіндер — көз түбі бейнелеуінің және DR градациялау міндетінің сипаттарына бапталуға мүмкіндік береді, ал төменгі, жалпырақ қабаттар консервативтірек бейімделеді немесе тіркелген қалады. Бұл frozen-содан-прогрессивті реттілік — теориясы §2.3.2-де баяндалған стандартты прогрессивті fine-tuning стратегиясы.

Кесте кандидаттың бұрынғы transfer-learning жұмысында негізделген. Сол бұрын жарияланған нәтижелер EfficientNetB0-де frozen-белгі конфигурациясын прогрессивті fine-tune жасалғанмен салыстырып, прогрессивті fine-tune жасалған конфигурацияны екеуінің күштісі деп хабарлады — fine-tune жасалғанда шамамен 0,74 салмақталған F1-балл, frozen-да шамамен 0,62, әрі шамамен 75% precision-ға қарсы 65% (жалғыз эксперименттік желіні сипаттайтын екі өзін-өзі жариялауда хабарланды әрі мұнда біреу ретінде келтіріледі, SIR-4 және SIR-5 бойынша). Екі ескерту бұл жазбаны пайдалануды

реттейді. Біріншіден, ол EfficientNetB0-мен алынды әрі қазіргі backbone-дарға немесе тиімді CNN архитектураларының класына жалпыланбайды (SIR-7); ол прогрессивті кестені таңдауды ResNet-50 немесе EfficientNet-B3 үшін оның нәтижесін орнықтырудан гөрі уәждейді. Екіншіден, frozen-ды прогрессивті fine-tuning-пен салыстыру осы диссертацияда тексеру астындағы гипотеза емес, оқыту-әдісі шешімі: fine-tuning стратегиясына қатысты ертерек гипотеза ертерек governance реконсилияциясында алынып тасталды, сондықтан мұнда ешбір осындай гипотеза бағаланбайды немесе қалпына келтірілмейді, әрі кесте тек барлық конфигурациялар оқытылатын әдіс ретінде тіркеледі.

Кестені біркелкі тіркеу басты біркелкі тіркеумен (§3.3.1) дәл сол мақсатқа қызмет етеді. Екі кезенді хаттама ResNet-50-ге де, EfficientNet-B3-ке де, әрі базалық пен біріктірілген арнаға да бірдей қолданылады, сонда оқыту процедурасы төрт конфигурация бойынша айырмашылық көзі болмайды әрі 1-эксперимент қарама-қарсылығы зерттелетін preprocessing-және-pretraining осьтеріне телінетін болып қалады, архитектура аралық келісім (EH-4) ортақ кесте аясында оқылады. Бейімдеу сияқты, кесте — тасымалдау әрекеті жасалатын тетік; fine-tuning кез келген инициализация аясында тиімді міндет бейімдеуін қаншалықты беретіні кепілдендірілмеген әрі эмпирикалық бағаланады (DGL-6). Оқыту кестесі тіркелген соң, §3.3.4 кесте минимизациялайтын loss функциясын — DR градациялау міндетінің теңгерімсіз, реттік құрылымы үшін таңдалған салмақталған формуляцияны — көрсетеді.

§3.3.4 Реттік класс құрылымы үшін салмақталған Loss функциясының формуляциясы


§3.3.3-тің екі кезенді кестесі диабеттік-ретинопатия градациялау міндетінің құрылымы үшін таңдалуы тиіс loss функциясын минимизациялайды: дәрежелері реттік әрі оқыту таралуы EyePACS-те қатты теңгерімсіз бес класты есеп (SB-2.1). Салмақталмаған cross-entropy мақсаты аясында градиент сигналы басым ауру-жоқ (DR 0) класымен басым болар еді, әрі желі орташа loss-ты минимизациялай отырып, клиникалық тұрғыдан ең елеулі сирек ауыр дәрежелерде нашар жұмыс істер еді. Сондықтан loss мұған тікелей қарсы тұратындай көрсетіледі, әрі ол шеңбер класс теңгерімсіздігіне қарсы пайдаланатын екі жобалау иінтірегінің негізгісін құрайды — екіншісі §3.1.3-тің 6-кезең augmentation-i.

Оқыту мақсаты — кері-жиілік класс салмақтауымен focal loss [75] (RESEARCH_ARCHITECTURE §4.0):

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t),$$

мұнда p_t — модельдің мысалдың шынайы класы үшін бағаланған ықтималдығы, γ — фокустау параметрі ($\gamma = 2$ орнатылған), ал α_t — класс бойынша салмақ. Бұл формуляцияда екі тетік бірге әрекет етеді. Focal модуляциялаушы фактор $(1 - p_t)^\gamma$ әлдеқашан сенімді әрі дұрыс жіктелген мысалдарды (олар үшін p_t 1-ге жуық, сондықтан фактор 0-ге жуық) төмендетіп, оқыту екпінін қиын және қате-жіктелген мысалдарға қарай қайта бағыттайды

— бұл қайта салмақтаудың схемасы 3.12-суретінде көрсетілген. Класс салмағы α_i әр кластың кері жиілігіне орнатылады, сонда сирек дәрежелер loss-қа жиілерге батудың орнына өздерінің сиректігіне пропорционал үлес қосады; бұл салмақтар §4.1.2-де құжатталған EyePACS класс үлестірімінен алынады. Сонымен focal модуляция жеке мысалдардың оңай/қиын теңгерімсіздігін шешеді, ал кері-жиілік салмақтауы кластар арасындағы жиілік теңгерімсіздігін шешеді, әрі екеуі толықтырушы.



Сурет 3.12 – focal-loss салмақтау схемасы

Бұл loss-жағы тетігі мен §3.1.3-тің augmentation-жағы тетігі — шеңбер теңгерімсіздікті шешетін екі иінтірек (SC-1.4): loss мақсат бетін қайта пішіндейді, ал augmentation кіріс таралуын қайта пішіндейді. Ешқайсысы теңгерімсіздікті шешеді деп бекітілмейді, әрі таңдау шығынға-сезімтал оқыту, белсенді бағыт болса да, жұқа валидацияланған әдебиетке қарсы жасалады — саланың жүйелі шолуы шолынған бір жүз жетпіс үш мақаланың тек екеуі ғана валидация зерттеуі болғанын тапты [74], жобалау таңдауын ол үшін DR-ге тән дәлел бермей шеңберлейтін шолу-деңгейлі байқау (SIR-3). Кандидаттың теңгерімсіз DR жіктеудегі бұрынғы жұмысы (EfficientNetB0 transfer-learning желісінде хабарланған, бұрынғы өз жұмысы ретінде әрі серіктес жарияланымымен бір желі ретінде келтіріледі, SIR-4/SIR-5) да қазіргі таңдауды валидациялаудан гөрі уәждейді, әрі оның EfficientNetB0 тұжырымдары қазіргі backbone-дарға жалпыланбайды (SIR-7).

Loss жалғыз тұрудан гөрі бағалау шеңберімен үйлестіріледі. DR дәрежелері реттік болғандықтан, екі дәрежеге қате жіктеу клиникалық

тұрғыдан бір дәрежеге қате жіктеуден нашар, әрі бұл реттік шығынды бағалау уақытында дәлел иерархиясы негізгі метрикалардың қатарына қоятын квадраттық-салмақталған Cohen's κ ұстайды (ЕН-1). Сонымен салмақталған loss оқыту кезінде теңгерімсіздікті шешеді, ал реттік-сезімтал метрика бағалау кезінде реттік қатені жазалайды; екеуі де §3.4.1-де көрсетілген. Loss өзінің канондық бастапқы дереккөзі бойынша [75], енді жинақталған әдебиет корпусында бар (§2.2.2-де алғаш аталғанда келтірілген), әрі диссертацияның governance-і бойынша (RESEARCH_ARCHITECTURE §4.0) анықталады; Lin және әріптестері focal loss-ты торқабық бейнелеуінде емес, COCO нысан-анықтау эталонында енгізгендіктен, ол мұнда DR-ге тән нәтиже ретінде емес, орнықтырылған loss-жоба негіздемесі үшін қабылданады (SIR-2). Бейімдеу, инициализация, fine-tuning кестесі және loss енді барлығы көрсетілген соң, §3.4 оқытылған модельдер бағаланатын шеңберге бұрылады.

§3.4.1 Көп-метрикалы бағалау шеңбері

§3.3-те көрсетілген оқыту процедурасы оқытылған модель тудырады; бұл бөлім сол модель қалай бағаланатынын көрсетеді. Басқарушы қағидат — диагностикалық тиімділік кез келген жалғыз саннан гөрі метрикалар иерархиясынан оқылатыны, деректерден тікелей туындайтын себеппен: EyePACS таралуы ауру-жоқ класына қарай қатты теңгерімсіз (SB-2.1), әрі мұндай теңгерімсіздік аясында жалпы дәлдік басым-класс өнімділігімен кампиды әрі клиникалық тұрғыдан ең маңызды сирек ауыр дәрежелер туралы ақпаратсыз — конволюциялық желілер үшін жүйелі құжатталған бұрмалау, онда класс теңгерімсіздігі өнімділікті нашарлатады әрі дәлдік адастырады [81]. Сондықтан шеңбер метрикаларын дәлелдік салмағы бойынша рейтингтейді әрі ең күшті дәлелдің теңгерімсіздікке ең берік метрикаларға сүйенуін талап етеді.

Негізгі метрикалар. Дәлел иерархиясы (ЕН-1) төрт негізгі метриканы кему дәлелдік салмағы бойынша реттейді: салмақталған F1-балл бірінші, өйткені ол класс теңгерімсіздігін ескереді әрі қисайған таралу аясында тікелей интерпретацияланады; ROC-AUC екінші, ажыратылушылықтың шектен-тәуелсіз өлшемі ретінде; квадраттық-салмақталған Cohen's κ үшінші, өйткені ол клиникалық тұрғыдан елеулі реттік қате-жіктеуді жазалайды — екі дәрежелі қате бір дәрежелі қатеден көп тұрады, бұл метриканы §3.3.4-тің реттік-сезімтал focal loss-пен жұптайтын қасиет; әрі дәлдік төртінші, хабарланады, бірақ теңгерімсіздік аясындағы кампуы себебінен ешқашан жалғыз жеткіліксіз. Конфигурация тек OD-5 операциялдық анықтамасының бірлескен шектерінен өткенде ғана диагностикалық тұрғыдан тиімді деп саналады, ол негізгі метрикалармен бірге 3.2-кестеде жинақталған. Бұл шектер еркін емес: олар кандидаттың бұрын жарияланған эмпирикалық нәтижелерінен алынды (Сапақова және әріптестері; бір зерттеуде салмақталған $F1 = 0,91$ және $ROC-AUC = 0,9638$, басқасында салмақталған орташа $= 0,81$ және дәлдік $= 0,80$), бұрынғы өз жұмысы ретінде келтіріліп, мұнда тиімділік еденінің сілтеме бекіткіштері ретінде пайдаланылады, қазіргі эксперименттерге тасымалданатын өнімділік мәндері ретінде емес (SIR-4); шағын деректер жиынтықтарында басқа

жерде хабарланған айтарлықтай жоғары көрсеткіштер айқын тасымалданбайды (SB-1.2). Төмендегі әр метрикаға ескерту қолданылады: әрқайсысы деректер жиынтығымен берілген эталондық дәрежелерге қарсы есептеледі, ал сол дәрежелердің сенімділігі өзі бағалау айнаымалысы — градациялаушы вариабельділігі көрінетін өнімділікті айтарлықтай ығыстыра алады, әрі төрелік етілген эталондық стандарттар оны азайтады, бірақ жоймайды [98]; диссертация жария деректер жиынтықтарының берілген таңбаларын және олардың эталондық-стандарт шектеулерін мұралайды (SIR-2).

ТАВ-3.2. Көп-метрикалы бағалау шеңбері және диагностикалық-тиімділік шектері (ЕН-1, ЕН-2, OD-5).

Деңгей	Метрика	Дәлелдік рөлі	Тиімділік шегі (OD-5)
Негізгі (ЕН-1)	Салмақталған F1-балл	Ең жоғары салмақ; класс теңгерімсіздігін ескереді	$\geq 0,80$
Негізгі (ЕН-1)	ROC-AUC	Шектен-тәуелсіз ажыратылушылық	$\geq 0,90$
Негізгі (ЕН-1)	Cohen's κ (квадраттық салмақтар)	Реттік қате-жіктеуді жазалайды	$\geq 0,70$
Негізгі (ЕН-1)	Accuracy	Хабарланады; теңгерімсіздік аясында қампиды, жалғыз жеткіліксіз	$\geq 0,80$
Қосалқы (ЕН-2)	Класс бойынша precision / recall	Ақпаратты; азшылық кластар үшін тұрақсыз	—
Қосалқы (ЕН-2)	Макро-орташа P/R/F1	Салмақталған орташамен бірге хабарланады	—
Қосалқы (ЕН-2)	Оқыту-жиыны метрикалары	Тек артық үйрену диагнозы (>15 пп оқыту-тест алшақтығы, OD-4)	—
Клиникалық скрининг	Сезімталдық / Спецификалық / PPV / NPV (referable DR, дәреже ≥ 2)	1, 3, 5-эксп. үшін хабарланады	—
Калибрлеу	Expected Calibration Error (ECE), Brier балы	Ықтималдықтардың эмпирикалық сенімділігі, клиникалық	—

		сенімділік емес (SB-1.10)	
Explainability	ALO (негізгі), IoU (қосалқы)	Назар–зақымдану қабаттасуы; клиникалық локализация емес (NC-14)	—
Жалпылау	$G = F1_external / F1_EyePACS$ (OD-4)	Деректер жиынтығы аралық тасымалдау	(H-4: $G \geq 0,85$)

Қосалқы метрикалар және артық үйрену. Қосалқы метрикалар (EH-2) толықтық үшін хабарланады, бірақ гипотезаны тәуелсіз орнықтыра немесе жоққа шығара алмайды. Класс бойынша precision мен recall ақпаратты, бірақ азшылық ауыр дәрежелер үшін тұрақсыз; макро орташалар олардың арасындағы кез келген алшақтықты ашу үшін салмақталған орташалармен бірге хабарланады; ал оқыту-жиыны метрикалары тек артық үйренуді диагностикалау үшін пайдаланылады, кез келген негізгі метрикада он бес пайыздық тармақтан асатын оқыту-мен-тест алшақтығы ретінде операционалданады (OD-4). Бұларды негізгі метрикалармен бірге хабарлау конфигурацияның салмақталған жиынтықта тиімді көрініп, азшылық дәрежеде сәтсіздікке ұшырауынан сақтайды.

Клиникалық-скрининг және калибрлеу метрикалары. Скринингке-бағытталған талдаулар үшін (1, 3 және 5-эксперименттер) сезімталдық, спецификалық, оң болжамдық мән және теріс болжамдық мән referable-DR шегі (дәреже ≥ 2) үшін хабарланады. Калибрлеу Expected Calibration Error және Brier балымен [97] бағаланады, олар модельдің болжанған ықтималдықтары бақыланған жиіліктерге сәйкес келе ме деп сандық бағалайды. Калибрлеу тек эмпирикалық диагностикалық қасиет ретінде хабарланады; ол болжанған ықтималдықтардың клиникалық сенімділігін орнықтырмайды, әрі ешбір осындай тұжырым жасалмайды (SB-1.10).

Кескін-сапасы метрикалары. Preprocessing әсерін downstream жіктеуден тәуелсіз сандық бағалау үшін — себептік тізбектің бірінші буынын, preprocessing → жақсартылған белгі көрінушілігін, жабу — pipeline кезеңдерінде төрт кескін-сапасы метрикасы өлшенеді, 3.3-кестеде жинақталған. Бұл метрикалар preprocessing кезеңін тек жіктеуіш арқылы емес, өз шарттарымен бағалайды, әрі олардың бірі, құрылымдық ұқсастық индексі [96], нақты күзет рөлін атқарады: өңделген мен түпнұсқа кескін арасындағы жоғары SSIM жақсарту кезеңдерінің бұзушы құрылымдық артефактілер енгізбегенін растайды, бұл §3.1.1-де pipeline үшін айтылған бұзушы-артефактсіз жобалау мақсатының өлшенетін түрі.

ТАБ-3.3. Алдын ала өндеуді бағалауға арналған кескін-сапасы метрикалары (RESEARCH ARCHITECTURE §3.3).

Метрика	Өлшейтіні	Preprocessing-тің күтілетін әсері
---------	-----------	-----------------------------------

Контраст-пен-шу қатынасы (CNR)	Тамыр құрылымдарының фонға қарсы сигнал сапасы	Жарық-өрісін түзету мен CLANE-ден кейін жоғарырақ
Тамыр көрінушілік индексі (VVI)	Торқабық тамыр жүйесінің анықталушылығы	Жарық-өрісін түзету мен CLANE-ден кейін жақсарған
Кескін энтропиясы	Кескіннің ақпарат мазмұны	Контрастты күшейткеннен кейін артқан
Құрылымдық ұқсастық (SSIM)	Түпнұсқаға қатысты құрылымды сақтау	Жоғары SSIM бұзушы артефактілер енгізілмегенін растайды

3.3-кестедегі бағыттық күтілімдер тиісті кезеңдердің жобалау ниеті ретінде айтылады, дәлелденген нәтижелер ретінде емес; өлшенген мәндер 2-эксперимент үшін хабарланады (§4.3.3), әрі §3.1.2-де орнықтырылған контраст операцияларының шарттылығы оларға да қолданылады.

Explainability метрикалары. Preprocessing-тің модель назарына әсері бағаланатын жерде (4-эксперимент) екі қабаттасу метрикасы Grad-CAM активация аймақтарын IDRiD-тің пиксел деңгейіндегі зақымдану масктарымен байланыстырады. Негізгі метрика — назар–зақымдану қабаттасуы, назар аймағы қамтитын зақымдану ауданының үлесі,

$$ALO = (\text{area}(\text{GradCAM} \cap \text{lesion_mask})) / \text{area}(\text{lesion_mask}),$$

ал қосалқы метрика — Intersection-over-Union,

$$IoU = (\text{area}(\text{GradCAM} \cap \text{lesion_mask})) / (\text{area}(\text{GradCAM} \cup \text{lesion_mask})),$$

нысан-анықтау бағалауынан алынған симметриялы қабаттасу критерийі [94], мұнда анықтау эталоны ретінде емес, қабаттасу өлшемі ретінде пайдаланылады. Екеуі де модель назары мен аннотацияланған зақымданулар арасындағы кеңістіктік келісімді сандық бағалайды; ешқайсысы патологияның клиникалық локализациясын құрамайды, әрі Grad-CAM активациясы — интерпретация сигналы, зақымдану шекараларының диагностикалық сызбасы емес (NC-14).

Жалпылау және жинақтау критерийлері. Деректер жиынтығы аралық тасымалдау жалпылау коэффициентімен $G = F1_external / F1_EyePACS (OD-4)$ өлшенеді, сол оқытылған модель аясында қайта оқытусыз сыртқы-мен-негізгі-деректер жиынтығы салмақталған F1 қатынасы; ол — кейіннен алдын ала тіркелген H-4 критерийі ($G \geq 0,85$) тексерілетін шама. Соңында, бұл метрикалар диссертацияның орталық тұжырымы деңгейінде оқшауланып әрекет етпейді: эмпирикалық-басымдық критерийі (EH-3) салмақталған F1-де кемінде бес пайыздық тармақ, ROC-AUC-те кемінде 0,02 бір мезгілде жақсаруды әрі Cohen's k-да нашарламауды талап етеді, ал жеткілікті валидация (EH-4) бұның сыртқы деректер жиынтығы мен екі архитектура бойынша қайталануын қосымша талап етеді. Бұл құрама критерийлер мұнда метрикалар

коректендіретін стандарт ретінде аталады; олардың нәтижелерге қолданылуы §4.2-ге тиесілі. Метрикалар анықталған соң, §3.4.2 олар сандық белгісіздікпен есептелетін cross-validation және статистикалық-сенімділік хаттамаларын көрсетеді.

§3.4.2 Cross-Validation және статистикалық сенімділік хаттамалары

§3.4.1-де көрсетілген метрикалар — бағалаулар, ал сандық белгісіздіксіз баға диссертация сүйенетін құрама басымдық пен валидация критерийлерін қолдай алмайды. Бұл бөлім метрикалардың деректер бөліктері бойынша қалай есептелетінін, олардың белгісіздігі қалай сандық бағаланатынын, конфигурациялардың статистикалық тұрғыдан қалай салыстырылатынын және қандай қайта жаңғыртылушылық шарттарында екенін көрсетеді — ЕН-3 пен ЕН-4 шешімдерінің жалғыз нүктелік бағалаулардан гөрі сандық дәлелге сүйенуіне мүмкіндік беретін хаттамалар.

Cross-validation және ағып кетуді бақылау. Барлық эксперименттер пациент-деңгейлі стратификацияланған бөлумен бес-fold cross-validation пайдаланады: деректер бес fold-қа бөлінеді, әр fold бір рет тест бөлігі ретінде қызмет етеді, ал қалған төртеуі модельді оқытады, әрі үдеріс бес fold бойынша қайталанады (RESEARCH_ARCHITECTURE §2.2, §5.0). Бөлу 3.13-суретінде көрсетілген. Айқындаушы қасиет — бөлу кескін деңгейінде емес, пациент деңгейінде жасалатыны: ешбір пациенттің кескіндері кез келген fold-тың оқыту мен тест бөлігінде бір мезгілде көрінбейді. Бұл — косметикалық таңдау емес. Көз түбі деректер жиынтықтары әдетте сол бір көздің бірнеше кескінін және сол бір пациенттің екі көзін қамтиды, олар қатты корреляцияланған; кескін деңгейінде бөлу бір пациенттің корреляцияланған кескіндерін бөлудің екі жағына да орналастырып, көрінетін тест өнімділігін ағып кетумен қампытар еді. Пациент-деңгейлі топтау сол ағып кету жолын жояды, әрі ол 6-кезең augmentation-нің тек оқыту мәртебесімен (§3.1.3) үйлеседі — ешбір augment жасалған кескін кез келген тест бөлігіне кірмейді — сонда тест бағасы көрінген пациенттерді жаттаудан гөрі көрінбеген пациенттерге жалпылауды бейнелейді. Әр негізгі метрика бес fold бойынша орташа $\pm$ стандартты ауытқу ретінде хабарланады, сонда fold-тан fold-қа вариабельділік орталық бағамен бірге көрінеді.

5-Fold Patient-Level Stratified Cross-Validation
(no patient appears in train and val of the same fold)

Train (≈80%)
Validation (≈20%)

	Patient group 1	Patient group 2	Patient group 3	Patient group 4	Patient group 5
Fold 1	Val	Train	Train	Train	Train
Fold 2	Train	Val	Train	Train	Train
Fold 3	Train	Train	Val	Train	Train
Fold 4	Train	Train	Train	Val	Train
Fold 5	Train	Train	Train	Train	Val

Сурет 3.13 – 5-fold пациент-деңгейлі cross-validation бөлуі

Статистикалық-тест жиынтығы. Конфигурациялар арасындағы айырмашылықтар әрқайсысы өзі қызмет ететін салыстыруға сәйкестендірілген тесттер жиынтығымен бағаланады (RESEARCH_ARCHITECTURE §6.8). McNemar тесті 1-эксперименттегі жұптасқан жіктеу салыстыруы үшін пайдаланылады, онда сол бір тест жағдайлары бәсекелес конфигурациялармен жіктеледі. DeLong тесті ROC-AUC мәндерін салыстыру үшін, 1 және 3-эксперименттерде пайдаланылады. Тоқсан бес пайыздық сенімділік интервалдары барлық эксперименттер үшін кемінде бір мың қайта іріктеумен bootstrap қайта іріктеу арқылы есептеледі, бұл — әр хабарланған метрикаға белгісіздік интервалын қосатын тетік — әрі өлшенген айырмашылықтың шудың ішіне түсуден гөрі ЕН-3 шектерінен асатынын бағалауға болатын негіз. 1-эксперимент үшін fold-тар бойынша аралас-әсерлер моделі fold-ты кездейсоқ әсер ретінде қарай отырып сәйкестендіріледі, қызығушылық тудыратын конфигурация әсерін fold-деңгейлі дисперсиядан ажыратады. 1 және 2-эксперименттер әрқайсысы конфигурациялар мен абляция деңгейлері бойынша көп бір мезгілді салыстыру жасайтындықтан, отбасы-бойынша қателік деңгейін бақылау үшін Bonferroni/Holm көп-салыстыру түзетуі қолданылады, сонда салыстыру саны жалған маңыздылықты жасамайды.

Басымдық пен валидация критерийлерімен қатынас. Бұл тесттер §3.4.1-де қайта айтылған құрама критерийлер артындағы машинерия. Эмпирикалық-басымдық критерийі (ЕН-3) салмақталған-F1-де кемінде бес пайыздық тармақ, ROC-AUC-те кемінде 0,02 бір мезгілде жақсаруды әрі Cohen's k-да нашарламауды талап етеді; bootstrap интервалдары мен жұптасқан тесттер бақыланған айырмашылықтың сол шектерден сенімді өтетінін айқындайтын нәрсе. Жеткілікті-валидация критерийі (ЕН-4) сол әсер бағытын кемінде бір сыртқы деректер жиынтығында және екі архитектура бойынша қайталауды қосымша талап етеді; осы хаттама тудыратын fold-бойынша, архитектура-бойынша, деректер жиынтығы-бойынша бағалар — дәл сол критерий бағаланатын нәрсе. Екі критерий де мұнда статистиканың рөлін

бекіту үшін қайта айтылады; олардың нәтижелерге қолданылуы 4-тарауға сақталған.

Қайта жаңғыртылушылық конфигурациясы. Барлық эксперименттер 3.1-кестеде жинақталған жалғыз стандартталған оқыту конфигурациясында, тіркелген кездейсоқ seed және детерминистік орындаумен, тіркелген augmentation параметрлерімен және тіркелген learning-rate кестесімен орындалады (RESEARCH_ARCHITECTURE §4.0, §9.3). Оптимизатор — Adam [99], 3.1-кестенің басқа гиперпараметрлерімен тұрақты ұсталады, сонда салыстырулар баптау айырмашылықтарынан гөрі конфигурация әсерін оқшаулайды. Бұларды тіркеу run-тан run-ға детерминистік еместікті шатасу ретінде жояды, сонда конфигурациялар арасындағы өлшенген айырмашылық seed вариациясынан гөрі конфигурацияға телінеді.

ТАБ-3.1. Стандартталған оқыту конфигурациясы (RESEARCH_ARCHITECTURE §4.0).

Параметр	Мән
Оптимизатор	Adam ($lr = 1 \times 10^{-4}$, $weight_decay = 1 \times 10^{-4}$)
Пакет өлшемі	16
Максималды эпохалар	20 (early stopping, patience = 5)
Loss функциясы	Focal loss ($\gamma = 2$, α = кері-жиілік класс салмақтары)
Кіріс ажыратымдылығы	512×512
Кіріс арналары	3 (базалық) немесе 4 (FOV маскасымен толық)
Аралас дәлдік (fp16)	ResNet-50 үшін қосулы; EfficientNet үшін өшірілі (fp16 толып кету)
Cross-validation	5-fold, пациент-деңгейлі стратификацияланған бөлу
Seed	42, deterministic = true

Бұл конфигурация беретін қайта жаңғыртылушылық құжатталған аппаратпен шектелген: есептеу тиімділігі немесе оқыту мінез-құлқы туралы тұжырымдар эксперименттер орындалатын аппаратқа тән әрі қайта бағалаусыз айтарлықтай түрлі есептеу контексттеріне тасымалданбайды (DGL-2), ал жабық клиникалық деректерге тәуелді нәтижелер §3.1.4-те атап өтілген қосымша қайта жаңғыртылушылық шегін алып жүреді (SB-2.2). Cross-validation, статистикалық және қайта жаңғыртылушылық хаттамалары көрсетілген соң, 3-тараудың әдістемелік денесі аяқталады; §3.C шеңбер қайта жаңғыртылатын шарттарды шоғырландырады.

§3.C 3-тарау бойынша қорытындылар

Бұл тарау біріктірілген preprocessing–CNN моделін және ол бағаланатын шеңберді екеуінің де қайта жаңғыртылуына әрі келесі эксперименттерде дәл айқындалған нысандар болуына жеткілікті егжей-тегжейде көрсетті. Сипаттама

осы жұмыстың орталық міндеттемесі айналасында — диагностикалық модель екі кезеңді жүйе, $model = preprocessing + CNN$, онда preprocessing қосалқы деректерді дайындау емес, интегралды модель компоненті — ұйымдастырылды, әрі тараудың төрт бөлігінің әрқайсысы сол міндеттеменің бір қырының инженерлік жүзеге асырылуы.

Төрт бөлік шикі кескіннен бағаланған болжамға дейінгі толық pipeline құрайды. §3.1 preprocessing компонентін көрсетті: pipeline-нің сегіз реттелген, детерминистік кезеңі — канондық аудару, оптикалық диск-фовеа айналу нормализациясы, көру-өрісін қию және изотропты өлшемін өзгерту, көру-өрісі маскасын генерациялау, адаптивті жарық-өрісін түзету, қос шектеулі CLANE, оқыту-уақыттық augmentation және деректер жиынтығына тән нормализация — клиникалық деректер үшін модельдің кіріс келісімін айқындайтын сыртқы-кескінді қабылдау хаттамасымен бірге. §3.2 желі компонентін көрсетті: түрлі архитектура отбасыларынан екі орнықтырылған backbone, ResNet-50 және EfficientNet-B3, архитектуралық-күрделілік анықтамасын шектейтін тарихи күрделілік сілтемелерімен. §3.3 желінің қалай дайындалатынын және оқытылатынын көрсетті: ортақ бес класты жіктеу басы, арнаға-тән инициализация (базалық арна үшін ImageNet, біріктірілген арна үшін офтальмологияға тән өзін-өзі бақылайтын алдын ала оқыту), екі кезеңді fine-tuning кестесі және теңгерімсіз реттік міндет үшін кері-жиілікпен-салмақталған focal loss. §3.4 өлшеуді көрсетті: дәлелдік салмағы бойынша реттелген көп-метрикалы бағалау шеңбері, әрі сәйкестендірілген статистикалық-тест жиынтығы мен көп-салыстыру түзетуімен пациент-деңгейлі бес-fold cross-validation-ға құрылған валидация хаттамасы.

Бірге алғанда, бұл сипаттамалар шеңбер қайта жаңғыртылатын шарттарды бекітеді. Оқыту конфигурациясы стандартталған әрі орындау тіркелген seed аясында детерминистік; дерек бөлуі ағып кетуді болдырмау үшін пациент деңгейінде жасалады; preprocessing параметрлері сыртқы зерттеулерден импортталудан гөрі диссертацияның өз шеңбері ішіндегі валидациямен айқындалады; әрі әр хабарланған метрика сандық белгісіздік алып жүруге тиіс. Бұл шарттар конфигурациялар арасындағы өлшенген айырмашылықты кедергі вариациясынан гөрі конфигурацияға телуге мүмкіндік беретін нәрсе.

Тарау сонымен қатар өзінің әдістемесі әдейі нені шектейтініне нақты болды, әрі бұл міндеттемелер 4-тараудың нәтижелері қалай оқылатынын шектейді. Негізгі эксперименттің тәуелсіз айнымалысы — preprocessing мен pretraining көзінің құрама факторы, сондықтан кез келген бақыланған әсер тек біріктірілген конфигурацияға телінеді әрі ешқашан тек preprocessing-ке емес (CFC-2.8). Біріктірілген арнаның өзін-өзі бақылайтын инициализациясы мұнда көрсетілген, бірақ әлі оқытылмаған; ол әдістемелік жоба және кандидат үлесі ретінде ұсынылады. Ол сүйенетін домен-ішілік өзін-өзі бақылайтын әдістер енді корпуста ұсынылған (v6.1.0 кеңейтуінде алынды әрі §1.3.2 мен §3.3.2-де келтірілген), бірақ нақты CNN-нативті біріктірілген-арна конфигурациясы оқытылмаған әрі оның тиімділігі сол дереккөздерден мұраланудан гөрі эмпирикалық орнықтырылуға тиіс. Классикалық оптикалық диск-фовеа

детекторының сенімділігі өлшеніп, адал хабарланды, фовеа локализациясы сенімсіз деген тұжырымды қоса, әрі pipeline-нің консервативті fallback-тары оны жасырудан гөрі сол тұжырыммен уәждемді. CLANE параметрлері деректер жиынтықтары бойынша тасымалданады деп жорылмайды, кез келген pretraining көзінен тасымалдау кепілдік емес, эмпирикалық сұрақ ретінде қаралады, ешбір кезең конфигурациясы әмбебап оңтайлы деп бекітілмейді, әрі кейбір валидацияның жабық клиникалық деректерге тәуелділігі сыртқы қайта жаңғыртылушылықты шектейді. Бұлар — ескерту ретінде бүркемеленген кемшіліктер емес, түпкі тұжырымдарды қорғалатын ететін эпистемикалық тәртіп. Модель мен оның бағалау шеңбері осылай көрсетіліп, осылай шектелген соң, диссертация деректер жиынтықтары мен эксперименттік конфигурацияны орнықтырып, содан кейін H-1-ден H-7-ге дейінгі гипотезаларды осында айқындалған басымдық пен жеткілікті-валидация критерийлеріне қарсы бағалайтын 4-тарауға өтеді.

4 ЭКСПЕРИМЕНТТІК ЗЕРТТЕУ — PREPROCESSING-ТІҢ CNN ДИАГНОСТИКАЛЫҚ ӨНІМДІЛІГІНЕ ӘСЕРІ

§4.1.1 Деректер жиынтығының архитектурасы

3-тарау диагностикалық модель мен оның бағалау шеңберін зерттеу нысаны ретінде көрсетті — кіріс келісімі бар сегіз кезеңді preprocessing pipeline, екі CNN backbone, арнаға-тән инициализация мен fine-tuning хаттамасы, әрі көп-метрикалы, пациент-деңгейлі cross-validation өлшеу жүйесі. Сол сипаттама нені бағалау керектігін және бағалауды қалай оқу керектігін бекітеді; ол бағалау орындалатын деректерді әлі бекітпейді. Қазіргі тарау кез келген гипотеза тексерілмес бұрын сол деректер мен конфигурацияны береді. Бұл бірінші бөлім деректер жиынтығының архитектурасын, §4.1.2 архитектура талап ететін таңба гармонизациясымен бірге оқыту корпусының класс үлестірімі мен бөлінуін, ал §4.1.3 аппарат пен қайта жаңғыртылушылық хаттамасын көрсетеді. Бұл үш бөлімнің ешқайсысы эксперименттік нәтиже хабарламайды; олар эксперименттік субстратты орнықтырады, ал H-1-ден H-7-ге дейінгі эмпирикалық бағалау §4.2-ден бастап сақталған.

Субстрат әдейі жалғыз корпус емес. Ол — сегіз деректер жиынтығының *функционалды деңгейленген архитектурасы*, онда деңгейге мүшелік деректер жиынтығының өлшемімен емес, оның дәлелде атқаратын рөлімен айқындалады. Төрт функционалды деңгей ажыратылады. **TRAINING** деңгейі жалғыз деректер жиынтығын, EyePACS-ті ұстайды, ол барлық модель сәйкестендіруді және 1 мен 2-эксперименттердің деректер-жиынтығы-ішілік бағалауын береді. **EXTERNAL** деңгейі модель ешқашан оқытылмаған деректердегі мінез-құлықты зерттеуге пайдаланылатын деректер жиынтықтарын ұстайды: APTOS 2019, нөл-шот деректер жиынтығы аралық тасымалдау үшін (3-эксперимент), және Messidor-2, клиникалық-төмендеу салыстыруы үшін (5-эксперимент). **CLINICAL** деңгейі кескін-деңгейлі

дәрежеден тыс клиникалық тұрғыдан мағыналы аннотацияларды алып жүретін екі деректер жиынтығын ұстайды: IDRiD, оның пиксел деңгейіндегі зақымдану масктары 4-эксперименттің сандық explainability талдауын мүмкін етеді, және сапалық explainability үшін және 7-эксперименттің ұсталынған тест корпусы ретінде пайдаланылатын қазақ медициналық-орталық Клиникалық жиыны. **DEVICE** деңгейі үш деректер жиынтығын — RFMiD, DDR және ODIR-5K — ұстайды, олар бойынша 6-эксперименттің құрылғы домен-ығысуын бағалауы орындалады; оның мақсаты — модельді оқыту жиынында ұсынылмаған камера аппаратына ұшырату, ал ол беретін құрылғыаралық нәтижелер — өнімділік вариабельділігінің эмпирикалық бақылаулары, құрылғы куәландыруы немесе нормативтік сәйкестік тұжырымы емес (NC-16). Толық архитектура 4.1-кестеде келтірілген.

ТАБ-4.1. Деңгейленген деректер жиынтығының архитектурасы (RESEARCH_ARCHITECTURE §2.1). Өлшемдер мен камера модельдері — деректер жиынтығы дескрипторлары хабарлаған деректер жиынтығы атрибуттары; олар эксперименттік нәтижелер емес.

Деректер жиынтығы	Деңгей	Негізгі рөлі (эксперименттер)	Шамамен өлшемі	DR таксономиясы	Камера модель(дері)	Жария
EyePACS	TRAINING	Негізгі оқыту + деректер-жиынтығы -ішілік бағалау (1, 2-эксп.; 3–6 үшін көз)	~35 126 таңбаланған кескін	5 класты ICDR (0–4)	Canon CR-1	Иә (Kaggle)
APTOS 2019	EXTERNAL	Нөл-шот деректер жиынтығы аралық тасымалдау (3-эксп.)	~3662 кескін	5 класты ICDR (0–4)	Аралас	Иә (Kaggle)
IDRiD	CLINICAL	Сандық explainability + клиникалық төмендеу + шағын-деректі оқыту (4, 5, 7-эксп.)	516 кескін (81 пиксел-аннотацияланған)	5 класты ICDR + пиксел зақымдану масктары	Kowa VX-10α	Иә
Messidor-2	EXTERNAL	Клиникалық	~1748 кескін	Referable /non-	Topcon TRC-NW6	Иә (тіркелуме)


		төмендеуге төзімділік (5-эксп.)		referable + дәреже		н)
RFMiD	DEVIC E	Құрылғы домен ығысуы (6- эксп.)	~3200 кескін	Көп ауру + DR ішкі жиыны (салысты ру құжаттал ған)	Topcon, Kowa	Иә
DDR	DEVIC E	Құрылғы домен ығысуы (6- эксп.)	~13 673 кескін	5 класты DR	Canon, Topcon	Иә
ODIR- 5K	DEVIC E	Құрылғы домен ығысуы (6- эксп.)	~5000 пациент (билатерал ды)	Көп ауру + DR ішкі жиыны (салысты ру құжаттал ған)	Canon, Zeiss	Иә
Клиник алық (қазақ)	CLINI CAL	Сапалық explainabili ty + ұсталынға н тест (4, 5, 7-эксп.)	60 кескін (30 пациент × 2 көз), теңгерілге н	5 класты ICDR (0– 4)	Институци оналды	Жоқ (институци оналды келісім)

EyePACS оқыту корпусы Cuadros пен Bresnick [100] телемедицина-жүйесі дескрипторымен [100] құжатталады, ол ETDRS/ICDR негізіндегі бес класты градациялауды және Canon мидриатикалық емес түсіруді (CR-DGi / CR-1) орнықтырады; мұнда сүйенілетін шамамен 35 126 таңбаланған көз түбі кескіні — Cuadros пен Bresnick өздері хабарлаған көрсеткіш емес, Kaggle Diabetic Retinopathy Detection бөлігінің атрибуты, әрі солай келтіріледі, қампытылмайды. Messidor-2 дескрипторы да енді карталанған [101], ол түпнұсқа Messidor-ды (1200 кескін) мұнда пайдаланылатын Messidor-2-ден (~1748 кескін) ажыратады. Қалған құрылғы-деңгейлі дескрипторлар — RFMiD (#49), DDR (#50) және ODIR-5K (#51), соңғысы индексте әлі беделді түрде айқындалмаған деп тіркелген — әлі арнайы әдебиет карталарынсыз индекстелген; әрқайсысы үшін тек 4.1-кестеде қайталанатын индекс-деңгейлі атрибуттарға сүйеніледі, әрі ешбір қосымша дескриптор егжей-тегжейі бекітілмейді. EyePACS бөлігінің тәуелсіз ауқымын Sharma және әріптестері [32] растайды, олар салыстырмалы өлшемді 30 262 кескінді EyePACS ішкі жиынын

хабарлайды; сол дереккөз мұнда тек деректер жиынтығы ауқымы үшін келтіріледі, өйткені оның ішкі сәйкессіз класс-деңгейлі өнімділік көрсеткіштері дәлел ретінде қабылданбайды (дереккөз #41; LITERATURE_INDEX 21-ескерту). IDRiD дескрипторы, керісінше, толық карталанған: Forwal және әріптестері [6] 516 кескінді құжаттайды, олардың 81-і төрт зақымдану түрі үшін пиксел деңгейіндегі зақымдану масктарын алып жүреді, ICDR шкаласында градацияланған әрі жалғыз Kowa VX-10α камерасымен жалғыз үнді көз клиникасында түсірілген [6]. Сол бір-орталықты, бір-камералы шығу тегі, әрі ешбір хабарланған класс-үлестірім статистикасының болмауы — әр IDRiD-тен алынған нәтиже мұралайтын шектеулер әрі осы жиынға сүйенетін explainability мен төмендеу талдауларына тасымалданады (SIR-2).

Архитектура оның деңгейлері жалғыз оқыту жиыны қамти алмайтын гетерогендікті жоба бойынша қамтитындай құрылған. Сол гетерогендіктің екі осі бар. Біріншісі — таксономиялық: EyePACS, APTOS 2019, IDRiD, DDR және Клиникалық жиын бес класты ICDR градациялауын тікелей пайдаланады, Messidor-2 ауырлық дәрежесімен қатар referable/non-referable айырмашылығымен таратылады, ал RFMiD пен ODIR-5K — диабеттік-ретинопатия таңбалары пайдаланудан бұрын бес класты шкалаға салыстырылуы құжатталуға тиіс ішкі жиын құрайтын көп ауру деректер жиынтықтары. Екіншісі — құрылғыға қатысты: корпус жиынтығында Canon, Topcon, Kowa және Zeiss көз түбі камераларын қамтиды, бұл дәл DEVICE деңгейін түсіру-аппараты ығысуы туралы ақпаратты ететін қасиет. Бұл екі еселі гетерогендік — бақыланбайтын шатасудан гөрі жобаның әдейі әрі шектелген ерекшелігі, бірақ ол диссертация тұтасымен сақтайтын тәртіпті таңады: деректер жиынтықтары арасында жасалған кез келген салыстыру оларды ажырататын бейнелеу жабдығындағы, пациент популяциясындағы, градациялау хаттамасындағы және ауру таксономиясындағы айырмашылықтарды өзімен алып жүруі тиіс (SIR-3; SB-2.3). DeepDRiD сол бір ICDR таксономиясын қабылдайтын заманауи эталон ретінде келтірілген жерде сол тәртіп қолданылады — сол эталон бір-орталықты әрі сенімділік интервалдарын хабарламайды, әрі бұл қасиеттер оның нені орнықтыра алатынын шектейді [15] (SIR-2). Деректер жиынтықтарының дәреже-бойынша визуалды сипаты 4.2-суретінде, ал деректер жиынтығы аралық және камера аралық құрамы 4.3-суретінде жинақталған.

Representative fundus images per DR grade across the dataset architecture



Сурет 4.2 – деректер жиынтығы архитектурасы бойынша DR дәрежесі бойынша репрезентативті көз түбі кескіндері

Эксперименттер бойынша деректер жиындары · Datasets per experiment

	EyePACS APTOS 2019 n = ~35 126	IDRiD n = 3 662	Messidor-2 n = 516	DDR n = 1 748	ODIR-5K n = 13 673	ODIR-5K n = ~5 000	RFMiD n = ~3 200	Clinical (KZ) n = 60	
									Train (source) Eval (target / zero-shot)
Exp 1 H-1	Train								Преобработка доминантности
Exp 2 H-2	Train								Компоненттер абляциясы
Exp 3 H-4	Train	Eval							Кросс-дәтсет жалпылау
Exp 4 H-5	Train		Eval						Түсіндірмелілік · ALO
Exp 5 H-7	Train		Eval	Eval					Деградацияға төзімділік
Exp 6 H-6	Train				Eval	Eval	Eval		Камералық домен ауысуы
Exp 7 small-data			Train					Eval	Кіші деректермен оқыту

Сурет 4.3 – деректер жиынтығы аралық және камера-туралау матрицасы

Бұл деңгейленген құрылыс — диссертацияның шектелген-жалпылау міндеттемесіне операциялық түр беретін нәрсе. Кейінгі эксперименттер алға тартатын әр өнімділік тұжырымы осында айқындалған деректер жиынтығы архитектурасына байланған: оқыту мен негізгі-бағалау көзі ретінде EyePACS-ке, сыртқы және клиникалық бағалау көздері ретінде APTOS 2019, IDRiD және Messidor-2-ге, әрі құрылғы-ығысуы көздері ретінде RFMiD, DDR және ODIR-5K-ға. Бұл архитектурадан тыс көз түбі деректер жиынтықтарына, осы корпусарда ұсынылмаған бейнелеу құрылғыларына немесе олармен іріктелмеген клиникалық популяцияларға кеңейту бекітілмейді әрі мұнда жүргізілмеген тәуелсіз эксперименттік валидацияны талап етер еді (DGL-1). Субстраттың өзіне қатысты екі шекаралық шарт басынан тіркеледі. EyePACS дәреже үлестірімі қатты теңгерімсіз, бұл негізгі метрикалар таңдауын да, бөлу стратегиясын да шарттайтын әрі §4.1.2-де егжей-тегжейлі қарастырылатын қасиет (SB-2.1). Клиникалық жиын институционалды дерек-пайдалану келісімі бойынша ұсталып, жария қолжетімді емес, сондықтан оған тәуелді нәтижелер құрылымдық қайта жаңғыртылушылық шегін алып жүреді (SB-2.2).


Бұл дерек көздерін пайдалану кандидаттың бұрынғы жұмысымен де айқын қатынаста тұр. Бұрын жарияланған зерттеулерде кандидат пен бірге авторлар transfer-learning мінез-құлқын APTOS 2019-да жабық клиникалық жиынмен бірге, жалғыз EfficientNetB0 backbone-ын пайдалана отырып бағалады (yesmukhamedov-conf.md мен yesmukhamedov-kbtu.md-да хабарланған әрі yesmukhamedov-scorus-q3.md-да одан әрі талданған жалғыз эксперименттік желі; SIR-4, SIR-5). Сол зерттеулер деректер жиынтығына тән оқыту олардың модельдерінің жалпылауын шектегенін және оларды астарлайтын жабық деректер жария қолжетімді болмағанын мойындады (yesmukhamedov-scorus-q3.md §II.6; SIR-2). Осы бөлімде көрсетілген деректер жиынтығы архитектурасы сол бұрынғы жұмысты дәл сол екі ось бойынша кеңейтеді: ол оқытуды үлкен, жария EyePACS корпусына қайта негіздейді әрі ертерек жалғыз-деректі жоба қолдай алмаған сыртқы, клиникалық және құрылғы-

ығысуы бағалауын ендіреді. Субстрат тіркеліп, шектелген соң, §4.1.2 оқыту деңгейінің класс үлестіріміне және архитектура талап ететін пациент-деңгейлі бөлу мен таңба-гармонизация хаттамасына бұрылады.

§4.1.2 Класс үлестірімі және деректерді бөлу

§4.1.1-де тіркелген деректер жиынтығы архитектурасы бағалаудағы әр жобалау таңдауына тікелей қатысты бір шекаралық шартты алға тасымалдады: EyePACS дәреже үлестірімі қатты теңгерімсіз (SB-2.1). Бұл бөлім сол теңгерімсіздікті әрекет етуге жеткілікті дәл етеді, ол айқындайтын үш downstream таңдауды — негізгі-метрика иерархиясын, loss функциясын және бөлу стратегиясын — қадағалайды, содан кейін кез келген деректер жиынтығын сәйкестендіруге немесе бағалауға пайдаланбас бұрын архитектураның таксономиялық гетерогендігі талап ететін таңба гармонизациясын көрсетеді. Қарастыру эксперименттік орнату деңгейінде қалады; мұнда ешбір жіктеу нәтижесі хабарланбайды.

EyePACS-тегі теңгерімсіздік кездейсоқ емес, құрылымдық. Бес класты International Clinical Diabetic Retinopathy (ICDR) градациялауы көрінетін-ретинопатия-жоқ дәрежесінде қатты шоғырланған әрі асқынғанырақ дәрежелер бойынша тік құлдырайтын үлестірім тудырады, сонда ауыр және пролиферативтік кластар салыстырмалы аз кескін санымен ұсынылады. Дәреже үлестірімі 4.1-суретінде көрсетілген; қазіргі мәтін сурет хабарлайтын дәреже-бойынша есептерді қайта айтудан гөрі оның пішінін сипаттайды. Бұл пішін — популяция-скрининг корпусының типтік профилі, онда бейнеленген көздердің көпшілігі зақымдалмаған немесе ерте-сатылы, әрі ол governance құжаттары барлық өнімділік тұжырымдарын үлестірімдік асимметрия контекстінде интерпретациялауды талап ететіні ретінде белгілейтін қасиет (SB-2.1).



Сурет 4.1 – EyePACS класс-үлестірімі DR дәрежелері 0–4 бойынша

Сол асимметрия — 3-тарауда әлдеқашан көрсетілген өлшеу мен оқыту таңдаулары артындағы негізгі иіптірек, әрі иіптіректі айқын атау — осы бөлімнің аналитикалық мақсаты (SC-1.4). Сондықтан бағалау дәлдікпен бастамайды: осыншама қисайған үлестірімде жіктеуіш басым дәрежені жай ғана қолдау арқылы жоғары дәлдікке жете алады, сондықтан дәлдік қолдаушы рөлге түсіріледі әрі негізгі-метрика иерархиясын салмақталған F1-балл мен квадраттық салмақтары бар Cohen's κ бастайды, ROC-AUC шектен-тәуелсіз өлшем ретінде (§3.4.1, EH-1; TAB-3.2). Салмақталған F1 қисайу аясында класс-бойынша өнімділікке сезімтал, ал квадраттық-салмақталған κ клиникалық тұрғыдан елеулі қателерді — бірнеше ауырлық қадамы бойынша қате-градациялайтындарды — көрші-дәреже шатасуларынан ауырырақ жазалайды. Сол теңгерімсіздік loss-тың салмақталмаған cross-entropy емес, §3.3.4-те көрсетілген кері-жиілікпен-салмақталған focal loss болуының да себебі, ол сирек ауыр және пролиферативтік дәрежелердің градиентке үлесін көтереді, ал 6-кезеңнің тек-оқыту augmentation-і (§3.1.3) тест таралуын өзгертпей азшылық-класс мысалдарының тиімді алуандығын арттыратын қосалқы иіптірек ретінде әрекет етеді. Бұл жауаптар мұнда тек класс үлестіріміндегі ортақ шығу тегін бекіту үшін қайта айтылады; олардың формальды анықтамалары қайта берілмейді.

Архитектураның §4.1.1-де орнықтырылған таксономиялық гетерогендігі екінші орнату міндетін таңады: құраушы деректер жиынтықтарының градациялау схемалары салыстырылмас бұрын ортақ мақсатқа

гармонизациялануы тиіс. Ортақ мақсат — EyePACS, APTOS 2019, IDRiD, DDR және Клиникалық жиын әлдеқашан градацияланған бес класты ICDR шкаласы. Ауырлық дәрежесімен қатар referable/non-referable айырмашылығымен таратылатын Messidor-2 және диабеттік-ретинопатия таңбалары кеңірек көз-ауру таксономиясының ішкі жиынын құрайтын көп ауру деректер жиынтықтары RFMiD пен ODIR-5K сол шкалаға айқын салыстыруды талап етеді. Салыстыруды екі конвенция реттейді, әрі екеуі де жорылудан гөрі құжатталады (SB-2.3; SIR-3). Біріншіден, көп ауру құрылғы-деңгейлі деректер жиынтықтары тек DR таңбаларын пайдаланатын 6-эксперимент үшін олардың диабеттік-ретинопатия мазмұнына дейін қысқартылады: DR емес ауру таңбалары алынып тасталады немесе DR емес категорияға салыстырылады, тексеру астындағы гипотезамен үйлесімді (H-6). Екіншіден, referable/non-referable осі пайдаланылған жерде ICDR дәрежелерімен сәйкестік айтылады, сонда кез келген деректер жиынтығы аралық салыстыру таңба эквиваленттігін алдын ала жорамалдаудан гөрі өзінің таксономиялық контекстін алып жүреді. Бұл гармонизация — сыртқы және құрылғы деңгейлерін ақпаратты ететін гетерогендікті қамтудың бағасы, әрі ол мөлдір төленеді.

Бөлу архитектура бойынша біркелкі қолданылатын, §3.4.2-де көрсетілген әрі мұнда қайта шығарусыз қайта пайдаланылатын жалғыз хаттамамен басқарылады. Барлық эксперименттер пациент-деңгейлі стратификацияланған бөлумен бес-fold cross-validation пайдаланады: бөлу кескін емес, пациент деңгейінде жасалады, сонда ешбір пациенттің кескіндері кез келген fold-тың оқыту мен тест бөлігінде көрінбейді, бұл корреляцияланған көп-кескінді және билатералды түсірілімдер әйтпесе ашатын ағып кету жолын жояды (§3.4.2; (3.13-сурет)). Дәреже бойынша стратификация класс пропорцияларын fold-тар бойынша сақтайды, сонда сирек ауыр дәрежелер біреуінде шоғырланудан гөрі әр тест бөлігінде ұсынылады, әрі хаттама 6-кезең augmentation-нің тек-оқыту мәртебесімен үйлеседі, сонда ешбір augment жасалған кескін кез келген тест бөлігіне кірмейді. Нәтижесінде әр fold-тың тест бағасы корпусқа тұтасымен сәйкес үлестірім аясында көрінбеген пациенттерге жалпылауды бейнелейді.

Бір мұраланған шектеу клиникалық деңгейді бөлуді шектейді. IDRiD дескрипторы класс-үлестірім статистикасын хабарламайды, әрі оның шығарылымы — бір-орталықты, бір-камералы түсірілім [6] (SIR-2); оның туа біткен 413/103 оқыту–тест бөлінуі — дескриптордың өзінікі, ал 7-эксперимент 516 IDRiD кескінін Клиникалық жиын тест корпусы ретінде ұсталына отырып ортақ пациент-деңгейлі бес-fold хаттамасы аясында қайта бөледі. IDRiD дәреже үлестірімі жарияланбағандықтан, сол жиындағы стратификация сыртқы үлестірімдік сілтемесіз берілген таңбалардан жүреді, бұл IDRiD-тен алынған нәтижелер кейіннен хабарланған жерде атап өтілетін шектеу. Оқыту деңгейі сипатталып, метрика мен loss таңдаулары оның үлестіріміне бекітіліп, деректер жиынтығы аралық таңбалар гармонизацияланып, әрі барлық деректер жиынтығы үшін бір ағып-кету-бақыланатын бөлу хаттамасы тіркелген соң, §4.1.3 эксперименттер орындалатын аппарат пен қайта жаңғыртылушылық хаттамасын көрсетеді.

§4.1.3 Аппарат және қайта жаңғыртылушылық хаттамасы

Деректер жиынтықтары тіркеліп (§4.1.1) және класс үлестірімі, таңба гармонизациясы мен бөлу хаттамасы көрсетілген соң (§4.1.2), эксперименттердің өздерінен бұрын эксперименттік орнатудың бір элементі қалады: модельдер сәйкестендіріліп, бағаланатын орындау ортасы және нәтижелерді қайта жаңғыртылатын ететін шарттар. Бұл бөлім құжатталған аппаратты көрсетеді, әр экспериментті басқаратын стандартталған оқыту конфигурациясын ұсынады, әрі қайта жаңғыртылушылық бақылауларын нәтижесіндегі есептеу мәлімдемелері орындалатын — аппаратпен тіркелген — шекпен бірге айтады.

Эксперименттер жалғыз тұтынушы-деңгейлі графикалық процессорда, 12 ГБ видеожадысы бар NVIDIA RTX 3060-та, Windows-тағы WSL2 Ubuntu ортасында және бағдарламалық тәуелділіктерді бекітетін тіркелген conda ортасында орындалады. Бұл конфигурация жалпыланатын сипаттама ретінде ұсынылудан гөрі құжатталған эксперименттік орнату ретінде айтылады: аппаратқа-тән қайта жаңғыртылушылық шектеуі бойынша, есептеу тиімділігі, оқыту уақыты немесе inference өткізу қабілеті туралы кез келген мәлімдеме осы конфигурациямен шектелген әрі қайта бағалаусыз айтарлықтай түрлі есептеу контекстеріне — бір шетте ARM процессорларындағы мобильді inference, екінші шетте сервер-класты GPU кластерлеріне — тасымалданбайды (DGL-2). Шектеу — фактіден кейін қосылған жай ескерту емес; ол конфигурацияны қалыптастыратын жобалау параметрі. 512×512 кіріс ажыратымдылығындағы он алты оқыту пакеті өлшемі — 12 ГБ жады шегінің тікелей салдары, ал ResNet-50 үшін аралас-дәлдік (fp16) есептеуді қосып, EfficientNet үшін өшіру — онда жарты-дәлдік сандық толып кету тудырды — еркін гиперпараметрден гөрі аппаратпен-жетектелетін инженерлік таңдау. Жалғыз-құрылғылы, тұтынушы-GPU ортасы — осы жұмыс орналастырылатын ресурсы шектеулі шеңбердің операциялық данасы (OD-6); алайда ол нақты-уақыттық клиникалық inference-ті көрсетпейді, әрі мұнда ешбір осындай қабілет бекітілмейді.

Әр эксперимент 4.2-кестеде қайта берілген жалғыз стандартталған оқыту конфигурациясында орындалады (§3.4.2-де 3.1-кесте ретінде енгізілгенмен бірдей). Барлық эксперименттер бойынша жалғыз конфигурацияны тіркеу — екі конфигурация арасындағы өлшенген айырмашылықты оптимизатордағы, кестедегі немесе пакет өлшеміндегі кездейсоқ өзгерістен гөрі тексеру астындағы фактордың әсері ретінде оқуға мүмкіндік беретін нәрсе.

ТАБ-3.1 (мұнда 4.2-кесте ретінде ұсынылған). Стандартталған оқыту конфигурациясы (RESEARCH ARCHITECTURE §4.0).

Параметр	Мән
Оптимизатор	Adam ($lr = 1 \times 10^{-4}$, $weight_decay = 1 \times 10^{-4}$)
Пакет өлшемі	16
Максималды эпохалар	20 (early stopping, patience = 5)
Loss функциясы	Focal loss ($\gamma = 2$, α = кері-жиілік класс салмақтары)

Kіріс ажыратымдылығы	512 × 512
Kіріс арналары	3 (базалық) немесе 4 (FOV маскасымен толық)
Аралас дәлдік (fp16)	ResNet-50 үшін қосулы; EfficientNet үшін өшірулі (fp16 толып кету)
Cross-validation	5-fold, пациент-деңгейлі стратификацияланған бөлу
Seed	42, deterministic = true

Қайта жаңғыртылушылық жорылудан гөрі инженерленетін қасиет ретінде қаралады, әрі әр бақылау ол жоятын вариация көзі үшін енгізіледі. Орындау жалғыз тіркелген кездейсоқ seed (42) аясында детерминистік, бұл run-тан run-ға детерминистік еместікті — кездейсоқ инициализация, дерек-реттілігі және стохастикалық-операция вариациясын — шатасу ретінде жояды, сонда екі run арасындағы айырмашылық seed вариациясынан гөрі олардың түрлі конфигурациясына телінеді. Augmentation параметрлері мен learning-rate кестесі де run-дар бойынша тіркеледі, бұл әйтпесе көрінетін әсерді бүркемелеуі немесе жасауы мүмкін тағы екі еркіндік дәрежесін жояды (RESEARCH_ARCHITECTURE §9.3). Бағдарламалық стек бекітілген — PyTorch, Torchvision, OpenCV, NumPy және Scikit-learn-мен Python 3.11 (RESEARCH_ARCHITECTURE §8.5) — әрі preprocessing pipeline мен оқыту коды нұсқаланып, А қосымшасында қайта берілген, сонда әр кескінге қолданылған түрлендіру және әр модельге қолданылған процедура тек прозада сипатталудан гөрі қалпына келтірілетін. Seed, кесте, augmentation және кодты осылай тәртіпті тіркеу — кандидаттың бұрынғы жарияланған жұмысында орнықтырылған сол қайта жаңғыртылатын-конфигурация тәжірибесі, оны қазіргі хаттама толық көп-деректі архитектураға формализациялайды әрі кеңейтеді (yesmukhamedov-kbtu.md, ♦ бұрынғы өз жұмысы; SIR-4).

Бұл хаттама беретін қайта жаңғыртылушылықты екі шек шектейді, әрі екеуі де шегерілуден гөрі айтылады. Біріншісі — әлдеқашан аталған аппарат шегі: конфигурация баламалы аппаратта қайта жаңғыртылады, бірақ ол көрсететін тиімділік сипаттары құжатталған орнатуға тән (DGL-2). Екіншісі деректерге қатысты. Жабық қазақ Клиникалық жиынына тәуелді нәтижелер құрылымдық қайта жаңғыртылушылық шегін алып жүреді, өйткені сол жиын институционалды дерек-пайдалану келісімі бойынша ұсталып, жария қолжетімді емес; сыртқы тарап жария-деректі эксперименттерді толық қайта жаңғырта алады, бірақ деректерсіз Клиникалық-тәуелді бағалауларды тәуелсіз қайта орындай алмайды (SB-2.2). Аппарат құжатталып, оқыту конфигурациясы тіркеліп, әрі қайта жаңғыртылушылық шарттары мен олардың шектері айтылған соң, §4.1-дің эксперименттік орнатуы аяқталады. Деректер жиынтықтары, олардың үлестірімі мен бөлінуі, әрі орындау шарттары енді H-1-ден H-7-ге дейінгі бағалауды қолдауға жеткілікті дәл айқындалған, оны осы тараудың кейінгі бөлімдері жүзеге асырады.

6 РЕСУРСТАРЫ ШЕКТЕУЛІ ОРТАҒА АРНАЛҒАН DR АВТОМАТТАНДЫРЫЛҒАН СКРИНИНГ ЖҮЙЕСІНІҢ АРХИТЕКТУРАСЫ

§6.1.1 Функционалдық және функционалдық емес талаптар сипаттамасы

Алдыңғы тараулар біріктірілген preprocessing-CNN моделін және оның диагностикалық тиімділігі өлшенетін шеңберді көрсетті: сегіз кезенді preprocessing pipeline мен екі CNN backbone айқындалған зерттеу нысаны ретінде тіркелді, ал метрика иерархиясы, cross-validation схемасы және статистикалық тесттер оны өлшейтін аппарат ретінде тіркелді. Бұл тарау модельден өлшеу нысаны ретінде модельге орналастырылатын компонент ретінде бұрылады. Ол сол модель айналасында құрылған автоматтандырылған диабеттік-ретинопатия скрининг жүйесі нені *істеуі* тиіс және оны қандай жағдайларда істеуі тиіс деп сұрайды. Кез келген талап айтылмас бұрын, тараудың эпистемикалық мәртебесі бекітіліп, тұтасымен ұсталуы тиіс: 6-тарауда ұсынылған архитектура — **тек жобалау сипаттамасы**. Ешбір прототип жүзеге асырылмады, ешбір далалық сынақ жүргізілмеді, әрі ешбір болжанған орналастыру нәтижесі осы зерттеудің тұжырымы ретінде айтылмайды (SB-4.1; DGL-4). Кейінгі әр талап, компонент және хаттама — орындалуға тиіс сипаттама, ұсталатыны көрсетілген қасиет емес.

Талаптардың екі анықтаушысы бар. Біріншісі — әлдеқашан көрсетілген модельдің өзі. Екіншісі — ол орналастырылуға тиіс орта, ол кез келген жүзеге асыру сақтауға тиіс шарттарды тіркейді. Архитектура мұнда жаңадан енгізілмейді. Кандидаттың бұрынғы жұмысында Есмұхамедов және әріптестері (2025) офтальмологиялық скрининг үшін модульдік, AI-жетектелетін ақпараттық-жүйе архитектурасын ұсынып, оны кескінді түсіру, кескінді өңдеу, тану, диагноз, есеп беру, пайдаланушы өзара әрекеттесуі, деректерді сақтау және қателерді өңдеу компоненттеріне ыдыратып, оны UML және мән-байланыс модельдеуі арқылы формализациялады (1-сурет, 83-б.; 2–3-кестелер, 82–83-б.). Сол жарияланым — бұрынғы өз жұмысы әрі солай келтіріледі; ол архитектураны жоба ретінде ұсынып, не прототип жүзеге асыруын, не оның қандай да бір сандық валидациясын хабарламады (оның мойындалған шектеуі, §II.6). Қазіргі бөлім сол бұрынғы жобаны екі нақты тәсілмен кеңейтеді: ол талаптарды 3-тарауда тіркелген біріктірілген модельге байлайды, әрі функционалдық емес қабықты осы диссертацияны басқаратын ресурсы шектеулі ортаның операциялдық анықтамасына бекітеді (OD-6). Сондықтан төменде келтірілген талаптар — жаңа жүйе тұжырымы емес, бұрын жарияланған архитектураның формализациясы әрі қатандатылуы.

Функционалдық тұрғыдан жүйе скрининг pipeline-ін түсірілген көз түбі кескінінен дәрігер қарап шыға алатын градацияланған нәтижеге дейін толық жүзеге асыруы тиіс. Есмұхамедов және әріптестерінің (2025) компонент ыдыратуынан алынған әрі 3-тарау моделіне салыстырылған функционалдық талаптар (FR) 6.1-кестеде жинақталған.

6.1-кесте — Функционалдық талаптар (жобалау сипаттамасы; FR бастапқы модель кезеңіне / #22 компонентіне сілтенген).

ID	Функционалдық талап	Шығу тегі
FR-1	Тасымалданатын және смартфонға негізделген камераларды қоса, гетерогенді түсіру көздерінен көз түбі кескіндерін қабылдау	#22 Кескінді түсіру компоненті (83-б.)
FR-2	Сегіз кезенді preprocessing pipeline-ді inference-ке дейін конфигурацияланатын өңдеу модулі ретінде қолдану	3-тарау (OD-3); #22 Кескінді өңдеу компоненті
FR-3	Оқытылған CNN backbone-нан бес класты DR дәрежесін (DR 0–4) тудыру	3-тарау моделі; #22 Тану/Диагноз компоненттері
FR-4	Дәрігер қарауы үшін интерпретацияланатын шешім-қолдау шығысын (дәреже плюс post-hoc Grad-CAM жабыны) шығару	#22 Есеп беру компоненті; NC-14 шеңберлеуі
FR-5	Нәтижелерді интерпретациялайтын, аудиттейтін және оларды қайтара алатын дәрігерге ұсыну (physician-in-the-loop)	#22 Дәрігер-AI кері байланыс механизмі (79, 85-б.)
FR-6	Кескіндерді, дәрежелерді және метадеректерді сақтап, оларды PACS/EHR интерфейстері арқылы пациент жазбаларымен байланыстыру	#22 Деректерді сақтау; DMP/өзара әрекеттесу (4-кесте, 86-б.)
FR-7	Бұзылған, төмен-сапалы немесе келісімнен-тыс кірістерді үнсіз сәтсіздіксіз анықтап, өңдеу	#22 Қателерді өңдеу компоненті

Функционалдық жиын жүйенің *нені* істейтінін тіркейді; ол өзі берілген жүзеге асырудың мақсатты ортада жарамды екенін тіркемейді. Бір талапты оқшаулау орынды: FR-3 дәлелденген қасиеттен гөрі қабылдау мақсатын алып жүреді. Осы диссертация үшін операциялық анықталған диагностикалық-тиімділік профилі (OD-5) — орналастырылған жіктеуіш қанағаттандыруға *міндетті* критерий; ол мұнда жобалау мақсаты ретінде айтылады, ал кез келген оқытылған модель оған жете ме — осы жобада бекітілген нәтиже емес, эксперименттік тарауларға сақталған эмпирикалық сұрақ.

Функционалдық емес талаптар (NFR) орналастыру контексімен басқарылады. Ресурсы шектеулі орта осы диссертация үшін мыналардың кемінде екеуімен сипатталатын орта ретінде анықталады: inference үшін GPU жеделдетудің болмауы; 16 ГБ-тан төмен қолжетімді жады; inference-ті нақты-уақытқа жуық клиникалық жұмыс үдерісі ішінде талап ететін өткізу қабілеті шектеулері; және үздіксіз бұлтқа сүйенуге жеткіліксіз желілік байланыс (OD-6). Бұл анықтама бұрынғы архитектураның модульдік, өзара әрекеттесу және қауіпсіздік атрибуттарымен бірге 6.2-кестедегі қабықты береді.

6.2-кесте — Функционалдық емес талаптар (жобалау сипаттамасы; NFR басқарушы шектеуге сілтенген).

ID	Функционалдық емес талап	Басқарушы шектеу
NFR-1	Inference арнайы GPU жеделдетуінсіз орындалатын	OD-6 (a)
NFR-2	Шектеулі жады бюджеті аясында жұмыс (16 ГБ-тан төмен хост)	OD-6 (b)
NFR-3	Клиникалық скрининг өткізу қабілеті ішінде нақты-уақытқа жуық жауап	OD-6 (c)
NFR-4	Үзік байланысқа төзімділік, store-and-forward жұмысын қоса	OD-6 (d)
NFR-5	Клиникалық контексттер бойынша бейімдеу үшін модульдік, тәуелсіз ауыстырылатын компоненттер	#22 модульдік архитектура (74–75, 90-б.)
NFR-6	Стандартталған алмасу арқылы аурухана жүйелерімен өзара әрекеттесу (FHIR/HL7)	#22 DMP/өзара әрекеттесу (4-кесте, 86-б.)
NFR-7	Жоба бойынша деректер	#22 қауіпсіздік (3-кесте,

	қауіпсіздігі мен пациент-дерекін қорғау (шифрлеу, аутентификация; GDPR/HIPAA-сәйкес)	83-б.); SB-4.2
NFR-8	Ақаулар аясында сенімділік пен мейірімді нашарлау	#22 Қателерді өңдеу (83- б.)

Бұл сипаттаманың аналитикалық салмағы кез келген скрининг жүйесі бөлісетін функционалдық тізімде емес, ресурсы шектеулі орта жобасын жақсы қамтамасыз етілген клиника жобасынан ажырататын функционалдық емес қабықта жатыр. Екі талап жиыны тәуелсіз емес: функционалдық емес шектеулер функционалдық талаптардың жарамды жүзеге асырыларын кесіп тастайды. Inference-тің (FR-3) тек-бұлттық жүзеге асырылуы NFR-4 аясында жарамсыз, өйткені үзік байланыс баруды-қайтуды кепілдей алмайды; сервер-класты жеделдетуді алдын ала жорамалдайтын FR-3 жүзеге асырылуы NFR-1 аясында жарамсыз; ал FR-2-нің preprocessing модулі, есептеу тұрғысынан маңызды бола отырып, шеттетілуден гөрі NFR-2 мен NFR-3 ішінде жүзеге асырылатын болуы тиіс. Сондықтан осы тараудың байланыстырушы жобалау проблемасы — функцияларды санамалау емес, оларды OD-6 қабығы ішінде жүзеге асыру, әрі келесі бөлімнің модульдік ыдыратуы сақтайтыны көрсетілуге тиіс — дәл сол қабық.

Екі шекара сипаттаманы жабады. Біріншіден, 6.1 мен 6.2-кестелердегі әр жазба — қол жеткізілген қасиет емес, жобалау талабы: диагностикалық мақсат (OD-5) — мақсат, қауіпсіздік талабы (NFR-7) — GDPR/HIPAA-сәйкес жобалау сипаттамасы, куәландырылған немесе тексерілген сәйкестік мәртебесі емес (SB-4.2), ал бұрынғы жарияланымның Қазақстандағы орналастыру үшін болжанған пайдалары — ауыл тұрғындарына қолжетімділік, кеш-сатылы асқынулар мен шығынның азаюы (Есмұхамедов және әріптестері, 2025, 88-б.) — тек контекст үшін келтірілген үшінші тарап болжамдары, әрі дәлелденген нәтижелер ретінде осы жүйеге телінбейді (SIR-8). Екіншіден, бұл талаптар жиынының жүзеге асырылуы мен валидациясы болашақ жұмысқа сақталған; бұл тараудың үлесі — сипаттаманың өзі (CFC-1.5). Функционалдық және функционалдық емес талаптар тіркелген соң, архитектура қанағаттандыруға тиіс сипаттама енді орнында. Келесі бөлім жүйені модульдерге ыдыратып, концептуалды UML архитектурасы деңгейінде сол модульдер бұл қабықты қанағаттандыру үшін қалай реттелетінін, PACS пен EHR инфрақұрылымына интеграциядан бастап, көрсетеді.

§6.1.2 PACS пен EHR интеграциясы бар модульдік архитектура

Алдыңғы бөлім архитектура қанағаттандыруға тиіс сипаттаманы тіркеді: скрининг жүйесі нені істейтінін сипаттайтын функционалдық жиын (6.1-кесте, FR-1...FR-7) және оны қандай ресурсы шектеулі қабық аясында істеуі тиіс

екенін сипаттайтын функционалдық емес жиын (6.2-кесте, NFR-1...NFR-8), функционалдық емес қабық — кез келген скрининг жүйесі бөлісетін функционалдық тізім емес — байланыстырушы жобалау драйвері деген аналитикалық қорытындымен, өйткені ол әр функцияның жарамды жүзеге асырыларын кесіп тастайды. Бұл бөлім сол қорытынды тудыратын міндетті орындайды: ол жүйені модульдерге ыдыратып, тандалған реттеу, оның аурухана Picture Archiving and Communication Systems (PACS) және Electronic Health Records (EHR)-мен интеграциясын қоса, сол қабықтың жарамды жүзеге асырылуы екенін көрсетеді. Тарау үшін орнықтырылған тек-жоба мәртебесі өзгеріссіз алып жүріледі: төмендегі ыдырату — **жобалау сипаттамасы**, жүзеге асырылған немесе далада-сыналған жүйе емес — ешбір модуль құрылып, интеграцияланбады, әрі ешбір интеграция мінез-құлқы тұжырым ретінде хабарланбайды (SB-4.1; DGL-4).

Модуль жиыны кандидаттың бұрын жарияланған архитектурасының компонент ыдыратуынан алынады. Кандидаттың бұрынғы жұмысында Есмұхамедов және әріптестері (2025) AI-жетектелетін денсаулық сақтау ақпараттық жүйесін компоненттер жиыны ретінде — Кескінді түсіру, Кескінді өңдеу, Тану моделі, Диагноз, Есеп беру, Пайдаланушы интерфейсі, Деректерді сақтау және Қателерді өңдеу — UML компонент диаграммасы арқылы байланыстырып, мән-байланыс және деректерді басқару модельдері арқылы формализациялап көрсетті (1-сурет, 83-б.; 2–4-кестелер, 82–86-б.). Сол жарияланым — бұрынғы өз жұмысы; ол архитектураны жоба ретінде ұсынып, не прототип жүзеге асыруын, не оның қандай да бір сандық валидациясын хабарламады (оның мойындалған шектеуі, §II.6). Қазіргі бөлім сол компонент тізімін жай қайталамайды. Оның кеңейтуі аналитикалық: ол компоненттерді 3-тарауда тіркелген біріктірілген preprocessing-CNN моделіне байлайды, әрі — бұрынғы жарияланымда жоқ қадам — олардың *реттелуін* OD-6 қабығымен шектейді, сонда модуль жиынының тек мүшелігі ғана емес, топологиясы орналастыру контексімен айқындалады. 6.3-кесте нәтижесіндегі модульдерді, әрқайсысы жүзеге асыратын функционалдық талапты, оның реттелуін басқаратын функционалдық емес шектеулерді және оның ішкі жүзеге асырылуы көрсетілетін бөлімді тіркейді.

6.3-кесте — Модуль ыдыратуы (жобалау сипаттамасы; әр модуль бастапқы FR мен басқарушы NFR-ларына сілтенген, жүзеге асырылуы атап өтілгендей шегерілген).

Модуль	Жүзеге асырады (FR)	Басқарушы NFR(лар)	Ішкі жүзеге асырылу
Қабылдау (Ingestion)	FR-1, FR-7	NFR-4, NFR-8	осы бөлім (шекара); §6.3.1 (түсіру/телемедицина)
Preprocessing қозғалтқышы	FR-2	NFR-2, NFR-3, NFR-5	§6.2.1
Inference	FR-3	NFR-1, NFR-2, NFR-3	§6.2.2 (тек-жоба)
Шешім-қолдау /	FR-4	NFR-3, NFR-5	§6.2.2, §6.3.2

Есеп беру			
Дәрігер интерфейсі	FR-5	NFR-5	§6.3.2
Деректерді басқару / PACS- EHR интеграциясы	FR-6	NFR-4, NFR-6, NFR-7	осы бөлім; §6.4.1 (қауіпсіздік/сәйкестік)
Оркестрлеу / Қателерді өңдеу	FR-7	NFR-4, NFR-8	осы бөлім

Ыдырату қамтамасыз етуге тиіс бірінші жобалау қасиеті — модульдіктің өзі (NFR-5). Модульдер бос байланысқан ретінде көрсетіледі: әрқайсысы ортақ ішкі күй арқылы емес, айқындалған интерфейс арқылы көршілерімен байланысады, сонда кез келген жалғыз модуль басқаларын қайта-архитектурасыз ауыстырыла алады. Бұл қасиет — жүйенің клиникалық контексттер бойынша ниеттелген бейімделуін ақтайтын нәрсе — түрлі түсіру құрылғысы бар сайт тек Қабылдау модулін ауыстырады, жергілікті дерек-резиденттігі қатаңырақ сайт тек Деректерді басқару модулін ауыстырады — әрі сондықтан ол жалпы бағдарламалық-инженерлік артықшылықтан гөрі ресурсы шектеулі-орналастыру мақсатының құрылымдық сыңары. Бос байланыс сонымен қатар 6.3-кестеде тіркелген шегерулердің алғышарты: Inference модулі өзінің интерфейсімен шектелгендіктен, оған ішкі модель-таңдау логикасы айналадағы топологияны бұзбай кейінірек көрсетіле алады (§6.2.2), ал Preprocessing қозғалтқышының сегіз кезеңді ішкі бөлігі §6.2.1-де FR-2 жүзеге асырылуы ретінде көрсетіле алады.

Аналитикалық тұрғыдан салмақ көтеретін модуль — Деректерді басқару / PACS-EHR интеграция қабаты, өйткені дәл сонда функционалдық емес қабық жобаны ең өткір кеседі. Функционалдық тұрғыдан бұл қабат кескіндерді, дәрежелерді және метадеректерді сақтап, оларды PACS пен EHR интерфейстері арқылы пациент жазбаларымен байланыстыруы тиіс (FR-6), әрі ол аурухана жүйелерімен стандартталған алмасу арқылы өзара әрекеттесуі тиіс (NFR-6). Бұрынғы архитектура соңғысының тетігін көрсетеді: сақтауды, интеграцияны және өзара әрекеттесуді делдалдайтын Деректерді басқару платформасы (DMP), өзара әрекеттесу FHIR және HL7 стандарттары арқылы деректер алмасу ретінде анықталған, әрі сақталатын мәндерді тіркейтін мән-байланыс моделі — Пациент, Медициналық жазба, Дәрігер, Қабылдау, Телемедицина сеансы, AI моделі, Диагностикалық нәтиже және Құрылғы (Есмұхамедов және әріптестері, 2025, 4-кесте, 86-б.; 5-сурет, 88-б.). Қабық таңатын шектеу — бұл алмасу *қалай* жоспарланатынына. NFR-4 бойынша байланыс үзік әрі store-and-forward жұмысы талап етіледі; NFR-1 мен NFR-2 бойынша inference жолы жергілікті, GPU-сыз, 16 ГБ-тан төмен хост ішінде жұмыс істеуі тиіс. Бірге бұлар дәреже тек аурухана PACS немесе EHR-ге синхронды баруды-қайтудан кейін ғана тудырыла алатын кез келген топологияны жарамсыз етеді: мұндай топология inference сын жолын қабық кепілдемейтін желілік ресурсқа байлар еді. Сондықтан жарамды жүзеге асыру — *асинхронды* интеграция қабаты —

inference мен preprocessing жергілікті аяқталады, нәтижелер мен кескіндер кезекке қойылады, ал PACS/EHR-мен FHIR/HL7 алмасуы байланыс рұқсат еткенде оппортунистік реттеледі. Топологияны бұлай кесу — диссертацияның түпнұсқа талдауы; ол функционалдық емес қабық, компонент түгендеуі емес, архитектураны қалыптастыратынының нақты мағынасы. AI-көмекті HL7/FHIR өзара әрекеттесуінің белсенді зерттелетін әрі прототиптелетін интеграция тәсілі екенін сырттан Nandal [102] растайды, ол AI-жетілдірілген HL7/FHIR алмасуын жүзеге асырып, оны sandbox ортасында MIMIC-III дерекқорында және синтетикалық HL7 хабарламаларында бағалады; сол зерттеу тек ішкі бағалауды, сыртқы немесе клиникалық валидациясыз хабарлайды, сондықтан ол мұнда осы жүйенің мінез-құлқының өлшемі ретінде емес, интеграция тәсілінің орындалатын әрі заманауи екенінің дәлелі ретінде келтіріледі.

Дәл сол интеграция шекарасы — деректер қауіпсіздігі шоғырланатын жер (NFR-7). Деректерді басқару қабатының сақталатын мәндері — дәл пациентті-айқындайтын жазбалар, сондықтан бұрынғы архитектура көрсететін қауіпсіздік тетіктері — компонент аралық тасымалдау үшін қауіпсіздік шлюзі, шифрлеу және пайдаланушы аутентификациясы (Есмұхамедов және әріптестері, 2025, 3-кесте, 83-б.; 90-б.) — жоба бойынша осы шекарада орналастырылады. Тараудың эпистемикалық мәртебесімен үйлесімді, бұл — архитектурада өрнектелген қауіпсіздік талабы, қол жеткізілген немесе куәландырылған қасиет емес: GDPR/HIPAA шеңберлеуі — жобалау сипаттамасы, тексерілген немесе куәландырылған сәйкестік мәртебесі емес (SB-4.2; NC-9), әрі оның егжей-тегжейлі хаттама-деңгейлі қарастырылуы §6.4.1-ге шегеріледі.

Бұл модуль жиынының компонент-деңгейлі көрінісін DIA-6.1, түсіру → preprocessing → inference → есеп беру ағынын параллель деректерді-сақтау және қателерді-өңдеу компоненттерімен көрсететін модульдік жүйе-архитектура диаграммасы береді [DIA-6.1: Модульдік жүйе архитектурасы (түсіру→өңдеу→inference→есеп) — defense/presentation/assets/architecture/06_system/02_system_architecture.png]. Ыдыратудың формальды UML қарастырылуы — жоғарыда аталған интерфейстерді нақтылайтын компонент, реттілік, класс, әрекет және ER диаграммалары — шегерілген концептуалды актив [DIA-6.3: Жүйе архитектурасы UML — ЖАСАЛАТЫН РЕСУРС]; оның болмауы прозаға әсер етпейді, ол диаграмма беретін ешбір деректі алып жүрмейді.

Сонымен ыдырату жобалау сипаттамасы ретінде тіркеледі: бос-байланысқан, тәуелсіз-ауыстырылатын модульдер жиыны, оның реттелуі — әрі әсіресе оның асинхронды PACS/EHR интеграция қабаты — функцияларды еркін бөлуден гөрі OD-6 қабығының жарамды жүзеге асырылуы. §6.1.1 талаптары сияқты, бұл жобаның жүзеге асырылуы мен валидациясы болашақ жұмысқа сақталған; мұндағы үлес — талап-жетектелетін ыдыратудың өзі (CFC-1.5). Келесі бөлімдер кесте шегеретін ішкі бөліктерді көрсетеді: §6.2.1 Preprocessing қозғалтқышын FR-2-нің конфигурацияланатын жүзеге асырылуы ретінде, §6.2.2 Inference модулін және оның модель-таңдау логикасын, §6.3 дәрігер интерфейсі мен Қабылдау модулінің телемедицина орналастыруын, ал

§6.4.1 интеграция қабатының қауіпсіздік пен деректерді-қорғау хаттамаларын егжей-тегжейлейді.

§6.2.1 Конфигурацияланатын pipeline бар Preprocessing ҚОЗҒАЛТҚЫШЫ

§6.1.2-нің модуль ыдыратуы жеті модульді тіркеп, олардың ішкі бөліктерін шегерді; 6.3-кесте preprocessing функциясының (FR-2) жүзеге асырылуын Preprocessing қозғалтқышына тағайындап, оның сипаттамасын осы бөлімге жіберді. Сол сипаттама мұнда тек жобалау сипаттамасы ретінде беріледі: төменде сипатталған қозғалтқыш — архитектуралық жоба, жүзеге асырылған немесе эталондалған компонент емес, әрі оның диагностикалық үлесі — ұсталатыны көрсетілген қасиет емес, орындалуға тиіс мақсат (SB-4.1; DGL-4).

Модульдің аналитикалық өзегі — 3-тарауда (§3.1) көрсетілген сегіз кезеңді preprocessing pipeline — канондық аудару, оптикалық диск/фовеа айналу нормализациясы, көру-өрісін қию және изотропты өлшемін өзгерту, FOV-маска генерациясы, адаптивті жарық-өрісін түзету, қос шектеулі CLANE, augmentation және деректер жиынтығына тән нормализация. Сол pipeline мұнда сілтеме бойынша қосылады әрі қайта шығарылмайды. Оның бұл тарауда қалай пайдаланылатынын дәл ескерту басқарады: pipeline — модуль өзегі *көрсетілгендей*, валидацияланғандай емес. Оның диагностикалық тиімділігі — осы диссертация үшін операциялық анықталған қабылдау мақсаты (OD-5), ал қозғалтқыштың кез келген конфигурациясы сол мақсатқа жете ме — эксперименттік тарауларға сақталған эмпирикалық сұрақ; ол мұнда орнықтырылған нәтиже ретінде бекітілмейді. Сондықтан Preprocessing қозғалтқышы — көрсетілген pipeline-нің архитектуралық қорабы, әрі осы бөлімнің жобалау үлесі — қораб — pipeline модуль ретінде қалай ашылатыны — pipeline қаншалықты жақсы жұмыс істейтіні туралы кез келген тұжырым емес.

Бұл шеңберлеу — модель preprocessing мен CNN backbone-ның құрамы деген орталық тезистің архитектуралық көрінісі. Кандидаттың бұрын жарияланған архитектурасында кескінді өңдеу деректерді өңдеуге жасырын бүктелген қадамнан гөрі жүйенің ерекше бірінші-класты компоненті ретінде әлдеқашан айқындалды (Есмұхамедов және әріптестері, 2025, Кескінді өңдеу компоненті, 1-сурет және 3-кесте, 83-б.); сол жарияланым компонентті жоба ретінде ұсынып, оның ешбір прототипін немесе сандық валидациясын хабарламады (оның мойындалған шектеуі, §II.6). Қазіргі бөлім сол компонентті *конфигурацияланатын* қозғалтқышқа қайрап, конфигурацияланушылықты салмақ көтеретін қасиет етеді, сонда preprocessing архитектураға одан жоғары қосалқы дайындау ретінде емес, inference жолындағы параметрленген модуль ретінде кіреді.

Конфигурацияланушылық үш ось бойынша көрсетіледі. Біріншіден, кезең таңдау: әр кезең — тәуелсіз қосылатын элемент, сонда қозғалтқыш толық сегіз кезеңді конфигурацияда немесе бір кезең айналып өтілетін қысқартылған

конфигурацияда жұмыс істей алады. Екіншіден, параметрлеу: бапталатын параметрлерді алып жүретін кезеңдер — олардың арасында жарық-өрісін түзету масштабы мен CLANE клип-лимиті — сол параметрлерді ішінде тіркеуден гөрі модуль шекарасында ашады, олардың көрсетілген мәндері мен формуляциялары §3.1-ден мұралаанады. Үшіншіден, режим: қозғалтқыш оқыту-уақыттық мінез-құлықты inference-уақыттықтан ажыратады, өйткені екі кезең 3-тарау сипаттамасы бойынша режимге-тәуелді — augmentation кезеңі тек оқыту кезінде қолданылады, ал CLANE кезеңі оқыту кезінде стохастикалық, бірақ inference кезінде детерминистік қолданылады. Олай болса, inference кезінде қозғалтқыш түсірілген көз түбі кескінінен inference модулі тұтылатын төрт арналы tensor-ға (RGB плюс FOV маскасы) детерминистік, augmentation-сыз түрлендіруге шешіледі.

Оқыту-уақыттық пен inference-уақыттық мінез-құлық арасындағы айырмашылық қозғалтқыштың интерфейс келісімін де тіркейді. Inference кезінде түрлендіру детерминистік әрі augmentation-сыз, сонда сол түсірілген кескін әр шақырғанда сол төрт арналы tensor-ға бейнеленеді; бұл қайта жаңғыртылушылық — §6.1.2-де тіркелген асинхронды, store-and-forward топологиясының алғышарты, онда қозғалтқыш пен inference модулі жергілікті аяқталады, ал нәтиже кейінірек аурухана жүйелерімен реттеу үшін кезекке қойылады. Келісім сонымен қатар қозғалтқышқа қабылдау шекарасы өткізетін бұзылған немесе келісімнен-тыс кірістерге айқындалған жауапты тағайындайды (FR-7): әрқашан-қосулы кезеңдер арқылы өткізілмейтін кескін — мысалы, көру өрісі шешілмейтіні — нашарлаған tensor-ды үнсіз тудырудан гөрі қозғалтқышта қабылданбайды, сәтсіздікті inference-ке таратудан гөрі айқын ұстайды.

Бұл конфигурацияланушылық — FR-2-ні OD-6 қабығы ішінде жарамды ететін нәрсе, әрі қозғалтқыштың тіркелгеннен гөрі конфигурацияланатын ретінде көрсетілуінің себебі. Preprocessing есептеуі маңызды, ал §6.1.1-де тіркелген қабық оны шектеулі жады бюджеті ішінде (NFR-2) және GPU жеделдетуі болмауы мүмкін хостта (NFR-1) нақты-уақытқа жуық клиникалық жұмыс үдерісі ішінде (NFR-3) орындауды талап етеді. Кезең таңдау мен параметрлерді модуль шекарасында ашу орналастыруға қозғалтқышты өзінің хостына бюджеттеуге — қолжетімді жадыға және кідіріс қабығына сай келетін кезең конфигурациясы мен параметр баптауларын таңдауға — мүмкіндік береді, әр хостты жалғыз тіркелген шығынға міндеттеудің орнына. Сол модуль шекарасы NFR-5-ті де жүзеге асырады: қозғалтқыш айқындалған кескін-кіреді, tensor-шығады интерфейсін арқылы байланасатындықтан, ол тәуелсіз ауыстырылады, сонда түрлі түсіру сипаттары бар сайт downstream inference модулін бұзбай қозғалтқышты қайта-баптай немесе ауыстыра алады. Бұл — жарамдылық пен бейімделушілік туралы мәлімдеме, оңтайлылық туралы емес екенін атап өту керек: қозғалтқыш оңтайлы деп бекітілген preprocessing конфигурациясын ендірмейді, әрі берілген ортаға қай конфигурация ең жақсы қызмет ететіні — тексерілген архитектуралар мен деректер жиынтықтарымен шектелген эмпирикалық сұрақ (NC-17), осы жобамен шешілмейді.

Қозғалтқыштың компонент-деңгейлі көрінісі — кезеңделген кескін-кіреді, tensor-шығады ағыны — 3-тараудан қайта пайдаланылған pipeline-шолу диаграммасы [DIA-6.2: Preprocessing қозғалтқышы — конфигурацияланатын сегіз кезеңді pipeline — defense/presentation/assets/preprocessing/10_input/04_preprocessing_pipeline_vertical.png]. Preprocessing функциясы OD-6 қабығы аясында төрт арналы tensor тудыратын конфигурацияланатын модуль ретінде көрсетілген соң, келесі бөлім сол tensor-ды тұтынатын модульді көрсетеді: inference модулі мен оның модель-таңдау логикасы.

§6.2.2 Модель-таңдау логикасы бар Inference модулі

§6.2.1-дің Preprocessing қозғалтқышы түсірілген көз түбі кескінін детерминистік төрт арналы tensor-ға шешеді; бұл бөлім оны тұтынатын модульді көрсетеді. Тараудың қалған бөлігі сияқты, inference модулі жобалау сипаттамасы ретінде ұсынылады: ешбір оқытылған модель орналастырылмайды әрі мұнда ешбір inference мінез-құлқы тұжырым ретінде хабарланбайды (SB-4.1). Модульдің тиімділігі — ол ұстайтын модель диагностикалық-тиімділік мақсаты OD-5-ке жете ме — эксперименттік тарауларға сақталған эмпирикалық сұрақ әрі осы жобада бекітілмейді.


Модульдің екі функционалдық талапқа сәйкес екі шығысы бар. Төрт арналы tensor-дан ол оқытылған CNN backbone-ды пайдалана отырып бес класты диабеттік-ретинопатия дәрежесін (DR 0–4) тудырады (FR-3), әрі дәрежемен қатар ол дәреженің негізін қарап шығатын дәрігерге оқылатын ету мақсатындағы post-hoc Grad-CAM жабынын тудырады (FR-4). Бұл жабынның мәртебесі дәл бекітілуі тиіс: ол — дәрежеден кейін есептелген интерпретация артефактісі, желінің болжамы ең сезімтал болған кескін аймақтарын көрсетеді, әрі ол патологияның клиникалық локализациясы емес — ол зақымдануларды анықтамайды, сызбаламайды немесе куәландырмайды (NC-14). Сондықтан модульдің шығыстары шешім ретінде емес, клиникалық шешімге кірістер ретінде көрсетіледі: жүйе — physician-in-the-loop аясында жұмыс істейтін шешім-қолдау компоненті, дербес диагностикалық аспап емес (SB-1.3). Дәреже мен жабын — §6.3.2-нің physician-in-the-loop интерфейсі интерпретация, аудит және мүмкін қайтару үшін ұсынатын пайдалы жүк.

Модульдің ерекшелейтін элементі — оның модель-таңдау логикасы, әрі сол логиканың жобалау ниеті өнімділік рейтингімен шатастырылмауы тиіс. Диссертация 3-тарауда екі CNN backbone тіркейді — ResNet-50 және EfficientNet-B3 — олар өздерінің есептеу профилінде ерекшеленеді: residual желі — жоғары-сыйымдылықты нұсқа, ал EfficientNet backbone — параметр-тиімдірек. Таңдау логикасы олардың арасынан орналастыру хостының ресурс профилі негізінде — оның қолжетімді жадысы, есептеуі және клиникалық жұмыс үдерісі рұқсат ететін кідірісі — таңдайды, сонда inference функциясы §6.1.1-дің функционалдық емес қабығына сай келеді (NFR-1-дің GPU жеделдетуінің болмауы мүмкіндігі, NFR-2-нің 16 ГБ-тан төмен бюджеті, NFR-3-тің нақты-уақытқа жуық талабы). Сондықтан критерий — орналастырудың

нақты аппаратына шартталған ресурс сәйкестігі (DGL-2); ол бір backbone екіншісінен дәлірек деген тұжырым айқын емес. Бұл жобада екі backbone-ның ешбір өнімділік реттелуі бекітілмейді, әрі ешбірі бекітіле де алмас еді, өйткені салыстыру — эксперименттік тараулардың нысаны әрі мұнда ешбір нәтиже импортталмайды.

Екі шекара бұл логиканы оның тек-жоба регистрі ішінде ұстайды. Біріншіден, backbone-ды оның ресурс профилі бойынша таңдау — *валидацияланған* немесе *оңтайлы* модельді таңдау емес: диссертация екі backbone-ның бірі міндет үшін оңтайлы архитектура деген тұжырым жасамайды (NC-6), әрі бір архитектура үшін алынған нәтижелер тиімді CNN-дердің кеңірек класына жалпыланбайды (SIR-7). Екіншіден, екі backbone — диагностикалық жеткіліктігі OD-5 қабылдау мақсаты болып қалатын жобалау нұсқалары; таңдау логикасы берілген хост қай нұсқаны орындай алатынын шешеді, қай нұсқа жақсырақ жұмыс істейтінін емес. Осы мағынада архитектура түпкі эксперименттік шешімге әдейі агностикалық — ол ресурс қабығы өткізетін кез келген backbone-ды орналастыруға жобаланған, әрі ол таңдау қағидатын өзгертпей сол ресурс осіндегі тағы бір backbone-ға кеңейер еді.

Осылай көрсетілген inference модулі — конфигурацияланатын Preprocessing қозғалтқышының ресурс-жағындағы сыңары: қозғалтқыш preprocessing шығынын хостқа бюджеттейтін жерде, таңдау логикасы модель шығынын хостқа бюджеттейді, әрі бірге олар бүкіл дәреже-тудырушы жолды жергілікті ұстайды — §6.1.2-де тіркелген асинхронды, store-and-forward жұмысының алғышарты, онда дәреже мен оның жабыны жергілікті тудырылып, кейінірек аурухана жүйелерімен реттеу үшін кезекке қойылады. Кандидаттың бұрын жарияланған архитектурасы Тану/Диагноз компонентін және клиникалық-шешім-қолдау функциясын жүйенің осы нүктесіне әлдеқашан орналастырды (Есмұхамедов және әріптестері, 2025, 1-сурет және 3-кесте, 83-б.), бірақ оларды прототипсіз немесе сандық валидациясыз жоба ретінде ұсынды (оның мойындалған шектеуі, §II.6); қазіргі бөлімнің үлесі — сол компонентті OD-6 қабығына байлайтын ресурс-шартталған таңдау логикасы. Дәреже мен жабын дәрігерге жететін орналастырылған интерфейсті жүйенің бақылау тақтасы иллюстрациялайды (6.1-сурет), ол мұнда өлшенген өнімділіктің дәлелі ретінде емес, жобаланған өзара әрекеттесудің иллюстрациясы ретінде көрсетіледі. Inference функциясы жобалау сипаттамасы ретінде тіркелген соң, §6.3 осы жергілікті inference жолын телемедицина мен тасымалданатын орталарда орналастыруға және оның шығыстарын тұтынатын physician-in-the-loop интерфейсіне бұрылады.



Сурет 6.1 – Орналастырылған веб-қосымша / шешім-қолдау бақылау тақтасы

§6.3.1 Ауылдық орналастыру үшін телемедицина және тасымалданатын құрылғыны қолдау

Алдыңғы екі бөлім жергілікті дәреже-тудырушы жолды тіркеді: конфигурацияланатын Preprocessing қозғалтқышы (§6.2.1) және ресурс-бюджеттелген Inference модулі (§6.2.2), олар бірге орналастыру хостында DR дәрежесін және шешім-қолдау жабынын тудырады. Бұл бөлім сол жол бүкіл архитектура бағыттайтын ортада — таралған, байланысы шектеулі және ауылдық — қалай орналастырылатынын көрсетеді. Орналастыру — жобалау сипаттамасы: ешбір жүйе орнатылмады, ешбір скрининг науқаны жүргізілмеді, әрі жобаның кез келген нақты денсаулық сақтау контексіне, Қазақстандікін қоса, қолданылуы далалық сынақтың болмауымен шектелген (SB-4.1; SB-4.3). Сыртқы скрининг бағдарламалары төменде *орналастыру модельділігінің* тәжірибеде орнықтырылғанының дәлелі ретінде келтіріледі, ешқашан осы жүйенің өлшемдері ретінде емес.

6.3.1.1 Таралған телемедицина жүйелеріндегі орналастыру

Телемедицина орналастыруы кескінді түсіруді шеткі сайттарға таратып, интерпретация мен қадағалауды басқа жерде шоғырландырады, әрі архитектура бұл таратуды модификациясыз қолдайды, өйткені §6.1.2-нің жобалау таңдаулары соған жасалды. Модуль жиыны екі табиғи орналастыруды өткізеді: Қабылдау, Preprocessing қозғалтқышы және Inference модульдері шеткі түсіру сайтында отырады, ал physician-in-the-loop қарау беті (§6.3.2) көп сайтқа қызмет ете алатын оқу орталығында отырады. Қабылдау модулі (FR-1) шеткі сайтта гетерогенді және тасымалданатын түсіру көздерінен кескіндерді өткізеді; жергілікті inference жолы дәреже мен жабынды сайтта тудырады; ал асинхронды, store-and-forward интеграция қабаты түсіру кезінде тірі байланысты талап етудің орнына, байланыс рұқсат еткенде нәтижені орталық жүйелермен реттеу үшін кезекке қояды. Бұл — §6.1.2-де кесілген топологияның

операциялық мағынасы: үзік байланыстар арқылы таралған телемедицина дәл сондықтан жарамды, өйткені сын жолдағы ешбір қадам синхронды байланысқа тәуелді емес. Қабылдау модулінің қателерді-өңдеу жауапкершілігі (FR-7) бұл орналастыруда салмақ көтереді: әрқашан-қосулы preprocessing кезеңдері арқылы өткізілмейтін кіріс шеткі сайтта белгіленеді, сонда скринингке жарамсыз түсірілім оқу орталығына берілгеннен кейін ғана анықталудан гөрі жергілікті қайта-түсіру үшін бетке шығарылады. Терең-оқыту DR скринингінің мұндай телемедицина мен бастапқы-медициналық жұмыс үдерістері ішінде жұмыс істей алатынын сыртқы дәлел қолдайды. Бастапқы медицинадағы терең-оқыту скринингінің мета-талдауы он зерттеу бойынша 0,87 біріктірілген сезімталдық пен 0,90 спецификалық хабарлады [62]; алайда сол талдау зерттеулер арасындағы шектен тыс гетерогендікті ($I^2 > 99\%$) және бастапқы-медициналық популяцияға тән 10% ауру таралымында тек 49% оң болжамдық мәнді тауып, авторларын дәлел әлі рутиналық клиникалық қолдану үшін жалпы ұсынысқа мүмкіндік бермейді деп қорытуға жетеледі. Проспективті түрде терең-оқыту жүйесі орта-табысты елде тоғыз бастапқы-медициналық сайт бойынша ұлттық скрининг бағдарламасына, медициналық көмек нүктесінде нақты-уақыттық градациялаумен және дәрігер емес персоналға міндет-ауыстырумен интеграцияланды [59]. Терең-оқыту DR жүйесі сол сияқты Сахарадан оңтүстіктегі африкалық бағдарлама ішінде скринингке орналастырылды [57], ал Таиландтағы он бір клиника бойынша адам-орталықты далалық бағалау әлеуметтік-экологиялық факторлар мен кескін-сапасы сүзгісі нақты-әлемдік орналастыруды айтарлықтай қалыптастырғанын құжаттады [14] — соңғысы модальдылық орындалатын, бірақ оның далалық өнімділігі жобалау сипаттамасы кепілдей алмайтын жағдайларға тәуелді екенін еске салады. Бұл зерттеулер, офтальмологиядағы терең оқытудың техникалық-және-клиникалық шолуларымен бірге [64], телемедицина скрининг модальдылығының орындалатын әрі заманауи екенін орнықтырады; олар тек сол прецедент үшін, өздерінің деректер жиынтықтары мен валидация жобаларымен келтіріледі, осында жобаланған жүйеге телінетін өнімділік ретінде емес.

6.3.1.2 Ұлттық eHealth платформаларымен интеграция

Ұлттық немесе аймақтық eHealth платформасы бар жерде жүйе арнайы интерфейс арқылы емес, §6.1.2-де көрсетілген деректерді-басқару қабаты арқылы онымен интеграцияланады: пациентті байланыстыру, кескінді мұрағаттау және нәтижені қайтару платформаның PACS пен EHR қызметтеріне қарсы стандартталған FHIR/HL7 алмасуы (NFR-6) арқылы тасымалданады. Кандидаттың бұрын жарияланған архитектурасы дәл осы интеграцияны Қазақстан контексті ішінде орналастырып, ұлттық орналастыру өзара әрекеттесетін PACS, бұлт және электронды-жазба компоненттерін сипаттады (Есмұхамедов және әріптестері, 2025, 86–87-б.); сол жұмыс — жоба әрі интеграцияның ешбір жүзеге асырылуын немесе валидациясын хабарламады, әрі сәтті қабылдау диагностикалық жабдыққа және инфрақұрылымға инвестицияны талап ететінін айқын атап өтті (оның мойындалған шектеуі,

§II.6). Диссертация сол алғышартты жоюдан гөрі мұралайды: ұлттық платформамен интеграция — платформа мен байланыс бар болуына шартталған жобалау сипаттамасы (DGL-4), ал store-and-forward жобасы — олар үзік түрде жоқ жағдайда архитектураның бейімделуі. Бұл шекара бойынша алмасу бірлігі — телемедицина кездесуі, әрі §6.1.2-ден алып жүрілген мән-байланыс моделі оның сақталатын түрін әлдеқашан тіркейді — Пациент, Телемедицина сеансы, Құрылғы, Диагностикалық нәтиже және AI моделі — платформа интеграциясы оқитын және жазатын мәндер. Бұлар таралған байланыс арқылы өтетін пациентті-айқындайтын жазбалар болғандықтан, интеграция шекарасы — деректерді-қорғау міндеттері шоғырланатын жер; олардың хаттама-деңгейлі қарастырылуы және GDPR/HIPAA шеңберлеуі куәландырылған мәртебе емес, жобалау талабы деген ескерту §6.4.1-де көрсетіледі. Бұрынғы жарияланымда мұндай интеграциямен байланысты кез келген болжанған ұлттық-ауқымды пайда — қол жеткізілген ауыл популяциясы немесе шығынның азаюы көрсеткіштері — контекст үшін келтірілген үшінші тарап болжамы әрі осы жұмыстың тұжырымы емес (SIR-8).

6.3.1.3 Ресурсы төмен аймақтардағы нақты-уақыттық қашықтан DR скринингі

Ресурсы төмен режим — бұл архитектура үшін шеткі жағдай емес, оның айқындаушы мақсаты: OD-6 қабығы — GPU жеделдетуінің болуы мүмкін еместігі, 16 ГБ-тан төмен жады бюджеті, нақты-уақытқа жуық өткізу қабілеті және үзік байланыс — осы тармақ қарастыратын дәл сол аймақтардың операциялды анықтамасы. Inference жолы мұндай хостта жергілікті орындалуға бюджеттелгендіктен (§6.2) және интеграция асинхронды болғандықтан (§6.1.2), қашықтағы, ресурсы төмен сайтта дәрежені нақты уақытта немесе оған жуық тудыру — жоба өткізуге құрылған орындалушылық. Алайда бұл — жобалық орындалушылық, дәлелденген қабілет емес: осы зерттеуде ешбір нақты-уақыттық қашықтан скрининг орындалмады немесе өлшенбеді, әрі мұнда жасалатын тұжырым — OD-6 қабығы аясындағы архитектуралық жарамдылық, далада қол жеткізілген өткізу қабілеті немесе дәлдік емес (SB-4.1; SB-4.3). Жобаның уәждемесі — құжатталған скрининг олқылығы — диабеттік науқастардың тек болжамды 35–55%-ы ғана жыл сайынғы көз скринингіне сай келеді [2] — оны қашықтан, тасымалданатын-түсіру скринингі тарылтуға арналған. Тасымалданушылық Қабылдау модулі арқылы кіреді: модуль тасымалданатын және смартфонға негізделген көз түбі камераларынан кірісті қабылдауға көрсетілген, бұл — бұрынғы жарияланым ауылдық орналастыру үшін қолжетімді түсіру алдыңғы-беті ретінде айқындаған құрылғы класы (Есмұхамедов және әріптестері, 2025, 87-б., онда репрезентативті тасымалданатын камера құны келтіріледі). Тасымалданатын түсіру — дәл Preprocessing қозғалтқышының рөлі ең айқын болатын жағдай: 3-тарауда көрсетілген көру-өрісін нормалау, маскалау және жарық-өрісін түзету кезеңдері арзан, мидриатикалық емес және операторға-тәуелді құрылғылар енгізетін түсіру вариабельділігін азайтуға жобаланған, сонда inference модулі түсіру алдыңғы-бетіне қарамастан салыстырмалы түрде жағдайланған tensor

алады. Құрылғыдан-тәуелсіз талдау өзі орнықтырылған бағыт — De Fauw және әріптестері [65] торқабық жолдамалау жүйесін аралық репрезентация арқылы нақты сканер аппаратынан ажыратты, дегенмен көз түбі фотосуреті емес, ОСТ үшін — бірақ жағдайлау көз түбі-камера кластары бойынша градациялау өнімділігін сақтауға жеткілікті ме — эксперименттік тарауларға сақталған эмпирикалық сұрақ әрі мұнда бекітілмейді. Сондықтан архитектура арзан, мобильді түсіру алдыңғы-бетін хост-жергілікті inference жолымен және асинхронды қайтару арнасымен жұптайды — ресурсы төмен ортаға жобаланған конфигурация, оның нақты-әлемдік өнімділігі болашақ далалық бағалауға сақталған.

Бұл үш орта бойынша орналастыру жобасы §6.1.2 мен §6.2-ден алып жүрілген жалғыз қасиетпен біріктіріледі: дәреже-тудырушы жол жергілікті, ал аурухана-жүйесі алмасуы асинхронды, бұл — таралған, инфрақұрылымы жеңіл, үзік-байланысты жұмысты жоба бойынша жарамды ететін нәрсе. Бұл орналастырудың қарау шетінде дәрігер дәреже мен жабынды алатын өзара әрекеттесуді жүйенің бақылау тақтасы иллюстрациялайды (6.1-сурет), ол далалық өнімділіктің дәлелі ретінде емес, жобаланған интерфейстің иллюстрациясы ретінде көрсетіледі. Келесі бөлім сол интерфейсті physician-in-the-loop шешім-қолдау беті ретінде көрсетеді.

§6.3.2 Physician-in-the-Loop шешім-қолдау интерфейсі

§6.3.1-дің телемедицина орналастыруы оқу орталығына қарау бетін орналастырды, онда дәрігер жергілікті inference жолының шығысын алады. Бұл бөлім сол бетті көрсетеді. Тараудың қалған бөлігі сияқты ол — жобалау сипаттамасы: интерфейс өзара әрекеттесу жобасы ретінде сипатталады, әрі мұнда ешбір пайдаланушылық зерттеуі, дәрігер-қабылдауын бағалау немесе шешім-сапасын өлшеу хабарланбайды (SB-4.1).

Интерфейс әр скринингтелген көз үшін екі артефактіні ұсынады: inference модулі тудырған бес класты диабеттік-ретинопатия дәрежесі (FR-3) және оған ілесетін post-hoc Grad-CAM жабыны (FR-4). Жабын дәрігерге модель-сезімталдығы картасы ретінде — болжам ең сезімтал болған кескін аймақтарының көрсеткіші — ұсынылады, әрі оның интерпретация мәртебесі тиісінше бекітіледі: ол модельдің берілген дәрежені неліктен тудырғанын түсінуге қолдау ретінде оқылады, патологияның клиникалық локализациясы ретінде емес, әрі ол зақымдануларды анықтамайды, сызбаламайды немесе куәландырмайды (NC-14). Сонымен интерфейс шешім ұсынысын да, сол ұсынысқа оқылушылық көмегін де бетке шығарады, бірақ оларды қорытынды ретінде емес, дәрігер интерпретациялайтын материал ретінде шығарады.

Бұл — бүкіл жүйенің байланыстырушы ауқымының архитектуралық көрінісі: ол — physician-in-the-loop аясында жұмыс істейтін шешім-қолдау компоненті, дербес диагностикалық аспап емес (SB-1.3). Интерфейс дәрігер шешім қабылдаушы болатындай жобаланған — дәреже мен жабын дәрігер интерпретациялайтын, кескінге қарсы аудиттейтін және қайтара алатын кірістер — әрі жүйе ешбір автономды диагноз шығармайды. Бұл реттеу

кандидаттың бұрын жарияланған архитектурасы дәрігерге тағайындаған рөлді жүзеге асырады: модель шығысының енжар тұтынушысы емес, нәтижелерді интерпретациялайтын және модельдің мінез-құлқын баптай немесе түзете алатын жүйенің «баптаушысы» және аудиторы, ол талдауды алғаннан кейін дәрігер түсіндірме немесе түзету сұрайтын Дәрігер-AI кері байланыс механизмі арқылы делдалданады (Есмұхамедов және әріптестері, 2025, 78–79, 85-б.). Сол жарияланым бұл өзара әрекеттесуді жоба ретінде көрсетіп, оның ешбір прототипін немесе бағалауын хабарламады (оның мойындалған шектеуі, §II.6); қазіргі бөлім сол өзара әрекеттесуді скрининг жүйесінің интерфейс келісімі ретінде, тағы да тексерілген артефакт емес, сипаттама ретінде алға тасымалдайды.

Қайтару-және-аудит арнасы — факультативті ыңғайлылық емес, шешім-қолдау ауқым шекарасының архитектуралық сыңары. Әр дәреженің оны қабылдай, түзете немесе қабылдамай алатын дәрігер арқылы өтуін талап ету арқылы интерфейс клиникалық жауапкершілікті модельге беруден гөрі дәрігерде ұстайды, бұл — автоматтандырылған скрининг көмекшісін автономды диагностикалық билікті бекітпей жұмыс үдерісіне енгізуге болатын жобалау шарты. Кері байланыс арнасы қосымша дәрігерге келіспеушілікті тіркеуге немесе түсіндірме сұрауға мүмкіндік береді, сонда интерфейс бір-жақты дисплейден гөрі екі-бағытты — модельдің ұсынысын дәрігерге, дәрігердің пайымдауын кері тасымалдайды. Бұл екі-бағыттылықтың дерек қабаты құрметтеуге тиіс сақтау салдары бар: §6.1.2-нің мән-байланыс моделінен алып жүрілген Диагностикалық нәтиже мәні модельдің дәрежесін ғана емес, дәрігердің оны қалай қарағанын — қабылдау, түзету немесе қайтару — жазады, сонда пациент жазбасына қарсы сақталатын беделді скрининг нәтижесі шикі модель шығысынан гөрі қаралған нәтиже болады. Сондықтан интерфейс — модельдің ұсынысы дәрігер-иеленетін шешімге айналатын нүкте, әрі жоба сол иеленуді тек көрсетілетінде ғана емес, сақталатында бекітеді. Таралған орналастыруда бұл бет — жүйе шешетін скрининг олқылығы түптеп келгенде жабылатын немесе жабылмайтын жер: жоба скрининг шешімін беретін акт ретінде модельдің дәрежесін емес, дәрігердің қарауын орналастырады, бұл жүйенің әдетте маман әлуетінен асатын скрининг жүгін басқаратын дәрігерлерге көмекші ретіндегі рөлімен үйлеседі [2].

Осылай көрсетілген интерфейс жүйені әр шығысы дәрігер интерпретациясы мен қайтаруына бағынатын physician-in-the-loop шешім-қолдау беті ретінде бекітеді, пайдаланушылық пен клиникалық-қабылдау дәлелі болашақ бағалауға сақталған. Бұл интерфейс оқитын және жазатын жазбалар — дәреже, жабын, пациентті байланыстыру — жүйенің сақтау және алмасу қабаты арқылы өтетін пациент деректері; келесі бөлім оларды басқаратын деректерді-басқару және қорғау хаттамаларын көрсетеді.

§6.4.1 GDPR/HIPAA-сәйкес деректерді басқару хаттамалары

§6.3.2-нің интерфейсі мен §6.1.2-нің интеграция қабаты пациентті-айқындайтын жазбаларды — көз түбі кескіндерін, дәрежелерді, Grad-CAM

жабындарын, пациентті байланыстыруларды және енді дәрігердің қарауын алып жүретін Диагностикалық нәтижені — таралған, үзік-байланысты орналастыру бойынша оқиды және жазады. Бұл бөлім сол жазбаларды басқаратын деректерді-басқару және қорғау хаттамаларын көрсетіп, §6.1.2 мен §6.3.1.2-ден шегерілген қауіпсіздік қарастыруын орындайды. Кез келген хаттама сипатталмас бұрын бір шекара бекітіліп, тұтасымен ұсталуы тиіс: төмендегі хаттамалар — GDPR және HIPAA деректерді-қорғау режимдерімен *сәйкес келуге* шеңберленген жобалау сипаттамасы; бұл сәйкестік — архитектура қанағаттандыруға жобаланған талап, куәландырылған, аудитталған немесе тексерілген сәйкестік мәртебесі емес (SB-4.2; SB-4.1).

Қорғау тетіктері деректерді-басқару қабатында шоғырланған, кандидаттың бұрын жарияланған жобасының қауіпсіздік архитектурасымен үйлесімді. Сол жұмыс компонент аралық тасымалдауды делдалдайтын қауіпсіздік шлюзін, шифрлеу, пайдаланушы аутентификациясымен бірге және — өзінің Деректерді басқару платформасы ішінде — деректерді анонимизациялау мен қорғалған алмасуды көрсетті (Есмұхамедов және әріптестері, 2025, 3-кесте, 83-б.; 4-кесте, 86-б.); ол оларды жоба ретінде ұсынып, олардың ешбір жүзеге асырылуын немесе қауіпсіздік тестілеуін хабарламады (оның мойындалған шектеуі, §II.6). Қазіргі сипаттама бұл тетіктерді скрининг жүйесі талап ететін хаттамаларға реттейді: жазбаларды тыныштықта да, тасымалда да шифрлеу; пациент деректеріне тиетін әр актер мен қызметті аутентификациялау; жазбаларды дәрігер мен оларға құқылы рөлдермен шектейтін рөлге-негізделген қол жеткізу бақылауы; тікелей күтім контексінен тыс пайдаланылатын деректерді де-идентификациялау; және әр Диагностикалық нәтижеге қарсы жазылған қол жеткізу мен дәрігер қарауын аудит журналдау.

Екі режим бөлісетін қағидаттарға салыстырғанда, бұл хаттамалар құпиялылық пен тұтастықты шифрлеу мен аутентификация арқылы, қол жеткізуді шектеу мен мақсатты шектеуді рөлге-негізделген қол жеткізу бақылауы мен де-идентификация арқылы, әрі есеп берушілікті аудит журналдау арқылы шешеді — §6.1.1-де NFR-7 ретінде тіркелген қауіпсіздік пен пациент-дерекін-қорғау талабының жоба-деңгейлі жүзеге асырылуы. Тағы екі қағидат сол деңгейде жобалау талаптары ретінде көрсетіледі. Деректерді минимизациялау мен сақтау жүйе ұстайтын жазбаларды кескіндерді шексіз жинаудан гөрі скрининг мақсаты үшін қажеттілермен және айқындалған сақтау кезеңімен шектейді; ал жоба дерек-субъектісі сұраулары үшін — пациент жазбаларына қол жеткізу және қолданылатын жерде өшіру — сол аутентификацияланған қол жеткізу қабаты арқылы қызмет көрсетілетін арна қалдырады. Салыстыру әдейі нақты заңнамалық ереже деңгейінен гөрі қағидат деңгейінде айтылады: берілген орналастыру GDPR-дың қай баптарын немесе HIPAA Қауіпсіздік ережесінің қай бақылауларын қанағаттандыруы тиіс — юрисдикция мен өңдеу контексіне тәуелді, әрі белгілі бір ережені қанағаттандырылды деп атау — осы жоба орнықтыратыннан асып кетер еді.

§6.1.2-де тіркелген store-and-forward топологиясы бұл талаптарды жұмсартудан гөрі қайрайды. Нәтижелер мен кескіндер байланыс жоқ кезде

орналастыру хостында жергілікті ұсталып, аурухана жүйелерімен оппортунистік реттелетіндіктен, қорғау жобасы сенімді, үздіксіз арнаны жора алмайды: шеткі хостта тыныштықта кезекке қойылған деректер орнында шифрленуі тиіс, ал PACS пен EHR қызметтерімен асинхронды алмасу болғанда өзара аутентификацияланып, тасымалда шифрленуі тиіс. Сондықтан жүйені ресурсы шектеулі орталарда орналастырылатын ететін үзік-байланысты, таралған сипат — оның деректерді-қорғау жобасын маңызды ететін нәрсе, әрі хаттамалар сол сипатқа қарамастан емес, сол сипат аясында ұсталатын етіп көрсетіледі.

Соңында, эпистемикалық шекара айқын етілуі тиіс, өйткені бұрынғы жарияланым оны етпеді. Сол жұмыс ұсынылған жүйесі «GDPR және HIPAA-сәйкес» деп қорытты (Есмұхамедов және әріптестері, 2025, 90-б.); қазіргі диссертация сол қорытындыны айтылғандай алға тасымалдамайды, әрі оны жобалау талабы ретінде қайта шеңберлейді. Бұл зерттеуде ешбір сәйкестік аудиті, формальды куәландыру, деректерді-қорғау әсерін бағалау немесе ену тесті жүргізілмеді, әрі ешбірі хабарланбайды (SB-4.2; NC-9). Осында көрсетілген хаттамалар — жүйе сәйкестікті бекіту үшін жүзеге асырып, содан кейін тәуелсіз бағалатуға тиіс жоба; осы бөлімнің тұжырымы — сипаттама, сәйкестік емес. Юрисдикцияға-тән сәйкестік — Қазақстандағы орналастыруға қолданылатын ұлттық деректерді-қорғау режимін қоса — қолданылуы дәл сол тек-жоба шегі аясында §6.4.2-де қарастырылатын жобалау мақсаты.

§6.4.2 Қазақстанның денсаулық сақтау инфрақұрылымына қолданылуы

Алдыңғы бөлім юрисдикцияға-тән сәйкестікті — нақты орналастыру елінің деректерді-қорғау режимін қоса — жобалау мақсаты ретінде сақтады. Бұл бөлім диссертацияның аталған контексті, Қазақстан, үшін тиісті қолданылу сұрағын қарастырып, оны айқын шек аясында жобалау дәлелі ретінде жауаптайды: архитектура Қазақстанның денсаулық сақтау инфрақұрылымына жоба бойынша қолданылады деп дәлелденеді, бірақ ешбір Қазақстан клиникалық ортасында ешбір орналастыру, пилот немесе далалық бағалау жүргізілмеді, әрі мұнда бекітілген қолданылу — дәлелденген әсер емес, жобалық сәйкестік (SB-4.1; SB-4.3).

Қолданылу бағаланатын контекст — кандидаттың бұрын жарияланған жұмысында құжатталғаны, ол Қазақстанның офтальмологиялық-күтім ортасын айқын маман тапшылығы мен ауылдық таралудың бірі ретінде сипаттады — ұлттық популяцияға реті бойынша 1200 офтальмолог, оның шамамен 40%-ы ауылдық, шамамен 8% диабет таралымына қарсы әрі мамандандырылған көз күтіміне шектеулі ауылдық қолжетімділік (Есмұхамедов және әріптестері, 2025, 74, 77, 86–87-б.). Сол жарияланым бұл контексті жобалау уәдесі ретінде хабарлап, оған қарсы ешбір жүйені валидацияламады, қабылдау жабдыққа және инфрақұрылымға инвестицияны, жергілікті деректерге бейімдеуді және ұлттық стандарттарды әзірлеуді талап ететінін атап өтті (оның мойындалған шектеуі,

§II.6). Бұл көрсеткіштер мұнда жоба шешетін құжатталған контекст ретінде келтіріледі, осы диссертацияның тұжырымдары ретінде емес.

Қолданылу дәлелі — осы контексттің шектеулері дәл архитектура сақтауға құрылған шектеулер екені, сонда оның жобалау таңдаулары Қазақстанның қажеттіліктерімен жай үйлесімді болудан гөрі оларға салыстырылады. Маман тапшылығы — physician-in-the-loop шешім-қолдау жүйесі — ол аз санды мамандардың қол жетімділігін әрқайсысының бастапқы түсіруі емес, скрининг ұсыныстарын қарауға мүмкіндік беру арқылы кеңейтеді әрі дәрігер емес персоналға міндет-ауыстырумен үйлесімді — ең пайдалы болатын шарт (§6.3.2). Ауылдық тарату мен үзік байланыс — store-and-forward топологиясы мен тасымалданатын-түсіру қабылдауы жобаланған шарттар (§6.3.1), ал ауылдық орналастыруға арзан түсіру алдыңғы-беті мен GPU-сыз, 16 ГБ-тан төмен inference хосты шешетін шығын кедергісі (§6.2). Басқаша айтқанда, OD-6 қабығы мұнда жалпы ресурсы шектеулі абстракция емес: ол Қазақстанның ауылдық офтальмологиялық-күтім контексті мысалдайтын орта түріне сай етіп рационалданды, әрі жобаның қолданылуы сол қабық-сәйкестігінен туындайды.

Алайда бұл қолданылу — сәйкестік туралы тұжырым, пайда туралы емес. Бұрынғы жарияланым мұндай орналастырудан елеулі ұлттық-ауқымды пайдаларды болжады — бірнеше миллион ауыл тұрғынына торқабық күтіміне қолжетімділік, кеш-сатылы диабеттік-ретинопатия асқынуларының 20–30% азаюы, байланысты денсаулық сақтау шығынының 15–20% азаюы және жыл сайын шамамен екі миллион адамды скрининг (Есмұхамедов және әріптестері, 2025, 87–88-б.). Бұлар — проблема шеңберленетін ауқымды көрсету үшін контекст үшін мұнда келтірілген үшінші тарап болжамдары; олар осы диссертацияның нәтижелері емес, осында жобаланған жүйеге телінбейді, әрі ешбір осындай қамту, шығын немесе асқыну көрсеткіші осы жұмыстың нәтижесі ретінде алға тартылмайды (SIR-8; NC-3). Осы архитектураны Қазақстанда орналастыру осы көрсеткіштердің кез келгеніне жақындар ма — далалық сынақ — осы зерттеуде жүргізілмеген — жауаптауға тиіс дәл сол эмпирикалық сұрақ.

Нормативтік қолданылу §6.4.1-де орнықтырылған сол жобалау-мақсаты деңгейінде қаралады: Қазақстандағы орналастыру онда көрсетілген GDPR/HIPAA-сәйкес хаттамалардан бөлек ұлттық деректерді-қорғау режимін қанағаттандыруы тиіс еді, әрі архитектура мұндай сәйкестікке бейімделуге жобаланған, бірақ ешбір нақты заңнамалық сәйкестік орнықтырылған деп бекітілмейді. Сондықтан жобаның Қазақстанға қолданылуы — шектелген жобалау дәлелі — жүйенің қабығы мен құжатталған ұлттық контекст арасындағы дәлелденген сәйкестік, жүзеге асырылу, пайда және куәландыру барлығы осы диссертациядан тыс жұмысқа сақталған. Бұл дәлел жасалған соң, тараудың жобалау сипаттамасы аяқталады; қорытынды бөлім оны шоғырландырып, тұтасымен басқарған тек-жоба мәртебесін қайта растайды.

§6.С 6-тарау бойынша қорытындылар

Бұл тарау алдыңғы тараулардың біріктірілген preprocessing-CNN моделін өлшеу нысанынан орналастыруға арналған компонентке аударып, ресурсы шектеулі орталар үшін оның айналасында құрылған автоматтандырылған диабеттік-ретинопатия скрининг жүйесінің архитектурасын көрсетті. Сипаттама жалғыз бағытта жүрді. Ол жүйе қанағаттандыруға тиіс талаптарды — жүйе нені істейтінін сипаттайтын функционалдық жиынды және оны қандай ресурсы шектеулі қабық аясында істеуі тиіс екенін сипаттайтын функционалдық емес жиынды (§6.1.1) — тіркеуден басталып, содан кейін жүйені топологиясы, оның PACS пен EHR инфрақұрылымына интеграциясын қоса, сол қабықтың жарамды жүзеге асырылуы екені көрсетілген бос-байланысқан модульдер жиынына ыдыратты (§6.1.2). Ол екі есептеу модулінің ішкі бөліктерін — конфигурацияланатын Preprocessing қозғалтқышын (§6.2.1) және ресурс-бюджеттелген Inference модулін (§6.2.2) — содан кейін нәтижесіндегі жергілікті скрининг жолын таралған телемедицина мен тасымалданатын орталарда (§6.3.1) және physician-in-the-loop шешім-қолдау интерфейсі арқылы (§6.3.2) орналастыруды көрсетті. Ол жүйенің пациент жазбаларын басқаратын деректерді-басқару және қорғау хаттамаларын көрсетіп (§6.4.1) және жобаның Қазақстанның денсаулық сақтау инфрақұрылымына қолданылуын дәлелдеп (§6.4.2) аяқтады.

Бұл прогрессия арқылы жалғыз аналитикалық желі жүреді. Осы диссертация үшін операциялық анықталған функционалдық емес қабық — ресурсы шектеулі орналастыру контексті (OD-6) — басынан тіркелген жай шектеу емес, әр кезеңдегі байланыстырушы жобалау драйвері болды. Ол жарамды топологияны бұлтқа-тәуелдіден гөрі асинхронды, store-and-forward реттеуге кескен нәрсе; Preprocessing қозғалтқышының конфигурацияланушылығы мен Inference модулінің ресурс-шартталған модель-таңдау логикасын уәждеген нәрсе; әрі таралған, үзік-байланысты орналастыруды және ол аясында ұсталуға тиіс деректерді-қорғау жобасын қалыптастырған нәрсе. Сондықтан тараудың үлесі — кез келген скрининг жүйесі бөлісетін компонент түгендеуі емес, сол компоненттерді ресурсы шектеулі қабыққа сай ететін талап-жетектелетін жоба — кандидаттың бұрын жарияланған архитектурасын осы диссертацияның моделі мен орналастыру қабығына қайрап, байлайтын жоба.

Сол үлес — тұтасымен бойы — жобалау сипаттамасы. Ешбір прототип жүзеге асырылмады, ешбір далалық сынақ жүргізілмеді, әрі ешбір болжанған орналастыру нәтижесі осы зерттеудің тұжырымы ретінде айтылмады (SB-4.1). Тарау көрсететін қасиеттер тиісінше қол жеткізілген нәтижелер емес, талаптар мен мақсаттар ретінде ұсталады: inference жолы қанағаттандыруға міндетті диагностикалық тиімділік (OD-5) — жетуі эксперименттік тарауларға сақталған қабылдау мақсаты; деректерді-басқару хаттамаларының GDPR/HIPAA шеңберлеуі — жоба бойынша сәйкестік, куәландырылған немесе тексерілген сәйкестік мәртебесі емес (SB-4.2); Қазақстанға қолданылуы — дәлелденген пайда емес, жоба мен құжатталған контекст арасындағы дәлелденген сәйкестік,

ал жол бойы келтірілген ұлттық-ауқымды болжамдар осы жұмыстың нәтижелері емес, үшінші тарап болжамдары болып қалады (SB-4.3; SIR-8). Архитектураның формальды UML нақтылауы да шегерілген актив болып қалады. Бұл сипаттаманың жүзеге асырылуы, валидациясы, куәландыруы және бағалауы — ол мүмкін ететін жұмыс, ол хабарлайтын жұмыс емес; тараудың үлесі — сипаттаманың өзі (CFC-1.5).

ҚОСЫМШАЛАР

А қосымшасы — Алдын ала өңдеу pipeline-нің бастапқы коды

§4.1.3 preprocessing pipeline мен оқыту кодын нұсқа бақылауына міндеттеп, оларды осында қайта беруге уәде берді, сонда әр кескінге қолданылған түрлендіру тек прозада сипатталудан гөрі бастапқы код ретінде қалпына келтірілетін болады. Бұл қосымша сол уәдені орындайды. Оны қосу — кездейсоқ құжаттама емес: осы жұмыстың орталық тезисі бойынша — модель preprocessing мен конволюциялық желінің құрамы, сегіз кезеңді pipeline қосалқы деректерді дайындау емес, интегралды модель компоненті — preprocessing бастапқы коды модель сипаттамасының *бөлігі*. Оны қайта беру — сол тезисті жай бекітілгеннен гөрі аудитталатын ететін нәрсе.

Код `experiments/src/` астында Python пакеті ретінде ұйымдастырылған. Preprocessing стегі канондық пакет `experiments/src/preprocessing/`-те орналасқан, оның жария интерфейсі `experiments/src/preprocessing/__init__.py`-дан экспортталады, ал оның оркестраторы, `experiments/src/preprocessing/pipeline.py`-дағы `PreprocessingPipeline`, сегіз кезеңді 3-тарауда көрсетілген тіркелген ретпен тізбектейді. Эксперименттерді қайта беруге қажетті қалған аппарат `experiments/src/`-тің бауырлас ішкі-пакеттері бойынша таратылған: `data/` (деректер жиынтығы жүктеуіштері, пациент-деңгейлі стратификацияланған k-fold бөлгіш, біртұтас augmentation және таңба гармонизациясы), `models/` (ResNet-50 және EfficientNet фабрикалары мен екі кезеңді fine-tuning утилитасы), `training/` (оқыту циклі, кері-жиілік салмақтары бар focal loss және checkpoint басқару), `evaluation/` (метрикалар, калибрлеу және статистикалық тесттер), `explainability/` (Grad-CAM, IoU/ALO және жабын рендерлеу), `experiments/` (жеті эксперимент драйвері) және `utils/` (YAML конфигурациясын өңдеу, қайта жаңғыртылушылық seed утилитасы және кескін-сапасы метрикалары). Төмендегі каталог осы жұмысты ажырататын модель компонентін жүзеге асыратын preprocessing пакетімен шектелген; кеңірек ағаш мұнда тек қайта беру толық локализацияланатын болуы үшін аталады.

А.1-кесте 3-тараудың әр pipeline кезеңін оны жүзеге асыратын модульге салыстырады. Әр жол репозиторий түбіріне қатысты беріледі әрі нұсқаланған бастапқы ағашта бар файлға сәйкес келеді.

А.1-кесте. Pipeline кезеңі → жүзеге асырушы модуль (experiments/src/preprocessing/).

Кезең	Сипаттама (3-тар.)	Жүзеге асырушы модуль
0	Канондық аудару (сол→оң көз бағдары)	canonical_flip.py, canonical_orientation.py
1	OD-фовеа айналу нормализациясы	od_fovea_detect.py, canonical_orientation.py
2	FOV қию + изотропты 512×512-ге өлшем өзгерту (ортаға нөл-padding)	crop_resize.py
3	FOV маска генерациясы (бинарлық → 4-ші арна)	crop_resize.py (маска өлшемі өзгертілген кескінмен қайтарылады)
4	Жарық-өрісін түзету (адаптивті $\sigma = 0,07 \cdot D$, маска ішінде)	flat_field.py
5	Қос шектеулі CLAHE (LAB L-арна; оқытуда стохастикалық)	upgraded_clahe.py, polar_clahe.py, clahe.py
6	Augmentation (біртұтас аффинді + жарықтылық/контраст + PCA түс; тек оқыту)	experiments/src/data/augmentation_unified.py
7	Деректер жиынтығына тән нормалау → tensor (әрқашан соңғы)	imagenet_normalize.py
—	Конфигурация беті (базалық пен толық-pipeline пресеттері)	config.py (PreprocessingConfig, PIPELINE_PRESETS)
—	Кезең оркестрациясы (тіркелген орындау реті)	pipeline.py (PreprocessingPipeline)

5-кезең бірден көп модульмен жүзеге асырылады, өйткені pipeline өзінің қазіргі әдепкісі ретінде қос шектеулі CLaHE-нің полярлық нұсқасымен (polar_clahe.py), түзусызықты тайлға-негізделген формуляциямен (upgraded_clahe.py) қатар жеткізіледі; екеуі де нұсқаланған бастапқы кодта бар әрі каталогталғандай қайта беріледі. 0–5 және 7-кезеңдер оқыту мен inference-те бірдей қолданылады, тек 5-кезең контрастты күшейту оқыту кезінде стохастикалық; 6-кезең augmentation тек оқыту кезінде қолданылады әрі uint8 кескіндерде жұмыс істеуі үшін 7-кезең нормализациясының алдына енгізіледі. Базалық конфигурация (A және C конфигурациялары) 0–6 кезеңдерді айналып өтіп, орнына қарапайым 512×512-ге созыла-өлшем өзгертуді, содан кейін үш арнада ImageNet нормализациясын pipeline-ді өңдеуден гөрі конфигурация пресеті арқылы таңдай отырып қолданады; толық pipeline (B және D конфигурациялары) сегіз кезеңнің бәрін орындап, төрт арна (RGB плюс FOV маскасы) шығарады.

Бұл каталог оны парафраздаудан гөрі нақты бастапқы кодты қайта беретінін орнықтыру үшін 4-кезең жарық-өрісі модулі experiments/src/preprocessing/flat_field.py-дан сөзбе-сөз қайта беріледі:

```
"""
```

Stage 4: Flat-Field Correction.

Reduces uneven illumination by subtracting a heavily blurred version of the image and re-centering at 128:

```
corrected = image - GaussianBlur(image,  $\sigma$ ) + 128
```

A large σ captures only the low-frequency illumination gradient, so the subtraction removes broad brightness variation while preserving local vessel and lesion detail.

σ is computed adaptively as $\sigma = 0.07 \times \text{FOV_diameter}$. Correction is applied only inside the FOV mask (padding pixels are left at zero).

Input/output images are RGB uint8 NumPy arrays.

```
"""
```

```
from __future__ import annotations
```

```
import cv2
```

```
import numpy as np
```

```
def apply_flat_field(
    image: np.ndarray,
    sigma: float = 45.0,
```



```

    mask: np.ndarray | None = None,
) -> np.ndarray:
    """
    Apply flat-field correction to reduce uneven illumination.

    Algorithm::

        blur      = GaussianBlur(image,  $\sigma$ )
        corrected = image - blur + 128

    When *mask* is provided, correction is applied only inside the mask
    (``mask > 0``). Padding areas (``mask == 0``) are left at zero.

    Kernel size is derived automatically from *sigma* (passed as ``(0,
0)``
to :func:`cv2.GaussianBlur`).

    Args:
        image: RGB uint8 NumPy array of shape ``(H, W, 3)``.
        sigma: Gaussian blur  $\sigma$  controlling the spatial scale of the
            illumination estimate.
        mask: Optional binary mask of shape ``(H, W)`` (float32 or
uint8).
            When provided, only pixels where ``mask > 0`` are corrected;
padding regions remain zero.

    Returns:
        Corrected RGB uint8 NumPy array of shape ``(H, W, 3)``.
    """
    blur = cv2.GaussianBlur(image, (0, 0), sigma)
    corrected = image.astype(np.float32) - blur.astype(np.float32) +
128.0
    corrected = np.clip(corrected, 0, 255).astype(np.uint8)
    if mask is not None:
        mask_3ch = np.expand_dims(mask > 0, axis=-1).astype(np.uint8)
        corrected = corrected * mask_3ch # zero out padding
    return corrected

```

Қалған модульдер код базасы үшін орнықтырылған сол конвенцияларды ұстанады — тип-белгіленген қолтаңбалар, **Args/Returns** docstring-тері, қатты-кодталудан гөрі конфигурациядан шешілген жолдар және тұтасымен **pathlib.Path** — әрі жинақталған құжатта сол пакеттен толық қайта беріледі. Pipeline шежіресі кандидаттың жаңартылған CLAHN мен preprocessing-жіктеу интеграциясы бойынша бұрын жарияланған жұмысынан тарайды ([yesmukhamedov-scorus-q2.md](#)/[yesmukhamedov-scorus-q3.md](#), [yesmukhamedov-kbtu.md](#) және конференция мақаласы, ♦ бұрынғы өз жұмысы; SIR-4); осында қайта берілген бастапқы код сол желіні 3-тарауда көрсетілген жалғыз нұсқаланған сегіз кезеңді жүйеге формализациялайды әрі шоғырландырады. §4.1.3-те айтылған аппаратқа-тән қайта жаңғыртылушылық

шегімен үйлесімді, бастапқы код баламалы аппаратта қайта жаңғыртылады, бірақ ол көрсететін есептеу-тиімділігі сипаттары құжатталған орнатуға тән болып қалады (DGL-2); оны қайта беру арқылы ешбір өнімділік, дәлдік немесе орналастыру дайындығы тұжырымы жасалмайды. Бастапқы код каталогталып, репрезентативті модуль нақты, дискідегі жүзеге асыру екені көрсетілген соң, §4.1.3-те ашылған қайта жаңғыртылушылық циклі жабылады: тіркелген конфигурация (4.2-кесте), құжатталған аппарат және осы нұсқаланған код бірге эксперименттік pipeline-ді қалпына келтіретін етеді.

Д қосымшасы — Сертификаттар мен жарияланым растамалары

Бұл қосымша осы диссертацияның компоненттері прогрессивті түрде таратылған бұрынғы рецензияланған жарияланымдарды, олар үшін ұсталатын индекстеу және жарияланым-растау активтерімен бірге тіркейді. Ол алғы материалдың апробация мен жарияланымдар мәлімдемелерінің (§0.11, §0.12) құжаттамалық негізін береді. Мұнда каталогталған әр жарияланым кандидат бірге авторланған әрі диссертацияда тұтасымен бұрынғы өз жұмысы ретінде қаралады: негізгі мәтін осы шығыстардың кез келгеніне сүйенген жерде, ол мұны айқын өзіне-сілтенумен (SIR-4) істейді, сонда жарияланған жазба мен қазіргі үлес арасындағы қатынас мөлдір болады. Қосымша әр жарияланымның *бар болуын, жариялау орнын және шығу тегін* тіркейді; ол сол жарияланымдар ішінде хабарланған өнімділік көрсеткіштерін қайта айтпайды немесе мақұлдамайды, олар нәтижелер ретінде импортталудан гөрі осы диссертацияның өз governance-і аясында қайта қаралады әрі қажет жерде шектеледі.

D.1-кесте бес ерекше рецензияланған шығысты тізеді. Олар диссертация біріктіретін төрт желіні қамтиды: көз түбі кескіндерін preprocessing-және-жіктеу, екі кезеңді transfer-learning бейімдеуі, жылулық-оптикалық лазер моделі және AI-диагностикалық жүйе архитектурасы. Бірінші жол *Eastern-European Journal of Enterprise Technologies*-тегі жалғыз мақалаға сәйкес келеді; сол бір мақаладан түрлі аналитикалық тұрғыдан екі әдебиет картасы (yesmukhamedov-scopus-q2.md және yesmukhamedov-scopus-q3.md, #23 және #24 индекстелген) дайындалды, сондықтан ол мұнда бір рет есептеледі (LITERATURE_INDEX 5-ескерту; SIR-5).

D.1-кесте. Кандидаттың бұрынғы рецензияланған жарияланымдары (барлығы ♦ бұрынғы өз жұмысы; SIR-4).

#	Авторлар (жыл)	Атауы	Жариял ау орны	Индексте у	DOI	Кар та ID
1	Sapakova, Yesmukham edov & Sapakov (2025)	Developm ent of an image quality enhancem ent	<i>Eastern- European Journal of Enterpris e Technolo</i>	Scopus (журнал)	10.15587/1729- 4061.2025.335570	#23 / #24

		approach for diabetic retinopathy diagnosis	<i>gies</i> , 4(9(136)), 79–88			
2	Sapakova, Yesmukham edov, Sapakov, Yemberdiyeva & Kozhamkulova (2025)	Methods for pre-processing and analysis of fundus images for detection of diabetic retinopathy	<i>Procedia Computer Science</i> , 272, 496–501 (DS 2025, Istanbul)	Scopus (конференция)	10.1016/j.procs.2025.10.237	#19
3	Yesmukham edov, Sapakova, Kozhamkulova, Daniyarova & Armankyzy (2025)	Methods for Preprocessing and Analysis of Fundus Images for Diabetic Retinopathy Detection	<i>Herald of the Kazakh-British Technical University</i> , 4(75), 119–130	KBTU Herald	10.55452/1998-6688-2025-22-4-119-130	#21
4	Sapakova, Daniyarova, Yesmukham edov, Armankyzy, Emberdieva & Kaldybaeva (2024)	Mathematical Modeling of Laser Exposure on Fundus Tissues in the Treatment of Diabetic Retinopathy	<i>Vestnik KazUTB</i> , 2(27-740)	KazUTB Vestnik	10.58805/kazutb.v.2.27-740	#20
5	Yesmukham	Developm	<i>News of</i>	NAS RK	10.32014/2025.2518-	#22

	edov, Sapakova, Al-Haddad & Daniyarova (2025)	ent of an informatio n system architectu re for healthcare institution s using artificial intelligenc e	<i>the National Academy of Sciences of the Republic of Kazakhsta n, Physico- Mathemat ical Series, 2(354), 74–91</i>		1726.345	
--	---	---	--	--	----------	--

Каталогқа екі құжаттамалық ескерту тіркеледі әрі басылудан гөрі тіркеледі. Біріншіден, EEJET мақаласы үшін екі карта (1-жазба) сақталады, өйткені диссертация сол мақаланы бірден көп бөлімнен келтіреді; қайталау — екі жарияланым емес, библиографиялық есеп жүргізу (SIR-5). Екіншіден, `yesmukhamedov-scopus-q2.md` картасы өзінің жазылған дәйексөзіне сәйкес келмейтін ішкі бірегей-ID өрісін (LC-Altimemy-2021) алып жүреді; аномалия корпус гигиенасы үшін мұнда белгіленеді әрі жоғарыдағы жазылған дәйексөз бен DOI-ге кілттенетін библиографиялық жазбаға қатысы жоқ. Күшейтпеу ережесімен үйлесімді, осы жарияланымдар ішінде айтылған өнімділік көрсеткіштерінің ешқайсысы — EEJET мақаласының өз аннотациясында хабарланған жоғары-дәлдік нәтижесін қоса — осы қосымшада қайталанбайды немесе мақұлданбайды, не диссертацияның гипотезалары үшін дәлел ретінде қаралмайды (SIR-1).

Осы шығыстар үшін ұсталатын жарияланым және индекстеу растамалары кескін активтері ретінде сақталған әрі төменде өздерінің нақты репозиторий жолымен тізілген; әрқайсысы түпкілікті жинақтау кезінде (§11.2) жинақталған құжатқа кескін ретінде енгізіледі. Активтер каталогқа былай салыстырылады:

- [APP-D: Scopus журнал индекстеу растамасы — `defense/presentation/assets/publications/SCOPUS.png`] → 1-жазба (EEJET).
- [APP-D: Scopus конференция индекстеу растамасы — `defense/presentation/assets/publications/SCOPUS_CONF.png`] → 2-жазба (Procedia / DS 2025).
- [APP-D: KBTU Herald жарияланым растамасы — `defense/presentation/assets/publications/KBTU.png`] → 3-жазба (KBTU Herald).

- [APP-D: KazUTB Vestnik жарияланым растамасы – defense/presentation/assets/publications/KAZTBU.png] → 4-жазба (KazUTB Vestnik).
- [APP-D: NAS RK жарияланым растамасы – defense/presentation/assets/publications/AKADEMY.png] → 5-жазба (NAS RK News).
- [APP-D: Жиынтық жарияланымдар жазбасы – defense/presentation/assets/publications/PUBLICATIONS.png] → жарияланым жазбасы бойынша шоғырландырылған растама.

Бірге, D.1-кесте мен осы алты растама активі §0.11 мен §0.12-нің астарындағы апробация дәлелін құрайды: кандидат бірге авторланған әрі тұтасымен бұрынғы өз жұмысы ретінде айқындалған рецензияланған жарияланым ізі, мұнда оның шығу тегі бұзылмай әрі оның ішкі өнімділік тұжырымдарының ешқайсысын осы диссертацияның тұжырымдары ретінде импорттамай тіркелген.

ПАЙДАЛАНЫЛҒАН ӘДЕБИЕТТЕР ТІЗІМІ

> Алғаш кездесу ретімен (GOST 7.32-2001 §6.11). Дереккөздер тізімі ағылшын тіліндегі мәтінмен бірдей нөмірленген (тіл-инварианттылық).

1. Kusahara, S., Fukushima, Y., Ogura, S., Inoue, N., & Uemura, A. (2018). Pathophysiology of diabetic retinopathy: The old and the new. *Diabetes & Metabolism Journal*, 42(5), 364–376. <https://doi.org/10.4093/dmj.2018.0182>
2. Morya, A. K., Ramesh, P. V., Nishant, P., Kaur, K., Gurnani, B., Heda, A., & Salodia, S. (2024). Diabetic retinopathy: A review on its pathophysiology and novel treatment modalities. *World Journal of Methodology*, 14(4), 95881. <https://doi.org/10.5662/wjm.v14.i4.95881>
3. Wang, W., & Lo, A. C. Y. (2018). Diabetic retinopathy: Pathophysiology and treatments. *International Journal of Molecular Sciences*, 19(6), 1816. <https://doi.org/10.3390/ijms19061816>
4. Gettinger, K., Lee, D., Tomita, Y., Negishi, K., & Kurihara, T. (2025). Diabetic retinopathy, a comprehensive overview on pathophysiology and relevant experimental models. *International Journal of Molecular Sciences*, 26, 9882. <https://doi.org/10.3390/ijms26209882>
5. Kesharwani, D., Parashar, S., Varghese, J., & Sune, P. (2021). A review of diabetic retinopathy—Pathophysiology, clinical presentation, and management. *Journal of Pharmaceutical Research International*, 33(60B), 698–704. <https://doi.org/10.9734/JPRI/2021/v33i60B34668>
6. Porwal, P., Pachade, S., Kamble, R., Kokare, M., Deshmukh, G., Sahasrabuddhe, V., & Meriaudeau, F. (2018). Indian Diabetic Retinopathy Image Dataset (IDRiD): A database for diabetic retinopathy screening research. *Data*, 3(3), 25. <https://doi.org/10.3390/data3030025>

7. Shen, Z., Fu, H., Shen, J., & Shao, L. (2020). Modeling and Enhancing Low-Quality Retinal Fundus Images. *IEEE Transactions on Medical Imaging*, 40(3), 996–1006. (arXiv:2005.05594)
8. Fu, H., Wang, B., Shen, J., Cui, S., Xu, Y., Liu, J., & Shao, L. (2020). Evaluation of Retinal Image Quality Assessment Networks in Different Color-spaces. *arXiv preprint arXiv:1907.05345v4*.
9. Zago, G. T., Andreão, R. V., Dorizzi, B., & Teatini Salles, E. O. (2018). Retinal image quality assessment using deep learning. *Computers in Biology and Medicine*, 103, 64–70.
10. Dai, L., Wu, L., Li, H., Cai, C., Wu, Q., Kong, H., ... Jia, W. (2021). A deep learning system for detecting diabetic retinopathy across the disease spectrum. *Nature Communications*, 12, 3242.
11. Rakhlin, A. (2017). Diabetic retinopathy detection through integration of deep learning classification framework [Preprint]. *bioRxiv*. <https://doi.org/10.1101/225508>
12. Voets, M., Møllersen, K., & Bongo, L. A. (2019). Reproduction study using public data of: Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs. *PLoS ONE*, 14(6), e0217541.
13. Gulshan, V., Peng, L., Coram, M., Stumpe, M. C., Wu, D., Narayanaswamy, A., Venugopalan, S., Widner, K., Madams, T., Cuadros, J., Kim, R., Raman, R., Nelson, P. C., Mega, J. L., & Webster, D. R. (2016). Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs. *JAMA*, 316(22), 2402–2410.
14. Beede, E., Baylor, E., Hersch, F., Iurchenko, A., Wilcox, L., Ruamviboonsuk, P., & Vardoulakis, L. M. (2020). A Human-Centered Evaluation of a Deep Learning System Deployed in Clinics for the Detection of Diabetic Retinopathy. *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems (CHI '20)*, 1–12.
15. Liu, R., Wang, X., Wu, Q., Dai, L., Fang, X., Yan, T., Son, J., Tang, S., Li, J., Gao, Z., Galdran, A., Poorneshwaran, J.M., Liu, H., Wang, J., Chen, Y., Porwal, P., Tan, G.S.W., Yang, X., Dai, C., Song, H., Chen, M., Li, H., Jia, W., Shen, D., Sheng, B., & Zhang, P. (2022). DeepDRiD: Diabetic Retinopathy—Grading and Image Quality Estimation Challenge. *Patterns*, 3(6), 100512. <https://doi.org/10.1016/j.patter.2022.100512>
16. Zhou, K., Liu, Z., Qiao, Y., Xiang, T., & Loy, C. C. (2022). Domain Generalization: A Survey.
17. Wang, M., & Deng, W. (2018). Deep visual domain adaptation: A survey. *Neurocomputing*.
18. Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., ... Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42, 60–88. (arXiv:1702.05747)
19. Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet Classification with Deep Convolutional Neural Networks. In *Advances in Neural Information Processing Systems 25 (NeurIPS 2012)*.

20. Simonyan, K., & Zisserman, A. (2015). Very Deep Convolutional Networks for Large-Scale Image Recognition. *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*. (arXiv:1409.1556)
21. Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., ... Rabinovich, A. (2015). Going Deeper with Convolutions. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 1–9. (arXiv:1409.4842)
22. Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., & Wojna, Z. (2016). Rethinking the Inception Architecture for Computer Vision. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2818–2826. (arXiv:1512.00567)
23. He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2016)* (pp. 770–778). IEEE.
24. Huang, G., Liu, Z., van der Maaten, L., & Weinberger, K. Q. (2017). Densely Connected Convolutional Networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 2261–2269).
25. Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. In *Proceedings of the 36th International Conference on Machine Learning (ICML 2019)*, PMLR 97.
26. Tan, M., & Le, Q. V. (2021). EfficientNetV2: Smaller Models and Faster Training. In *Proceedings of the 38th International Conference on Machine Learning (ICML 2021)*, PMLR 139, 10096–10106.
27. Pratt, H., Coenen, F., Broadbent, D. M., Harding, S. P., & Zheng, Y. (2016). Convolutional neural networks for diabetic retinopathy. *Procedia Computer Science*, 90, 200–205.
28. Full Citation (APA 7)
29. Gargeya, R., & Leng, T. (2017). Automated Identification of Diabetic Retinopathy Using Deep Learning. *Ophthalmology*, 124(7), 962–969.
30. Quellec, G., Charrière, K., Boudi, Y., Cochener, B., & Lamard, M. (2017). Deep image mining for diabetic retinopathy screening. *Medical Image Analysis*, 39, 178–193. (arXiv:1610.07086)
31. Arora, L., Singh, S. K., Kumar, S., Gupta, H., Alhalabi, W., Arya, V., Bansal, S., Chui, K. T., & Gupta, B. B. (2024). Ensemble deep learning and EfficientNet for accurate diagnosis of diabetic retinopathy. *Scientific Reports*, 14, 30554. <https://doi.org/10.1038/s41598-024-81132-4>
32. Sharma, V., Rishu, Kukreja, V., Dogra, A., & Goyal, B. (2025). Transforming retinal diagnostics: Advanced detection of diabetic retinopathy using vision transformers and capsule networks. *Journal of Computer Science*, 21(2), 304–321. <https://doi.org/10.3844/jcssp.2025.304.321>
33. Wan, C., Chen, Y., Li, H., Zheng, B., Chen, N., Yang, W., Wang, C., & Li, Y. (2021). EAD-Net: A novel lesion segmentation method in diabetic retinopathy using neural networks. *Disease Markers*, 2021, Article 6482665. <https://doi.org/10.1155/2021/6482665>

34. Zhou, Y., Wang, B., Huang, L., Cui, S., & Shao, L. (2020). A Benchmark for Studying Diabetic Retinopathy: Segmentation, Grading, and Transferability. *IEEE Transactions on Medical Imaging*, 40(3), 818–828. (Preprint: arXiv:2008.09772v3.)
35. Khosravi, P., Huck, N. A., Shahraki, K., Ghafari, E., Azimi, R., Kim, S. Y., Crouch, E., Xie, X., & Suh, D. W. (2025). External validation of deep learning models for classifying etiology of retinal hemorrhage using diverse fundus photography datasets. *Bioengineering*, 12(1), 20. <https://doi.org/10.3390/bioengineering12010020>
36. Ryu, G., Lee, K., Park, D., Park, S. H., & Sagong, M. (2021). A deep learning model for identifying diabetic retinopathy using optical coherence tomography angiography. *Scientific Reports*, 11, 23024. <https://doi.org/10.1038/s41598-021-02479-6>
37. Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639), 115–118.
38. Burlina, P. M., Joshi, N., Pekala, M., Pacheco, K. D., Freund, D. E., & Bressler, N. M. (2017). Automated Grading of Age-Related Macular Degeneration From Color Fundus Images Using Deep Convolutional Neural Networks. *JAMA Ophthalmology*, 135(11), 1170–1176.
39. Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2021). An image is worth 16×16 words: Transformers for image recognition at scale. *International Conference on Learning Representations (ICLR 2021)*.
40. Goh, J. H. L., Ang, E., Srinivasan, S., Lei, X., Loh, J., Quek, T. C., Xue, C., Xu, X., Liu, Y., Cheng, C.-Y., Rajapakse, J. C., & Tham, Y.-C. (2024). Comparative analysis of vision transformers and conventional convolutional neural networks in detecting referable diabetic retinopathy. *Ophthalmology Science*, 4(6), 100552.
41. Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., Lin, S., & Guo, B. (2021). Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 10012–10022. (arXiv:2103.14030)
42. González-Díaz, J. E., Reyes-Delgado, A. J., Sánchez-Cervantes, J. L., Mejía-Miranda, J., Alor-Hernández, G., & Rodríguez-Mazahua, L. (2024). Use of Vision Transformers in Ophthalmology for Early Detection of Age-Related Macular Degeneration (AMD): A Comparative Analysis. *Preprints.org*, 20241101740. <https://doi.org/10.20944/preprints202411.1740.v1>
43. Geetha, T., & Hema, C. (2026). Deep learning-based joint analysis of diabetic retinopathy and glaucoma in retinal fundus images. *Scientific Reports*, 16, 3133. <https://doi.org/10.1038/s41598-025-32991-y>
44. Saxena, G., Verma, D. K., Paraye, A., Rajan, A., & Rawat, A. (2020). Improved and robust deep learning agent for preliminary detection of diabetic retinopathy using public datasets. *Intelligence-Based Medicine*, 3–4, 100022.

45. Cheplygina, V., de Bruijne, M., & Pluim, J. P. W. (2018). Not-so-supervised: A survey of semi-supervised, multi-instance, and transfer learning in medical image analysis. [Preprint]. arXiv.
46. Zhou, Y., Chia, M. A., Wagner, S. K., Ayhan, M. S., Williamson, D. J., Struyven, R. R., ... Keane, P. A. (2023). A foundation model for generalizable disease detection from retinal images. *Nature*, 622(7981), 156–163.
47. Azizi, S., Mustafa, B., Ryan, F., Beaver, Z., Freyberg, J., Deaton, J., ... Norouzi, M. (2021). Big Self-Supervised Models Advance Medical Image Classification. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. (arXiv:2101.05224)
48. Tjoa, E., & Guan, C. (2020). A Survey on Explainable Artificial Intelligence (XAI): towards Medical XAI. arXiv preprint arXiv:1907.07374v5.
49. Samek, W., Wiegand, T., & Müller, K.-R. (2017). Explainable artificial intelligence: Understanding, visualizing and interpreting deep learning models. arXiv preprint arXiv:1708.08296.
50. Zhou, B., Khosla, A., Lapedriza, A., Oliva, A., & Torralba, A. (2016). Learning Deep Features for Discriminative Localization. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2016)* (pp. 2921–2929).
51. Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 618–626.
52. Chattopadhyay, A., Sarkar, A., Howlader, P., & Balasubramanian, V. N. (2018). Grad-CAM++: Improved visual explanations for deep convolutional networks. arXiv preprint arXiv:1710.11063.
53. Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. In *Proceedings of the 31st Conference on Neural Information Processing Systems (NIPS 2017)*, Long Beach, California, USA. arXiv:1705.07874v2.
54. Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). “Why Should I Trust You?”: Explaining the Predictions of Any Classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD 2016)*, 1135–1144. ACM.
55. Abràmoff, M. D., Lavin, P. T., Birch, M., Shah, N., & Folk, J. C. (2018). Pivotal trial of an autonomous AI-based diagnostic system for detection of diabetic retinopathy in primary care offices. *npj Digital Medicine*, 1(39). <https://doi.org/10.1038/s41746-018-0040-6>.
56. Ting, D. S. W., Cheung, C. Y.-L., Lim, G., Tan, G. S. W., Quang, N. D., Gan, A., Hamzah, H., Garcia-Franco, R., San Yeo, I. Y., Lee, S. Y., Wong, E. Y. M., Sabanayagam, C., Baskaran, M., Ibrahim, F., Tan, N. C., Finkelstein, E. A., Lamoureux, E. L., Wong, I. Y., Bressler, N. M., ... Wong, T. Y. (2017). Development and validation of a deep learning system for diabetic retinopathy and related eye diseases using retinal images from multiethnic populations with diabetes. *JAMA*, 318(22), 2211–2223.

57. Bellemo, V., Lim, Z. W., Lim, G., Nguyen, Q. D., Xie, Y., Yip, M. Y. T., ... Ting, D. S. W. (2019). Artificial intelligence using deep learning to screen for referable and vision-threatening diabetic retinopathy in Africa: a clinical validation study. *The Lancet Digital Health*, 1(1), e35–e44.
58. Zhang, G., Lin, J.-W., Wang, J., Ji, J., Cen, L.-P., Chen, W., Xie, P., Zheng, Y., Xiong, Y., Wu, H., Li, D., Ng, T. K., Pang, C. P., & Zhang, M. (2022). Automated multidimensional deep learning platform for referable diabetic retinopathy detection: A multicentre, retrospective study. *BMJ Open*, 12, e060155. <https://doi.org/10.1136/bmjopen-2021-060155>
59. Ruamviboonsuk, P., Tiwari, R., Sayres, R., Nganthavee, V., Hemarat, K., Kongprayoon, A., Raman, R., Levinstein, B., Liu, Y., Schaekermann, M., Lee, R., Virmani, S., Widner, K., Chambers, J., Hersch, F., Peng, L., & Webster, D. R. (2022). Real-time diabetic retinopathy screening by deep learning in a multisite national screening programme: A prospective interventional cohort study. *The Lancet Digital Health*, 4(4), e235–e244.
60. Sánchez-Gutiérrez, V., Hernández-Martínez, P., Muñoz-Negrete, F. J., Engelberts, J., Luger, A. M., & van Grinsven, M. J. J. P. (2022). Performance of a deep learning system for detection of referable diabetic retinopathy in real clinical settings. [Journal name NOT REPORTED in preprint].
61. Baget-Bernaldiz, M., Romero-Aroca, P., Santos-Blanco, E., Navarro-Gil, R., Valls, A., Moreno, A., Rashwan, H. A., & Puig, D. (2021). Testing a deep learning algorithm for detection of diabetic retinopathy in a Spanish diabetic population and with MESSIDOR database. *Diagnostics*, 11(8), 1385.
62. Wewetzer, Held, & Steinhäuser (2021) — Meta-Analysis of DL Screening for DR in Primary Care
63. Senapati, A., Tripathy, H. K., Sharma, V., & Gandomi, A. H. (2024). Artificial intelligence for diabetic retinopathy detection: A systematic review. *Informatics in Medicine Unlocked*, 45, 101445. <https://doi.org/10.1016/j.imu.2024.101445>
64. Ting, D. S. W., Peng, L., Varadarajan, A. V., Keane, P. A., Burlina, P. M., Chiang, M. F., ... Wong, T. Y. (2019). Deep learning in ophthalmology: The technical and clinical considerations. *Progress in Retinal and Eye Research*, 72, 100759.
65. De Fauw, J., Ledsam, J. R., Romera-Paredes, B., Nikolov, S., Tomasev, N., Blackwell, S., ... Ronneberger, O. (2018). Clinically applicable deep learning for diagnosis and referral in retinal disease. *Nature Medicine*, 24(9), 1342–1350.
66. Pizer, S. M., Amburn, E. P., Austin, J. D., Cromartie, R., Geselowitz, A., Greer, T., ter Haar Romeny, B., Zimmerman, J. B., & Zuiderveld, K. (1987). Adaptive histogram equalization and its variations. *Computer Vision, Graphics, and Image Processing*, 39(3), 355–368. Academic Press.
67. Zuiderveld, K. (1994). Contrast Limited Adaptive Histogram Equalization. In P. S. Heckbert (Ed.), *Graphics Gems IV* (pp. 474–485). Academic Press.
68. Hayati, M., Muchtar, K., Roslidar, Maulina, N., Syamsuddin, I., Elwirehardja, G. N., & Pardamean, B. (2023). Impact of CLAHE-based image enhancement

- for diabetic retinopathy classification through deep learning. *Procedia Computer Science*, 216, 57–66.
69. Shaout, A., & Han, J. (2025). A novel retinal image contrast enhancement — Fuzzy-based method. *arXiv preprint arXiv:2502.17850v2*.
 70. Full Citation (APA 7)
 71. Tomasi, C., & Manduchi, R. (1998). Bilateral filtering for gray and color images. In *Proceedings of the 1998 IEEE International Conference on Computer Vision (ICCV)*, Bombay, India. IEEE.
 72. Buades, A., Coll, B., & Morel, J.-M. (2011). Non-Local Means Denoising. *Image Processing On Line*, 1, 208–212. https://doi.org/10.5201/ipol.2011.bcm_nlm.
 73. Cui, Y., Jia, M., Lin, T.-Y., Song, Y., & Belongie, S. (2019). Class-Balanced Loss Based on Effective Number of Samples. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 9268–9277. (arXiv:1901.05555)
 74. Araf, I., Idri, A., & Chairi, I. (2024). Cost-sensitive learning for imbalanced medical data: a review. *Artificial Intelligence Review*, 57, 80. <https://doi.org/10.1007/s10462-023-10652-8>
 75. Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal Loss for Dense Object Detection. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2980–2988. (arXiv:1708.02002)
 76. Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learning Research*, 15(56), 1929–1958.
 77. Ioffe, S., & Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, 448–456. (arXiv:1502.03167)
 78. Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on Image Data Augmentation for Deep Learning. *Journal of Big Data*, 6(1), 60.
 79. Zhang, H., Cisse, M., Dauphin, Y. N., & Lopez-Paz, D. (2018). mixup: Beyond Empirical Risk Minimization. *Proceedings of the 6th International Conference on Learning Representations (ICLR)*. (arXiv:1710.09412)
 80. Cubuk, E. D., Zoph, B., Shlens, J., & Le, Q. V. (2020). RandAugment: Practical automated data augmentation with a reduced search space. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 702–703. (arXiv:1909.13719)
 81. Buda, M., Maki, A., & Mazurowski, M. A. (2018). A systematic study of the class imbalance problem in convolutional neural networks. *Neural Networks*, 106, 249–259. (arXiv:1710.05381)
 82. Pan, S. J., & Yang, Q. (2010). A Survey on Transfer Learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10), 1345–1359.
 83. Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks? In *Advances in Neural Information Processing Systems (NeurIPS/NIPS 2014)*.

84. Arrieta, J., Perdomo, O. J., & González, F. A. (2022). Deep semi-supervised and self-supervised learning for diabetic retinopathy detection. *arXiv:2208.02408v1*.
85. Kornblith, S., Shlens, J., & Le, Q. V. (2019). Do Better ImageNet Models Transfer Better? In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR 2019)* (pp. 2661–2671). IEEE/CVF.
86. Ganin, Y., Ustinova, E., Ajakan, H., Germain, P., Larochelle, H., Laviolette, F., Marchand, M., & Lempitsky, V. (2016). Domain-adversarial training of neural networks. *Journal of Machine Learning Research*, 17(59), 1–35.
87. Shurrab, S., & Duwairi, R. (2022). Self-supervised learning methods and applications in medical imaging analysis: a survey. *PeerJ Computer Science*, 8, e1045.
88. Chen, T., Kornblith, S., Norouzi, M., & Hinton, G. (2020). A Simple Framework for Contrastive Learning of Visual Representations. *Proceedings of the 37th International Conference on Machine Learning (ICML)*, 1597–1607. (arXiv:2002.05709)
89. He, K., Fan, H., Wu, Y., Xie, S., & Girshick, R. (2020). Momentum Contrast for Unsupervised Visual Representation Learning. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 9729–9738. (arXiv:1911.05722)
90. Grill, J.-B., Strub, F., Altché, F., Tallec, C., Richemond, P. H., Buchatskaya, E., ... Valko, M. (2020). Bootstrap Your Own Latent: A New Approach to Self-Supervised Learning. *Advances in Neural Information Processing Systems (NeurIPS)*, 33, 21271–21284. (arXiv:2006.07733)
91. Chen, X., & He, K. (2021). Exploring Simple Siamese Representation Learning. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 15750–15758. (arXiv:2011.10566)
92. Caron, M., Touvron, H., Misra, I., Jégou, H., Mairal, J., Bojanowski, P., & Joulin, A. (2021). Emerging Properties in Self-Supervised Vision Transformers. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 9650–9660. (arXiv:2104.14294)
93. He, K., Chen, X., Xie, S., Li, Y., Dollár, P., & Girshick, R. (2022). Masked Autoencoders Are Scalable Vision Learners. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 16000–16009. (arXiv:2111.06377)
94. Everingham, M., Van Gool, L., Williams, C. K. I., Winn, J., & Zisserman, A. (2010). The PASCAL Visual Object Classes (VOC) Challenge. *International Journal of Computer Vision*, 88(2), 303–338. <https://doi.org/10.1007/s11263-009-0275-4>
95. Rezatofghi, H., Tsoi, N., Gwak, J., Sadeghian, A., Reid, I., & Savarese, S. (2019). Generalized Intersection over Union: A Metric and A Loss for Bounding Box Regression. *arXiv*. <https://arxiv.org/abs/1902.09630>
96. Wang, Z., Bovik, A. C., Sheikh, H. R., & Simoncelli, E. P. (2004). Image Quality Assessment: From Error Visibility to Structural Similarity. *IEEE Transactions on Image Processing*, 13(4), 600–612.

97. Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On Calibration of Modern Neural Networks. Proceedings of the 34th International Conference on Machine Learning (ICML), PMLR 70, 1321–1330. (arXiv:1706.04599)
98. Krause, J., Gulshan, V., Rahimy, E., Karth, P., Widner, K., Corrado, G. S., Peng, L., & Webster, D. R. (2018). Grader Variability and the Importance of Reference Standards for Evaluating Machine Learning Models for Diabetic Retinopathy. *Ophthalmology*, 125(8), 1264–1272. (arXiv:1710.01711)
99. Kingma, D. P., & Ba, J. (2015). Adam: A Method for Stochastic Optimization. Proceedings of the 3rd International Conference on Learning Representations (ICLR). (arXiv:1412.6980)
100. Cuadros, J., & Bresnick, G. (2009). EyePACS: An Adaptable Telemedicine System for Diabetic Retinopathy Screening. *Journal of Diabetes Science and Technology*, 3(3), 509–516.
101. Decencière, E., Zhang, X., Cazuguel, G., Lay, B., Cochener, B., Trone, C., Gain, P., Ordóñez-Varela, J.-R., Massin, P., Erginay, A., Charton, B., & Klein, J.-C. (2014). Feedback on a Publicly Distributed Image Database: The Messidor Database. *Image Analysis & Stereology*, 33(3), 231–234.
102. Nandal, A. (2024). Optimizing interoperability in healthcare: AI-driven HL7 and FHIR implementations for seamless data exchange. *Journal of International Crisis and Risk Communication Research*, 7(S1), 70–76.

> **Ескерту — кейінге қалдырылған жазбалар.** Кандидаттың өзіне сілтемелері (Есмұхамедов; Сапақова, Есмұхамедов және Сапақов, 2024–2025) мен Қосымша Д жариялым жазбалары әдейі автор-жыл түрінде қалдырылды: бірдей жазылым әртүрлі бөлімдерде әртүрлі өз мақалаға сәйкес келеді, сондықтан олардың [N] нөмірлері түпкі түптеуге дейін қолмен бөлім-бойынша ажыратуды талап етеді. Мәтіндегі SIR-4 'кандидаттың алдыңғы жеке жұмысы' тұжырымдамасы сақталған.